



fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

Giải thích Negative Transfer trong Meta-learning

Interpret Negative Transfer in Meta-learning

1 THÔNG TIN CHUNG

Người hướng dẫn:

- GS.TS. Lê Hoài Bắc (Bộ môn Khoa học Máy tính - Khoa Công nghệ Thông tin)

[Nhóm] Sinh viên thực hiện:

1. Nguyễn Lê Tuấn Khải (MSSV: 20120503)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Trong những thập kỷ gần đây, lĩnh vực Trí Tuệ Nhân Tạo (AI) nói chung và lĩnh vực Học Máy (ML) nói riêng đã chứng kiến những bước phát triển thần kỳ nhờ vào các yếu tố quan trọng như sự tích lũy lượng dữ liệu lớn, sự phát triển của các công cụ tính toán mạnh mẽ và sự ra đời của các thuật toán phức tạp [1].

Tuy nhiên, trên thực tế, các thuật toán Học Máy vẫn gặp phải những rào cản để đáp ứng các tình huống đặc thù do sự thiếu hụt các tập dữ liệu khả thi. Mà nguyên nhân chủ yếu của vấn đề này có thể xuất phát từ những bất cập gặp phải trong việc thu thập dữ liệu. Mà có thể kể đến như do tính đặc thù của việc thử nghiệm trong các lĩnh vực y khoa hay công nghệ cao, hoặc do bị ràng buộc về mặt đạo đức, pháp luật,... Dẫn tới rất khó để có thể thu thập được lượng dữ liệu đủ đa dạng. Cuối cùng tạo thành hệ quả là, các mô hình học máy truyền thống thường thất bại trong việc khái quát hóa tri thức từ các tập dữ liệu nhỏ. Và đây cũng chính là động lực cốt lõi thúc đẩy sự ra đời và phát triển của **Few-Shot Learning** cũng như **Meta-Learning**.

Được truyền cảm hứng từ khả năng học của con người - con người có thể nhanh chóng học được khái niệm mới chỉ qua vài lần trải nghiệm, nhờ tận dụng tri thức tích lũy - **Meta-Learning** đã được đưa ra như một phương pháp để giải quyết bài toán **Few-Shot Learning**. Mặc dù hiện tại vẫn chưa có định nghĩa thống nhất trong nhiều tài liệu, nhưng **Meta-Learning**, còn được gọi là học cách học, trong các tài liệu nghiên cứu gần đây [2], [3], [4] đặt ra với mục tiêu xây dựng các tri thức tiền nghiệm (kinh nghiệm) từ những tác vụ khác nhau, sau đó sử dụng kiến thức đó để hỗ trợ cho việc học các tác vụ mới một cách nhanh chóng. Mà trong đó ba hướng tiếp **Metric-based**, **Network-based** và **Gradient-based** nổi lên như ba phương pháp hứa hẹn chính. Và các hướng tiếp cận dựa trên gradient (**Gradient-based**) mang tính hứa hẹn cao hơn cả, bởi tính linh hoạt cao có thể

sử dụng được cho tất cả các mô hình có tính khả vi, đồng thời đạt được hiệu suất vượt trội so với các phương pháp khác.

Dẫn chứng cho điều này, phương pháp **Model-Agnostic Meta-Learning (MAML)** được đề xuất bởi C.Finn và các cộng sự [5] và các biến thể của nó [6], [7],..., là một trong những kỹ thuật thành công nhất trong hướng tiếp cận này. Trọng tâm của phương pháp này chính là tạo ra một meta-learner, được thiết kế để có thể hiệu chỉnh trọng số khởi tạo của tác vụ đích, do đó tăng khả năng khái quát của mô hình khi học tác vụ đích, tức là sinh ra một trọng số khởi tạo tốt và có thể nhảy tới trọng số tối ưu của tác vụ đích khi chỉ với một hoặc một vài bước nhảy gradient (gradient-step). Tuy nhiên, do lượng dữ liệu nhỏ và các điểm dữ liệu rời rạc gây ra hiện tượng quá khớp (over-fitting). Do đó, đây vẫn là một trong những mục tiêu cần đạt được để cải tiến Meta-Learning.

Ngoài ra, mặc dù các phương pháp dựa trên gradient đạt được hiệu suất đáng mong đợi, nhưng về bản chất, chúng đều là các *mô hình hộp đen (black-box models)*. Điều này có nghĩa là chúng không cung cấp thông tin rõ ràng về cơ chế quyết định của mình và không phải lúc nào mô hình cũng đảm bảo việc đưa ra lời giải tối ưu. Do đó, trong những tình huống như vậy, người dùng không nhận được thông tin cụ thể để nhận biết và cải thiện mô hình của mình kịp thời, cũng như không thể sử dụng kết quả của mô hình để tham khảo. Trong các ứng dụng thực tế, việc thiếu khả năng giải thích của các mô hình có thể tạo ra nhiều rủi ro tiềm ẩn trong xã hội.

Ví dụ, hai hệ thống phổ biến là PredPol và COMPAS [8], được sử dụng lần lượt bởi lực lượng cảnh sát và hệ thống tư pháp Hoa Kỳ, đã bị chỉ trích vì đưa ra các quyết định không công bằng và có xu hướng phân biệt chủng tộc. Cụ thể, PredPol tập trung vào khu vực cư trú của những cộng đồng da màu, trong khi COMPAS thường đối xử không công bằng với các tội phạm da đen. Thêm vào đó, trong các hệ thống nhận dạng, các mô hình luôn nhạy cảm bởi nhiều có thể dẫn đến nhận dạng sai lầm. Do đó, hiểu rõ hơn về cơ chế quyết định và hành vi của các mô hình

hộp đen có thể tăng niềm tin của người dùng vào kết quả mà chúng đưa ra. Hơn nữa, việc hiểu rõ cơ chế này cũng có thể được xem như một công cụ gỡ lỗi giúp các chuyên gia Trí Tuệ Nhân Tạo có thể phát hiện và sửa chữa các vấn đề, từ đó cải thiện hiệu suất của mô hình.

2.2 Mục tiêu đề tài

Mặc dù **MAML** và các biến thể của chúng đã đạt được hiệu suất cao trong nhiều tình huống. Tuy nhiên, liệu trọng số khởi tạo tốt sẽ luôn luôn hỗ trợ cho tác vụ đích? Hay nói cách khác, liệu tri thức có được từ việc trích xuất từ các tác vụ khác nhau có phải sẽ luôn có lợi cho việc học tác vụ đích? **Yue và các cộng sự** [9] đã chỉ ra rằng *tri thức có thể sẽ gây ra bất lợi cho tác vụ đích khi tập huấn luyện và tập kiểm định của tác vụ đích không tương đồng với nhau*.

Để ví dụ cho điều này, ta xét tác vụ phân loại ảnh sư tử và chó hoang châu phi cụ thể như hình minh họa 1 dưới đây. Do việc áp dụng tri thức tiền nghiệm lên đặc trưng về bối cảnh của bức ảnh nên gây ra sự nhầm lẫn trong việc đưa ra dự đoán (với ảnh có nền cỏ xanh mô hình sẽ nhầm lẫn mà gán nhãn nó là con sư tử, ngược lại ảnh có nền cỏ vàng mô hình cũng nhầm lẫn mà gán nhãn nó là chó hoang châu Phi). Điều này đã được tác giả lý giải dựa trên mô hình nhân quả có cấu trúc. Và hiện tượng này còn được biết đến với tên gọi là **chuyển giao cực đoan (negative-transfer)**.



Hình 1: Ví dụ cho chuyển giao cực đoan - do tri thức tiền nghiệm gây nhiễu đến quá trình học tác vụ đích.[9]


Để cải thiện và giải quyết hiện tượng này, chúng ta có thể áp dụng các điểm lợi của các kỹ thuật XAI có thể mang lại nhằm tìm ra những tri thức gây nhiễu, sau đó loại bỏ các yếu tố gây nhiễu trong quá trình học tác vụ đích. Tuy nhiên, hiện nay vẫn còn rất ít các công trình nghiên cứu về điều này. Bởi vì, **Meta-Learning** vẫn chưa có một định nghĩa hình thức một cách thống nhất cho nên việc áp dụng XAI cho các kỹ thuật Meta-Learning vẫn còn là một thách thức lớn. Vì những lý do đó, việc phát triển các kỹ thuật để diễn giải các mô hình meta-learning là cấp bách.

2.3 Phạm vi của đề tài

2.3.1 Few-Shot Learning

Few-Shot Learning là bài toán nhằm tạo ra một mô hình có thể khái quát tốt khi được huấn luyện trên tập dữ liệu có số lượng mẫu hạn chế. Trong phạm vi luận văn, chúng ta chỉ đề cập đến bài toán N -way- K -shot áp dụng cho bài toán phân lớp ảnh.

Trong bài toán này, mô hình được huấn luyện trên tập dữ liệu gồm N nhãn, và mỗi nhãn có K mẫu dữ liệu (thông thường $K = 1$ hoặc 5), được gọi là *tập hỗ trợ* (*support set*), ký hiệu là tập S . Và sau đó, mô hình sẽ được kiểm định trên *tập truy vấn* (*query set*), được ký hiệu là tập Q .



Hình 2: Ví dụ minh họa cho bài toán 3-way-2-shot với bài toán nhận diện chữ số viết tay (tập dữ liệu Ominiglot).

Để tiến hành thực nghiệm, trong phạm vi khóa luận, một số bộ dữ liệu phổ biến được sử dụng trong các công trình nghiên cứu trước đây sẽ được sử dụng. Cụ thể như sau.

- **Mini-ImageNet** [10] gồm 100 nhãn được chọn ngẫu nhiên từ tập **ImageNet** với kích thước mỗi ảnh là 84×84 , trong đó mỗi nhãn có 600 ảnh. Tập dữ liệu này được sử dụng rộng rãi trong các nghiên cứu về Meta-Learning vì kích thước nhỏ, có độ tương đồng nhất định thích hợp cho việc mô phỏng các tình huống trong thế giới thực.
- **tieredImageNet** [11] cũng được lấy mẫu từ tập **ImageNet**, tuy nhiên, nó xét đến việc cấu trúc phân cấp các nhãn trong tập ImageNet. Do đó, tập dữ liệu này tổng cộng gồm 34 nhãn cha, được chia với tỉ lệ 20/6/8 để dùng cho huấn luyện, kiểm định và xác thực, mỗi nhãn cha chứa từ 10 đến 30 nhãn, và có tổng cộng 608 nhãn trong tập dữ liệu này. Bởi vì có tổ chức phân cấp nên tập dữ liệu này phù hợp để đánh giá sự hiệu quả của mô hình.
- **CIFAR-FS** [12] là một tập dữ liệu với các ảnh từ tập **CIFAR-100** với 100 nhãn, mỗi nhãn gồm có 600 ảnh.
- **CUB-200-2011** [13], còn gọi là **CUB**, là một tập dữ liệu với các ảnh về loài chim, với 200 nhãn, và tổng cộng có 11.788 ảnh. Là một tập dữ liệu mang tính thách thức với sự tương đồng cao giữa các nhãn. Và trong luận văn này, tập

này sẽ được tuân thủ nghiêm ngặt theo phương án mà Chen cùng các cộng sự đề ra [14].

2.3.2 Meta-learning và phương pháp MAML

Trước khi đi vào nghiên cứu sâu hơn, ta cần định nghĩa cách tiếp cận cơ sở của đối tượng áp dụng giải thích. Trong phạm vi khóa luận này, thì đó là Meta-Learning và phương pháp MAML của C.Finn và các cộng sự.

Ngược với các phương pháp Học Máy truyền thống, khi mô hình f học trên một tập dữ liệu $D = \{(x_i, y_i)\}_{i=1}^n$ để tìm ra bộ tham số tối ưu θ^* nhằm cực tiểu hóa hàm mất mát $\mathcal{L}$ trên toàn bộ phân phối dữ liệu. Thì Meta-Learning tiếp cận bài toán ở cấp độ cao hơn.

Thay vì học trên các điểm dữ liệu đơn lẻ, Meta-Learning học trên một tập hợp các tác vụ (tasks) $\mathcal{T} = \{\mathcal{T}_1, \mathcal{T}_2, \dots, \mathcal{T}_M\}$. Mà trong đó, mỗi tác vụ $\mathcal{T}_i$ được cấu thành từ hai tập con riêng biệt.

- Tập hỗ trợ (Support set), $S = \mathcal{D}_i^{sup} = \{(x_j, y_j)\}_{j=1}^k$, đóng vai trò là tri thức nền tảng để mô hình thích nghi nhanh.
- Tập truy vấn (Query set), $Q = \mathcal{D}_i^{que} = \{(x_j, y_j)\}_{j=1}^m$, dùng để đánh giá khả năng tổng quát hóa của mô hình sau khi đã học từ tập hỗ trợ.

Khi đó, mục tiêu chính cốt lõi của Meta-learning là tối ưu hóa bộ tham số khởi tạo θ_0 sao cho tồn tại một hàm thích nghi g_{θ_0} có khả năng chuyển đổi nhanh chóng thông tin từ tập hỗ trợ S thành một mô hình tối ưu cho tập truy vấn Q .

Và như đã đề cập ở phần giới thiệu, để tìm ra bộ tham số khởi tạo (θ_0) tối ưu, thì có ba phương pháp được nêu ra. Nhưng trong phạm vi đề tài khóa luận, chúng ta chỉ xét đến các lớp phương pháp dựa trên **Gradient-based**, mà cụ thể truy về phương pháp **MAML** mà C.Finn cùng các cộng sự đặt ra.

Với phương pháp này, thì hàm thích nghi g_{θ_0} là quy trình Gradient Descent. Mô hình học cách tìm vị trí xuất phát θ_0 sao cho chỉ cần vài bước đạo hàm trên S là chạm đến cực trị.


Cụ thể quá trình (siêu) huấn luyện - meta-training - của MAML sẽ hoạt động như thuật toán 1 và hình 3 dưới đây.

Algorithm 1: Thuật toán meta-training với Model Agnostic Meta-Learning (MAML)

Require: $p(\mathcal{T})$: Phân phối trên các tác vụ

Require: α, β : Các siêu tham số về bước nhảy (tốc độ học)

- 1: Khởi tạo tham số θ_0 ngẫu nhiên
- 2: **while** chưa dừng **do**
- 3: Lấy mẫu một lô các tác vụ (meta-batch) $\mathcal{T}_i \sim p(\mathcal{T})$
- 4: **for all** $\mathcal{T}_i$ **do**
- 5: Tính $\nabla_{\Phi} \mathcal{L}_{\mathcal{T}_i}(f_{\theta_0}, S_i)$
- 6: Tính các tham số thích nghi bằng Gradient Descent: $\Phi_i = \theta'_i = \theta_0 - \alpha \nabla_{\Phi} \mathcal{L}_{\mathcal{T}_i}(f_{\theta_0}, S_i)$
- 7: **end for**
- 8: Cập nhật tham số tổng quát: $\theta_0 \leftarrow \theta_0 - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\Phi_i}, Q_i)$
- 9: **end while**




Hình 3: Hình minh họa quá trình meta-training trong MAML

2.3.3 Mô hình cấu trúc nhân quả - SCM

Tuy MAML và các biến thể của nó đạt hiệu suất ấn tượng trong nhiều tình huống thực tế. Nhưng với bản chất phức tạp của Meta-Learning thì vẫn khó để mà hiểu được một cách tường minh cơ chế chuyển giao tri thức thực sự diễn ra bên trong.

Yue và các cộng sự [9] đã đưa ra một góc nhìn khác dựa trên mô hình cấu trúc nhân quả (Structural Causal Model) như hình minh họa 4 bên dưới, để biểu diễn quá trình thích ứng nhanh (*fast-adaptation*) trong giai đoạn meta-testing.



Hình 4: Mô hình cấu trúc nhân quả - Structural Causal Model

Mô hình này giả định rằng quá trình học và dự đoán trong Meta-Learning bị chi phối bởi bốn biến số trừu tượng.

- **D (Pretrained Knowledge):** Đại diện cho tri thức tích lũy từ giai đoạn siêu huấn luyện, bao gồm tập dữ liệu nguồn và bộ tham số khởi tạo θ_0 .
- **X_S (Feature Representation):** Các đặc trưng được trích xuất từ S thông qua mô hình f_Φ .
- **C (Context/Semantic Manifold):** Biểu diễn ngữ cảnh hoặc các khái niệm ngữ nghĩa trừu tượng mà cơ sở của nó được kế thừa từ D .
- **Y_S (Classification Effect):** Kết quả dự đoán cuối cùng của mô hình.

Đồng thời, từ **SCM 4**, ta có thể bóc tách ra được Y_S dựa trên hai con đường chính.

1. **$X \rightarrow Y$ (Trực tiếp):** Đặc trưng hình ảnh trực tiếp quyết định nhãn dự đoán.
2. **$X \rightarrow C \rightarrow Y$ (Gián tiếp):** Đặc trưng X được ánh xạ vào không gian ngữ nghĩa C , nơi nó kết hợp với tri thức bối cảnh từ D để đưa ra dự đoán.

Và sự tồn tại của các cạnh $D \rightarrow X$ và $D \rightarrow C$ cho thấy tri thức tiền huấn luyện đóng vai trò là một biến gây nhiễu (confounder). Điều này tạo ra các tương quan

ảo (spurious correlations), nơi mô hình dự đoán nhãn Y dựa trên bối cảnh C hơn là dựa trên bản chất của đặc trưng X .

2.3.4 Phát biểu bài toán

Tương tự với các nghiên cứu phát triển các phương pháp XAI, trước hết chúng ta cần đặt ra những câu hỏi xoay quanh cơ chế của mô hình. Trong ngữ cảnh **Meta-Learning**, câu hỏi được đặt ra là, *những gì thật sự đã được chuyển giao trong quá trình thích ứng với tác vụ mới? hay những mẫu - patterns - nào đã được sử dụng trong quá trình học tác vụ mới?*

Đồng thời, cũng phải xét đến các mẫu (patterns) đó ảnh hưởng như thế nào đến việc đưa ra dự đoán của mô hình sau quá trình thích ứng. Do đó, để giải quyết bài toán diễn giải trong **Meta-Learning** ta cần giải quyết đồng thời hai bài toán con là diễn giải cho quá trình thích ứng nhanh (*fast-adaptation*) và diễn giải cho quá trình ra quyết định của mô hình kết quả.

Cụ thể hơn, với MAML và các biến thể liên quan (như mô tả tại thuật toán 1), quá trình thích ứng nhanh (*fast adaptation*) trong giai đoạn *meta-testing* được thực hiện dựa trên tập dữ liệu hỗ trợ (*support set*) S và tham số khởi tạo θ_0 đã học từ giai đoạn siêu huấn luyện (*meta-training*). Với giả định chỉ sử dụng một bước cập nhật gradient, tham số thích ứng Φ được xác định như sau phương trình 1.

$$\Phi = \theta' = \theta_0 - \alpha \nabla_{\theta_0} \mathcal{L}(\theta_0, S) \quad (1)$$

Sau đó, để đánh giá hiệu suất thực tế, tham số thích ứng Φ thu được từ phương trình 1 sẽ được áp dụng trực tiếp trên tập truy vấn (*query set*) Q .

Tại giai đoạn *meta-testing* này, giá trị hàm tổn thất $\mathcal{L}(\Phi, Q)$ hoặc các độ đo khác như (*accuracy*) - gọi chung là acc_α - trên tập Q sẽ đóng vai trò là chỉ số đánh giá khả năng thích ứng nhanh của mô hình đối với các tác vụ mới (unseen tasks).

Từ đây có thể thấy được, để diễn giải cho quá trình thích ứng nhanh này, chính xác ta cần phải xác định các đặc trưng chung F giữa mô hình f_{θ_0} và f_Φ .

2.4 Cách tiếp cận dự kiến


Dựa trên phát biểu bài toán, để xác định được đặc trưng chung F ta cần thiết phải thực hiện thông qua phương pháp hậu diễn giải (post-hoc) với hai giai đoạn chính.

Đầu tiên dựa trên **SCM** 4 ta có thể rõ ràng, f_{θ_0} đã truyền cho f_{Φ} những thông tin chung C thể hiện qua F . Nhưng ta vẫn chưa biết nó đã chuyển giao bao nhiêu, và tác động xấu hay tốt đến việc học tác vụ mới.

Hay nói cách khác, chính là F có gây ra hiện tượng tương quan giả hay không? Hoặc có dẫn đến hiện tượng *chuyển giao tiêu cực* (*negative transfer*) hay không. Thành thử, ở bước đầu tiên, việc cần làm chính là định nghĩa một độ đo acc_{α} hợp lý.

Đồng thời, sau khi xác định được mức độ F được chuyển giao. Tiếp theo đó, ta cần phải xác định rõ mối tương quan giữa θ_0 và Φ thông qua việc xác định F một cách rõ ràng.

Và trong khuôn khổ khóa luận, quy trình thực hiện hai bước trên sẽ được minh họa thông qua sơ đồ như hình 5 dưới đây.



Hình 5: Cách tiếp cận dự kiến

2.4.1 Xác định độ đo acc_{α}

Để xác định được độ đo acc_{α} hợp lý, ta cần nó thỏa mãn các tiêu chí sau.

- **Khả năng chỉ ra được tương quan giả.** Phải mô tả và bóc tách được bản chất của các lỗi sai trên từng nhóm.
- **Tính trung thành (Faithfulness).** Xác định xem các yếu tố mà mô hình

đang chú ý có thực sự là nguyên nhân cốt lõi định hình nên quyết định dự đoán hay không.

Khi đã xác định được tiêu chí, ta có thể dựa trên nó để tham khảo các độ đo sau.

1. **Conventional Accuracy** (Độ chính xác truyền thống), là thước đo tỷ lệ dự đoán đúng trên toàn bộ tập dữ liệu.
2. **CAM-Acc** (Độ chính xác định vị đặc trưng) [9], là thước đo định lượng liệu mô hình có "chú ý" đến đối tượng thực sự khi đưa ra dự đoán hay không. Được định nghĩa là tỷ lệ phần trăm số điểm ảnh (pixels) nằm bên trong bounding box có điểm số Grad-CAM vượt qua một ngưỡng nhất định, chẳng hạn như lớn hơn 0,9.
3. **Hardness-specific Acc** (Độ chính xác theo độ khó), là thước đo hiệu suất của mô hình được phân tách dựa trên mức độ phức tạp của dữ liệu đầu vào. Chỉ số này giúp xác định xem mô hình gặp khó khăn ở các mẫu nhiễu, thiếu sáng hay các trường hợp biên (edge cases), từ đó đánh giá độ tin cậy của dự đoán trong các điều kiện thực tế khác nhau.
4. **Lượng hóa Negative Transfer Gap (NTI)** (Lượng hóa khoảng cách chuyển đổi tiêu cực), là một chỉ số đo lường sự sụt giảm hiệu suất của mô hình khi việc học từ một tác vụ nguồn gây cản trở hoặc làm sai lệch kết quả trên tác vụ đích. NTI giúp xác định mức độ không tương thích giữa các miền dữ liệu (domain discrepancy) trong quá trình Transfer Learning hoặc Domain Adaptation.

2.4.2 Xác định F

Sau khi đã định hình được các thước đo hiệu suất tại bước trước, mục tiêu tiếp theo là cụ thể hóa không gian đặc trưng chung F . Trong ngữ cảnh của khóa luận, F không chỉ là một tập hợp các đặc trưng trừu tượng mà là "vùng tri thức" mà mô hình f_{θ_0} đã chuyển giao cho f_{Φ} .

Để xác định F một cách trực quan và định lượng, các phương pháp sử dụng Bản đồ kích hoạt lớp (Class Activation Map - CAM) ([15], [16], [17], [18], [19]) được đề xuất làm công cụ chủ đạo. Cụ thể, quá trình xác định F được thực hiện thông qua các bước sau.

- **Trích xuất vùng chú ý (Attention Extraction):** Sử dụng kỹ thuật Grad-CAM để tạo ra bản đồ nhiệt M , thể hiện mức độ đóng góp của từng vùng không gian trên ảnh đầu vào đối với quyết định phân loại của f_Φ .
- **Phân lập đặc trưng F :** Không gian F được xác định là tập hợp các tọa độ điểm ảnh (x, y) có giá trị kích hoạt vượt ngưỡng τ (với $\tau = 0,9$ như đã định nghĩa ở mục CAM-Acc). Vùng này đại diện cho những đặc trưng mà mô hình coi là quan trọng nhất để đưa ra dự đoán.
- **Phân tích sự tương quan giữa θ_0 và Φ :** Bằng cách so sánh vùng kích hoạt F của mô hình tiền huấn luyện f_{θ_0} và mô hình sau khi tinh chỉnh f_Φ , ta có thể đánh giá được liệu các đặc trưng cốt lõi có bị thay đổi (shift) hay bị nhiễu bởi các yếu tố ngoại cảnh hay không.

Việc xác định F thông qua CAM cho phép ta thực hiện phép hậu diễn giải (post-hoc) một cách tường minh. Nếu F hội tụ tại các vùng chứa đối tượng (Object-centric), mô hình đang học được các đặc trưng ngữ nghĩa bền vững. Ngược lại, nếu F phân tán vào vùng nền (Background), đây là minh chứng cho việc tồn tại hiện tượng tương quan giả (spurious correlation) được chuyển giao từ tác vụ nguồn sang tác vụ đích, dẫn đến negative transfer. Kết quả của việc xác định F sẽ là cơ sở để điều chỉnh chiến lược huấn luyện hoặc lọc dữ liệu nhằm tối ưu hóa sự chuyển giao tri thức giữa hai tác vụ.

2.5 Kết quả dự kiến của đề tài

Trong phạm vi khóa luận, các kết quả dự kiến có thể đạt được được trình bày như sau:

- Mô hình đạt được kết quả cạnh tranh trong khi vẫn cân bằng được với khả năng diễn giải của mô hình.
- Hoàn thiện được một hình mẫu (framework) hậu diễn giải cho mô hình Meta-Learning cụ thể là các phương pháp dựa trên Gradient-based thông qua các phương pháp hậu diễn giải.

2.6 Kế hoạch thực hiện

Đề tài nghiên cứu của luận văn được thực hiện tại Khoa Công nghệ Thông tin, trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh.

Thời gian thực hiện đề tài nghiên cứu 06 tháng kể từ tháng 01/2026 đến 06/2026. Kế hoạch thực hiện chi tiết cho đề tài nghiên cứu được liệt kê như trong bảng 1.

Công việc	Thời gian thực hiện
Tìm hiểu các hướng tiếp cận và công trình liên quan	01/01/2026 - 15/02/2026
Khảo sát, đánh giá các công trình tiêu biểu và hoàn thiện đề cương	16/02/2026 - 16/03/2026
Nghiên cứu các phương pháp giải quyết bài toán diễn giải cho Meta-Learning	17/03/2026 - 20/04/2026
Đề xuất phương pháp cải tiến, thực nghiệm và báo cáo giữa kỳ	21/04/2026 - 06/05/2026
Thực hiện thực nghiệm bổ sung, đánh giá kết quả và viết bản thảo luận văn	07/05/2026 - 30/06/2026
Hoàn thiện quyển luận văn, chỉnh sửa theo góp ý của GVHD và chuẩn bị bảo vệ	01/07/2026 - 15/07/2026

Bảng 1: Bảng kế hoạch thực hiện đề tài khóa luận

Tài liệu

- [1] M. Haenlein and A. Kaplan, “A brief history of artificial intelligence: On the past, present, and future of artificial intelligence,” *California management review*, vol. 61, no. 4, pp. 5–14, 2019.
- [2] Y. Song and H. Jeong, “Towards cross domain generalization of hamiltonian representation via meta learning,” *arXiv preprint arXiv:2212.01168*, 2022.
- [3] C. Lu, Y. Wu, J. M. Hernández-Lobato, and B. Schölkopf, “Invariant causal representation learning for out-of-distribution generalization,” in *International conference on learning representations*, 2021.
- [4] D. Li, Y. Yang, Y.-Z. Song, and T. Hospedales, “Learning to generalize: Meta-learning for domain generalization,” in *Proceedings of the AAAI conference on artificial intelligence*, vol. 32, 2018.
- [5] C. Finn, P. Abbeel, and S. Levine, “Model-agnostic meta-learning for fast adaptation of deep networks,” in *International conference on machine learning*, pp. 1126–1135, PMLR, 2017.
- [6] H. Yao, Y. Wei, J. Huang, and Z. Li, “Hierarchically structured meta-learning,” in *International conference on machine learning*, pp. 7045–7054, PMLR, 2019.
- [7] H. Yao, X. Wu, Z. Tao, Y. Li, B. Ding, R. Li, and Z. Li, “Automated relational meta-learning,” in *International Conference on Learning Representations*, 2020.
- [8] W. D. Heaven, “Predictive policing algorithms are racist. they need to be dismantled,” *MIT Technology Review*, vol. 17, p. 2020, 2020.
- [9] Z. Yue, H. Zhang, Q. Sun, and X.-S. Hua, “Interventional few-shot learning,” *Advances in neural information processing systems*, vol. 33, pp. 2734–2746, 2020.

- [10] O. Vinyals, C. Blundell, T. Lillicrap, D. Wierstra, *et al.*, “Matching networks for one shot learning,” *Advances in neural information processing systems*, vol. 29, 2016.
- [11] M. Ren, E. Triantafillou, S. Ravi, J. Snell, K. Swersky, J. B. Tenenbaum, H. Larochelle, and R. S. Zemel, “Meta-learning for semi-supervised few-shot classification,” *arXiv preprint arXiv:1803.00676*, 2018.
- [12] L. Bertinetto, J. F. Henriques, P. H. Torr, and A. Vedaldi, “Meta-learning with differentiable closed-form solvers,” *arXiv preprint arXiv:1805.08136*, 2018.
- [13] C. Wah, S. Branson, P. Welinder, P. Perona, and S. Belongie, “The caltech-ucsd birds-200-2011 dataset,” 2011.
- [14] W.-Y. Chen, Y.-C. Liu, Z. Kira, Y.-C. F. Wang, and J.-B. Huang, “A closer look at few-shot classification,” *arXiv preprint arXiv:1904.04232*, 2019.
- [15] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, “Learning deep features for discriminative localization,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2921–2929, 2016.
- [16] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE international conference on computer vision*, pp. 618–626, 2017.
- [17] A. Chattopadhyay, A. Sarkar, P. Howlader, and V. N. Balasubramanian, “Grad-cam++: Generalized gradient-based visual explanations for deep convolutional networks,” in *2018 IEEE winter conference on applications of computer vision (WACV)*, pp. 839–847, IEEE, 2018.
- [18] H. Wang, Z. Wang, M. Du, F. Yang, Z. Zhang, S. Ding, P. Mardziel, and X. Hu, “Score-cam: Score-weighted visual explanations for convolutional neu-

ral networks,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*, pp. 24–25, 2020.

- [19] S.-Y. Byun and W. Lee, “Reciprocam: Lightweight gradient-free class activation map for post-hoc explanations,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8364–8370, 2024.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 16 tháng 03 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)