

Khóa luận tốt nghiệp

Đề tài: Giải thích Negative Transfer trong Meta-Learning

Người thực hiện: Nguyễn Lê Tuấn Khải - 20120503

GVHD: GS.TS. Lê Hoài Bắc

Mục lục


1. Giới thiệu đề tài
2. Phát biểu bài toán
3. Các công trình liên quan
4. Phương pháp
5. Thực nghiệm
6. Kết luận

1. Giới thiệu đề tài


Meta-Learning là phương pháp giải quyết bài toán học trên lượng dữ liệu nhỏ (Few-shot Learning/N-way K-shot).

Meta-Learning = Learning-to-learn (học cách học trên nhiều tác vụ) + Fast-adaptation (thích ứng nhanh trên tác vụ đích)

MAML (Model Agnostic Meta-Learning) hay các phương pháp dựa trên tối ưu (optimization-based) là phương pháp tiêu biểu nhờ tính khả vi và linh hoạt, áp dụng cho mọi loại kiến trúc.



θ_0 càng mạnh (mô hình được huấn luyện trên nhiều tác vụ quá khứ có tính đa dạng cao).




Quá trình thích ứng nhanh cho tác vụ mới (downstream tasks) sẽ càng tốt.

1. Giới thiệu đề tài

Tuy nhiên thực tế thì tri thức từ θ_0 sẽ gây ra nhiễu cho downstream task (Negative Transfer - Chuyển giao tiêu cực). [1]



Hình 1: Minh họa *negative transfer* khi S khác Q. Do ít mẫu, tri thức tiền nghiệm khiến mô hình học nhầm các tương quan giả (grass/sand) thay vì quan hệ nhân quả, gây sai lệch trên Q. [1]





Hình 2: Giải thích nguyên nhân qua sơ đồ cấu trúc nhân quả (SCM) [1]

Làm thế nào để giải thích hiện tượng này trong ngữ cảnh Meta-Learning?

1. Giới thiệu đề tài

Tính blackbox của quá trình thích ứng nhanh

- Đa phần các phương pháp meta-learning hay MAML-based hiện tại vẫn là **mô hình hộp đen**.
- Do đó, một cơ chế giải thích quá trình thích ứng nhanh của Meta-Learning là cần thiết.




Làm cách nào để biết chính xác quá trình thích ứng này có **lợi** hay có **hại**, và **bao nhiêu**?

Nếu quá trình đó có lợi/hại thì **cái gì đã gây ra điều đó**?

2. Phát biểu bài toán

Meta-Training



Hình 3: Sơ đồ tổng quát giai đoạn meta-training (MAML-based)

2. Phát biểu bài toán


Quá trình thích ứng nhanh - Fast Adaptation

- Quá trình thích ứng nhanh được định hướng bởi tập hỗ trợ S_i . Do đó, để giải thích hiện tượng negative transfer, chúng ta cần diễn giải cơ chế thích ứng nhanh thông qua:

- + **Định lượng** được sự định hướng đó mang lại giá trị tích cực hay tiêu cực.
- + **Định vị** các biểu diễn đặc trưng trong tập hỗ trợ S_i gây ra hiện tượng đó.


inner-loop

$$\phi_j = \phi_{j-1} - \alpha \nabla_{\phi} \mathcal{L}(S_i, \phi_{j-1})$$



2. Phát biểu bài toán


Trong đó giá trị định hướng (Độ lợi thích ứng - Adaptation Gain) ΔM là kết quả của một phép can thiệp nhân quả vào tri thức tiền nghiệm θ_0 nhằm cô lập ảnh hưởng của S_i lên θ_0 .



⇒ **Độ lợi thích ứng** là phần đóng góp thêm mà việc cập nhật backbone mang lại, ngoài phần đã có sẵn nhờ tái sử dụng đặc trưng (feature-reuse).

2. Phát biểu bài toán


Với ΔM ta xác định các giá trị quy kết ngược về từng mẫu $\{x_k \in S_i\}$ tại mọi trạng thái ϕ_j của quỹ đạo thích ứng và chiếu lên không gian đặc trưng chung F



3. Các nghiên cứu liên quan

Heterogeneous task (tác vụ không đồng nhất)

- Các tác vụ dùng trong quá trình meta-training đến từ nhiều phân phối con có đặc tính khác biệt.
- Nhìn chung có rất nhiều nghiên cứu giải quyết bài toán này (HSML [5], ARML [6],...) nhưng chỉ dừng ở mức điều chỉnh tham số khởi tạo chuyên biệt mà chưa có giải thích cơ chế thích ứng.
- Gần đây, Si và các cộng sự [7] đã khảo sát và chỉ ra 3 nguyên nhân phổ biến gây ra tác vụ không đồng nhất:
 1. **Task khó (hard task):** ngưỡng cảnh mờ hồ, ranh giới giữa các lớp không rõ ràng.
 2. **Task nhiễu (noisy task):** nhãn trong tập support/query bị gán sai.
 3. **Task ngoại lai (outlier task):** phân phối khác biệt hẳn so với đa số tác vụ còn lại.



[5] HSML - Yao et al '19

[6] ARML - Yao et al '20

[7] HeTroM - Si et al '25

3. Các nghiên cứu liên quan

Giải thích bằng việc mở rộng hàm ảnh hưởng

(Task level Explanation of Meta-Learning via Influence Functions - **TLXML**)

TLXML (Mitsuka và các cộng sự [8]) mở rộng influence functions sang bối cảnh Meta-Learning

- Định lượng ảnh hưởng của từng tác vụ trong meta-training lên hành vi thích ứng trên tác vụ đích.
- Actionable insight: ảnh hưởng tích cực mạnh → re-weight; ảnh hưởng tiêu cực → discard

Hạn chế: vẫn coi thao tác thích ứng trên tập hỗ trợ S_i là "hộp đen" ở cấp tác vụ, và đòi hỏi quyền truy cập toàn bộ dữ liệu meta-training - khó khả thi khi triển khai thực tế.






Figure 1: Key insights of TLXML.

3. Các nghiên cứu liên quan

Open-MAML

Áp dụng GradCAM [9] để giải thích mô hình sau quá trình thích ứng nhanh.

Hạn chế: chỉ trích xuất tại một trạng thái tham số tĩnh (sau hội tụ [10]) → không giải phẫu được động lực học của fast-adaptation




Hình 4: Sơ đồ cách thức mà Open-MAML thực hiện.

4. Phương pháp đề xuất

Độ lợi thích ứng (Adaptation Gain)

$$\phi_j = \phi_{j-1} - \alpha \nabla_{\phi} \mathcal{L}(S_i, \phi_{j-1})$$



Quỹ đạo thích ứng nhanh qua $T + 1$ trạng thái.


$$\Rightarrow \Delta M = \mathbb{E}_{Q_i \sim \tau_i} [\mathcal{L}(Q_i, \phi_T^f) - \mathcal{L}(Q_i, \phi_T)]$$

$\Delta M > 0$: chuyển giao tích cực
 $\Delta M < 0$: chuyển giao tiêu cực
 $\Delta M \approx 0$: chỉ là feature-reuse.
(việc cập nhật không đóng góp gì thêm)

4. Phương pháp đề xuất

Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution)

$$\Delta M = \mathbb{E}_{Q_i \sim \tau_i} [\mathcal{L}(Q_i, \phi_T^f) - \mathcal{L}(Q_i, \phi_T)]$$



S_i ảnh hưởng như thế nào đến quá trình thích ứng?

$$\frac{\partial \Delta M}{\partial S_i} \Rightarrow \frac{\partial \mathcal{L}(Q_i, \phi_T)}{\partial S_i} = - \sum_{j=1}^T \alpha \frac{\partial \mathcal{L}(Q_i, \phi_T)}{\partial \phi_j} \frac{\partial^2 \mathcal{L}(S_i, \phi_{j-1})}{\partial \phi_{j-1} \partial S_i} \sim O(T P^2)$$

4. Phương pháp đề xuất


Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution)

Xét hệ động lực $x(t)$ tiến hoá theo $\frac{dx}{dt} = f((x(t), u(t)))$

Pontryagin định nghĩa biến liên hợp $\psi(t)$
sao cho độ nhạy của mục tiêu cuối đối với
trạng thái tại thời điểm t bất kỳ

$$\psi(t_1) = \nabla_x \Phi(x(t_1))$$

$$\frac{d\psi}{dt} = - \left(\frac{\partial f}{\partial x} \right)^T \psi(t)$$



$$\phi_j = \phi_{j-1} - \alpha \nabla_{\phi} \mathcal{L}(S_i, \phi_{j-1})$$

$$\frac{\partial \phi_j}{\partial \phi_{j-1}} = I - \alpha H_{j-1}$$

$$\lambda_j = \frac{\partial \mathcal{L}(Q_i, \phi_T)}{\partial \phi_j}$$

$$\Rightarrow \lambda_{j-1} = (I - \alpha H_{j-1}) \lambda_j \sim O(P)$$

Hessian-vector
Product (HVP)

4. Phương pháp đề xuất

Phân bố Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution)

$$S_i \xrightarrow{f_{\phi_{j-1}^b}} A_{j-1} \rightarrow \mathcal{L}(Q_i, \phi_T)$$


$$\text{Attr}_{j-1} = \frac{\partial}{\partial A_{j-1}} [\lambda_j \nabla_{\phi} \mathcal{L}(S_i, \phi_{j-1})]$$

$$w_j^c = \frac{1}{HW} \sum_{m,n} \text{Attr}_{j-1}^{(c,m,n)}$$


$$\text{CAM}_{j-1}^{(m,n)} = \sum_c w_j^c A_{j-1}^{(c,m,n)}$$

$$\widehat{\text{CAM}}_{j-1} = \text{Upsample}(\text{CAM}_{j-1}^{(m,n)})$$

$$\Phi_{\text{FAMA}} = \sum_{j=1}^T \widehat{\text{CAM}}_{j-1}$$



5. Thực nghiệm



5. Thực nghiệm


Siêu tham số	Giá trị
Kiến trúc backbone	Conv4 (4 khối: conv 3×3 + BN + ReLU + maxpool 2×2)
Tốc độ học vòng trong α	0.01
Tốc độ học vòng ngoài β (Adam)	0.001
Số bước thích ứng huấn luyện T_{train}	5
Số bước thích ứng kiểm tra T_{test}	10
Kích thước meta-batch	4
Số vòng lặp meta-training	60.000
Cấu hình N -way K -shot	5-way 1-shot

5. Thực nghiệm



Mini-Imagenet

- Vật thể tự nhiên đa dạng.
- Các lớp phân tách ngẫu nhiên. *Các lớp train/test có thể cùng nhóm ngữ nghĩa.*



Tiered-Imagenet

- Vật thể tự nhiên, phân cấp theo 34 nhóm cha.
- Các lớp phân tách theo các lớp cha. *Đảm bảo dữ liệu giữa train và (test/val) thuộc cross-domain.*



CUB-200-2011

- Thu thập từ 600 loài chim.
- Ảnh cực kỳ chi tiết và mịn. Tất cả đều thuộc cùng một phạm trù "chim". Khác biệt nằm ở cục bộ. (Hard tasks)

miniImageNet → CUB

tiered-ImageNet → CUB

CUB → mini/tiered


dịch chuyển vừa phải (vật thể tự nhiên tổng quát → 1 phạm trù hẹp/fine-grained)

dịch chuyển lớn hơn (tiered đã chia theo nhóm cha nên bản thân domain train đã đa dạng/phân tán hơn mini, cộng thêm bước nhảy sang fine-grained)


kiểm tra tính bất đối xứng của negative transfer — domain train hẹp/fine-grained (CUB) có thích ứng tốt sang domain rộng hơn không, hay chiều ngược lại dễ/khó hơn?

5. Thực nghiệm


Min2Cub - Adaptation Gain = 24.24%




Min2Cub - Adaptation Gain = -7.91%



Tiered2Cub - Adaptation Gain = 41.24%



Tiered2Cub - Adaptation Gain = -25.88%




5. Thực nghiệm

BiADT: Nếu bản đồ quy kết cuối cùng là trung thực, ta kỳ vọng hai chiều xóa-và-đo mang lại hai xu hướng đối lập, và cùng tách biệt rõ rệt khỏi đường cơ sở ngẫu nhiên.

- Xóa lần lượt các vùng ảnh theo các chiều hướng
 - + mức độ quan trọng giảm dần
 - + mức độ quan trọng tăng dần
 - + ngẫu nhiên
- Tính diện tích lệch khỏi đường ngẫu nhiên (AOPC (Area Over Perturbation Curve))

$$ABC_{\downarrow} := \int_0^1 \left[\Delta M(\rho, \text{ngẫu nhiên}) - \Delta M(\rho, \text{giảm dần}) \right] d\rho,$$

$$ABC_{\uparrow} := \int_0^1 \left[\Delta M(\rho, \text{tăng dần}) - \Delta M(\rho, \text{ngẫu nhiên}) \right] d\rho.$$



Bộ dữ liệu	$ABC_{\downarrow}$ (mean $\pm$ std)	p -value	$ABC_{\uparrow}$ (mean $\pm$ std)	p -value
tieredImageNet	0.1861 $\pm$ 0.109	1.99×10^{-4} (< 0.001)	0.289 $\pm$ 0.122	7.01×10^{-7} (< 0.001)

5. Thực nghiệm

Sanity Check

- Nếu bản đồ quy kết thực sự phản ánh tri thức tiên nghiệm đã học (θ_0), hệ số tương quan giữa hai bản đồ quy kết do việc ngẫu nhiên hóa tham số so với khi không can thiệp phải thấp hơn đáng kể.

Khối bị phá hủy	Pearson (tiered2cub)	Spearman (tiered2cub)	Pearson (cub2tiered)	Spearman (cub2tiered)
Head	0.1109	0.108	0.0106	0.0103
Block 1	-0.008	-0.007	-0.002	-0.002
Block 2	0.004	0.0025	0.007	0.006
Block 3	-0.008	-0.006	0.0127	0.0104
Block 4	-0.009	-0.01	0.006	0.0048

5. Thực nghiệm

Sanity Check

- Nếu bản đồ quy kết thực sự phản ánh vai trò định hướng của tập hỗ trợ S_i , hệ số tương quan giữa hai bản đồ quy kết do việc can thiệp vào S_i (bằng cách i, ii, iii) so với khi không can thiệp phải thấp hơn đáng kể.

(i) - Ngẫu nhiên gây nhiễu các label trong tập hỗ trợ (hoán vị lớp)

(ii) - Thêm các mẫu khác từ ngoài phân phối đã học trong quá trình meta-training (trộn tác vụ)

(iii) - Làm mờ hoặc gây nhiễu các mẫu để ranh giới các lớp bị xóa nhòa (tăng độ khó tác vụ)

Kịch bản can thiệp	Pearson (tiered2cub)	Spearman (tiered2cub)	Pearson (cub2tiered)	Spearman (cub2tiered)
Trộn tác vụ (OOD tasks)	0.3605	0.3506	0.015	0.013
Hoán vị lớp (Noisy tasks)	0.4386	0.425	0.025	0.024
Tăng độ khó tác vụ (Hard tasks)	0.2723	0.2634	0.017	0.016

6. Kết luận

Đóng góp chính

- Độ lợi thích ứng ΔM : định lượng khả vi chiều hướng chuyển giao (tích cực / tiêu cực / feature-reuse) của việc thích ứng backbone
- FAMA: quy kết đa trạng thái xuyên suốt toàn bộ quỹ đạo thích ứng (không chỉ tại ϕT), giữ nguyên dấu, không cần dữ liệu meta-training
- Kiểm chứng: BiADT ($p < 0.001$ ở cả hai chiều) cùng hai bài kiểm tra tỉnh táo theo θ_0 và S_i xác nhận tính trung thực và đáng tin cậy của bản đồ quy kết

Hạn chế

- Backbone Conv4 nông $\rightarrow$ lưới đặc trưng thô, gây "tràn màu" (spatial bleeding) và sai số biên lớn trong BiADT
- Kịch bản OOD chưa đủ khắc nghiệt do tương đồng thị giác cấp thấp giữa các bộ dữ liệu

Hướng phát triển

1. Backbone sâu hơn (ResNet-10) để cải thiện độ phân giải không gian
2. Tinh chỉnh kịch bản OOD bằng tập phi-vật-thể (Places, texture)
3. Tổng quát hoá ΔM /FAMA sang ANIL, BOIL, Meta-SGD
4. Áp dụng FAMA để can thiệp chủ động nhằm tự động hiệu chỉnh S_i

Xin chân thành cảm ơn.