

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Lê Tuấn Khải

GIẢI THÍCH NEGATIVE TRANS-
FER TRONG META-LEARNING

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHÍNH QUY

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Lê Tuấn Khải - 20120503
**GIẢI THÍCH NEGATIVE TRANS-
FER TRONG META-LEARNING**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHÍNH QUY

GIÁO VIÊN HƯỚNG DẪN
GS.TS Lê Hoài Bắc

Tp. Hồ Chí Minh, tháng 07/2026

Lời cảm ơn

Trước hết, tôi xin được gửi lời tri ân sâu sắc nhất đến GS.TS. Lê Hoài Bắc, người đã tận tình hướng dẫn, định hướng và hỗ trợ tôi trong suốt quá trình thực hiện luận văn này. Những góp ý chuyên môn sâu sắc từ thầy chính là động lực to lớn giúp tôi hoàn thành nghiên cứu này một cách trọn vẹn.

Bên cạnh đó, tôi cũng xin bày tỏ lòng kính trọng và biết ơn sâu sắc đến tập thể giảng viên Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM, đã truyền thụ cho tôi những nền tảng tri thức chuyên môn vững chắc trong suốt quá trình học tập tại trường. Chính những tri thức này đã định hình tư duy một cách hoàn thiện để đạt được các kết quả trong nghiên cứu này.

Cuối cùng, tôi muốn gửi lời cảm tạ tới gia đình, bạn bè đã luôn đồng hành cùng tôi trong suốt hành trình vừa qua.

Và lời kết, dù đã dành nhiều tâm huyết và nỗ lực, song đề án khó tránh khỏi những điểm thiếu sót ngoài ý muốn. Cho nên, tôi kính mong nhận được những lời nhận xét, góp ý quý báu từ quý thầy cô và Hội đồng để nghiên cứu này ngày càng hoàn thiện hơn.

Tôi xin trân trọng cảm ơn!

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP
**Giải thích Negative Transfer trong
Meta-learning**

Interpret Negative Transfer in Meta-learning

1 THÔNG TIN CHUNG

Người hướng dẫn:

- GS.TS. Lê Hoài Bắc (Bộ môn Khoa học Máy tính - Khoa Công nghệ Thông tin)

[Nhóm] Sinh viên thực hiện:

1. Nguyễn Lê Tuấn Khải (MSSV: 20120503)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Trong những thập kỷ gần đây, lĩnh vực Trí Tuệ Nhân Tạo (AI) nói chung và lĩnh vực Học Máy (ML) nói riêng đã chứng kiến những bước phát triển thần kỳ nhờ vào các yếu tố quan trọng như sự tích lũy lượng dữ liệu lớn, sự phát triển của các công cụ tính toán mạnh mẽ và sự ra đời của các thuật toán phức tạp [1].

Tuy nhiên, trên thực tế, các thuật toán Học Máy vẫn gặp phải những rào cản để đáp ứng các tình huống đặc thù do sự thiếu hụt các tập dữ liệu khả thi. Mà nguyên nhân chủ yếu của vấn đề này có thể xuất phát từ những bất cập gặp phải trong việc thu thập dữ liệu. Mà có thể kể đến như do tính đặc thù của việc thử nghiệm trong các lĩnh vực y khoa hay công nghệ cao, hoặc do bị ràng buộc về mặt đạo đức, pháp luật,... Dẫn tới rất khó để có thể thu thập được lượng dữ liệu đủ đa dạng. Cuối cùng tạo thành hệ quả là, các mô hình học máy truyền thống thường thất bại trong việc khái quát hóa tri thức từ các tập dữ liệu nhỏ. Và đây cũng chính là động lực cốt lõi thúc đẩy sự ra đời và phát triển của **Few-Shot Learning** cũng như **Meta-Learning**.

Được truyền cảm hứng từ khả năng học của con người - con người có thể nhanh chóng học được khái niệm mới chỉ qua vài lần trải nghiệm, nhờ tận dụng tri thức tích lũy - **Meta-Learning** đã được đưa ra như một phương pháp để giải quyết bài toán **Few-Shot Learning**. Mặc dù hiện tại vẫn chưa có định nghĩa thống nhất trong nhiều tài liệu, nhưng **Meta-Learning**, còn được gọi là học cách học, trong các tài liệu nghiên cứu gần đây [2], [3], [4] đặt ra với mục tiêu xây dựng các tri thức tiền nghiệm (kinh nghiệm) từ những tác vụ khác nhau, sau đó sử dụng kiến thức đó để hỗ trợ cho việc học các tác vụ mới một cách nhanh chóng. Mà trong đó ba hướng tiếp cận **Metric-based**, **Network-based** và **Gradient-based** nổi lên như ba phương pháp hứa hẹn chính. Và các hướng tiếp cận dựa trên gradient (**Gradient-based**) mang tính hứa hẹn cao hơn cả, bởi tính linh hoạt cao có thể

sử dụng được cho tất cả các mô hình có tính khả vi, đồng thời đạt được hiệu suất vượt trội so với các phương pháp khác.

Dẫn chứng cho điều này, phương pháp **Model-Agnostic Meta-Learning (MAML)** được đề xuất bởi C.Finn và các cộng sự [5] và các biến thể của nó [6], [7],..., là một trong những kỹ thuật thành công nhất trong hướng tiếp cận này. Trọng tâm của phương pháp này chính là tạo ra một meta-learner, được thiết kế để có thể hiệu chỉnh trọng số khởi tạo của tác vụ đích, do đó tăng khả năng khái quát của mô hình khi học tác vụ đích, tức là sinh ra một trọng số khởi tạo tốt và có thể nhảy tới trọng số tối ưu của tác vụ đích khi chỉ với một hoặc một vài bước nhảy gradient (gradient-step). Tuy nhiên, do lượng dữ liệu nhỏ và các điểm dữ liệu rời rạc gây ra hiện tượng quá khớp (over-fitting). Do đó, đây vẫn là một trong những mục tiêu cần đạt được để cải tiến Meta-Learning.

Ngoài ra, mặc dù các phương pháp dựa trên gradient đạt được hiệu suất đáng mong đợi, nhưng về bản chất, chúng đều là các *mô hình hộp đen (black-box models)*. Điều này có nghĩa là chúng không cung cấp thông tin rõ ràng về cơ chế quyết định của mình và không phải lúc nào mô hình cũng đảm bảo việc đưa ra lời giải tối ưu. Do đó, trong những tình huống như vậy, người dùng không nhận được thông tin cụ thể để nhận biết và cải thiện mô hình của mình kịp thời, cũng như không thể sử dụng kết quả của mô hình để tham khảo. Trong các ứng dụng thực tế, việc thiếu khả năng giải thích của các mô hình có thể tạo ra nhiều rủi ro tiềm ẩn trong xã hội.

Ví dụ, hai hệ thống phổ biến là PredPol và COMPAS [8], được sử dụng lần lượt bởi lực lượng cảnh sát và hệ thống tư pháp Hoa Kỳ, đã bị chỉ trích vì đưa ra các quyết định không công bằng và có xu hướng phân biệt chủng tộc. Cụ thể, PredPol tập trung vào khu vực cư trú của những cộng đồng da màu, trong khi COMPAS thường đối xử không công bằng với các tội phạm da đen. Thêm vào đó, trong các hệ thống nhận dạng, các mô hình luôn nhạy cảm bởi nhiều có thể dẫn đến nhận dạng sai lầm. Do đó, hiểu rõ hơn về cơ chế quyết định và hành vi của các mô hình

hộp đen có thể tăng niềm tin của người dùng vào kết quả mà chúng đưa ra. Hơn nữa, việc hiểu rõ cơ chế này cũng có thể được xem như một công cụ gỡ lỗi giúp các chuyên gia Trí Tuệ Nhân Tạo có thể phát hiện và sửa chữa các vấn đề, từ đó cải thiện hiệu suất của mô hình.

2.2 Mục tiêu đề tài

Mặc dù **MAML** và các biến thể của chúng đã đạt được hiệu suất cao trong nhiều tình huống. Tuy nhiên, liệu trọng số khởi tạo tốt sẽ luôn luôn hỗ trợ cho tác vụ đích? Hay nói cách khác, liệu tri thức có được từ việc trích xuất từ các tác vụ khác nhau có phải sẽ luôn có lợi cho việc học tác vụ đích? **Yue và các cộng sự** [9] đã chỉ ra rằng *tri thức có thể sẽ gây ra bất lợi cho tác vụ đích khi tập huấn luyện và tập kiểm định của tác vụ đích không tương đồng với nhau*.

Để ví dụ cho điều này, ta xét tác vụ phân loại ảnh sư tử và chó hoang châu phi cụ thể như hình minh họa 1 dưới đây. Do việc áp dụng tri thức tiền nghiệm lên đặc trưng về bối cảnh của bức ảnh nên gây ra sự nhầm lẫn trong việc đưa ra dự đoán (với ảnh có nền cỏ xanh mô hình sẽ nhầm lẫn mà gán nhãn nó là con sư tử, ngược lại ảnh có nền cỏ vàng mô hình cũng nhầm lẫn mà gán nhãn nó là chó hoang châu Phi). Điều này đã được tác giả lý giải dựa trên mô hình nhân quả có cấu trúc. Và hiện tượng này còn được biết đến với tên gọi là **chuyển giao cực đoan (negative-transfer)**.



Hình 1: Ví dụ cho chuyển giao cực đoan - do tri thức tiền nghiệm gây nhiễu đến quá trình học tác vụ đích.[9]


Để cải thiện và giải quyết hiện tượng này, chúng ta có thể áp dụng các điểm lợi của các kỹ thuật XAI có thể mang lại nhằm tìm ra những tri thức gây nhiễu, sau đó loại bỏ các yếu tố gây nhiễu trong quá trình học tác vụ đích. Tuy nhiên, hiện nay vẫn còn rất ít các công trình nghiên cứu về điều này. Bởi vì, **Meta-Learning** vẫn chưa có một định nghĩa hình thức một cách thống nhất cho nên việc áp dụng XAI cho các kỹ thuật Meta-Learning vẫn còn là một thách thức lớn. Vì những lý do đó, việc phát triển các kỹ thuật để diễn giải các mô hình meta-learning là cấp bách.

2.3 Phạm vi của đề tài

2.3.1 Few-Shot Learning

Few-Shot Learning là bài toán nhằm tạo ra một mô hình có thể khái quát tốt khi được huấn luyện trên tập dữ liệu có số lượng mẫu hạn chế. Trong phạm vi luận văn, chúng ta chỉ đề cập đến bài toán N -way- K -shot áp dụng cho bài toán phân lớp ảnh.

Trong bài toán này, mô hình được huấn luyện trên tập dữ liệu gồm N nhãn, và mỗi nhãn có K mẫu dữ liệu (thông thường $K = 1$ hoặc 5), được gọi là *tập hỗ trợ (support set)*, ký hiệu là tập S . Và sau đó, mô hình sẽ được kiểm định trên *tập truy vấn (query set)*, được ký hiệu là tập Q .



Hình 2: Ví dụ minh họa cho bài toán 3-way-2-shot với bài toán nhận diện chữ số viết tay (tập dữ liệu Ominiglot).

Để tiến hành thực nghiệm, trong phạm vi khóa luận, một số bộ dữ liệu phổ biến được sử dụng trong các công trình nghiên cứu trước đây sẽ được sử dụng. Cụ thể như sau.

- **Mini-ImageNet** [10] gồm 100 nhãn được chọn ngẫu nhiên từ tập **ImageNet** với kích thước mỗi ảnh là 84×84 , trong đó mỗi nhãn có 600 ảnh. Tập dữ liệu này được sử dụng rộng rãi trong các nghiên cứu về Meta-Learning vì kích thước nhỏ, có độ tương đồng nhất định thích hợp cho việc mô phỏng các tình huống trong thế giới thực.
- **tieredImageNet** [11] cũng được lấy mẫu từ tập **ImageNet**, tuy nhiên, nó xét đến việc cấu trúc phân cấp các nhãn trong tập ImageNet. Do đó, tập dữ liệu này tổng cộng gồm 34 nhãn cha, được chia với tỉ lệ 20/6/8 để dùng cho huấn luyện, kiểm định và xác thực, mỗi nhãn cha chứa từ 10 đến 30 nhãn, và có tổng cộng 608 nhãn trong tập dữ liệu này. Bởi vì có tổ chức phân cấp nên tập dữ liệu này phù hợp để đánh giá sự hiệu quả của mô hình.
- **CIFAR-FS** [12] là một tập dữ liệu với các ảnh từ tập **CIFAR-100** với 100 nhãn, mỗi nhãn gồm có 600 ảnh.
- **CUB-200-2011** [13], còn gọi là **CUB**, là một tập dữ liệu với các ảnh về loài chim, với 200 nhãn, và tổng cộng có 11.788 ảnh. Là một tập dữ liệu mang tính thách thức với sự tương đồng cao giữa các nhãn. Và trong luận văn này, tập

này sẽ được tuân thủ nghiêm ngặt theo phương án mà Chen cùng các cộng sự đề ra [14].

2.3.2 Meta-learning và phương pháp MAML

Trước khi đi vào nghiên cứu sâu hơn, ta cần định nghĩa cách tiếp cận cơ sở của đối tượng áp dụng giải thích. Trong phạm vi khóa luận này, thì đó là Meta-Learning và phương pháp MAML của C.Finn và các cộng sự.

Ngược với các phương pháp Học Máy truyền thống, khi mô hình f học trên một tập dữ liệu $D = \{(x_i, y_i)\}_{i=1}^n$ để tìm ra bộ tham số tối ưu θ^* nhằm cực tiểu hóa hàm mất mát $\mathcal{L}$ trên toàn bộ phân phối dữ liệu. Thì Meta-Learning tiếp cận bài toán ở cấp độ cao hơn.

Thay vì học trên các điểm dữ liệu đơn lẻ, Meta-Learning học trên một tập hợp các tác vụ (tasks) $\mathcal{T} = \{\mathcal{T}_1, \mathcal{T}_2, \dots, \mathcal{T}_M\}$. Mà trong đó, mỗi tác vụ $\mathcal{T}_i$ được cấu thành từ hai tập con riêng biệt.

- Tập hỗ trợ (Support set), $S = \mathcal{D}_i^{sup} = \{(x_j, y_j)\}_{j=1}^k$, đóng vai trò là tri thức nền tảng để mô hình thích nghi nhanh.
- Tập truy vấn (Query set), $Q = \mathcal{D}_i^{que} = \{(x_j, y_j)\}_{j=1}^m$, dùng để đánh giá khả năng tổng quát hóa của mô hình sau khi đã học từ tập hỗ trợ.

Khi đó, mục tiêu chính cốt lõi của Meta-learning là tối ưu hóa bộ tham số khởi tạo θ_0 sao cho tồn tại một hàm thích nghi g_{θ_0} có khả năng chuyển đổi nhanh chóng thông tin từ tập hỗ trợ S thành một mô hình tối ưu cho tập truy vấn Q .

Và như đã đề cập ở phần giới thiệu, để tìm ra bộ tham số khởi tạo (θ_0) tối ưu, thì có ba phương pháp được nêu ra. Nhưng trong phạm vi đề tài khóa luận, chúng ta chỉ xét đến các lớp phương pháp dựa trên **Gradient-based**, mà cụ thể truy về phương pháp **MAML** mà C.Finn cùng các cộng sự đặt ra.

Với phương pháp này, thì hàm thích nghi g_{θ_0} là quy trình Gradient Descent. Mô hình học cách tìm vị trí xuất phát θ_0 sao cho chỉ cần vài bước đạo hàm trên S là chạm đến cực trị.


Cụ thể quá trình (siêu) huấn luyện - meta-training - của MAML sẽ hoạt động như thuật toán 1 và hình 3 dưới đây.

Algorithm 1: Thuật toán meta-training với Model Agnostic Meta-Learning (MAML)

Require: $p(\mathcal{T})$: Phân phối trên các tác vụ

Require: α, β : Các siêu tham số về bước nhảy (tốc độ học)

- 1: Khởi tạo tham số θ_0 ngẫu nhiên
- 2: **while** chưa dừng **do**
- 3: Lấy mẫu một lô các tác vụ (meta-batch) $\mathcal{T}_i \sim p(\mathcal{T})$
- 4: **for all** $\mathcal{T}_i$ **do**
- 5: Tính $\nabla_{\Phi} \mathcal{L}_{\mathcal{T}_i}(f_{\theta_0}, S_i)$
- 6: Tính các tham số thích nghi bằng Gradient Descent: $\Phi_i = \theta'_i = \theta_0 - \alpha \nabla_{\Phi} \mathcal{L}_{\mathcal{T}_i}(f_{\theta_0}, S_i)$
- 7: **end for**
- 8: Cập nhật tham số tổng quát: $\theta_0 \leftarrow \theta_0 - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\Phi_i}, Q_i)$
- 9: **end while**




Hình 3: Hình minh họa quá trình meta-training trong MAML

2.3.3 Mô hình cấu trúc nhân quả - SCM

Tuy MAML và các biến thể của nó đạt hiệu suất ấn tượng trong nhiều tình huống thực tế. Nhưng với bản chất phức tạp của Meta-Learning thì vẫn khó để mà hiểu được một cách tường minh cơ chế chuyển giao tri thức thực sự diễn ra bên trong.

Yue và các cộng sự [9] đã đưa ra một góc nhìn khác dựa trên mô hình cấu trúc nhân quả (Structural Causal Model) như hình minh họa 4 bên dưới, để biểu diễn quá trình thích ứng nhanh (*fast-adaptation*) trong giai đoạn meta-testing.



Hình 4: Mô hình cấu trúc nhân quả - Structural Causal Model

Mô hình này giả định rằng quá trình học và dự đoán trong Meta-Learning bị chi phối bởi bốn biến số trừu tượng.

- **D (Pretrained Knowledge):** Đại diện cho tri thức tích lũy từ giai đoạn siêu huấn luyện, bao gồm tập dữ liệu nguồn và bộ tham số khởi tạo θ_0 .
- **X_S (Feature Representation):** Các đặc trưng được trích xuất từ S thông qua mô hình f_Φ .
- **C (Context/Semantic Manifold):** Biểu diễn ngữ cảnh hoặc các khái niệm ngữ nghĩa trừu tượng mà cơ sở của nó được kế thừa từ D .
- **Y_S (Classification Effect):** Kết quả dự đoán cuối cùng của mô hình.

Đồng thời, từ **SCM 4**, ta có thể bóc tách ra được Y_S dựa trên hai con đường chính.

1. **$X \rightarrow Y$ (Trực tiếp):** Đặc trưng hình ảnh trực tiếp quyết định nhãn dự đoán.
2. **$X \rightarrow C \rightarrow Y$ (Gián tiếp):** Đặc trưng X được ánh xạ vào không gian ngữ nghĩa C , nơi nó kết hợp với tri thức bối cảnh từ D để đưa ra dự đoán.

Và sự tồn tại của các cạnh $D \rightarrow X$ và $D \rightarrow C$ cho thấy tri thức tiền huấn luyện đóng vai trò là một biến gây nhiễu (confounder). Điều này tạo ra các tương quan

ảo (spurious correlations), nơi mô hình dự đoán nhãn Y dựa trên bối cảnh C hơn là dựa trên bản chất của đặc trưng X .

2.3.4 Phát biểu bài toán

Tương tự với các nghiên cứu phát triển các phương pháp XAI, trước hết chúng ta cần đặt ra những câu hỏi xoay quanh cơ chế của mô hình. Trong ngữ cảnh **Meta-Learning**, câu hỏi được đặt ra là, *những gì thật sự đã được chuyển giao trong quá trình thích ứng với tác vụ mới? hay những mẫu - patterns - nào đã được sử dụng trong quá trình học tác vụ mới?*

Đồng thời, cũng phải xét đến các mẫu (patterns) đó ảnh hưởng như thế nào đến việc đưa ra dự đoán của mô hình sau quá trình thích ứng. Do đó, để giải quyết bài toán diễn giải trong **Meta-Learning** ta cần giải quyết đồng thời hai bài toán con là diễn giải cho quá trình thích ứng nhanh (*fast-adaptation*) và diễn giải cho quá trình ra quyết định của mô hình kết quả.

Cụ thể hơn, với MAML và các biến thể liên quan (như mô tả tại thuật toán 1), quá trình thích ứng nhanh (*fast adaptation*) trong giai đoạn *meta-testing* được thực hiện dựa trên tập dữ liệu hỗ trợ (*support set*) S và tham số khởi tạo θ_0 đã học từ giai đoạn siêu huấn luyện (*meta-training*). Với giả định chỉ sử dụng một bước cập nhật gradient, tham số thích ứng Φ được xác định như sau phương trình 1.

$$\Phi = \theta' = \theta_0 - \alpha \nabla_{\theta_0} \mathcal{L}(\theta_0, S) \quad (1)$$

Sau đó, để đánh giá hiệu suất thực tế, tham số thích ứng Φ thu được từ phương trình 1 sẽ được áp dụng trực tiếp trên tập truy vấn (*query set*) Q .

Tại giai đoạn *meta-testing* này, giá trị hàm tổn thất $\mathcal{L}(\Phi, Q)$ hoặc các độ đo khác như (*accuracy*) - gọi chung là acc_α - trên tập Q sẽ đóng vai trò là chỉ số đánh giá khả năng thích ứng nhanh của mô hình đối với các tác vụ mới (unseen tasks).

Từ đây có thể thấy được, để diễn giải cho quá trình thích ứng nhanh này, chính xác ta cần phải xác định các đặc trưng chung F giữa mô hình f_{θ_0} và f_Φ .

2.4 Cách tiếp cận dự kiến


Dựa trên phát biểu bài toán, để xác định được đặc trưng chung F ta cần thiết phải thực hiện thông qua phương pháp hậu diễn giải (post-hoc) với hai giai đoạn chính.

Đầu tiên dựa trên **SCM** 4 ta có thể rõ ràng, f_{θ_0} đã truyền cho f_{Φ} những thông tin chung C thể hiện qua F . Nhưng ta vẫn chưa biết nó đã chuyển giao bao nhiêu, và tác động xấu hay tốt đến việc học tác vụ mới.

Hay nói cách khác, chính là F có gây ra hiện tượng tương quan giả hay không? Hoặc có dẫn đến hiện tượng *chuyển giao tiêu cực* (*negative transfer*) hay không. Thành thử, ở bước đầu tiên, việc cần làm chính là định nghĩa một độ đo acc_{α} hợp lý.

Đồng thời, sau khi xác định được mức độ F được chuyển giao. Tiếp theo đó, ta cần phải xác định rõ mối tương quan giữa θ_0 và Φ thông qua việc xác định F một cách rõ ràng.

Và trong khuôn khổ khóa luận, quy trình thực hiện hai bước trên sẽ được minh họa thông qua sơ đồ như hình 5 dưới đây.



Hình 5: Cách tiếp cận dự kiến

2.4.1 Xác định độ đo acc_{α}

Để xác định được độ đo acc_{α} hợp lý, ta cần nó thỏa mãn các tiêu chí sau.

- **Khả năng chỉ ra được tương quan giả.** Phải mô tả và bóc tách được bản chất của các lỗi sai trên từng nhóm.
- **Tính trung thành (Faithfulness).** Xác định xem các yếu tố mà mô hình

đang chú ý có thực sự là nguyên nhân cốt lõi định hình nên quyết định dự đoán hay không.

Khi đã xác định được tiêu chí, ta có thể dựa trên nó để tham khảo các độ đo sau.

1. **Conventional Accuracy** (Độ chính xác truyền thống), là thước đo tỷ lệ dự đoán đúng trên toàn bộ tập dữ liệu.
2. **CAM-Acc** (Độ chính xác định vị đặc trưng) [9], là thước đo định lượng liệu mô hình có "chú ý" đến đối tượng thực sự khi đưa ra dự đoán hay không. Được định nghĩa là tỷ lệ phần trăm số điểm ảnh (pixels) nằm bên trong bounding box có điểm số Grad-CAM vượt qua một ngưỡng nhất định, chẳng hạn như lớn hơn 0,9.
3. **Hardness-specific Acc** (Độ chính xác theo độ khó), là thước đo hiệu suất của mô hình được phân tách dựa trên mức độ phức tạp của dữ liệu đầu vào. Chỉ số này giúp xác định xem mô hình gặp khó khăn ở các mẫu nhiễu, thiếu sáng hay các trường hợp biên (edge cases), từ đó đánh giá độ tin cậy của dự đoán trong các điều kiện thực tế khác nhau.
4. **Lượng hóa Negative Transfer Gap (NTI)** (Lượng hóa khoảng cách chuyển đổi tiêu cực), là một chỉ số đo lường sự sụt giảm hiệu suất của mô hình khi việc học từ một tác vụ nguồn gây cản trở hoặc làm sai lệch kết quả trên tác vụ đích. NTI giúp xác định mức độ không tương thích giữa các miền dữ liệu (domain discrepancy) trong quá trình Transfer Learning hoặc Domain Adaptation.

2.4.2 Xác định F

Sau khi đã định hình được các thước đo hiệu suất tại bước trước, mục tiêu tiếp theo là cụ thể hóa không gian đặc trưng chung F . Trong ngữ cảnh của khóa luận, F không chỉ là một tập hợp các đặc trưng trừu tượng mà là "vùng tri thức" mà mô hình f_{θ_0} đã chuyển giao cho f_{Φ} .

Để xác định F một cách trực quan và định lượng, các phương pháp sử dụng Bản đồ kích hoạt lớp (Class Activation Map - CAM) ([15], [16], [17], [18], [19]) được đề xuất làm công cụ chủ đạo. Cụ thể, quá trình xác định F được thực hiện thông qua các bước sau.

- **Trích xuất vùng chú ý (Attention Extraction):** Sử dụng kỹ thuật Grad-CAM để tạo ra bản đồ nhiệt M , thể hiện mức độ đóng góp của từng vùng không gian trên ảnh đầu vào đối với quyết định phân loại của f_Φ .
- **Phân lập đặc trưng F :** Không gian F được xác định là tập hợp các tọa độ điểm ảnh (x, y) có giá trị kích hoạt vượt ngưỡng τ (với $\tau = 0,9$ như đã định nghĩa ở mục CAM-Acc). Vùng này đại diện cho những đặc trưng mà mô hình coi là quan trọng nhất để đưa ra dự đoán.
- **Phân tích sự tương quan giữa θ_0 và Φ :** Bằng cách so sánh vùng kích hoạt F của mô hình tiền huấn luyện f_{θ_0} và mô hình sau khi tinh chỉnh f_Φ , ta có thể đánh giá được liệu các đặc trưng cốt lõi có bị thay đổi (shift) hay bị nhiễu bởi các yếu tố ngoại cảnh hay không.

Việc xác định F thông qua CAM cho phép ta thực hiện phép hậu diễn giải (post-hoc) một cách tường minh. Nếu F hội tụ tại các vùng chứa đối tượng (Object-centric), mô hình đang học được các đặc trưng ngữ nghĩa bền vững. Ngược lại, nếu F phân tán vào vùng nền (Background), đây là minh chứng cho việc tồn tại hiện tượng tương quan giả (spurious correlation) được chuyển giao từ tác vụ nguồn sang tác vụ đích, dẫn đến negative transfer. Kết quả của việc xác định F sẽ là cơ sở để điều chỉnh chiến lược huấn luyện hoặc lọc dữ liệu nhằm tối ưu hóa sự chuyển giao tri thức giữa hai tác vụ.

2.5 Kết quả dự kiến của đề tài

Trong phạm vi khóa luận, các kết quả dự kiến có thể đạt được được trình bày như sau:

- Mô hình đạt được kết quả cạnh tranh trong khi vẫn cân bằng được với khả năng diễn giải của mô hình.
- Hoàn thiện được một hình mẫu (framework) hậu diễn giải cho mô hình Meta-Learning cụ thể là các phương pháp dựa trên Gradient-based thông qua các phương pháp hậu diễn giải.

2.6 Kế hoạch thực hiện

Đề tài nghiên cứu của luận văn được thực hiện tại Khoa Công nghệ Thông tin, trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh.

Thời gian thực hiện đề tài nghiên cứu 06 tháng kể từ tháng 01/2026 đến 06/2026. Kế hoạch thực hiện chi tiết cho đề tài nghiên cứu được liệt kê như trong bảng 1.

Công việc	Thời gian thực hiện
Tìm hiểu các hướng tiếp cận và công trình liên quan	01/01/2026 - 15/02/2026
Khảo sát, đánh giá các công trình tiêu biểu và hoàn thiện đề cương	16/02/2026 - 16/03/2026
Nghiên cứu các phương pháp giải quyết bài toán diễn giải cho Meta-Learning	17/03/2026 - 20/04/2026
Đề xuất phương pháp cải tiến, thực nghiệm và báo cáo giữa kỳ	21/04/2026 - 06/05/2026
Thực hiện thực nghiệm bổ sung, đánh giá kết quả và viết bản thảo luận văn	07/05/2026 - 30/06/2026
Hoàn thiện quyển luận văn, chỉnh sửa theo góp ý của GVHD và chuẩn bị bảo vệ	01/07/2026 - 15/07/2026

Bảng 1: Bảng kế hoạch thực hiện đề tài khóa luận

Tài liệu

- [1] M. Haenlein and A. Kaplan, “A brief history of artificial intelligence: On the past, present, and future of artificial intelligence,” *California management review*, vol. 61, no. 4, pp. 5–14, 2019.
- [2] Y. Song and H. Jeong, “Towards cross domain generalization of hamiltonian representation via meta learning,” *arXiv preprint arXiv:2212.01168*, 2022.
- [3] C. Lu, Y. Wu, J. M. Hernández-Lobato, and B. Schölkopf, “Invariant causal representation learning for out-of-distribution generalization,” in *International conference on learning representations*, 2021.
- [4] D. Li, Y. Yang, Y.-Z. Song, and T. Hospedales, “Learning to generalize: Meta-learning for domain generalization,” in *Proceedings of the AAAI conference on artificial intelligence*, vol. 32, 2018.
- [5] C. Finn, P. Abbeel, and S. Levine, “Model-agnostic meta-learning for fast adaptation of deep networks,” in *International conference on machine learning*, pp. 1126–1135, PMLR, 2017.
- [6] H. Yao, Y. Wei, J. Huang, and Z. Li, “Hierarchically structured meta-learning,” in *International conference on machine learning*, pp. 7045–7054, PMLR, 2019.
- [7] H. Yao, X. Wu, Z. Tao, Y. Li, B. Ding, R. Li, and Z. Li, “Automated relational meta-learning,” in *International Conference on Learning Representations*, 2020.
- [8] W. D. Heaven, “Predictive policing algorithms are racist. they need to be dismantled,” *MIT Technology Review*, vol. 17, p. 2020, 2020.
- [9] Z. Yue, H. Zhang, Q. Sun, and X.-S. Hua, “Interventional few-shot learning,” *Advances in neural information processing systems*, vol. 33, pp. 2734–2746, 2020.

- [10] O. Vinyals, C. Blundell, T. Lillicrap, D. Wierstra, *et al.*, “Matching networks for one shot learning,” *Advances in neural information processing systems*, vol. 29, 2016.
- [11] M. Ren, E. Triantafillou, S. Ravi, J. Snell, K. Swersky, J. B. Tenenbaum, H. Larochelle, and R. S. Zemel, “Meta-learning for semi-supervised few-shot classification,” *arXiv preprint arXiv:1803.00676*, 2018.
- [12] L. Bertinetto, J. F. Henriques, P. H. Torr, and A. Vedaldi, “Meta-learning with differentiable closed-form solvers,” *arXiv preprint arXiv:1805.08136*, 2018.
- [13] C. Wah, S. Branson, P. Welinder, P. Perona, and S. Belongie, “The caltech-ucsd birds-200-2011 dataset,” 2011.
- [14] W.-Y. Chen, Y.-C. Liu, Z. Kira, Y.-C. F. Wang, and J.-B. Huang, “A closer look at few-shot classification,” *arXiv preprint arXiv:1904.04232*, 2019.
- [15] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, “Learning deep features for discriminative localization,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2921–2929, 2016.
- [16] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE international conference on computer vision*, pp. 618–626, 2017.
- [17] A. Chattopadhyay, A. Sarkar, P. Howlader, and V. N. Balasubramanian, “Grad-cam++: Generalized gradient-based visual explanations for deep convolutional networks,” in *2018 IEEE winter conference on applications of computer vision (WACV)*, pp. 839–847, IEEE, 2018.
- [18] H. Wang, Z. Wang, M. Du, F. Yang, Z. Zhang, S. Ding, P. Mardziel, and X. Hu, “Score-cam: Score-weighted visual explanations for convolutional neu-

ral networks,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*, pp. 24–25, 2020.

- [19] S.-Y. Byun and W. Lee, “Reciprocam: Lightweight gradient-free class activation map for post-hoc explanations,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8364–8370, 2024.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 16 tháng 03 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Danh mục các từ viết tắt

ARML Automated Relational Meta-Learning.

BiADT Bi-directional Attribution Deletion Test.

DL học sâu (Deep Learning).

FAMA Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning
(Feature-space Adjoint Meta-Learning Attribution).

FSL học ít mẫu (Few-shot Learning).

HeTRoM Heterogeneous Tasks Robust Meta-learning.

HSFM Hard-Set-Guided Feature-Space Meta-Learning.

HSML Hierarchically Structured Meta-Learning.

IFSL Interventional Few-shot Learning.

LIME Local Interpretable Model-Agnostic Explanations.

MAML Model-Agnostic Meta-Learning.

ML học máy (Machine Learning).

SHAP Shapley Additive Explanations.

XAI Explainable AI.

Mục lục

Lời cảm ơn	i
Đề cương chi tiết	ii
Mục lục	xx
Danh mục các từ viết tắt	xx
Tóm tắt	xxiv
1 Phần mở đầu	1
1.1 Tính cấp thiết của đề tài	1
1.2 Mục tiêu nghiên cứu	4
1.3 Phương pháp tiếp cận	5
1.4 Đóng góp của đề tài	6
1.5 Bố cục luận văn	7
2 Tổng quan nghiên cứu	9
2.1 Cơ sở lý thuyết	9
2.1.1 Bài toán học ít mẫu (Few-shot Learning) (FSL) và Meta-Learning	9
2.1.2 Model-Agnostic Meta-Learning (MAML)	10
2.1.3 Explainable AI (XAI)	13
2.1.4 Correctness và trustworthiness của một phương pháp XAI	16
2.2 Các nghiên cứu liên quan	17
2.2.1 Tác vụ không đồng nhất (heterogeneous task) và hiện tượng Negative Transfer	18
2.2.2 Các phương pháp giải thích hậu nghiệm dựa trên gradients và nhiễu loạn	20

2.2.3	Các phương pháp XAI cho Meta-Learning và Few-Shot Learning	21
2.2.4	Attribution dựa trên quỹ đạo huấn luyện	22
2.2.5	Tổng hợp và định vị nghiên cứu	23
3	Phương pháp đề xuất	25
3.1	Phát biểu bài toán	25
3.2	Độ lợi thích ứng	27
3.2.1	Định nghĩa	28
3.3	Phương pháp Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)	30
3.3.1	Ý tưởng cốt lõi	30
3.3.2	Trạng thái đối ngẫu và đệ quy ngược qua quỹ đạo	31
3.3.3	Từ đạo hàm theo S_i sang bản đồ phân bổ trên F	32
3.3.4	Định nghĩa chính thức FAMA	34
3.3.5	Thuật toán và độ phức tạp	35
3.4	Cơ sở đánh giá	35
	Tài liệu tham khảo	36
A	Chứng minh Mệnh đề 1	41
A.1	Khai triển Taylor	41
A.1.1	Trường hợp $T = 1$: $R_h = 0$ chính xác	41
A.1.2	Trường hợp $T > 1$: cận $R_h = O((T\alpha)^2)$	41

Danh sách hình

1.1	(A) Hình minh họa hiện tượng chuyển giao tiêu cực thông qua ví dụ về bài toán phân loại sử tử và chó sa mạc. (B) Sơ đồ mô hình cấu trúc nhân quả của meta-learning.	3
2.1	Hình minh họa một bài toán nhận diện hình học.	11
2.2	Quá trình MAML tìm kiếm vị trí khởi tạo thuận lợi cho tham số θ_0 trong giai đoạn meta-training.	12
2.3	Minh họa sự thay đổi của không gian biểu diễn F sau thích ứng nhanh.	14

Danh sách bảng

Chương 1

Phần mở đầu

1.1 Tính cấp thiết của đề tài

Trong khoảng một thập kỷ trở lại đây, học máy (Machine Learning) (ML) nói chung và học sâu (Deep Learning) (DL) nói riêng đã đạt được những thành tựu vượt bậc trên nhiều bài toán thuộc các lĩnh vực khác nhau. Tuy nhiên, phần lớn thành công này dựa trên giả định rằng mô hình có thể được huấn luyện trên một tập dữ liệu quy mô lớn và đa dạng. Đồng thời, mạng có độ sâu càng sâu thì khả năng tổng quát hóa càng cao. Dù vậy, trong tình huống thực tế, giả định này vấp phải một rào cản lớn. Đối với các tác vụ nhạy cảm hoặc mang tính đặc thù cao, nơi việc thu thập dữ liệu bị ràng buộc bởi chi phí, rủi ro, hoặc các rào cản về đạo đức và pháp lý, việc xây dựng một tập dữ liệu đủ lớn là vô cùng thách thức, thậm chí bất khả thi [6], [36].


Xuất phát từ thực tiễn đó, bài toán học ít mẫu (Few-shot Learning) (FSL) vốn đã được đặt nền móng từ trước khi học sâu (Deep Learning) bùng nổ, đã trở nên đặc biệt cấp thiết trở lại trong kỷ nguyên học sâu (Deep Learning). Các phương pháp học ít mẫu (Few-shot Learning) hiện đại ra đời nhằm trực tiếp giải quyết rào cản về dữ liệu, cho phép mô hình học và tổng quát hóa hiệu quả chỉ với một lượng rất nhỏ mẫu được gán nhãn. Trong số các hướng tiếp cận, Meta-Learning (học cách học) [5], [25], là nền tảng đặc trưng và phổ biến nhất cho lớp bài toán này. Đặc biệt, với đột phá của C.Finn và các cộng sự [8], lớp phương pháp dựa trên gradient (gradient-based), tiêu biểu là Model-Agnostic Meta-Learning (MAML) đã trở thành hướng tiếp cận chủ đạo nhờ tính linh hoạt và khả năng tích hợp trên mọi kiến trúc mạng khả vi.

Dù vậy, cũng như phần lớn các mô hình học sâu khác, các mô hình Meta-Learning nói chung và MAML nói riêng vẫn là các mô hình hộp đen

(black-box models). Cơ chế mà tri thức tiên nghiệm (prior knowledge) ẩn chứa trong bộ tham số khởi tạo θ_0 chi phối quá trình thích ứng nhanh (fast-adaptation) trên tập hỗ trợ (support set) S vẫn chưa được biểu diễn một cách tường minh. Sự thiếu minh bạch này đã đặt ra các rào cản lớn trong việc triển khai các hệ thống đòi hỏi độ tin cậy cao, nơi người dùng cần có khả năng kiểm chứng các quyết định của mô hình thay vì chấp nhận các kết quả thuần túy dựa trên sự tương quan thống kê. [2], [13].

Đồng thời, tri thức tiên nghiệm (prior knowledge) không phải lúc nào cũng mang lại lợi ích cho tác vụ đích. Trong các kịch bản phức tạp như tác vụ không đồng nhất (heterogeneous tasks) được phân loại thành dữ liệu khó (hard tasks), dữ liệu nhiễu (noisy tasks), hoặc dữ liệu nằm ngoài phân phối (out-of-distribution) so với giai đoạn meta-training [28], quá trình thích ứng nhanh (fast-adaptation) có thể bị giảm hiệu suất nghiêm trọng. Mà nguyên nhân cốt lõi của sự suy giảm này là hiện tượng chuyển giao tiêu cực (negative transfer). Qua thực nghiệm, Yue và cộng sự [38] đã chỉ ra rằng khi có sự sai khác về phân phối giữa tập hỗ trợ và tập truy vấn, các mô hình trích xuất đặc trưng (backbone) mạnh thậm chí còn hoạt động kém hơn các mô hình yếu. Điều này xảy ra do mô hình có xu hướng học các tương quan giả (spurious correlations) từ tri thức tiên nghiệm thay vì đặc trưng thực sự của đối tượng, chẳng hạn như dùng bối cảnh nền (cỏ, sa mạc) để phân loại thay vì nhận diện con vật. Dưới góc nhìn của mô hình cấu trúc nhân quả (Structural Causal Model - SCM), tri thức tiên nghiệm (D) đã vô tình mở ra các luồng nhân quả sai lệch (backdoor paths), như tri thức sinh ra đặc trưng sai lệch ($D \rightarrow X$) hoặc tri thức sinh ra ngữ cảnh sai lệch ($D \rightarrow X \rightarrow C$), khiến mô hình đưa ra quyết định dựa trên đặc trưng hoặc bối cảnh thiên lệch này thay vì bản chất cốt lõi của dữ liệu (Hình 2.1).

Dù tác động của việc chuyển giao tiêu cực đã được ghi nhận, các nghiên cứu hiện tại chủ yếu mới chỉ nhận diện hiện tượng này thông qua biểu hiện của sự sụt giảm độ chính xác trên tác vụ đích, thay vì giải thích tường minh ở cấp độ nguyên nhân của bản thân quá trình thích ứng nhanh vẫn còn tồn tại như một dạng hộp đen. Một kết quả khác do Raghu và các cộng sự [21] công bố, đã chỉ ra phần lớn hiệu quả của MAML thực chất đến từ việc tái sử dụng đặc trưng (feature reuse) thông qua việc thực hiện



Hình 1.1: (A) Hình minh họa hiện tượng chuyển giao tiêu cực thông qua ví dụ về bài toán phân loại sử tử và chó sa mạc. (B) Sơ đồ mô hình cấu trúc nhân quả của meta-learning.

đóng băng phần thân trích xuất đặc trưng (backbone) và chỉ cho phép phần đầu bộ phân lớp (head) được cập nhật thích ứng. Ngược lại, Oh và các cộng sự [17] chỉ ra đối với các tác vụ ngoài phân phối (cross-domain), việc đảo ngược quá trình, đóng băng phần đầu và chỉ cập nhật phần trích xuất đặc trưng (backbone) mới giúp mô hình thích ứng vượt trội thông qua việc thay đổi biểu diễn (representation change). Từ hai kết quả này, đã cho ta một giả thuyết cốt lõi về vai trò của tập hỗ trợ S . Trong đó, đóng vai trò như một tín hiệu điều hướng (steering signal) - hoặc tổ hợp lại tri thức cũ, hoặc tái cấu trúc biểu diễn mới - trên không gian đặc trưng đã được thiết lập từ quá trình meta-training. Hệ quả là, bản thân tập hỗ trợ S đã cụ thể hóa các biến nhiễu ẩn từ tri thức tiền nghiệm, làm bóp méo tín hiệu điều hướng và dẫn dắt mô hình hội tụ vào các tương quan giả trong bước thích ứng. Giả thuyết này được củng cố mạnh mẽ bởi Parast và các cộng sự [18] trong nghiên cứu gần đây cho thấy việc trực tiếp can thiệp lên các biểu diễn nhúng của tập S (support embeddings) trên một không gian đặc trưng đã được đóng băng có thể ngăn chặn hiệu quả việc mô hình đi chệch hướng.

Tuy nhiên tất cả các phương pháp trên, chỉ dừng ở việc **hiệu chỉnh** các biểu diễn hoặc cơ chế thích ứng nhằm cải thiện hiệu suất khái quát hóa của tác vụ đích, mà không nhằm **giải thích cho con người** về cơ chế mà tập hỗ trợ S đã định hướng như thế nào?

Ở một khía cạnh khác, lĩnh vực Explainable AI (XAI) trong những năm gần đây đã được giới học thuật đã chú ý trở lại và đạt được nhiều thành công đáng kể trong việc khai mở và giải thích các mô hình hộp đen.

Tiêu biểu là các phương pháp diễn giải cục bộ (local explanation) như Grad-CAM [27] hay SHAP [14] đã được đề xuất, áp dụng và nghiên cứu cải tiến một cách rộng rãi. Dù vậy, việc tích hợp các kỹ thuật giải thích này vào những kiến trúc tối ưu hai tầng như meta-learning hay MAML vẫn còn rất hạn chế.

Đối với dữ liệu phi cấu trúc như hình ảnh, các nỗ lực diễn giải chủ yếu chỉ tập trung vào giai đoạn sau thích ứng (post-adaptation) như Grad-CAM cục bộ [34], mà hoàn toàn bỏ qua quá trình thích ứng. Nổi bật gần đây có phương pháp TL-XML do Mitsuka và cộng sự đề xuất [15] nhằm mở rộng hàm ảnh hưởng (influence functions) sang cấp độ tác vụ (task-level) để định lượng tác động của dữ liệu meta-training lên hành vi thích ứng. Nhưng nhược điểm của phương pháp này là sự phụ thuộc hoàn toàn vào dữ liệu huấn luyện gốc, gây ra rào cản khổng lồ về chi phí tính toán và tính khả thi trong các ứng dụng thực tế nơi dữ liệu meta-training bị đóng gói hoặc bảo mật.

Xuất phát từ khoảng trống trên, nghiên cứu này đặt ra câu hỏi trung tâm, *điều gì gây ra negative transfer trong quá trình thích ứng nhanh của meta-learning?*. Và câu hỏi này có thể được cụ thể hóa thành hai câu hỏi nghiên cứu theo thứ tự lần lượt như sau. Thứ nhất, quá trình thích ứng từ tri thức tiền nghiệm (prior knowledge) sang tri thức cụ thể (specific knowledge) với một tác vụ đích cho trước là có lợi hay có hại, và mức độ ảnh hưởng của nó là bao nhiêu? Thứ hai, những đặc trưng nào trong tập hỗ trợ S là nguyên nhân gây ra ảnh hưởng tích cực hay tiêu cực đó, và chúng nằm ở đâu trong không gian đặc trưng F ?

Để giải quyết và trả lời hai câu hỏi nghiên cứu trên, thứ đòi hỏi không chỉ là một cơ chế diễn giải đơn lẻ mà là một độ đo định lượng kết hợp cùng một cơ chế hậu diễn giải (post-hoc explanation) đáng tin cậy nhằm truy vết ngược nguyên nhân từ cho quá trình thích ứng nhanh là cần thiết và cấp bách.

1.2 Mục tiêu nghiên cứu

Xuất phát từ khoảng trống đã được phân tích ở phần 1.1 với hai câu hỏi nghiên cứu đã nêu, mục tiêu của đề tài hướng đến việc xây dựng một

cơ chế hậu diễn giải kép (post-hoc explanation framework) gồm hai thành phần chính, cùng với các bài kiểm tra thực nghiệm nhằm chứng minh tính trung thực và độ tin cậy của khung phương pháp này.

Với mục tiêu thứ nhất, là xây dựng một độ đo định lượng ứng với thành phần đầu tiên trong cơ chế diễn giải, nhằm xác định mức độ lợi/hại của các bước thích ứng nhanh trên một tác vụ đích cụ thể. Đồng thời, độ đo này phải nhạy cảm với sự thay đổi của S , thay vì chỉ đo hiệu suất tổng thể như độ chính xác truyền thống.

Với mục tiêu thứ hai, là xây dựng một phương pháp diễn giải thông qua trực quan hóa nhằm định vị các đặc trưng trong S , ứng với vị trí trong không gian đặc trưng chung F , đóng góp tích cực hay tiêu cực cho độ lợi thích ứng đo được ở thành phần thứ nhất.

Cuối cùng, đề tài đặt mục tiêu là thông qua các thực nghiệm định lượng lẫn định tính trên các bộ dữ liệu và kiến trúc mô hình chuẩn, nhằm minh chứng cho phương pháp được đề xuất là hiệu quả, trung thực (fairfulness) và đáng tin cậy (trustworthiness) trong việc phản ánh đúng cơ chế thích ứng.

1.3 Phương pháp tiếp cận

Tương ứng với các mục tiêu đã nêu, đề tài đề xuất một khung phương pháp gồm hai thành phần nối tiếp nhau, kết hợp cùng các phép kiểm định nhằm đảm bảo tính trung thực của cơ chế diễn giải. Đối với mục tiêu thứ nhất, để định lượng quá trình thích ứng, chúng tôi đề xuất xây dựng đại lượng **độ lợi thích ứng (adaptation gain)** ΔM dựa trên mức chênh lệch giá trị mất mát của tập truy vấn Q tại thời điểm sau khi thực hiện quá trình thích ứng nhanh với hai trường hợp thích ứng toàn phần và thích ứng phần đầu của bộ phân lớp (head). Giá trị này vừa trả lời cho câu hỏi định lượng đầu tiên, vừa cung cấp hàm mục tiêu cho bước giải thích. Đối với mục tiêu thứ hai, để truy vết nguyên nhân của ΔM thông qua các biểu diễn trên tập hỗ trợ, chúng tôi giới thiệu thuật toán **Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)** dựa nền tảng của phương pháp liên hợp (Adjoint method) cho phép mở rộng kỹ thuật

diễn giải của Grad-CAM vượt ra khỏi phạm vi một lớp mạng đơn lẻ để quét qua toàn bộ chuỗi gradient liên tiếp của quá trình thích ứng. Nhờ cơ chế này, FAMA có khả năng chiếu giá trị ΔM lên không gian đặc trưng chung F của tập S , qua đó cô lập chính xác các biểu diễn mang lại giá trị tích cực hoặc tiêu cực đối với tác vụ đích.

Cuối cùng, để kiểm chứng tính trung thực (fairfulness) của cơ chế diễn giải, chúng tôi thiết lập hai chuyên biệt dựa trên các bài kiểm tra nền tảng truyền thống. Đầu tiên, chúng tôi phát triển bài kiểm tra Bi-directional Attribution Deletion Test (BiADT), được điều chỉnh từ các phương pháp kiểm tra xóa-và-đo (deletion test) truyền thống để áp dụng vào bối cảnh động của quá trình thích ứng nhanh. Với mục đích là minh rằng các vùng phân bổ do FAMA chỉ ra có tác động trực tiếp đến hành vi thay đổi độ lợi thích ứng của mô hình. Thứ hai, chúng tôi áp dụng bài kiểm tra sự tỉnh táo (sanity check) theo đề xuất của Adebayo và cộng sự [1], được hiệu chỉnh để chứng minh rằng các phân bổ đặc trưng của FAMA không phải là kết quả ngẫu nhiên, mà phụ thuộc mật thiết vào cả tham số khởi tạo θ_0 (tri thức tiền nghiệm được rút ra từ quá trình meta-training) lẫn cấu trúc biểu diễn thực tế của tập hỗ trợ S . Thông qua đó, chúng tôi bảo chứng rằng FAMA phản ánh chính xác cơ chế diễn giải mô hình thay vì chỉ thực hiện các phép biến đổi hình ảnh vô nghĩa.

1.4 Đóng góp của đề tài

Trong khuôn khổ luận văn, đề tài mang lại các đóng góp chính sau.

Thứ nhất, đề tài thiết lập một cách tiếp cận mới trong việc nghiên cứu hiện tượng chuyển giao tiêu cực (negative transfer) trong Meta-Learning. Thay vì dừng lại ở việc nhận diện thông qua biến thiên độ chính xác, chúng tôi phát biểu negative transfer trong meta-learning như một bài toán diễn giải hậu nghiệm ở cấp độ đặc trưng cho *bản thân quá trình thích ứng nhanh (fast-adaptation)*. (Chương 3).

Thứ hai, đề tài đề xuất **độ lợi thích ứng** (ΔM), là một độ đo định lượng nhằm đánh giá tường minh mức độ lợi - hại mà quá trình thích ứng mang lại cho một tác vụ đích cụ thể. Nhằm tạo cơ sở để phát hiện và cô lập hiện tượng chuyển giao tiêu cực từ khía cạnh hiệu suất (Chương 3).

Thứ ba, đề tài giới thiệu Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA), là cơ chế diễn giải trực quan (visual explanation) có khả năng truy vết trên không gian đặc trưng chung F để chỉ ra các đặc trưng có lợi hay có hại cho quá trình thích ứng trong tập hỗ trợ. Từ đó hỗ trợ phát hiện và khắc phục được hiện tượng chuyển giao tiêu cực (negative transfer) bằng cách hiệu chỉnh các điểm dữ liệu trong tập hỗ trợ S để mô hình đạt được hiệu suất tốt nhất cho tác vụ đích. (Chương 3).

Thứ tư, đề tài hiệu chỉnh và đưa ra hai bài kiểm tra lần lượt là BiADT và sanity check tương ứng với bối cảnh thích ứng nhanh của các phương pháp dựa trên MAML nói riêng và các phương pháp Meta-Learning nói chung. Hai phương pháp này mang tính tổng quát và không phụ thuộc vào phương pháp FAMA và có thể áp dụng để kiểm định tính trung thực và khả năng tin cậy của bất kỳ phương pháp XAI nào khác được phát triển cho bài toán thích ứng nhanh trong Meta-Learning trong tương lai (Chương ??).

1.5 Bố cục luận văn

Phần còn lại của luận văn được tổ chức thành các chương như sau:

- **Chương 2 - Tổng quan nghiên cứu:** Trình bày các nền tảng lý thuyết về học ít mẫu (Few-shot Learning), Meta-Learning, tập trung vào cấu trúc tối ưu hóa hai tầng (bi-level) của MAML. Bên cạnh đó, các lý thuyết về hậu diễn giải (post-hoc explanation). Trên cơ sở đó, các công trình liên quan cũng sẽ được xem xét nhằm chỉ ra các hạn chế còn tồn đọng.
- **Chương 3 - Phương pháp đề xuất:** Phát biểu bài toán và trình bày chi tiết hai thành phần chính của cơ chế diễn giải. Bao gồm việc xây dựng **độ lợi thích ứng ΔM** và **phương pháp Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)**, các cơ sở lý thuyết và ý nghĩa của chúng.

- **Chương 4 - Thực nghiệm và đánh giá:** Mô tả thiết lập thực nghiệm trên các bộ dữ liệu chuẩn và các phương pháp đối chứng. Đồng thời, cũng trình bày kết quả phân tích định lượng lẫn định tính qua các bài kiểm định tính trung thực và độ tin cậy của FAMA.
- **Chương 5 - Kết luận và hướng phát triển:** Tổng kết các kết quả đạt được của luận văn, và thảo luận về những hạn chế hiện tại của phương pháp, và đề xuất các hướng phát triển tiềm năng trong tương lai.

Chương 2

Tổng quan nghiên cứu

2.1 Cơ sở lý thuyết

2.1.1 Bài toán học ít mẫu (Few-shot Learning) (FSL) và Meta-Learning

Bài toán học ít mẫu (Few-shot Learning) (FSL) khởi nguồn từ các công trình về one-shot learning dựa trên suy luận Bayesian, khai thác tri thức đã học từ các lớp đối tượng trước đó để nhận diện một lớp mới chỉ từ một hoặc vài mẫu quan sát [7]. Khái niệm này ra đời từ trước khi học sâu (Deep Learning) bùng nổ, nhưng đã trở nên đặc biệt cấp thiết trở lại trong kỷ nguyên deep learning và từ đó phát triển thành một nhánh nghiên cứu riêng với hàng loạt phương pháp dựa trên mạng nơ-ron sâu, tập trung xây dựng các mô hình có khả năng khái quát hóa mạnh mẽ trên các lớp hoặc tác vụ mới mà không cần thu thập lượng dữ liệu quy mô lớn [36].

Về mặt hình thức, FSL phổ biến nhất với bài toán N -way K -shot, nơi mô hình cần xử lý các tác vụ, phân biệt N lớp, với điều kiện mỗi lớp chỉ có K mẫu được gán nhãn. Để mô hình đạt được năng lực khái quát hoá này, quá trình huấn luyện được tổ chức theo cơ chế *episodic training* trên một tập hợp các tác vụ nền (base tasks) phong phú, gọi là giai đoạn *meta-training*. Hiệu suất của mô hình sau đó sẽ được kiểm chứng trên các tác vụ hoàn toàn mới, không trùng lặp với giai đoạn trước, giai đoạn này gọi là *meta-testing*. Mỗi tác vụ $\mathcal{T}_i$ trong cả hai giai đoạn đều được phân tách thành hai tập con biệt lập, gồm tập hỗ trợ (support set) $S_i = \{(x_k^S, y_k^S)\}_{k=1}^{NK}$, đóng vai trò như một "cuốn sách giáo khoa" chỉ với vài mẫu để mô hình được phép quan sát và thích ứng nhanh chóng, và tập truy vấn (query set) $Q_i = \{(x_k^Q, y_k^Q)\}_{k=1}^M$, dùng để đánh giá năng lực của mô hình sau thích ứng.

Dựa trên cách thức khai thác tri thức tiên nghiệm (prior knowledge), FSL thường được phân thành ba nhóm phương pháp chính [31], [36]: tăng cường dữ liệu (data augmentation/hallucination), học chuyển giao (transfer learning) và Meta-Learning. Trong đó, **Meta-Learning** hay còn gọi là "học cách học" tiếp cận bài toán bằng cách tối ưu hóa trên toàn bộ phân phối tác vụ $p(\mathcal{T})$ thay vì một tác vụ đơn lẻ. Mục tiêu của Meta-Learning là tìm kiếm một cơ chế thích ứng sao cho mô hình đạt được hiệu năng tối ưu trên tập truy vấn Q_i sau khi đã tiếp nhận tín hiệu từ tập hỗ trợ S_i của tác vụ $\mathcal{T}_i$ tương ứng.

Dựa trên thành phần được tối ưu ở cấp độ phân phối tác vụ, các phương pháp Meta-Learning được chia thành ba nhóm tiêu biểu [9].


Nhóm thứ nhất, là các phương pháp **Metric-based** học trên không gian nhúng (embedding space) sao cho khoảng cách giữa các mẫu trong cùng một lớp được tối thiểu, với tiêu biểu là Matching Networks [35] và Prototypical Networks [30]. **Nhóm thứ hai**, là các phương pháp **Model-based** sử dụng kiến trúc bộ nhớ ngoài hoặc siêu mạng (hyper-network) để trực tiếp sinh ra tham số cho tác vụ mới, mà tiêu biểu là Memory-Augmented Neural Networks [24]. **Cuối cùng**, là các phương pháp **Optimization-based** thực hiện việc thích ứng một cách tường minh qua các bước cập nhật gradient trên tập hỗ trợ S . Đây cũng là nhóm phương pháp có liên quan mật thiết nhất đến luận văn này, với đại diện tiêu biểu là MAML do C.Finn và các cộng sự đề xuất [8].

2.1.2 Model-Agnostic Meta-Learning (MAML)

Model-Agnostic Meta-Learning (MAML) [8] là đại diện tiêu biểu và có ảnh hưởng nhất trong nhóm các phương pháp dựa trên tối ưu hóa. Tiếp nối thành công của MAML nhiều biến thể đã được đề xuất nhằm tối ưu hóa quá trình học như Reptile [16] (một xấp xỉ bậc một của MAML), Meta-SGD [12] - tự động hóa việc học tốc độ học (learning rate) như một siêu tham số, ALFA [4] - học một cơ chế sinh siêu tham số thích ứng theo từng bước và từng tác vụ, Meta-Curvature [19] - học một ma trận tiền điều kiện (preconditioner) để định hình lại hình học của không gian tham số trong inner loop, iMAML [22] - sử dụng định lý hàm ẩn để tránh phải lan

truyền ngược qua toàn bộ quỹ đạo T bước của inner loop. Mà điểm chung của toàn bộ các phương pháp dựa trên tối ưu hoá này là chúng đều thừa nhận vai trò trung tâm của tập hỗ trợ S như một "lực định hướng" cho quá trình thích ứng thông qua quá trình tối ưu hai tầng (bi-level optimization) đối với bộ tham số khởi tạo chung (shared initialization parameters) θ_0 .

Cụ thể, để giải quyết bài toán học ít mẫu (Few-shot Learning), MAML dựa trên cảm hứng về cơ chế học tập của con người. Trong suốt cuộc đời, con người sử dụng tri thức tích lũy từ quá khứ để nắm bắt nhanh các cấu trúc đặc thù của một bài toán mới. Chẳng hạn, khi đối diện với các bài toán hình học lạ, con người tận dụng tri thức về số lượng cạnh, đỉnh hay tính chất bất biến của phép quay để truy xuất lời giải thay vì bắt đầu từ con số không (Hình 2.1).



Hình 2.1: Hình minh họa một bài toán nhận diện hình học.

Dựa trên cơ chế đó, MAML giải quyết bài toán học ít mẫu (Few-shot Learning) thông qua một quá trình tối ưu gồm hai tầng (Hình ??). Với tầng lặp trong (inner loop), mô hình học xuất phát từ tham số khởi tạo chung θ_0 thực hiện T bước cập nhật gradient trên hàm mất mát tính trên tập hỗ trợ S_i của tác vụ $\mathcal{T}_i$, theo phương trình 2.1.


$$\phi_j = \phi_{j-1} - \alpha \nabla_{\phi} \mathcal{L}_{S_i}(\phi_{j-1}), \quad j = 1, 2, \dots, T, \quad \phi_0 = \theta_0 \quad (2.1)$$

Trong đó α là tốc độ học của inner loop, và nghiệm sau T bước được ký

hiệu là $\phi_i^* := \phi_T$. Sau đó, ở tầng lặp ngoài (outer loop), tham số khởi tạo chung θ_0 sẽ được cập nhật theo phương trình 2.2 sao cho tổng (hoặc trung bình) giá hàm mất mát trên các tập truy vấn Q_i , tính tại nghiệm đã thích ứng ϕ_i^* , được tối thiểu hoá trên toàn bộ phân phối tác vụ.

$$[h]\theta = \theta_0 - \beta \nabla_{\theta} \sum_k \mathcal{L}_{Q_i}(\phi_i^*) \quad (2.2)$$

Trong đó, β là tốc độ học của outer loop, $\mathcal{L}_{Q_i}$ là hàm mất mát trên tập truy vấn Q_i với mô hình sau khi cập nhật bởi inner loop và $\sum_k$ là tổng hàm mất mát của tất cả các tác vụ trong một meta-batch.



Hình 2.2: Quá trình MAML tìm kiếm vị trí khởi tạo thuận lợi cho tham số θ_0 trong giai đoạn meta-training.

Để lý giải cơ thích ứng nhanh của MAML, Raghu và các cộng sự [21] đã thực hiện thí nghiệm đóng băng phần thân trích xuất đặc trưng (backbone) θ_0^b và chỉ cho phép phần đầu phân loại (head) θ_0^h cập nhật trong inner loop - thuật toán ANIL (Almost No Inner Loop). Bằng cách so sánh biểu diễn của backbone trước và sau thích ứng thông qua CCA và CKA, nhóm tác giả cho thấy các lớp tích chập gần như không dịch chuyển, trong khi chỉ riêng head thay đổi đáng kể. Từ đó, đi tới kết luận rằng hiệu quả của MAML chủ yếu đến từ việc θ_0 đã sẵn mang những đặc trưng tổng quát, có thể tái sử dụng nguyên trạng các đặc trưng này cho hầu hết tác vụ mới (feature reuse). Trạng thái này được khái quát hóa tại Hình 2.3 A, trong đó không gian biểu diễn sau thích ứng (ϕ_i^*) duy trì sự đồng nhất gần như tuyệt đối với không gian tiền nghiệm (θ_0). Cũng đồng nghĩa với việc vai


trò thực sự của S_i , trong trường hợp này, chỉ là căn chỉnh lại ranh giới quyết định ở phần đầu phân loại (head) cho phù hợp với từng tác vụ cụ thể.

Mặc dù vậy, giả thuyết về tính phổ quát của việc *tái sử dụng đặc trưng* (feature reuse) bộc lộ sự hạn chế khi đối mặt với sự dịch chuyển phân phối (distribution shift) lớn giữa miền dữ liệu huấn luyện (meta-training) và miền kiểm tra (meta-testing). Oh và các cộng sự [17] đã phản bác hệ quả của ANIL thông qua một can thiệp kiến trúc đối xứng mang tên BOIL (Body Only Inner Loop) — chỉ cập nhật θ_0^b và đóng băng θ_0^h . Kết quả là trên các môi trường có miền dữ liệu khác nhau (cross-domain), tri thức tiền nghiệm θ_0 không chứa sẵn các biểu diễn có lợi và phù hợp cho tác vụ đích buộc phải dưới áp lực của S_i dần bị thu hẹp và bị triệt tiêu tối đa, nhường chỗ cho sự dịch chuyển và hình thành các vùng biểu diễn hoàn toàn mới (Hình 2.3 B).

Từ sự đối lập của hai cơ chế trên, có thể thấy MAML tiêu chuẩn khi không bị ràng buộc bởi việc đóng băng trên toàn bộ mạng, đã cho phép nó hoạt động dựa trên một trạng thái linh hoạt điều chỉnh tỷ trọng giữa việc "tái sử dụng" và "tái cấu trúc". Lập luận này được củng cố bởi các thí nghiệm do Gou và các cộng sự thực hiện kiểm chứng trên các tập dữ liệu có sự khác biệt lớn, với kết luận tỷ trọng biến đổi của phần thân (backbone) tỷ lệ thuận với khoảng cách phân phối dữ liệu (domain shift). Hệ quả là, không gian biểu diễn chung F của MAML sau khi thích ứng trở thành một môi trường giao thoa phức hợp bao gồm ba miền, (1) miền kế thừa nguyên trạng từ θ_0 , (2) miền đặc trưng cũ bị bẻ cong/điều biến dưới áp lực của S_i , và (3) miền tiếp thu các cấu trúc hoàn toàn mới (Hình 2.3 C).

2.1.3 Explainable AI (XAI)

Mặc dù MAML và các biến thể đã chứng minh được hiệu quả trong việc cải thiện *phương thức* thích ứng, cơ chế vận hành của "lực định hướng" này tại cấp độ đặc trưng vẫn là một dạng "hộp đen". Các phương pháp hiện nay chưa cung cấp một lý giải tường minh cho câu hỏi: *Tại sao một tập hỗ trợ cụ thể lại điều hướng mô hình tới một hướng thích ứng nhất định?* Sự thiếu vắng này đặc biệt đáng chú ý tại không gian đặc trưng chung F . Dẫn



Hình 2.3: Minh họa sự thay đổi của không gian biểu diễn F sau thích ứng nhanh.

đến việc chúng ta không thể truy vết được nguồn gốc của các tương quan giả khi mô hình rơi vào trạng thái chuyển giao tiêu cực (negative transfer).

Explainable AI (XAI) là lĩnh vực nghiên cứu các phương pháp giúp con người hiểu được cơ chế ra quyết định của một mô hình học máy, ra đời như một phản ứng tất yếu trước sự phát triển của các mô hình học sâu. Trong khi các mô hình như hồi quy tuyến tính hay cây quyết định vốn có tính minh bạch nội tại (intrinsic model), cho phép truy vết trực tiếp đường đi từ đặc trưng đầu vào đến dự đoán đầu ra, thì các kiến trúc phức tạp hơn như mạng nơ-ron sâu lại đánh đổi tính minh bạch đó để lấy độ chính xác, trở thành những mô hình "hộp đen" mà cơ chế nội tại không thể quan sát trực tiếp.

Dựa trên thời điểm can thiệp vào mô hình, các kỹ thuật XAI được chia thành hai nhóm. *Ante-hoc*, với tính khả diễn giải được tích hợp ngay từ khi thiết kế kiến trúc mô hình (cây quyết định, cơ chế attention, Self-Explaining Neural Networks) và *post-hoc*, với các kỹ thuật diễn giải được áp dụng ngay sau khi mô hình đã huấn luyện xong, nhằm phân tích và diễn giải một mô hình đã có mà không cần huấn luyện lại. Do các phương pháp post-hoc không yêu cầu thay đổi kiến trúc hay quy trình huấn luyện gốc của mô hình, nên chúng có tính linh hoạt cao và có thể áp dụng cho các mô hình hộp đen phức tạp đã được huấn luyện. Theo Arrieta và các cộng sự [3], các kỹ thuật post-hoc thường dựa trên một trong ba cách tiếp

cận chính. Gồm, đơn giản hoá mô hình (model simplification, xây dựng một mô hình thay thế — surrogate — dễ diễn giải hơn để xấp xỉ hành vi cục bộ của mô hình hộp đen, như LIME), độ liên quan đặc trưng (feature relevance explanation, xếp hạng mức độ quan trọng của từng đặc trưng đầu vào đối với một dự đoán cụ thể, như SHAP) và cuối cùng là trực quan hoá (visual explanation, cho phép con người quan sát trực tiếp bằng hình ảnh cơ chế mà mô hình đưa ra quyết định).

Trong ba hướng trên, trực quan hoá cho phép con người dễ dàng diễn giải lựa chọn của mô hình thông qua hình ảnh trực quan thay vì các con số trừu tượng. Tiêu biểu đối với các mạng nơ-ron tích chập (CNN) dùng cho các bài toán thị giác máy tính, các kỹ thuật trực quan hoá mức độ đóng góp (attribution visualization) đã được phát triển nhằm định vị và làm nổi bật những vùng đầu vào chi phối mạnh nhất đến kết quả dự đoán của mô hình. Khởi nguồn cho hướng tiếp cận này là bản đồ nổi bật (saliency map) của Simonyan và các cộng sự [29], sử dụng đạo hàm điểm ảnh (vanilla gradient) ứng với một lớp mục tiêu để sinh ra bản đồ có cùng kích thước không gian với ảnh đầu vào, qua đó định lượng trực tiếp mức độ đóng góp của từng vị trí vào quyết định của mô hình. Kế thừa nền tảng này, Guided Backpropagation [32] sau đó đã điều chỉnh lại quy tắc lan truyền ngược qua hàm kích hoạt ReLU nhằm triệt tiêu các gradient âm, từ đó tạo ra bản đồ phân bố sắc nét hơn, dù vẫn bị giới hạn ở các điểm ảnh riêng lẻ. Nhằm dịch chuyển trọng tâm phân tích sang các vùng không gian ngữ nghĩa, Zhou và các cộng sự [39] đề xuất Class Activation Mapping (CAM) bằng cách chèn thêm lớp global average pooling vào cuối kiến trúc mạng. Tuy nhiên, đổi lại CAM đòi hỏi phải thay đổi kiến trúc gốc và huấn luyện lại mô hình. Để khắc phục điểm nghẽn này, Gradient-weighted Class Activation Mapping (Grad-CAM) [26] đã tổng quát hoá CAM, cho phép áp dụng hậu diễn giải (post-hoc) trên mọi mạng CNN mà không cần can thiệp kiến trúc. Bằng cách tận dụng gradient của lớp mục tiêu lan truyền ngược đến lớp tích chập cuối cùng, Grad-CAM đã tổng hợp thành một bản đồ nhiệt không gian, một đặc tính vô cùng giá trị khi làm việc với các mô hình đã huấn luyện sẵn. Mặc dù vậy, một điểm mù cố hữu của toàn bộ các biến thể CAM là việc trích xuất tín hiệu diễn giải luôn bị bó hẹp tại một *trạng thái tham số tĩnh* duy nhất, tức thời điểm suy luận sau khi mạng đã

hội tụ. Đặc tính tĩnh này khiến chúng trở nên bất lực khi phải giải phẫu hệ động lực học của quá trình thích ứng nhanh (fast adaptation), nơi không gian biểu diễn không đứng yên mà liên tục biến thiên qua từng bước cập nhật gradient.

2.1.4 Correctness và trustworthiness của một phương pháp XAI

Theo Hướng dẫn Đạo đức cho AI Đáng tin cậy (Ethics Guidelines for Trustworthy AI) của Nhóm chuyên gia cấp cao về AI thuộc Ủy ban Châu Âu (EC) [10], tính minh bạch (transparency), bao hàm khả năng diễn giải (explainability), là một trong bảy yêu cầu tiên quyết để kiến tạo một hệ thống AI đáng tin cậy (*trustworthy*). Dẫu vậy, cần phân định rạch ròi giữa hai cấp độ khái niệm: "đáng tin cậy" là thuộc tính vĩ mô của *toàn bộ hệ thống*, trong khi một phương pháp XAI, để đóng góp vào thuộc tính này, trước hết phải tự chứng minh được **tính đúng đắn** (*correctness*) nội tại. Cụ thể, điều này đòi hỏi mức độ trung thành (*faithfulness*) tuyệt đối của lời giải thích đối với cơ chế ra quyết định thực tế của mô hình, hoàn toàn độc lập với việc lời giải thích đó "nhìn có vẻ hợp lý" dưới lăng kính trực giác cảm quan của con người.

Để định lượng tính trung thành này, **nguyên lý thứ nhất** được thiết lập dựa trên kỹ thuật nhiễu loạn đặc trưng, nổi bật là phép kiểm định *xóa-và-đo* (deletion test) do Samek và các cộng sự [23] đặt nền móng. Với ý tưởng cốt lõi là nếu bản đồ phân bố định vị chuẩn xác các vùng đầu vào mang tính quyết định, thì việc tuần tự che khuất các vùng này (bằng nhiễu hoặc giá trị nền) theo thứ tự độ quan trọng giảm dần sẽ khiến hiệu năng dự đoán của mô hình suy sụp nhanh hơn đáng kể so với việc xóa ngẫu nhiên. Kế thừa tư tưởng này, Petsiuk và các cộng sự [20] đã tiêu chuẩn hóa thành hai độ đo nghịch đảo — *Xóa* (*Deletion*) và *Thêm* (*Insertion*) — cho phép đánh giá khách quan tính trung thành thông qua diện tích dưới đường cong (AUC) của biểu đồ hiệu năng, qua đó triệt tiêu hoàn toàn sự phụ thuộc vào sự phán xét chủ quan của mắt người.

Nguyên lý thứ hai, được biết đến qua các phép kiểm tra tính hợp lý (sanity checks) do Adebayo và các cộng sự [1] đề xuất, lại tập trung vào khả năng phản chiếu tri thức. Nguyên lý này lập luận, "một bản đồ

phân bố đích thực phải thể hiện sự *nhạy cảm* trước những biến động phá vỡ cấu trúc tri thức tiềm ẩn của mạng". Thông qua kỹ thuật ngẫu nhiên hóa tham số lan truyền ngược từ lớp đầu ra (*cascading randomization*), nhóm tác giả chỉ ra việc nếu bản đồ phân bố gần như bất biến dù trọng số mô hình đã bị phá hủy ngẫu nhiên, phương pháp XAI đó thực chất không trích xuất bất kỳ tri thức nào, mà chỉ đang hoạt động như một bộ dò biên cạnh (edge detector) vô tri. Nghiên cứu này đã phơi bày một lỗ hổng nghiêm trọng của nhiều phương pháp XAI phổ biến thời bấy giờ (như Guided Backpropagation) khi chúng hoàn toàn trơ lì trước các lớp trọng số bậc cao, một "tử huyệt" bị che đậy đằng sau hình thức trực quan bắt mắt.

Tuy nhiên, như đã phân tích trước đó, dù cả hai nguyên lý trên đều cung cấp một khung đánh giá vững chắc, nhưng cũng đều tồn tại một điểm mù cố hữu. Chúng được thiết kế độc quyền cho các kiến trúc mô hình *tĩnh*, nơi tín hiệu diễn giải được trích xuất từ một trạng thái tham số bất động tại một thời điểm suy luận duy nhất. Khi áp đặt vào hệ động lực học của quá trình thích ứng nhanh (fast-adaptation), nơi các bản đồ phân bố được trích xuất liên tục chạy dọc theo một quỹ đạo cập nhật gradient, tính hiệu lực của các nguyên lý này lập tức bị thách thức. Bài toán làm thế nào để định lượng tính trung thành của một diễn giải XAI không chỉ tại một tọa độ tĩnh, mà xuyên suốt *một chuỗi các biến thiên tham số liên tiếp*, hiện vẫn là một "vùng tối" chưa có lời giải trong cộng đồng nghiên cứu, đòi hỏi một nỗ lực tái định chuẩn và mở rộng hệ thống đo lường toàn diện.

2.2 Các nghiên cứu liên quan

Dựa trên nền tảng lý thuyết ở Mục 2.1, chúng tôi tiến hành rà soát bốn nhóm nghiên cứu liên quan trực tiếp đến đề tài. Gồm, các phương pháp hiện có giải quyết bài toán tác vụ không đồng nhất (heterogenous task) và hiện tượng Negative Transfer (Mục 2.2.1), các công cụ hiện có cho hậu diễn giải (post-hoc) tổng quát dựa trên gradient và nhiễu loạn (perturbation) (Mục 2.2.2), khảo sát các phương pháp diễn giải hiện đang áp dụng riêng cho meta-learning (Mục 2.2.3) và attribution dựa trên quỹ đạo tham số (Mục 2.2.4). Mục 2.2.5 tổng hợp lại toàn bộ và chỉ ra các khoảng trống

còn tồn tại.

2.2.1 Tác vụ không đồng nhất (heterogeneous task) và hiện tượng Negative Transfer

Phần lớn các phương pháp meta-learning giả định ngầm rằng tập hợp tác vụ dùng để meta-training tương đối đồng nhất (*homogeneous*), sao cho một điểm khởi tạo chung θ_0 duy nhất là đủ tốt cho mọi tác vụ [8], [24], [30], [35]. Một nhánh nghiên cứu song song đã chỉ ra giả định này thường bị vi phạm trong thực tế, khi các tác vụ đích đến từ phân phối tác vụ không đồng nhất (task heterogeneous) với phân phối tác vụ trong giai đoạn meta-training. Dẫn đến sự ra đời của các cơ chế tùy chỉnh (customize) tri thức tiên nghiệm theo từng cụm hoặc nhóm tác vụ thay vì chia sẻ toàn cục.

Yao và các cộng sự đã đề xuất Hierarchically Structured Meta-Learning (HSML) **yao2019hierarchically**, tổ chức các tác vụ thành một cấu trúc phân cụm phân cấp, qua đó đặc thù hóa tri thức chuyển giao cho từng nhóm tác vụ thay vì buộc mọi tác vụ chia sẻ một tri thức toàn cục, dựa trên cảm hứng từ cách con người tổ chức tri thức theo thứ bậc. Tiếp nối hướng đi này, nhóm tác giả tiếp tục phát triển Automated Relational Meta-Learning (ARML) **yao2020automated**, thay thế cho cấu trúc phân cụm thủ công bằng một siêu đồ thị tri thức (meta-knowledge graph) được xây dựng một cách tự động, cho phép mô hình hóa quan hệ giữa các tác vụ linh hoạt hơn. Theo đó, một hướng tiếp cận khác, HetMAML do Chen và các cộng sự **chen2021hetmaml** đã mở rộng bài toán tác vụ không đồng nhất sang không gian đặc trưng đầu vào (heterogeneous input/modality), làm rõ tính đa dạng của khái niệm "tác vụ không đồng nhất", từ sự không đồng nhất về phân phối ngữ nghĩa đến không đồng nhất về cấu trúc dữ liệu đầu vào.

Ở một góc nhìn khác, Yue và các cộng sự tập trung vào nguyên nhân nhân quả thay vì cấu trúc tác vụ, và đề xuất phương pháp Interventional Few-shot Learning (IFSL) [38] nhằm tạo ra sự can thiệp nhân quả để khắc phục hiện tượng chuyển giao tiêu cực (negative transfer). Đồng thời, lý giải hiện tượng này thông qua một mô hình cấu trúc nhân quả (Structural

Causal Model), trong đó tri thức tiền huấn luyện đóng vai trò như một biến gây nhiễu (confounder) và tạo ra các tương quan giả cho việc dự đoán nhân, khiến mô hình vô tình gây ra sai lệch. Song song đó, Deleu và Bengio **deleu2018negative** định nghĩa khái niệm *negative adaptation*: vì MAML chỉ tối thiểu hóa hàm mất mát trên tập truy vấn mà không có ràng buộc chặt chẽ, do đó tham số sau thích ứng có thể làm giảm hiệu năng so với trạng thái khởi tạo θ_0

Gần đây, Si và các cộng sự đề xuất phương pháp Heterogeneous Tasks Robust Meta-learning (HeTRoM) [28], nhằm giải quyết bài toán từ góc độ *độ khó không đồng đều* giữa các tác vụ. Thay vì gán trọng số bằng nhau cho toàn bộ các tác vụ trong giai đoạn meta-training như giả định của MAML, HeTRoM sử dụng mục tiêu học tập dựa trên xếp hạng (rank-based task-level learning objective) để ngăn các tác vụ "dễ" lấn át quá trình tối ưu. Đồng thời, Parast và các cộng sự cũng đề xuất Hard-Set-Guided Feature-Space Meta-Learning (HSFM) [18] nhằm can thiệp trực tiếp lên các biểu diễn, bằng cách trực tiếp thao tác trên các embedding của tập hỗ trợ trong không gian đặc trưng đã đóng băng (frozen backbone), lan truyền ngược qua các bước thích ứng của bộ phân loại để tinh chỉnh support embeddings, giúp mô hình hoạt động tốt hơn trước các tương quan giả.

Nhìn chung, các nghiên cứu giải quyết bài toán tác vụ không đồng nhất cho thấy một xu hướng nhất quán. Cộng đồng ngày càng thừa nhận tính không đồng nhất là nguyên nhân cốt lõi gây suy giảm hiệu năng thích ứng, và các giải pháp đang đi sâu vào can thiệp ở cấp độ biểu diễn (embeddings). Tuy nhiên, không một phương pháp nào trong chuỗi này hướng đến việc *diễn giải tương minh* cơ chế mà S_i đã định hướng sai ở đâu trong không gian đặc trưng chung. Tất cả các nghiên cứu hiện hành đều dừng lại ở mức phát hiện qua biểu hiện của các chỉ số (thường là độ chính xác suy giảm) hoặc sửa chữa qua tối ưu hóa lại biểu diễn, mà chưa cung cấp một bản đồ phân bổ (attribution) trực quan nào có thể chẩn đoán được nguyên nhân của sự chệch hướng trong quá trình thích ứng.

2.2.2 Các phương pháp giải thích hậu nghiệm dựa trên gradients và nhiễu loạn

Ngoài các kiến trúc diễn giải nội tại như Class Activation Mapping đã trình bày ở Mục 2.1.3, cộng đồng nghiên cứu XAI đã phát triển các phương pháp **hậu diễn giải** (*post-hoc*) tổng quát. Các kỹ thuật này không bị giới hạn bởi cấu trúc kiến trúc mạng cụ thể, cho phép phân tích hành vi của mô hình một cách linh hoạt hơn. Có thể chia các phương pháp này thành hai nhánh chính dựa trên cơ chế tác động.

Nhánh thứ nhất dựa trên phân tích gradient (đạo hàm) của đầu ra theo từng đặc trưng đầu vào. Integrated Gradients [33] tích phân gradient dọc theo đường thẳng nối giữa một điểm nền (*baseline*) và dữ liệu cần giải thích, thoả mãn các tiên đề về *Sensitivity* và *Implementation Invariance*. Trong khi đó, SmoothGrad **smilkov2017smoothgrad** khắc phục tình trạng nhiễu bằng cách lấy trung bình các bản đồ gradient được tính trên các biến thể của dữ liệu gốc đã bị thêm nhiễu ngẫu nhiên, dựa trên quan sát rằng gradient của các mô hình sâu thường dao động mạnh trong vùng lân cận nhỏ của đầu vào.

Nhánh thứ hai dựa trên kỹ thuật **nhiễu loạn** (*perturbation*), nơi tầm quan trọng của đặc trưng được suy luận qua sự biến thiên của đầu ra khi dữ liệu đầu vào bị thay đổi thông qua làm nhiễu hoặc xáo trộn. Local Interpretable Model-Agnostic Explanations (LIME) **ribeiro2016lime** xấp xỉ hành vi cục bộ của mô hình "hộp đen" bằng một mô hình tuyến tính đơn giản, huấn luyện trên tập các mẫu bị nhiễu loạn xung quanh điểm dữ liệu mục tiêu. Shapley Additive Explanations (SHAP) [14] định lượng đóng góp của đặc trưng dựa trên giá trị Shapley, đảm bảo tính công bằng (*efficiency, symmetry*) mà các phương pháp như LIME không đạt được. RISE [20] tạo bản đồ phân bố được trích xuất từ sự tương quan giữa các mặt nạ ngẫu nhiên che đi dữ liệu đầu vào và điểm số dự đoán tương ứng.

Tuy nhiên, điểm chung của toàn bộ các phương pháp kể trên là bất kể dựa trên gradient hay nhiễu loạn, chúng đều giải thích hành vi của mô hình dựa trên giả định về một *trạng thái tham số tĩnh*. Các phương pháp này được thiết kế để giải thích hành vi mô hình tại một thời điểm suy luận duy nhất, do đó hoàn toàn thiếu khả năng tích lũy hoặc tổng hợp thông

tin dọc theo một quỹ đạo biến thiên tham số. Đây chính là rào cản mang tính hệ thống khiến chúng không thể triển khai nhằm diễn giải cơ chế thích ứng nhanh của các phương pháp dựa trên gradient.

2.2.3 Các phương pháp XAI cho Meta-Learning và Few-Shot Learning

Mặc dù các nỗ lực giải quyết bài toán tác vụ không đồng nhất nói riêng và việc khai mở bản chất "hộp đen" của meta-learning nói chung đã đạt được những bước tiến nhất định, nhưng, nhìn chung việc xây dựng các khung diễn giải toàn diện và hệ thống vẫn còn nhiều hạn chế. Thực tế, các hướng nghiên cứu hiện nay vẫn tồn tại sự phân hóa rõ rệt, các nỗ lực diễn giải đang tập trung vào những hướng đi rất khác biệt thay vì hội tụ về một phương pháp chung. Cụ thể, có thể phân loại hai hướng tiếp cận tiêu biểu gần đây trong việc nỗ lực diễn giải cơ chế hoạt động của các mô hình meta-learning.

Hướng thứ nhất mở rộng *influence functions*, công cụ vốn được thiết kế để định lượng giá trị ảnh hưởng của một mẫu dữ liệu huấn luyện lên dự đoán của mô hình, sang cấu trúc phù hợp với bối cảnh meta-learning. Đại diện tiêu biểu là TLXML [15], phương pháp này định lượng mức độ ảnh hưởng của từng *tác vụ* trong giai đoạn meta-training lên hành vi thích ứng trên một tác vụ đích. Bằng cách sử dụng xấp xỉ Gauss-Newton cho Hessian, TLXML giải quyết được bài toán chi phí tính toán cao vốn là rào cản đặc thù của *influence functions* trong bối cảnh tối ưu hóa hai tầng. Tuy nhiên, phương pháp này vẫn coi thao tác thích ứng trên tập hỗ trợ (S_i) là một "hộp đen" ở cấp độ tác vụ, đồng thời đòi hỏi quyền truy cập vào toàn bộ dữ liệu đã huấn luyện trong quá trình meta-training, một điều kiện khó đáp ứng trong triển khai thực tế.

Hướng thứ hai tích hợp trực tiếp các kỹ thuật dựa trên CAM vào quy trình huấn luyện few-shot nhằm giám sát mô hình tập trung vào đặc trưng ngữ nghĩa thay vì tương quan giả. Một số framework như *expert-guided* cho ảnh y khoa [34] là đại diện sử dụng hướng đi này, bằng cách sử dụng Grad-CAM kết hợp với hàm mất mát căn chỉnh (alignment loss) giữa bản đồ nhiệt (heat map) và vùng chú thích đã được chuyên gia tạo

sẵn (ground-truth). Do đó, điểm hạn chế chung của các phương pháp này là bản đồ nhiệt chỉ được trích xuất tại thời điểm mô hình *đã thích ứng hoàn tất* ($f_{\phi_i^*}$) tức là chỉ diễn giải kết quả suy luận cuối cùng và chúng cần các vùng chú thích được tạo sẵn. Thành thử, các phương pháp này hoàn toàn bỏ qua việc giải thích bản chất của quá trình dịch chuyển tham số từ điểm khởi tạo θ_0 sang trạng thái thích ứng ϕ_i^* .

Tóm lại, cả hai hướng tiếp cận trên, dù có khác biệt về mặt kỹ thuật, nhưng đều bộc lộ giới hạn chung về mặt diễn giải. Với hướng thứ nhất bỏ qua cơ chế thích ứng nội tại ở cấp độ đặc trưng, trong khi hướng thứ hai xem nhẹ vai trò định hướng của tập hỗ trợ trong chính bước dịch chuyển không gian tham số.

2.2.4 Attribution dựa trên quỹ đạo huấn luyện

Khác với các tiến trình huấn luyện cố định, quá trình thích ứng nhanh (*fast adaptation*) trong meta-testing được đặc trưng bởi một chuỗi cập nhật tham số liên tiếp (như mô tả tại Phương trình 2.1). Đặc tính này đòi hỏi một cơ chế diễn giải mới cho các công cụ giải thích. Thay vì tìm kiếm nguyên nhân tại một trạng thái dừng (*static state*), ta cần một cơ chế có khả năng truy vết sự đóng góp của dữ liệu xuyên suốt toàn bộ **quỹ đạo biến thiên tham số** (*parameter trajectory*). Để xác lập cơ sở lý thuyết cho phương pháp đề xuất, chúng tôi sẽ hệ thống hóa các hướng nghiên cứu attribution hiện nay.

Influence Functions được Koh và các cộng sự [11] lần đầu đưa ra khái niệm xuất phát từ thống kê bền vững (robust statistics) áp dụng vào học máy, nhằm ước lượng ảnh hưởng của mẫu huấn luyện z_i lên loss tại mẫu kiểm thử z_{test} thông qua khai triển Taylor bậc nhất.

$$\mathcal{I}_{\text{up,loss}}(z_i, z_{\text{test}}) = -\nabla_{\theta} \mathcal{L}(z_{\text{test}}, \hat{\theta})^{\top} H_{\hat{\theta}}^{-1} \nabla_{\theta} \mathcal{L}(z_i, \hat{\theta}). \quad (2.3)$$

Phương pháp này chỉ quan sát *trạng thái hội tụ* $\hat{\theta}$, đòi hỏi mô hình khả vi bậc hai, lỗi chặt và chi phí tính toán nghịch đảo Hessian $O(np^2 + p^3)$ rất lớn.

Representer Point Selection được Yeh và cộng sự [37] giới thiệu dựa trên định lý representer cho tầng cuối của mạng nơ-ron. Với điều kiện

chính quy hoá L_2 trên trọng số Θ_1 của tầng cuối, giá trị tiền kích hoạt (pre-activation) tại một điểm kiểm thử x_t có thể được phân tích thành tổ hợp tuyến tính của các đặc trưng huấn luyện.

$$\Phi(x_t, \Theta^*) = \sum_{i=1}^n \alpha_i f_i^\top f_t, \quad \alpha_i = \frac{1}{-2\lambda n} \frac{\partial \mathcal{L}(x_i, y_i, \Theta)}{\partial \Phi(x_i, \Theta)}. \quad (2.4)$$

Phương pháp này tách biệt đóng góp *kích thích* ($\alpha_i > 0$) và *ức chế* ($\alpha_i < 0$), đồng thời hiệu quả hơn Influence Functions nhờ tránh được Hessian. Tuy nhiên, nó vẫn bị giới hạn tại *điểm dừng tĩnh* Θ^* và chỉ giải thích được logit dự đoán, không trực tiếp giải thích được loss.

TracIn (Attribution dựa trên quỹ đạo) được Pruthi và các cộng sự **pruthi2020estimating** đưa ra nhằm giải quyết các hạn chế của hai phương pháp trên. Đồng thời cũng là phương pháp duy nhất định lượng ảnh hưởng thông qua tích lũy gradient dọc theo quỹ đạo huấn luyện.

$$\mathcal{I}(z_i, z_{\text{test}}) = \sum_{e=1}^E \nabla_{\theta} \mathcal{L}(z_i, \theta_e) \cdot \nabla_{\theta} \mathcal{L}(z_{\text{test}}, \theta_e). \quad (2.5)$$

Trực giác cốt lõi của TracIn là xấp xỉ tổng mức giảm loss trên mẫu kiểm thử, tích lũy qua toàn bộ quá trình huấn luyện, mỗi khi mẫu huấn luyện z_i được sử dụng để cập nhật tham số. Về bản chất, đây là một phép tích lũy (aggregation) tín hiệu attribution qua *nhiều trạng thái tham số liên tiếp* $\{\theta_e\}_{e=1}^E$, thay vì chỉ tại một trạng thái duy nhất như hai phương pháp ở trên. Nhờ vậy, TracIn không đòi hỏi điều kiện hội tụ hay tối ưu bậc nhất, và có thể áp dụng cho bất kỳ mô hình nào huấn luyện bằng SGD hoặc biến thể của nó.

2.2.5 Tổng hợp và định vị nghiên cứu

Từ các cơ sở lý thuyết và phân tích ở trên, ta có thể nhận thấy ba khoảng trống nổi bật khi đối chiếu chúng với nhau. **Thứ nhất**, các phương pháp diễn giải cho meta-learning hiện có (TLXML, Grad-CAM-FSL) đều xử lý thao tác thích ứng ở một trong hai cách, hoặc là diễn giải hộp đen ở cấp tác vụ, hoặc là chỉ quan sát tại trạng thái cuối cùng và vẫn chưa tồn tại phương pháp nào tổng hợp các phân bổ (attribution) qua nhiều

trạng thái tham số của chính quá trình thích ứng nhanh (fast-adaptation). **Thứ hai**, toàn bộ các phương pháp giải quyết không đồng nhất/negative transfer (HSML, ARML, IFSL, HeTRoM, HSFM) đều dừng ở mức biểu hiện (đo bằng hiệu năng, như HSML/ARML/HeTRoM) hoặc sửa chữa (chỉnh sửa biểu diễn, như IFSL hoặc HSFM), trong đó HSFM là phương pháp duy nhất thao tác đa trạng thái trong không gian đặc trưng, nhưng mục tiêu của nó vẫn là sửa chữa để tăng hiệu năng, không phải sinh ra một attribution có thể diễn giải được cho con người. **Thứ ba**, các phương pháp giải thích dựa trên việc truy vết quỹ đạo như TracIn chứng minh nguyên lý tích lũy attribution qua nhiều trạng thái tham số là một hướng đi vững chắc về mặt toán học, nhưng chỉ được xây dựng cho bối cảnh huấn luyện dài hạn nhằm quy kết trách nhiệm cho từng mẫu dữ liệu huấn luyện, không phải cho bối cảnh thích ứng nhanh của meta-learning. **Cuối cùng**, chưa có phương pháp nào kết hợp đồng thời cả ba đặc điểm, diễn giải được cho con người, tổng hợp thông tin qua toàn bộ T bước của quá trình thích ứng thay vì một trạng thái đơn lẻ, và không đòi hỏi quyền truy cập vào tập dữ liệu meta-training.

Chương 3

Phương pháp đề xuất

3.1 Phát biểu bài toán

Như đã đề cập tại Mục 1.1 và được hệ thống hóa qua các phân tích ở Chương 2, việc trả lời hai câu hỏi nghiên cứu đặt ra ở Chương 1 đòi hỏi phải giải quyết đồng thời hai bài toán. Thứ nhất, xây dựng một độ đo định lượng có sự nhạy cảm với hiện tượng chuyển giao tiêu cực, và có thể cho thấy mức độ đóng góp tích cực hay tiêu cực của quá trình thích ứng của các tri thức tiền nghiệm ẩn trong tham số khởi tạo chung θ_0 trên tập hỗ trợ S_i . Thứ hai, dựa trên giá trị độ lợi chuyển giao, cần phải có một cơ chế hậu diễn giải có khả năng tổng hợp thông tin qua nhiều trạng thái tham số của quá trình thích ứng, điều mà chưa phương pháp nào hiện thời có thể đáp ứng cả ba tiêu chí đã nêu trong mục 2.2.5.

Trước khi xây dựng độ đo định lượng hay một cơ chế cụ thể, ta xét bài toán diễn giải trên một mô hình dựa trên MAML đã hoàn tất giai đoạn meta-training, với bộ tham số khởi tạo chung θ_0 có được từ việc tối ưu hai cấp (bi-level optimization) theo phương trình (2.2) và (2.1). Với một tác vụ đích $\mathcal{T}_i$ bất kỳ tại thời điểm meta-testing, bao gồm một tập hỗ trợ $S_i = \{(x_k^S, y_k^S)\}_{k=1}^{NK}$ và tập truy vấn $Q_i = \{(x_k^Q, y_k^Q)\}_{k=1}^M$, thì quá trình thích ứng nhanh sinh ra một quỹ đạo tham số gồm $T + 1$ trạng thái liên tiếp sau theo đúng quy tắc cập nhật inner-loop (2.1).

$$\phi_0 = \theta_0 \longrightarrow \phi_1 \longrightarrow \cdots \longrightarrow \phi_T = \phi_i^*, \quad (3.1)$$

Với F là không gian đặc trưng chung mà ϕ_i^* và θ_0 cùng chia sẻ sau quá trình thích ứng nhanh, ta có thể phân rã mỗi trạng thái tham số ϕ_j trong quỹ đạo (3.1) thành hai thành phần chức năng $\phi_j = (\phi_j^b, \phi_j^h)$, tương ứng với phần thân trích xuất đặc trưng (backbone) ϕ_j^b và phần đầu phân lớp (head) ϕ_j^h , kế thừa theo đúng cách phân tách đã được Raghu và các cộng

sự [21] cũng như Oh và các cộng sự [17] sử dụng. Theo đó, hàm trích xuất đặc trưng $f_{\phi_j^b} : \mathcal{X} \rightarrow F$ ánh xạ một mẫu đầu vào x về không gian đặc trưng chung F , trong khi hàm phân lớp $g_{\phi_j^b} : F \rightarrow \mathcal{Y}$ đưa ra quyết định cuối cùng dựa trên biểu diễn đã được trích xuất, sao cho $h_{\phi_j}(x) = g_{\phi_j^b} \circ f_{\phi_j^b}(x)$. Đặc biệt, tại trạng thái khởi đầu $\phi_0 = \theta_0$, không gian F chính là không gian đặc trưng tiền nghiệm được hình thành từ giai đoạn meta-training; còn tại trạng thái cuối $\phi_T = \phi_i^*$, cùng một không gian F này đã ít nhiều bị điều biến bởi T bước cập nhật gradient chịu tác động trực tiếp từ tập hỗ trợ S_i . Chính vì ϕ_i^* và θ_0 cùng chia sẻ trên một không gian F duy nhất, mọi sự dịch chuyển giữa hai trạng thái này, dù là tái sử dụng đặc trưng (feature reuse) hay tái cấu trúc biểu diễn (representation change), đều có thể được quan sát và đối chiếu trực tiếp mà không cần một phép biến đổi trung gian nào khác.

Dựa trên sự phân rã này, bài toán diễn giải mà chúng tôi đặt ra không nhằm vào một trạng thái tham số đơn lẻ, như cách các phương pháp Grad-CAM cục bộ [26], [34] chỉ trích xuất tại ϕ_T , mà mục tiêu chính là **sự đóng góp thực sự của việc thích ứng phần thân trích xuất đặc trưng (backbone)** vào hiệu năng trên tác vụ đích. Để cô lập đóng góp này, bên cạnh quỹ đạo thích ứng đầy đủ (full adaptation) (3.1), ta xét thêm một quỹ đạo can thiệp (intervention) $\{\phi_0^f, \phi_1^f, \dots, \phi_T^f\}$, được sinh ra bằng cách chủ động đóng băng phần thân tại θ_0^b trong suốt T bước, chỉ cho phép phần đầu phân lớp cập nhật theo quy tắc inner-loop (2.1), tức $\phi_j^f = (\theta_0^b, \phi_j^{f,h})$ với mọi $j = 0, \dots, T$. Việc can thiệp này chính là sự hiện thực hóa giả thuyết *tái sử dụng đặc trưng* (feature reuse) của Raghu và các cộng sự [21], đóng vai trò như một đường cơ sở (baseline) phản ánh phần hiệu năng mà mô hình đạt được *mà không cần* backbone rời khỏi θ_0^b . Trong khi đó, quỹ đạo đầy đủ $\{\phi_0, \dots, \phi_T\}$, nơi cả backbone lẫn head cùng thích ứng tự do, phản ánh khả năng *tái cấu trúc biểu diễn* (representation change) như quan sát của Oh và các cộng sự [17].

Cụ thể hơn, với $h(\phi, Q_i)$ là hành vi dự đoán của mô hình trên tập truy vấn Q_i khi được tham số hóa bởi ϕ , hai câu hỏi nghiên cứu đặt ra ở Mục 1.1 có thể được thu gọn về hai bài toán con có quan hệ nhân quả với nhau. Bài toán con thứ nhất đòi hỏi định lượng khoảng cách hiệu năng giữa $h(\phi_T^f, Q_i)$ (nhánh can thiệp, backbone đóng băng) và $h(\phi_T, Q_i) = h(\phi_i^*, Q_i)$

(nhánh thích ứng toàn bộ, không can thiệp) theo một cách nhạy cảm với S_i , thay vì chỉ dừng ở độ chính xác thô trên từng nhánh riêng lẻ. Nói cách khác, đại lượng cần đo không phải là hiệu năng tuyệt đối sau thích ứng, mà là *phần chênh lệch do chính backbone rời khỏi θ_0^b mang lại*: nếu $h(\phi_T, Q_i) \approx h(\phi_T^f, Q_i)$, việc thích ứng backbone gần như không tạo thêm giá trị so với khi bị can thiệp đóng băng; nếu $h(\phi_T, Q_i)$ vượt trội hơn $h(\phi_T^f, Q_i)$, sự tái cấu trúc biểu diễn mang lại chuyển giao tích cực; ngược lại, nếu $h(\phi_T, Q_i)$ kém hơn $h(\phi_T^f, Q_i)$, chính việc thích ứng backbone dưới áp lực của S_i là nguyên nhân gây ra chuyển giao tiêu cực. Bài toán con thứ hai, với giả thiết rằng độ lợi đo được ở bài toán con thứ nhất là một đại lượng có thể quy kết được, đòi hỏi truy vết ngược đại lượng đó về từng mẫu $(x_k^S, y_k^S) \in S_i$ và định vị chúng trên không gian đặc trưng F tại từng trạng thái ϕ_j của quỹ đạo, chứ không chỉ tại ϕ_T .

Việc phát biểu bài toán theo hướng này cho phép chúng tôi tránh được hạn chế cố hữu của các phương pháp diễn giải tĩnh (Mục 2.2.2) vốn chỉ quan sát một lát cắt duy nhất của mô hình, đồng thời không đòi hỏi quyền truy cập vào dữ liệu meta-training như TL-XML [15], do toàn bộ thông tin cần thiết, gồm cặp quỹ đạo $\{\phi_0, \dots, \phi_T\}$ và $\{\phi_0^f, \dots, \phi_T^f\}$, tập hỗ trợ S_i và tập truy vấn Q_i , đều đã sẵn có ngay tại thời điểm meta-testing. Trên cơ sở phát biểu bài toán này, Mục 3.2 tiếp theo sẽ trình bày chi tiết cách xây dựng độ lợi thích ứng ΔM nhằm giải quyết bài toán con thứ nhất, trước khi Mục 3.3 trình bày cơ chế FAMA nhằm giải quyết bài toán con thứ hai.

3.2 Độ lợi thích ứng

Như đã trình bày ở Mục 3.1, bài toán con thứ nhất đòi hỏi một đại lượng có khả năng định lượng phần chênh lệch hiệu năng sinh ra bởi chính việc backbone rời khỏi θ_0^b , thay vì đo hiệu năng tuyệt đối trên từng nhánh riêng lẻ. Để đại lượng này phục vụ được cả hai mục tiêu nghiên cứu đã nêu, chúng tôi đặt ra ba tiêu chí thiết kế bắt buộc.

Thứ nhất, tính khả vi (differentiability). Vì FAMA (Mục 3.3) cần truy vết ngược đóng góp của đại lượng này về từng mẫu trong S_i thông qua lan truyền ngược qua quỹ đạo thích ứng, độ đo không thể là một đại lượng rời rạc như accuracy, mà phải liên tục và khả vi theo ϕ .

Thứ hai, tính nhạy cảm với chuyển giao tiêu cực (sensitivity to negative transfer). Độ đo phải phản ánh được *chiều hướng* của đóng góp, tức phân biệt rõ ràng giữa trường hợp việc thích ứng backbone mang lại lợi ích (positive transfer), gây hại (negative transfer), hay không tạo thêm giá trị so với việc chỉ tái sử dụng đặc trưng sẵn có (feature reuse). Điều này loại trừ các độ đo chỉ đo độ lớn tuyệt đối của sự thay đổi (như khoảng cách biểu diễn CCA/CKA) mà không cho biết thay đổi đó tốt hay xấu cho tác vụ đích.

Thứ ba, tính tổng quát (generality). Độ đo không được ràng buộc vào một tác vụ $\mathcal{T}_i$, một kiến trúc, hay một tập dữ liệu cụ thể, mà phải được biểu diễn dưới dạng kỳ vọng trên toàn bộ phân phối tác vụ $p(\mathcal{T})$ tại thời điểm meta-testing, nhất quán với cách MAML được đánh giá (Phương trình (2.2)).

3.2.1 Định nghĩa

Dựa trên cơ sở của ba tiêu chí được đặt ra, với

$$\mathcal{L}(Q_i, \phi) := \frac{1}{M} \sum_{k=1}^M \ell(h_\phi(x_k^Q), y_k^Q) \quad (3.2)$$

là hàm mất mát trung bình (chẳng hạn như cross-entropy) được tính từ hành vi dự đoán $h(\phi, Q_i)$ đã định nghĩa ở Mục 3.1 đối chiếu với nhãn thật trên tập truy vấn, chúng tôi định nghĩa **độ lợi thích ứng** như sau.

$$\Delta M := \mathbb{E}_{Q_i \sim p(\mathcal{T})} \left[\mathcal{L}(Q_i, \phi_T^f) - \mathcal{L}(Q_i, \phi_T) \right], \quad (3.3)$$

trong đó $\phi_T = \phi_i^*$ là trạng thái cuối của quỹ đạo thích ứng đầy đủ, còn $\phi_T^f = (\theta_0^b, \phi_T^{f,h})$ là trạng thái cuối của quỹ đạo can thiệp với backbone bị đóng băng tại θ_0^b , cả hai đều được sinh ra từ cùng một tập hỗ trợ S_i theo quy tắc inner-loop (2.1).

Định nghĩa (3.3) ngầm giả định rằng toàn bộ chênh lệch $L(Q_i, \phi_T^f) - L(Q_i, \phi_T)$ đến từ việc backbone dịch chuyển khỏi θ_0^b . Tuy nhiên, vì head ở hai nhánh cũng được cập nhật trên các quỹ đạo khác nhau (ϕ_j^h so với $\phi_j^{f,h}$), một câu hỏi cần được trả lời trước khi diễn giải ΔM : *liệu phần chênh lệch*

do bản thân head thích ứng khác nhau giữa hai nhánh có làm nhiễu tín hiệu backbone hay không? Bằng khai triển Taylor bậc hai của $L(Q_i, \cdot)$ quanh θ_0 (chi tiết tại Phụ lục A), ΔM có thể được phân rã thành

$$\begin{aligned} \Delta M = & - \underbrace{\left[g_b^\top \Delta b_T + \frac{1}{2} \Delta b_T^\top H_{bb} \Delta b_T + \Delta b_T^\top H_{bh} \Delta h_T \right]}_{C_b - \text{đóng góp thuần của backbone}} \\ & + \underbrace{\left[g_h^\top (\Delta h_T^f - \Delta h_T) + \frac{1}{2} (\Delta h_T^f{}^\top H_{hh} \Delta h_T^f - \Delta h_T^\top H_{hh} \Delta h_T) \right]}_{R_h - \text{dư sai lệch từ head}}, \end{aligned} \quad (3.4)$$

với g_b, g_h và H_{bb}, H_{bh}, H_{hh} lần lượt là gradient và các khối Hessian của $L(Q_i, \cdot)$ tại θ_0 , còn $\Delta b_T, \Delta h_T, \Delta h_T^f$ là độ dịch chuyển tích lũy sau T bước của mỗi nhánh. Số hạng R_h chỉ triệt tiêu tuyệt đối khi $\Delta h_T = \Delta h_T^f$, tức khi hai nhánh cho ra cùng một quỹ đạo head — điều chỉ đúng chính xác khi $T = 1$ (hai nhánh khởi đầu từ cùng θ_0 nên bước gradient head đầu tiên trùng nhau). Với $T > 1$, hai nhánh dần tách khỏi nhau do backbone chỉ dịch chuyển ở nhánh đầy đủ, kéo theo $\Delta h_T \neq \Delta h_T^f$ và $R_h \neq 0$.

Giả định 1 (Chế độ thích ứng nhanh) Quá trình thích ứng nhanh của MAML vận hành với số bước T nhỏ và tốc độ học α nhỏ, sao cho $T\alpha \ll 1$. Đây không phải một điều kiện ngoại lai, mà chính là tiền đề cấu thành nên khái niệm fast-adaptation của MAML [8]: khác với huấn luyện tiêu chuẩn chạy hàng nghìn bước gradient, MAML được thiết kế để hội tụ tại meta-testing chỉ sau một vài bước cập nhật trên tập hỗ trợ nhỏ S_i .

Mệnh đề 1 (Tính chủ đạo của đóng góp backbone) Dưới Giả thuyết 1, $C_b = O(T\alpha)$ trong khi $R_h = O((T\alpha)^2)$. Do đó,

$$\Delta M = -C_b + O((T\alpha)^2), \quad (3.5)$$

tức trong chế độ thích ứng nhanh, ΔM xấp xỉ tuyến tính đóng góp thuần của backbone, còn phần dư do head bị lệch quỹ đạo là vô cùng bé bậc cao và không làm sai lệch chiều hướng (dấu) của ΔM .

Chúng minh chi tiết của Mệnh đề 1, bao gồm khai triển Taylor đầy đủ,

trường hợp $T = 1$ (đẳng thức chính xác $R_h = 0$), và lập luận quy nạp cho $T > 1$ dẫn tới cận $R_h = O((T\alpha)^2)$, được trình bày tại Phụ lục A.

Nhờ Mệnh đề 1, dấu và độ lớn của ΔM có thể được diễn giải trực tiếp qua C_b — đại lượng chỉ phụ thuộc vào độ dịch chuyển của backbone. Nếu $\Delta M > 0$ (tương đương $C_b < 0$), việc để backbone thích ứng tự do giúp giảm mất mát trên Q_i — quá trình tái cấu trúc biểu diễn (representation change) mang lại **chuyển giao tích cực**. Nếu $\Delta M < 0$ (tương đương $C_b > 0$), chính việc thích ứng backbone dưới áp lực của S_i làm tăng mất mát trên Q_i so với khi bị đóng băng — nguyên nhân trực tiếp của **chuyển giao tiêu cực**, dù θ_0^b vẫn đủ tốt nếu được giữ nguyên. Nếu $\Delta M \approx 0$ ($C_b \approx 0$), giả thuyết **tái sử dụng đặc trưng** (feature reuse) của Raghu và các cộng sự [21] là đủ để giải thích hiệu năng đạt được.

Trong thực nghiệm, kỳ vọng $\mathbb{E}_{Q_i \sim p(\mathcal{T})}[\cdot]$ ở Phương trình (3.3) được xấp xỉ Monte Carlo bằng trung bình ΔM trên một tập hợp lớn tác vụ lấy mẫu từ $p(\mathcal{T})$ tại thời điểm meta-testing, theo đúng giao thức đánh giá chuẩn của MAML.

3.3 Phương pháp Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)

Mục này xây dựng lời giải cho bài toán con thứ hai đã phát biểu ở công thức (??): lan truyền ngược Δ — đại lượng đã xây dựng ở Mục 3.2 — qua toàn bộ quỹ đạo thích ứng (3.1) để quy về từng vị trí không gian trong biểu diễn đặc trưng f_k của từng mẫu hỗ trợ. Phần 3.3.1 trình bày ý tưởng cốt lõi; Phần 3.3.2 xây dựng trạng thái đối ngẫu (adjoint state) và phép đệ quy ngược qua quỹ đạo; Phần 3.3.3 chuyển đạo hàm từ không gian dữ liệu thô sang không gian đặc trưng F ; Phần 3.3.4 phát biểu định nghĩa chính thức; Phần 3.3.5 trình bày thuật toán và phân tích độ phức tạp.

3.3.1 Ý tưởng cốt lõi

Bài toán tính $\partial \Delta M / \partial S_i$ về bản chất là một bài toán đạo hàm qua một quá trình tối ưu hóa lồng (unrolled optimization), tương tự lớp bài toán

hypergradient đã được nghiên cứu trong các công trình về gradient bậc hai của MAML [finn2017maml](#) và iMAML [rajeswaran2019imaml](#): S_i không chỉ ảnh hưởng đến ΔM qua một đường duy nhất, mà ảnh hưởng tại *mọi* bước $j = 1, \dots, K$ của quỹ đạo (3.1), vì mỗi bước cập nhật inner-loop đều tính gradient của hàm mất mát trên chính S_i . Do đó, đạo hàm cần tìm là một *tổng* các đóng góp cục bộ tại từng bước, được kết nối với nhau qua một tín hiệu lan truyền ngược duy nhất — đây chính là cơ sở để FAMA thỏa mãn yêu cầu tổng hợp đa trạng thái đã đặt ra ở Mục ??, khác với Grad-CAM cục bộ [34] vốn chỉ sử dụng gradient tại $\theta_{i,K}$.

3.3.2 Trạng thái đối ngẫu và đệ quy ngược qua quỹ đạo

Định nghĩa trạng thái đối ngẫu. Với mỗi bước $j = 0, \dots, K$ trên quỹ đạo (3.1), định nghĩa trạng thái đối ngẫu

$$\lambda_{i,j} := \frac{d \mathbb{E}_Q[\mathcal{L}(Q, \theta_{i,K})]}{d \theta_{i,j}} \in \mathbb{R}^{|\theta|},$$

tức đạo hàm *toàn phần* của hàm mất mát tại trạng thái cuối theo trạng thái trung gian $\theta_{i,j}$, tính bằng cách lan truyền qua các bước $j + 1, \dots, K$ còn lại của quỹ đạo. Điều kiện biên tại $j = K$ chính là gradient meta-học tiêu chuẩn:

$$\lambda_{i,K} = \nabla_{\theta_{i,K}} \mathbb{E}_Q[\mathcal{L}(Q, \theta_{i,K})].$$

Đệ quy ngược. Từ quy tắc cập nhật inner-loop $\theta_{i,j} = \theta_{i,j-1} - \alpha \nabla_{\theta_{i,j-1}} \mathcal{L}_{S_i}(\theta_{i,j-1})$, đạo hàm Jacobian của bước cập nhật là

$$\frac{\partial \theta_{i,j}}{\partial \theta_{i,j-1}} = I - \alpha H_{i,j-1}, \quad H_{i,j-1} := \nabla_{\theta_{i,j-1}}^2 \mathcal{L}_{S_i}(\theta_{i,j-1}),$$

trong đó $H_{i,j-1}$ là ma trận Hessian của hàm mất mát trên S_i tại $\theta_{i,j-1}$. Áp dụng quy tắc dây chuyền vào (3.3.2), ta thu được phép đệ quy ngược (chạy từ $j = K$ về $j = 1$):

$$\lambda_{i,j-1} = \lambda_{i,j} (I - \alpha H_{i,j-1}) = \lambda_{i,j} - \alpha \lambda_{i,j} H_{i,j-1}.$$

Đây chính xác là phép đệ quy bạn đã suy ra; điểm cần chuẩn hóa là

chỉ số: $\lambda_{i,j}$ là đạo hàm *toàn phần* tại trạng thái j (đã "gộp" toàn bộ ảnh hưởng của các bước sau nó), trong khi phần đóng góp trực tiếp của S_i tại từng bước — trình bày ngay sau đây — chỉ là đạo hàm *riêng* (cục bộ). Sự phân biệt này giải quyết đúng điểm bạn còn phân vân.

Tránh tính Hessian tường minh. Vì $H_{i,j-1}$ có kích thước $|\theta| \times |\theta|$, việc lưu tường minh là không khả thi. Tuy nhiên tích $\lambda_{i,j}H_{i,j-1}$ (một vector-Hessian product) có thể tính hiệu quả bằng đẳng thức đạo hàm kép chuẩn trong tối ưu hóa lồi:

$$\lambda_{i,j}H_{i,j-1} = \lambda_{i,j} \nabla_{\theta_{i,j-1}}^2 \mathcal{L}_{S_i}(\theta_{i,j-1}) = \nabla_{\theta_{i,j-1}} \left(\lambda_{i,j}^\top \nabla_{\theta_{i,j-1}} \mathcal{L}_{S_i}(\theta_{i,j-1}) \right),$$

tức: tính đại lượng vô hướng $s_j := \lambda_{i,j}^\top \nabla_{\theta_{i,j-1}} \mathcal{L}_{S_i}(\theta_{i,j-1})$ bằng một lượt lan truyền xuôi–ngược thông thường, sau đó lấy đạo hàm của s_j theo $\theta_{i,j-1}$ bằng một lượt lan truyền ngược thứ hai (double backward). Đây đúng là cơ chế mà MAML bậc hai và iMAML [rajeswaran2019imaml](#) đã dùng để tính meta-gradient — FAMA không cần thêm cơ chế đạo hàm mới, chỉ tái sử dụng đúng phép tính này.

3.3.3 Từ đạo hàm theo S_i sang bản đồ phân bố trên F

Tổng hợp đạo hàm theo S_i qua các bước. Vì θ_0 không phụ thuộc S_i (Mục ??), $\partial \Delta M / \partial S_i = -\partial \mathbb{E}_Q[\mathcal{L}(Q, \theta_{i,K})] / \partial S_i$. Do S_i xuất hiện tường minh tại ****mọi**** bước cập nhật, đạo hàm toàn phần này phân rã thành tổng các đóng góp cục bộ tại từng bước, mỗi đóng góp được "cân" bởi trạng thái đối ngẫu $\lambda_{i,j}$ tương ứng:

$$\frac{\partial \Delta M}{\partial S_i} = - \sum_{j=1}^K \lambda_{i,j} \cdot \left(\frac{\partial \theta_{i,j}}{\partial S_i} \right)_{\text{trực tiếp}},$$

trong đó ký hiệu "trực tiếp" nhấn mạnh đây là đạo hàm *riêng* của phương trình cập nhật tại bước j theo S_i , giữ $\theta_{i,j-1}$ cố định — phần ảnh hưởng gián tiếp qua các bước trước đã được $\lambda_{i,j}$ gộp sẵn thông qua đệ quy (3.3.2). Đây chính là cách giải quyết điểm mơ hồ toàn phần/riêng: **mỗi số hạng trong tổng là đạo hàm riêng, còn bản thân tổng là**

đạo hàm toàn phần.

Từ $\theta_{i,j} = \theta_{i,j-1} - \alpha \nabla_{\theta_{i,j-1}} \mathcal{L}_{S_i}(\theta_{i,j-1})$:

$$\left(\frac{\partial \theta_{i,j}}{\partial S_i} \right)_{\text{trực tiếp}} = -\alpha \nabla_{\theta_{i,j-1}, S_i}^2 \mathcal{L}_{S_i}(\theta_{i,j-1}),$$

thay vào (3.3.3), hai đầu trừ triệt tiêu:

$$\frac{\partial \Delta M}{\partial S_i} = \alpha \sum_{j=1}^K \lambda_{i,j} \nabla_{\theta_{i,j-1}, S_i}^2 \mathcal{L}_{S_i}(\theta_{i,j-1}).$$

Chuyển sang không gian đặc trưng F . Trực tiếp lấy $\partial \Delta M / \partial S_i$ cho một bản đồ trên không gian ảnh thô (pixel), không phải trên F như yêu cầu ở (??). Theo giả thuyết feature reuse [21] đã dùng làm nền tảng ở Mục 3.1, backbone Φ gần như không đổi qua các bước j , nên có thể tách hàm mất mát trên mẫu k thành một hàm của biểu diễn đặc trưng $f_k = \Phi(x_k^S)$ thay vì của x_k^S trực tiếp:

$$\mathcal{L}_{S_i}(\theta_{i,j-1}) = \frac{1}{NK} \sum_{k=1}^{NK} \ell(y_k^S, f_{\theta_{i,j-1}}(x_k^S)) \approx \frac{1}{NK} \sum_{k=1}^{NK} \ell_k(\theta_{i,j-1}; f_k),$$

với $\ell_k(\cdot; f_k)$ là hàm mất mát của mẫu k xem như hàm của phần đầu phân loại (head) tại đầu vào f_k cố định. Thay S_i bằng f_k trong (3.3.3) và áp dụng đẳng thức đạo hàm kép (3.3.2) (nay lấy đạo hàm theo f_k thay vì $\theta_{i,j-1}$), ta thu được **tensor gradient tích lũy** cho từng mẫu hỗ trợ k :

$$g_k := \frac{\partial \Delta M}{\partial f_k} = \alpha \sum_{j=1}^K \nabla_{f_k} \left(\lambda_{i,j}^\top \nabla_{\theta_{i,j-1}} \ell_k(\theta_{i,j-1}; f_k) \right) \in \mathbb{R}^{C \times H \times W}.$$

Mỗi số hạng trong tổng chỉ cần một cặp lượt lan truyền xuôi–ngược, tái sử dụng đúng cơ chế đạo hàm kép đã dùng cho $\lambda_{i,j}$ — không cần thêm giả định hay cơ chế mới.

3.3.4 Định nghĩa chính thức FAMA

Từ g_k tính theo (3.3.3), FAMA quy về bản đồ phân bố $a_k \in \mathbb{R}^{H \times W}$ theo đúng dạng thức (??) bằng phép rút gọn theo kênh kiểu Grad-CAM: trọng số mỗi kênh c được lấy bằng trung bình không gian của g_k ,

$$w_k^c = \frac{1}{HW} \sum_{h=1}^H \sum_{w=1}^W g_k[c, h, w],$$

và bản đồ phân bố cuối cùng là tổ hợp tuyến tính có trọng số của các kênh đặc trưng thực tế:

$$a_k[h, w] = \sum_{c=1}^C w_k^c \cdot f_k[c, h, w]$$

Khác biệt có chủ đích so với Grad-CAM gốc. Grad-CAM nguyên bản áp dụng $\text{ReLU}(\cdot)$ sau bước tổ hợp tuyến tính, vì mục tiêu của nó là chỉ giữ lại bằng chứng *ứng hộ* một lớp cụ thể. FAMA không áp dụng ReLU : vì mục tiêu của FAMA — theo đúng phát biểu ở (??) và câu hỏi nghiên cứu thứ hai — là xác định *cả* vùng đặc trưng góp phần tích cực ($a_k[h, w] > 0$, tương thích với chiều dương của ΔM) lẫn vùng gây hại ($a_k[h, w] < 0$, nguyên nhân của negative transfer). Cắt bỏ phần âm bằng ReLU sẽ xóa đi chính thông tin cần thiết để trả lời câu hỏi nghiên cứu thứ hai — đây là điều chỉnh có chủ đích, không phải sai sót khi so với các phương pháp CAM nền tảng đã điểm ở Mục ??.

Kiểm tra lại hai yêu cầu đặt ra ở Mục ??. (i) *Tổng hợp đa trạng thái*: a_k được tính từ tổng theo $j = 1, \dots, K$ trong (3.3.3), sử dụng gradient tại toàn bộ K bước, không chỉ tại $\theta_{i,K}$. (ii) *Không cần dữ liệu meta-training*: toàn bộ phép tính từ (3.3.2) đến (3.3.4) chỉ dùng θ_0 (để khởi tạo quỹ đạo), S_i (sinh quỹ đạo và các $H_{i,j}$), và Q_i (để tính $\lambda_{i,K}$) — không truy cập tập dữ liệu đã dùng ở giai đoạn meta-training, khắc phục đúng hạn chế đã nêu đối với TLXML [15].

3.3.5 Thuật toán và độ phức tạp

Độ phức tạp. Vòng lặp ngoài chạy K bước, mỗi bước cần một lượt lan truyền kép (double backward) cho λ_{j-1} và NK lượt double-backward tương ứng để cập nhật g_k — tổng chi phí là $O(K \cdot NK)$ lượt lan truyền ngược qua backbone. Về bản chất tính toán, chi phí cho phần λ_j trùng khớp hoàn toàn với chi phí tính meta-gradient bậc hai mà chính MAML đã thực hiện trong giai đoạn meta-training **finn2017maml** — FAMA không đưa vào cơ chế đạo hàm mới, chỉ mở rộng đúng phép tính đã tồn tại để tích lũy thêm tín hiệu g_k tại mỗi bước thay vì chỉ dùng nó để cập nhật θ_0 . Phần chi phí phụ trội duy nhất — hệ số NK — có thể tính song song theo batch vì mỗi g_k độc lập với nhau tại một bước j cố định.

3.4 Cơ sở đánh giá

Tài liệu tham khảo

Tiếng Anh

- [1] Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M., and Kim, B., “Sanity checks for saliency maps,” *Advances in neural information processing systems*, vol. 31, 2018.
- [2] Angwin, J., Larson, J., Mattu, S., and Kirchner, L., “Machine Bias,” *Propublica*, 2016. [Online]. Available: <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>.
- [3] Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., *et al.*, “Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai,” *Information fusion*, vol. 58, pp. 82–115, 2020.
- [4] Baik, S., Choi, M., Choi, J., Kim, H., and Lee, K. M., “Meta-learning with adaptive hyperparameters,” *Advances in neural information processing systems*, vol. 33, pp. 20 755–20 765, 2020.
- [5] Bengio, S., Bengio, Y., Cloutier, J., and Gecsei, J., “On the optimization of a synaptic learning rule,” in *Optimality in biological and artificial networks?* Routledge, 2013, pp. 265–287.
- [6] Fawakherji, M., Alaoui, S., and Turjya, S. M., “Learning to see with less: A survey on computer vision with limited and imperfect data,” *Archives of Computational Methods in Engineering*, pp. 1–37, 2026.
- [7] Fei-Fei, L., Fergus, R., and Perona, P., “One-shot learning of object categories,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 28, no. 4, pp. 594–611, 2006.

- [8] Finn, C., Abbeel, P., and Levine, S., “Model-agnostic meta-learning for fast adaptation of deep networks,” in *International conference on machine learning*, PMLR, 2017, pp. 1126–1135.
- [9] Gharoun, H., Momenifar, F., Chen, F., and Gandomi, A. H., “Meta-learning approaches for few-shot learning: A survey of recent advances,” *ACM Computing Surveys*, vol. 56, no. 12, pp. 1–41, 2024.
- [10] High-Level Expert Group on AI, “Ethics guidelines for trustworthy AI,” European Commission, Brussels, Report, Apr. 2019. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>.
- [11] Koh, P. W. and Liang, P., “Understanding black-box predictions via influence functions,” in *International conference on machine learning*, PMLR, 2017, pp. 1885–1894.
- [12] Li, Z., Zhou, F., Chen, F., and Li, H., “Meta-sgd: Learning to learn quickly for few-shot learning,” *arXiv preprint arXiv:1707.09835*, 2017.
- [13] Lum, K. and Isaac, W., “To predict and serve?” *Significance*, vol. 13, no. 5, pp. 14–19, 2016.
- [14] Lundberg, S. M. and Lee, S.-I., “A unified approach to interpreting model predictions,” *Advances in neural information processing systems*, vol. 30, 2017.
- [15] Mitsuka, Y., Golestan, S., Sufiyan, Z., Miwa, S., and Zaiane, O. R., “Tlxml: Task-level explanation of meta-learning via influence functions,” *arXiv preprint arXiv:2501.14271*, 2025.
- [16] Nichol, A., Achiam, J., and Schulman, J., “On first-order meta-learning algorithms,” *arXiv preprint arXiv:1803.02999*, 2018.
- [17] Oh, J., Yoo, H., Kim, C., and Yun, S.-Y., “Boil: Towards representation change for few-shot learning,” *arXiv preprint arXiv:2008.08882*, 2020.
- [18] Parast, A. Y., Islam, K., Won, S., Azam, B., and Akhtar, N., “Hsfm: Hard-set-guided feature-space meta-learning for robust classification under spurious correlations,” *arXiv preprint arXiv:2603.29313*, 2026.

- [19] Park, E. and Oliva, J. B., “Meta-curvature,” *Advances in neural information processing systems*, vol. 32, 2019.
- [20] Petsiuk, V., Das, A., and Saenko, K., “Rise: Randomized input sampling for explanation of black-box models,” *arXiv preprint arXiv:1806.07421*, 2018.
- [21] Raghu, A., Raghu, M., Bengio, S., and Vinyals, O., “Rapid learning or feature reuse? towards understanding the effectiveness of maml,” *arXiv preprint arXiv:1909.09157*, 2019.
- [22] Rajeswaran, A., Finn, C., Kakade, S. M., and Levine, S., “Meta-learning with implicit gradients,” *Advances in neural information processing systems*, vol. 32, 2019.
- [23] Samek, W., Binder, A., Montavon, G., Lapuschkin, S., and Müller, K.-R., “Evaluating the visualization of what a deep neural network has learned,” *IEEE transactions on neural networks and learning systems*, vol. 28, no. 11, pp. 2660–2673, 2016.
- [24] Santoro, A., Bartunov, S., Botvinick, M., Wierstra, D., and Lillicrap, T., “Meta-learning with memory-augmented neural networks,” in *International conference on machine learning*, PMLR, 2016, pp. 1842–1850.
- [25] Schmidhuber, J., “Evolutionary principles in self-referential learning, or on learning how to learn: The meta-meta-... hook,” Ph.D. dissertation, Technische Universität München, 1987.
- [26] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D., “Grad-cam: Visual explanations from deep networks via gradient-based localization,” *International journal of computer vision*, vol. 128, no. 2, pp. 336–359, 2020.
- [27] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D., “Grad-cam: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 618–626.

- [28] Si, Z., Hu, S., Ji, K., and Lyu, S., “Meta-learning with heterogeneous tasks,” in *International Joint Conference on Artificial Intelligence*, Springer, 2025, pp. 74–94.
- [29] Simonyan, K., Vedaldi, A., and Zisserman, A., “Visualising image classification models and saliency maps,” *Deep Inside Convolutional Networks*, vol. 2, no. 2, 2014.
- [30] Snell, J., Swersky, K., and Zemel, R., “Prototypical networks for few-shot learning,” *Advances in neural information processing systems*, vol. 30, 2017.
- [31] Song, Y., Wang, T., Cai, P., Mondal, S. K., and Sahoo, J. P., “A comprehensive survey of few-shot learning: Evolution, applications, challenges, and opportunities,” *ACM Computing Surveys*, vol. 55, no. 13s, pp. 1–40, 2023.
- [32] Springenberg, J. T., Dosovitskiy, A., Brox, T., and Riedmiller, M., “Striving for simplicity: The all convolutional net,” *arXiv preprint arXiv:1412.6806*, 2014.
- [33] Sundararajan, M., Taly, A., and Yan, Q., “Axiomatic attribution for deep networks,” in *International conference on machine learning*, PMLR, 2017, pp. 3319–3328.
- [34] Uddin, I. I., Wang, L., and Santosh, K., “Expert-guided explainable few-shot learning for medical image diagnosis,” in *MICCAI Workshop on Data Engineering in Medical Imaging*, Springer, 2025, pp. 95–104.
- [35] Vinyals, O., Blundell, C., Lillicrap, T., Wierstra, D., *et al.*, “Matching networks for one shot learning,” *Advances in neural information processing systems*, vol. 29, 2016.
- [36] Wang, Y., Yao, Q., Kwok, J. T., and Ni, L. M., “Generalizing from a few examples: A survey on few-shot learning,” *ACM computing surveys (csur)*, vol. 53, no. 3, pp. 1–34, 2020.
- [37] Yeh, C.-K., Kim, J., Yen, I. E.-H., and Ravikumar, P. K., “Representer point selection for explaining deep neural networks,” *Advances in neural information processing systems*, vol. 31, 2018.

- [38] Yue, Z., Zhang, H., Sun, Q., and Hua, X.-S., “Interventional few-shot learning,” *Advances in neural information processing systems*, vol. 33, pp. 2734–2746, 2020.
- [39] Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., and Torralba, A., “Learning deep features for discriminative localization,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 2921–2929.

Chương A

Chứng minh Mệnh đề 1

A.1 Khai triển Taylor

Khai triển $L(Q_i, \cdot)$ bậc hai quanh $\theta_0 = (b_0, h_0)$:

$$\begin{aligned} L(Q_i, \phi_T) &\approx L(Q_i, \theta_0) + g_b^\top \Delta b_T + g_h^\top \Delta h_T \\ &\quad + \frac{1}{2} \Delta b_T^\top H_{bb} \Delta b_T + \frac{1}{2} \Delta h_T^\top H_{hh} \Delta h_T + \Delta b_T^\top H_{bh} \Delta h_T, \end{aligned} \quad (\text{A.1})$$

$$L(Q_i, \phi_T^f) \approx L(Q_i, \theta_0) + g_h^\top \Delta h_T^f + \frac{1}{2} \Delta h_T^{f\top} H_{hh} \Delta h_T^f, \quad (\text{A.2})$$

với $\Delta b_T = \phi_T^b - b_0$, $\Delta h_T = \phi_T^h - h_0$, $\Delta h_T^f = \phi_T^{f,h} - h_0$ (nhánh can thiệp có $\Delta b = 0$). Lấy (A.2) trừ (A.1) và nhóm số hạng, ta thu được đúng Phương trình (3.4).

A.1.1 Trường hợp $T = 1$: $R_h = 0$ chính xác

Cả hai nhánh xuất phát từ $\phi_0 = \phi_0^f = \theta_0$. Theo quy tắc inner-loop (2.1),

$$\Delta h_1 = \alpha \nabla_h \mathcal{L}_{S_i}(b_0, h_0) = \Delta h_1^f,$$

vì cả hai đều tính gradient trên S_i tại đúng cùng điểm (b_0, h_0) . Do đó $\Delta h_T - \Delta h_T^f = 0$ tại $T = 1$, kéo theo $R_h \equiv 0$ và $\Delta M = -C_b$ **đúng tuyệt đối**, không cần xấp xỉ.

A.1.2 Trường hợp $T > 1$: cận $R_h = O((T\alpha)^2)$

Đặt $\delta_j := \Delta h_j - \Delta h_j^f$ ($\delta_0 = 0$). Từ quy tắc inner-loop áp dụng riêng cho từng nhánh,

$$\delta_j = \delta_{j-1} - \alpha \left[\nabla_h \mathcal{L}_{S_i}(b_0 + \Delta b_{j-1}, h_0 + \Delta h_{j-1}) - \nabla_h \mathcal{L}_{S_i}(b_0, h_0 + \Delta h_{j-1}^f) \right].$$

Khai triển gradient bậc nhất quanh $(b_0, h_0 + \Delta h_{j-1}^f)$ và ký hiệu H_{bh}^S, H_{hh}^S là các khối Hessian của $\mathcal{L}_{S_i}$ tại điểm này,

$$\delta_j \approx (I - \alpha H_{hh}^S) \delta_{j-1} - \alpha H_{bh}^S \Delta b_{j-1}.$$

Đây là một hệ đệ quy tuyến tính với $\delta_0 = 0$, được điều khiển bởi Δb_{j-1} . Vì backbone chỉ tích lũy ở nhánh đầy đủ theo quy tắc tương tự, $\|\Delta b_j\| = O(j\alpha)$. Giải đệ quy trên (xem là tổng chập/telescoping của các số hạng điều khiển), ta có

$$\|\delta_T\| = O\left(\alpha \|H_{bh}^S\| \sum_{j=0}^{T-1} \|\Delta b_j\|\right) = O(\alpha \|H_{bh}^S\| \cdot T \cdot T\alpha) = O((T\alpha)^2).$$

Vì R_h trong (3.4) là hàm tuyến tính và bậc hai của $\delta_T = \Delta h_T - \Delta h_T^f$, ta có $R_h = O(\|\delta_T\|) = O((T\alpha)^2)$. Trong khi đó, số hạng chủ đạo của C_b là $g_b^\top \Delta b_T = O(T\alpha)$ (bậc nhất). Dưới Giả thuyết 1 ($T\alpha \ll 1$), ta có $O((T\alpha)^2) \ll O(T\alpha)$, suy ra R_h là vô cùng bé bậc cao so với C_b , hoàn tất chứng minh Mệnh đề 1. ■