

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Lê Tuấn Khải

GIẢI THÍCH NEGATIVE TRANS-
FER TRONG META-LEARNING

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHÍNH QUY

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Lê Tuấn Khải - 20120503
**GIẢI THÍCH NEGATIVE TRANS-
FER TRONG META-LEARNING**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHÍNH QUY

GIÁO VIÊN HƯỚNG DẪN
GS.TS Lê Hoài Bắc

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Tôi là Nguyễn Lê Tuấn Khải, sinh viên chuyên ngành Khoa học Máy tính, khoa CNTT, trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM. Tôi xin khẳng định và cam đoan rằng luận văn này là công trình nghiên cứu khoa học do tôi thực hiện dưới sự hướng dẫn của GS.TS Lê Hoài Bắc.

Toàn bộ nội dung, kết quả, số liệu, bảng biểu và hình ảnh được trình bày trong luận văn này đều được tôi thu thập, xử lý, phân tích và trình bày một cách trung thực, khách quan và có trích dẫn đầy đủ theo đúng quy định và pháp luật. Những tài liệu, dữ liệu và công trình nghiên cứu của các tác giả trong và ngoài nước được sử dụng để tham khảo đều đã được ghi rõ nguồn và thực hiện đúng theo quy định về trích dẫn tài liệu khoa học.

Và tôi xin tự chịu hoàn toàn trách nhiệm trước Hội đồng và trước pháp luật về tính xác thực, tính khách quan cũng như mọi vấn đề pháp lý liên quan đến bản quyền của công trình nghiên cứu này. Nếu có bất kỳ sai phạm nào liên quan đến vấn đề sao chép, gian lận hoặc vi phạm bản quyền, tôi xin chịu mọi hình thức xử lý theo quy định hiện hành.

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(HƯỚNG NGHIÊN CỨU)

Tên đề tài: GIẢI THÍCH NEGATIVE TRANSFER TRONG META-LEARNING.

Sinh viên thực hiện: Nguyễn Lê Tuấn Khải – 20120503

Giảng viên hướng dẫn: Lê Hoài Bắc

1. Chủ đề và ý tưởng nghiên cứu:

- Tính cấp thiết cao: Giải quyết bài toán hộp đen trong Meta-Learning.
- Ý tưởng chính: Nghiên cứu nguyên nhân thay vì chỉ ghi nhận biểu hiện chuyển giao tiêu cực.
- Cách tiếp cận mới: Đặt bài toán dưới góc nhìn mô hình cấu trúc nhân quả SCM.
- Định hướng rõ ràng: Kết hợp Explainable AI (XAI) vào cấu trúc tối ưu hóa hai tầng.

2. Phương pháp nghiên cứu:

- Cơ sở toán học vững chắc: Ứng dụng phương pháp liên hợp (Adjoint method) tối ưu.
- Độ đo định lượng chuẩn xác: Đề xuất chỉ số độ lợi thích ứng Delta M tường minh.
- Giải thuật FAMA sáng tạo: Mở rộng Class Activation Mapping qua chuỗi nhiều bước gradient.
- Khung kiểm chứng chặt chẽ: Phát triển phép thử toán học BiADT và Sanity check.
- Thực nghiệm quy mô: Đánh giá nghiêm túc trên 3 bộ dữ liệu chuẩn gồm 600 tác vụ

3. Đóng góp Khoa học và thực tiễn:

- Về mặt khoa học: Định nghĩa hình thức hóa cơ chế giải thích hậu nghiệm cho Meta-Learning.
- Phát hiện cốt lõi: Chứng minh "thiên lệch ngữ cảnh" là gốc rễ của negative transfer.
- Về mặt thực tiễn: Cung cấp bộ công cụ trực quan hóa đặc trưng gây hại.
- Khả năng mở rộng: Làm nền tảng hiệu chỉnh dữ liệu, tối ưu hiệu suất mô hình.

4. Quá trình thực hiện và quản lý dự án:

Sinh viên thường xuyên trao đổi và báo cáo với GVHD. Thực hiện đúng các yêu cầu đặt ra

5. Báo cáo viết:

- Cấu trúc chuẩn mực: Bố cục mạch lạc, đầy đủ danh mục hình vẽ, bảng biểu.
- Lập luận logic: Dẫn dắt từ tổng quan lý thuyết đến thực nghiệm thuyết phục.
- Văn phong khoa học: Sử dụng chính xác các thuật ngữ chuyên ngành học máy.
- Lỗi nhỏ cần sửa: Đồng bộ hóa ký hiệu lỗi phong chữ "P hi" ở trang 11

6. Điểm cần làm rõ và góp ý hoàn thiện

- Mở rộng kiến trúc mạng: Thực nghiệm hiện tại chủ yếu trên backbone Conv4. Khóa luận nên thảo luận thêm về khả năng mở rộng sang ResNet hoặc Vision Transformer (ViT).
- Độ phức tạp tính toán: Cần làm rõ chi phí tính toán của FAMA so với Grad-CAM truyền thống trong thực tế.
- Ứng dụng thực tế: Nên bổ sung đề xuất cụ thể để lọc dữ liệu dựa trên kết quả của FAMA.
- Lỗi chính tả nhỏ: Trang 11 có ký hiệu "P hi" bị rời rạc, cần chuẩn hóa thành chữ Hy Lạp.

7. Trình bày trước hội đồng: Tốt

8. Công bố khoa học/ ứng dụng thực tế: chưa có

Đánh giá xếp loại: Đạt yêu cầu khóa luận tốt nghiệp ngành Khoa học Máy tính

TP.HCM, ngày 28 tháng 07 năm 2026

Giảng viên hướng dẫn



Lê Hoài Bắc

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(HƯỚNG NGHIÊN CỨU)

Tên đề tài : Giải thích Negative Transfer trong Meta-learning

Sinh viên thực hiện : Nguyễn Lê Tuấn Khải – 20120503

Giảng viên phản biện: TS. Lê Ngọc Thành

1. Chủ đề và ý tưởng nghiên cứu:

Khóa luận nghiên cứu bài toán diễn giải quá trình thích ứng nhanh của các phương pháp meta-learning dựa trên gradient, tiêu biểu là MAML. Thay vì chỉ nhận diện negative transfer qua biểu hiện sụt giảm độ chính xác, đề tài đặt bài toán ở cấp độ đặc trưng với hai câu hỏi: (i) định lượng mức lợi/hại mà bước thích ứng phần backbone mang lại cho tác vụ đích, và (ii) định vị trên không gian đặc trưng những vùng ảnh trong tập hỗ trợ là nguyên nhân gây ra ảnh hưởng đó. Ý tưởng “tách hai nhánh” (thích ứng toàn phần so với đóng băng backbone) nhằm cô lập đóng góp thuần của backbone là một ý tưởng hợp lý của đề tài.

2. Phương pháp nghiên cứu:

Sinh viên đã khảo sát các nền tảng liên quan: few-shot learning, MAML và các biến thể (ANIL, BOIL, Meta-SGD, iMAML), lý thuyết feature-reuse so với representation-change (Raghu, Oh), cùng các phương pháp XAI (Grad-CAM, LIME, SHAP, Integrated Gradients, TracIn). Về phương pháp, đề tài đã xây dựng độ đo độ lợi thích ứng ΔM và đề xuất FAMA, vận dụng phương pháp trạng thái liên hợp từ lý thuyết điều khiển tối ưu để lan truyền tín hiệu dọc toàn bộ quỹ đạo thích ứng, kết hợp kỹ thuật Hessian-vector product (Pearlmutter) để hạ chi phí từ $O(TP^2)$ xuống $O(TP)$.

3. Đóng góp Khoa học và thực tiễn:

Đề tài có ba đóng góp chính gồm độ đo ΔM cho phép xác định dấu và chiều hướng của chuyển giao, phương pháp FAMA nhằm mở rộng attribution kiểu CAM và bộ ba bài kiểm chứng, đặc biệt BiADT hai chiều có tính đến dấu, mang tính tổng quát và có thể tái sử dụng cho các phương pháp XAI khác trong meta-learning. Thực nghiệm còn một số điểm chưa tốt như chỉ được báo cáo trên MỘT bộ dữ liệu (tieredImageNet). miniImageNet chỉ xuất hiện ở phần định tính, còn

CUB-200-2011 chỉ dùng làm miền OOD. Thiếu so sánh với phương pháp diễn giải đối chứng, ví dụ Grad-CAM áp dụng thẳng tại ϕ_T , TL-XML, hay attribution kiểu TracIn.. Thiếu baseline làm suy yếu luận cứ về sự cần thiết và ưu thế của phương pháp. Kết luận định tính “contextual bias” chủ yếu rút ra từ vài tác vụ cực trị chọn tay, thiếu thước đo định lượng (ví dụ mức trùng khớp đầu của Φ_{FAMA} với mặt nạ đối tượng/nền trên toàn bộ 600 tác vụ) để củng cố.

4. Báo cáo viết:

Bố cục 5 chương hợp lý và mạch lạc. Tuy nhiên, có nhiều tài liệu được nhắc trong Chương 2 không có trong Danh mục tài liệu tham khảo. Tham chiếu chéo bị lỗi như trong trang 11. Báo cáo thống kê chưa nhất quán: Bảng 4.2 ghi “mean $\pm$ std” nhưng phần nhận xét lại gọi đó là “sai số biên (MoE)”, trong khi Bảng 4.5 ghi “Mean $\pm$ MoE”.

5. Trình bày trước hội đồng:

Trình bày tốt trước hội đồng.

6. Công bố khoa học/ ứng dụng thực tế:

Chưa có công bố khoa học.

Đánh giá xếp loại: Đạt yêu cầu của khóa luận tốt nghiệp cử nhân CNTT.

TP.HCM, ngày 28 tháng 07 năm 2026

Giảng viên phản biện



Lê Ngọc Thành

Lời cảm ơn

Trước hết, tôi xin được gửi lời tri ân sâu sắc nhất đến GS.TS. Lê Hoài Bắc, người đã tận tình hướng dẫn, định hướng và hỗ trợ tôi trong suốt quá trình thực hiện luận văn này. Những góp ý chuyên môn sâu sắc từ thầy chính là động lực to lớn giúp tôi hoàn thành nghiên cứu này một cách trọn vẹn.

Bên cạnh đó, tôi cũng xin bày tỏ lòng kính trọng và biết ơn sâu sắc đến tập thể giảng viên Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM, đã truyền thụ cho tôi những nền tảng tri thức chuyên môn vững chắc trong suốt quá trình học tập tại trường. Chính những tri thức này đã định hình tư duy một cách hoàn thiện để đạt được các kết quả trong nghiên cứu này.

Cuối cùng, tôi muốn gửi lời cảm tạ tới gia đình, bạn bè đã luôn đồng hành cùng tôi trong suốt hành trình vừa qua.

Và lời kết, dù đã dành nhiều tâm huyết và nỗ lực, song đề án khó tránh khỏi những điểm thiếu sót ngoài ý muốn. Cho nên, tôi kính mong nhận được những lời nhận xét, góp ý quý báu từ quý thầy cô và Hội đồng để nghiên cứu này ngày càng hoàn thiện hơn.

Tôi xin trân trọng cảm ơn!

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP
**Giải thích Negative Transfer trong
Meta-learning**

Interpret Negative Transfer in Meta-learning

1 THÔNG TIN CHUNG

Người hướng dẫn:

- GS.TS. Lê Hoài Bắc (Bộ môn Khoa học Máy tính - Khoa Công nghệ Thông tin)

[Nhóm] Sinh viên thực hiện:

1. Nguyễn Lê Tuấn Khải (MSSV: 20120503)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Trong những thập kỷ gần đây, lĩnh vực Trí Tuệ Nhân Tạo (AI) nói chung và lĩnh vực Học Máy (ML) nói riêng đã chứng kiến những bước phát triển thần kỳ nhờ vào các yếu tố quan trọng như sự tích lũy lượng dữ liệu lớn, sự phát triển của các công cụ tính toán mạnh mẽ và sự ra đời của các thuật toán phức tạp [1].

Tuy nhiên, trên thực tế, các thuật toán Học Máy vẫn gặp phải những rào cản để đáp ứng các tình huống đặc thù do sự thiếu hụt các tập dữ liệu khả thi. Mà nguyên nhân chủ yếu của vấn đề này có thể xuất phát từ những bất cập gặp phải trong việc thu thập dữ liệu. Mà có thể kể đến như do tính đặc thù của việc thử nghiệm trong các lĩnh vực y khoa hay công nghệ cao, hoặc do bị ràng buộc về mặt đạo đức, pháp luật,.... Dẫn tới rất khó để có thể thu thập được lượng dữ liệu đủ đa dạng. Cuối cùng tạo thành hệ quả là, các mô hình học máy truyền thống thường thất bại trong việc khái quát hóa tri thức từ các tập dữ liệu nhỏ. Và đây cũng chính là động lực cốt lõi thúc đẩy sự ra đời và phát triển của **Few-Shot Learning** cũng như **Meta-Learning**.

Được truyền cảm hứng từ khả năng học của con người - con người có thể nhanh chóng học được khái niệm mới chỉ qua vài lần trải nghiệm, nhờ tận dụng tri thức tích lũy - **Meta-Learning** đã được đưa ra như một phương pháp để giải quyết bài toán **Few-Shot Learning**. Mặc dù hiện tại vẫn chưa có định nghĩa thống nhất trong nhiều tài liệu, nhưng **Meta-Learning**, còn được gọi là học cách học, trong các tài liệu nghiên cứu gần đây [2], [3], [4] đặt ra với mục tiêu xây dựng các tri thức tiền nghiệm (kinh nghiệm) từ những tác vụ khác nhau, sau đó sử dụng kiến thức đó để hỗ trợ cho việc học các tác vụ mới một cách nhanh chóng. Mà trong đó ba hướng tiếp cận **Metric-based**, **Network-based** và **Gradient-based** nổi lên như ba phương pháp hứa hẹn chính. Và các hướng tiếp cận dựa trên gradient (**Gradient-based**) mang tính hứa hẹn cao hơn cả, bởi tính linh hoạt cao có thể

sử dụng được cho tất cả các mô hình có tính khả vi, đồng thời đạt được hiệu suất vượt trội so với các phương pháp khác.

Dẫn chứng cho điều này, phương pháp **Model-Agnostic Meta-Learning (MAML)** được đề xuất bởi C.Finn và các cộng sự [5] và các biến thể của nó [6], [7],..., là một trong những kỹ thuật thành công nhất trong hướng tiếp cận này. Trọng tâm của phương pháp này chính là tạo ra một meta-learner, được thiết kế để có thể hiệu chỉnh trọng số khởi tạo của tác vụ đích, do đó tăng khả năng khái quát của mô hình khi học tác vụ đích, tức là sinh ra một trọng số khởi tạo tốt và có thể nhảy tới trọng số tối ưu của tác vụ đích khi chỉ với một hoặc một vài bước nhảy gradient (gradient-step). Tuy nhiên, do lượng dữ liệu nhỏ và các điểm dữ liệu rời rạc gây ra hiện tượng quá khớp (over-fitting). Do đó, đây vẫn là một trong những mục tiêu cần đạt được để cải tiến Meta-Learning.

Ngoài ra, mặc dù các phương pháp dựa trên gradient đạt được hiệu suất đáng mong đợi, nhưng về bản chất, chúng đều là các *mô hình hộp đen (black-box models)*. Điều này có nghĩa là chúng không cung cấp thông tin rõ ràng về cơ chế quyết định của mình và không phải lúc nào mô hình cũng đảm bảo việc đưa ra lời giải tối ưu. Do đó, trong những tình huống như vậy, người dùng không nhận được thông tin cụ thể để nhận biết và cải thiện mô hình của mình kịp thời, cũng như không thể sử dụng kết quả của mô hình để tham khảo. Trong các ứng dụng thực tế, việc thiếu khả năng giải thích của các mô hình có thể tạo ra nhiều rủi ro tiềm ẩn trong xã hội.

Ví dụ, hai hệ thống phổ biến là PredPol và COMPAS [8], được sử dụng lần lượt bởi lực lượng cảnh sát và hệ thống tư pháp Hoa Kỳ, đã bị chỉ trích vì đưa ra các quyết định không công bằng và có xu hướng phân biệt chủng tộc. Cụ thể, PredPol tập trung vào khu vực cư trú của những cộng đồng da màu, trong khi COMPAS thường đối xử không công bằng với các tội phạm da đen. Thêm vào đó, trong các hệ thống nhận dạng, các mô hình luôn nhạy cảm bởi nhiều có thể dẫn đến nhận dạng sai lầm. Do đó, hiểu rõ hơn về cơ chế quyết định và hành vi của các mô hình

hộp đen có thể tăng niềm tin của người dùng vào kết quả mà chúng đưa ra. Hơn nữa, việc hiểu rõ cơ chế này cũng có thể được xem như một công cụ gỡ lỗi giúp các chuyên gia Trí Tuệ Nhân Tạo có thể phát hiện và sửa chữa các vấn đề, từ đó cải thiện hiệu suất của mô hình.

2.2 Mục tiêu đề tài

Mặc dù **MAML** và các biến thể của chúng đã đạt được hiệu suất cao trong nhiều tình huống. Tuy nhiên, liệu trọng số khởi tạo tốt sẽ luôn luôn hỗ trợ cho tác vụ đích? Hay nói cách khác, liệu tri thức có được từ việc trích xuất từ các tác vụ khác nhau có phải sẽ luôn có lợi cho việc học tác vụ đích? **Yue và các cộng sự** [9] đã chỉ ra rằng *tri thức có thể sẽ gây ra bất lợi cho tác vụ đích khi tập huấn luyện và tập kiểm định của tác vụ đích không tương đồng với nhau*.

Để ví dụ cho điều này, ta xét tác vụ phân loại ảnh sư tử và chó hoang châu phi cụ thể như hình minh họa 1 dưới đây. Do việc áp dụng tri thức tiền nghiệm lên đặc trưng về bối cảnh của bức ảnh nên gây ra sự nhầm lẫn trong việc đưa ra dự đoán (với ảnh có nền cỏ xanh mô hình sẽ nhầm lẫn mà gán nhãn nó là con sư tử, ngược lại ảnh có nền cỏ vàng mô hình cũng nhầm lẫn mà gán nhãn nó là chó hoang châu Phi). Điều này đã được tác giả lý giải dựa trên mô hình nhân quả có cấu trúc. Và hiện tượng này còn được biết đến với tên gọi là **chuyển giao cực đoan (negative-transfer)**.



Hình 1: Ví dụ cho chuyển giao cực đoan - do tri thức tiền nghiệm gây nhiễu đến quá trình học tác vụ đích.[9]


Để cải thiện và giải quyết hiện tượng này, chúng ta có thể áp dụng các điểm lợi của các kỹ thuật XAI có thể mang lại nhằm tìm ra những tri thức gây nhiễu, sau đó loại bỏ các yếu tố gây nhiễu trong quá trình học tác vụ đích. Tuy nhiên, hiện nay vẫn còn rất ít các công trình nghiên cứu về điều này. Bởi vì, **Meta-Learning** vẫn chưa có một định nghĩa hình thức một cách thống nhất cho nên việc áp dụng XAI cho các kỹ thuật Meta-Learning vẫn còn là một thách thức lớn. Vì những lý do đó, việc phát triển các kỹ thuật để diễn giải các mô hình meta-learning là cấp bách.

2.3 Phạm vi của đề tài

2.3.1 Few-Shot Learning

Few-Shot Learning là bài toán nhằm tạo ra một mô hình có thể khái quát tốt khi được huấn luyện trên tập dữ liệu có số lượng mẫu hạn chế. Trong phạm vi luận văn, chúng ta chỉ đề cập đến bài toán N -way- K -shot áp dụng cho bài toán phân lớp ảnh.

Trong bài toán này, mô hình được huấn luyện trên tập dữ liệu gồm N nhãn, và mỗi nhãn có K mẫu dữ liệu (thông thường $K = 1$ hoặc 5), được gọi là *tập hỗ trợ* (*support set*), ký hiệu là tập S . Và sau đó, mô hình sẽ được kiểm định trên *tập truy vấn* (*query set*), được ký hiệu là tập Q .



Hình 2: Ví dụ minh họa cho bài toán 3-way-2-shot với bài toán nhận diện chữ số viết tay (tập dữ liệu Ominiglot).

Để tiến hành thực nghiệm, trong phạm vi khóa luận, một số bộ dữ liệu phổ biến được sử dụng trong các công trình nghiên cứu trước đây sẽ được sử dụng. Cụ thể như sau.

- **Mini-ImageNet** [10] gồm 100 nhãn được chọn ngẫu nhiên từ tập **ImageNet** với kích thước mỗi ảnh là 84×84 , trong đó mỗi nhãn có 600 ảnh. Tập dữ liệu này được sử dụng rộng rãi trong các nghiên cứu về Meta-Learning vì kích thước nhỏ, có độ tương đồng nhất định thích hợp cho việc mô phỏng các tình huống trong thế giới thực.
- **tieredImageNet** [11] cũng được lấy mẫu từ tập **ImageNet**, tuy nhiên, nó xét đến việc cấu trúc phân cấp các nhãn trong tập ImageNet. Do đó, tập dữ liệu này tổng cộng gồm 34 nhãn cha, được chia với tỉ lệ 20/6/8 để dùng cho huấn luyện, kiểm định và xác thực, mỗi nhãn cha chứa từ 10 đến 30 nhãn, và có tổng cộng 608 nhãn trong tập dữ liệu này. Bởi vì có tổ chức phân cấp nên tập dữ liệu này phù hợp để đánh giá sự hiệu quả của mô hình.
- **CIFAR-FS** [12] là một tập dữ liệu với các ảnh từ tập **CIFAR-100** với 100 nhãn, mỗi nhãn gồm có 600 ảnh.
- **CUB-200-2011** [13], còn gọi là **CUB**, là một tập dữ liệu với các ảnh về loài chim, với 200 nhãn, và tổng cộng có 11.788 ảnh. Là một tập dữ liệu mang tính thách thức với sự tương đồng cao giữa các nhãn. Và trong luận văn này, tập

này sẽ được tuân thủ nghiêm ngặt theo phương án mà Chen cùng các cộng sự đề ra [14].

2.3.2 Meta-learning và phương pháp MAML

Trước khi đi vào nghiên cứu sâu hơn, ta cần định nghĩa cách tiếp cận cơ sở của đối tượng áp dụng giải thích. Trong phạm vi khóa luận này, thì đó là Meta-Learning và phương pháp MAML của C.Finn và các cộng sự.

Ngược với các phương pháp Học Máy truyền thống, khi mô hình f học trên một tập dữ liệu $D = \{(x_i, y_i)\}_{i=1}^n$ để tìm ra bộ tham số tối ưu θ^* nhằm cực tiểu hóa hàm mất mát $\mathcal{L}$ trên toàn bộ phân phối dữ liệu. Thì Meta-Learning tiếp cận bài toán ở cấp độ cao hơn.

Thay vì học trên các điểm dữ liệu đơn lẻ, Meta-Learning học trên một tập hợp các tác vụ (tasks) $\mathcal{T} = \{\mathcal{T}_1, \mathcal{T}_2, \dots, \mathcal{T}_M\}$. Mà trong đó, mỗi tác vụ $\mathcal{T}_i$ được cấu thành từ hai tập con riêng biệt.

- Tập hỗ trợ (Support set), $S = \mathcal{D}_i^{sup} = \{(x_j, y_j)\}_{j=1}^k$, đóng vai trò là tri thức nền tảng để mô hình thích nghi nhanh.
- Tập truy vấn (Query set), $Q = \mathcal{D}_i^{que} = \{(x_j, y_j)\}_{j=1}^m$, dùng để đánh giá khả năng tổng quát hóa của mô hình sau khi đã học từ tập hỗ trợ.

Khi đó, mục tiêu chính cốt lõi của Meta-learning là tối ưu hóa bộ tham số khởi tạo θ_0 sao cho tồn tại một hàm thích nghi g_{θ_0} có khả năng chuyển đổi nhanh chóng thông tin từ tập hỗ trợ S thành một mô hình tối ưu cho tập truy vấn Q .

Và như đã đề cập ở phần giới thiệu, để tìm ra bộ tham số khởi tạo (θ_0) tối ưu, thì có ba phương pháp được nêu ra. Nhưng trong phạm vi đề tài khóa luận, chúng ta chỉ xét đến các lớp phương pháp dựa trên **Gradient-based**, mà cụ thể truy về phương pháp **MAML** mà C.Finn cùng các cộng sự đặt ra.

Với phương pháp này, thì hàm thích nghi g_{θ_0} là quy trình Gradient Descent. Mô hình học cách tìm vị trí xuất phát θ_0 sao cho chỉ cần vài bước đạo hàm trên S là chạm đến cực trị.


Cụ thể quá trình (siêu) huấn luyện - meta-training - của MAML sẽ hoạt động như thuật toán 1 và hình 3 dưới đây.

Algorithm 1: Thuật toán meta-training với Model Agnostic Meta-Learning (MAML)

Require: $p(\mathcal{T})$: Phân phối trên các tác vụ

Require: α, β : Các siêu tham số về bước nhảy (tốc độ học)

- 1: Khởi tạo tham số θ_0 ngẫu nhiên
- 2: **while** chưa dừng **do**
- 3: Lấy mẫu một lô các tác vụ (meta-batch) $\mathcal{T}_i \sim p(\mathcal{T})$
- 4: **for all** $\mathcal{T}_i$ **do**
- 5: Tính $\nabla_{\Phi} \mathcal{L}_{\mathcal{T}_i}(f_{\theta_0}, S_i)$
- 6: Tính các tham số thích nghi bằng Gradient Descent: $\Phi_i = \theta'_i = \theta_0 - \alpha \nabla_{\Phi} \mathcal{L}_{\mathcal{T}_i}(f_{\theta_0}, S_i)$
- 7: **end for**
- 8: Cập nhật tham số tổng quát: $\theta_0 \leftarrow \theta_0 - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\Phi_i}, Q_i)$
- 9: **end while**




Hình 3: Hình minh họa quá trình meta-training trong MAML

2.3.3 Mô hình cấu trúc nhân quả - SCM

Tuy MAML và các biến thể của nó đạt hiệu suất ấn tượng trong nhiều tình huống thực tế. Nhưng với bản chất phức tạp của Meta-Learning thì vẫn khó để mà hiểu được một cách tường minh cơ chế chuyển giao tri thức thực sự diễn ra bên trong.

Yue và các cộng sự [9] đã đưa ra một góc nhìn khác dựa trên mô hình cấu trúc nhân quả (Structural Causal Model) như hình minh họa 4 bên dưới, để biểu diễn quá trình thích ứng nhanh (*fast-adaptation*) trong giai đoạn meta-testing.



Hình 4: Mô hình cấu trúc nhân quả - Structural Causal Model

Mô hình này giả định rằng quá trình học và dự đoán trong Meta-Learning bị chi phối bởi bốn biến số trừu tượng.

- **D (Pretrained Knowledge):** Đại diện cho tri thức tích lũy từ giai đoạn siêu huấn luyện, bao gồm tập dữ liệu nguồn và bộ tham số khởi tạo θ_0 .
- **X_S (Feature Representation):** Các đặc trưng được trích xuất từ S thông qua mô hình f_Φ .
- **C (Context/Semantic Manifold):** Biểu diễn ngữ cảnh hoặc các khái niệm ngữ nghĩa trừu tượng mà cơ sở của nó được kế thừa từ D .
- **Y_S (Classification Effect):** Kết quả dự đoán cuối cùng của mô hình.

Đồng thời, từ **SCM 4**, ta có thể bóc tách ra được Y_S dựa trên hai con đường chính.

1. **$X \rightarrow Y$ (Trực tiếp):** Đặc trưng hình ảnh trực tiếp quyết định nhãn dự đoán.
2. **$X \rightarrow C \rightarrow Y$ (Gián tiếp):** Đặc trưng X được ánh xạ vào không gian ngữ nghĩa C , nơi nó kết hợp với tri thức bối cảnh từ D để đưa ra dự đoán.

Và sự tồn tại của các cạnh $D \rightarrow X$ và $D \rightarrow C$ cho thấy tri thức tiền huấn luyện đóng vai trò là một biến gây nhiễu (confounder). Điều này tạo ra các tương quan

ảo (spurious correlations), nơi mô hình dự đoán nhãn Y dựa trên bối cảnh C hơn là dựa trên bản chất của đặc trưng X .

2.3.4 Phát biểu bài toán

Tương tự với các nghiên cứu phát triển các phương pháp XAI, trước hết chúng ta cần đặt ra những câu hỏi xoay quanh cơ chế của mô hình. Trong ngữ cảnh **Meta-Learning**, câu hỏi được đặt ra là, *những gì thật sự đã được chuyển giao trong quá trình thích ứng với tác vụ mới? hay những mẫu - patterns - nào đã được sử dụng trong quá trình học tác vụ mới?*.

Đồng thời, cũng phải xét đến các mẫu (patterns) đó ảnh hưởng như thế nào đến việc đưa ra dự đoán của mô hình sau quá trình thích ứng. Do đó, để giải quyết bài toán diễn giải trong **Meta-Learning** ta cần giải quyết đồng thời hai bài toán con là diễn giải cho quá trình thích ứng nhanh (*fast-adaptation*) và diễn giải cho quá trình ra quyết định của mô hình kết quả.

Cụ thể hơn, với MAML và các biến thể liên quan (như mô tả tại thuật toán 1), quá trình thích ứng nhanh (*fast adaptation*) trong giai đoạn *meta-testing* được thực hiện dựa trên tập dữ liệu hỗ trợ (*support set*) S và tham số khởi tạo θ_0 đã học từ giai đoạn siêu huấn luyện (*meta-training*). Với giả định chỉ sử dụng một bước cập nhật gradient, tham số thích ứng Φ được xác định như sau phương trình 1.

$$\Phi = \theta' = \theta_0 - \alpha \nabla_{\theta_0} \mathcal{L}(\theta_0, S) \quad (1)$$

Sau đó, để đánh giá hiệu suất thực tế, tham số thích ứng Φ thu được từ phương trình 1 sẽ được áp dụng trực tiếp trên tập truy vấn (*query set*) Q .

Tại giai đoạn *meta-testing* này, giá trị hàm tổn thất $\mathcal{L}(\Phi, Q)$ hoặc các độ đo khác như (*accuracy*) - gọi chung là acc_α - trên tập Q sẽ đóng vai trò là chỉ số đánh giá khả năng thích ứng nhanh của mô hình đối với các tác vụ mới (unseen tasks).

Từ đây có thể thấy được, để diễn giải cho quá trình thích ứng nhanh này, chính xác ta cần phải xác định các đặc trưng chung F giữa mô hình f_{θ_0} và f_Φ .

2.4 Cách tiếp cận dự kiến


Dựa trên phát biểu bài toán, để xác định được đặc trưng chung F ta cần thiết phải thực hiện thông qua phương pháp hậu diễn giải (post-hoc) với hai giai đoạn chính.

Đầu tiên dựa trên **SCM** 4 ta có thể rõ ràng, f_{θ_0} đã truyền cho f_{Φ} những thông tin chung C thể hiện qua F . Nhưng ta vẫn chưa biết nó đã chuyển giao bao nhiêu, và tác động xấu hay tốt đến việc học tác vụ mới.

Hay nói cách khác, chính là F có gây ra hiện tượng tương quan giả hay không? Hoặc có dẫn đến hiện tượng *chuyển giao tiêu cực* (*negative transfer*) hay không. Thành thử, ở bước đầu tiên, việc cần làm chính là định nghĩa một độ đo acc_{α} hợp lý.

Đồng thời, sau khi xác định được mức độ F được chuyển giao. Tiếp theo đó, ta cần phải xác định rõ mối tương quan giữa θ_0 và Φ thông qua việc xác định F một cách rõ ràng.

Và trong khuôn khổ khóa luận, quy trình thực hiện hai bước trên sẽ được minh họa thông qua sơ đồ như hình 5 dưới đây.



Hình 5: Cách tiếp cận dự kiến

2.4.1 Xác định độ đo acc_{α}

Để xác định được độ đo acc_{α} hợp lý, ta cần nó thỏa mãn các tiêu chí sau.

- **Khả năng chỉ ra được tương quan giả.** Phải mô tả và bóc tách được bản chất của các lỗi sai trên từng nhóm.
- **Tính trung thành (Faithfulness).** Xác định xem các yếu tố mà mô hình

đang chú ý có thực sự là nguyên nhân cốt lõi định hình nên quyết định dự đoán hay không.

Khi đã xác định được tiêu chí, ta có thể dựa trên nó để tham khảo các độ đo sau.

1. **Conventional Accuracy** (Độ chính xác truyền thống), là thước đo tỷ lệ dự đoán đúng trên toàn bộ tập dữ liệu.
2. **CAM-Acc** (Độ chính xác định vị đặc trưng) [9], là thước đo định lượng liệu mô hình có "chú ý" đến đối tượng thực sự khi đưa ra dự đoán hay không. Được định nghĩa là tỷ lệ phần trăm số điểm ảnh (pixels) nằm bên trong bounding box có điểm số Grad-CAM vượt qua một ngưỡng nhất định, chẳng hạn như lớn hơn 0,9.
3. **Hardness-specific Acc** (Độ chính xác theo độ khó), là thước đo hiệu suất của mô hình được phân tách dựa trên mức độ phức tạp của dữ liệu đầu vào. Chỉ số này giúp xác định xem mô hình gặp khó khăn ở các mẫu nhiễu, thiếu sáng hay các trường hợp biên (edge cases), từ đó đánh giá độ tin cậy của dự đoán trong các điều kiện thực tế khác nhau.
4. **Lượng hóa Negative Transfer Gap (NTI)** (Lượng hóa khoảng cách chuyển đổi tiêu cực), là một chỉ số đo lường sự sụt giảm hiệu suất của mô hình khi việc học từ một tác vụ nguồn gây cản trở hoặc làm sai lệch kết quả trên tác vụ đích. NTI giúp xác định mức độ không tương thích giữa các miền dữ liệu (domain discrepancy) trong quá trình Transfer Learning hoặc Domain Adaptation.

2.4.2 Xác định F

Sau khi đã định hình được các thước đo hiệu suất tại bước trước, mục tiêu tiếp theo là cụ thể hóa không gian đặc trưng chung F . Trong ngữ cảnh của khóa luận, F không chỉ là một tập hợp các đặc trưng trừu tượng mà là "vùng tri thức" mà mô hình f_{θ_0} đã chuyển giao cho f_{Φ} .

Để xác định F một cách trực quan và định lượng, các phương pháp sử dụng Bản đồ kích hoạt lớp (Class Activation Map - CAM) ([15], [16], [17], [18], [19]) được đề xuất làm công cụ chủ đạo. Cụ thể, quá trình xác định F được thực hiện thông qua các bước sau.

- **Trích xuất vùng chú ý (Attention Extraction):** Sử dụng kỹ thuật Grad-CAM để tạo ra bản đồ nhiệt M , thể hiện mức độ đóng góp của từng vùng không gian trên ảnh đầu vào đối với quyết định phân loại của f_Φ .
- **Phân lập đặc trưng F :** Không gian F được xác định là tập hợp các tọa độ điểm ảnh (x, y) có giá trị kích hoạt vượt ngưỡng τ (với $\tau = 0,9$ như đã định nghĩa ở mục CAM-Acc). Vùng này đại diện cho những đặc trưng mà mô hình coi là quan trọng nhất để đưa ra dự đoán.
- **Phân tích sự tương quan giữa θ_0 và Φ :** Bằng cách so sánh vùng kích hoạt F của mô hình tiền huấn luyện f_{θ_0} và mô hình sau khi tinh chỉnh f_Φ , ta có thể đánh giá được liệu các đặc trưng cốt lõi có bị thay đổi (shift) hay bị nhiễu bởi các yếu tố ngoại cảnh hay không.

Việc xác định F thông qua CAM cho phép ta thực hiện phép hậu diễn giải (post-hoc) một cách tường minh. Nếu F hội tụ tại các vùng chứa đối tượng (Object-centric), mô hình đang học được các đặc trưng ngữ nghĩa bền vững. Ngược lại, nếu F phân tán vào vùng nền (Background), đây là minh chứng cho việc tồn tại hiện tượng tương quan giả (spurious correlation) được chuyển giao từ tác vụ nguồn sang tác vụ đích, dẫn đến negative transfer. Kết quả của việc xác định F sẽ là cơ sở để điều chỉnh chiến lược huấn luyện hoặc lọc dữ liệu nhằm tối ưu hóa sự chuyển giao tri thức giữa hai tác vụ.

2.5 Kết quả dự kiến của đề tài

Trong phạm vi khóa luận, các kết quả dự kiến có thể đạt được được trình bày như sau:

- Mô hình đạt được kết quả cạnh tranh trong khi vẫn cân bằng được với khả năng diễn giải của mô hình.
- Hoàn thiện được một hình mẫu (framework) hậu diễn giải cho mô hình Meta-Learning cụ thể là các phương pháp dựa trên Gradient-based thông qua các phương pháp hậu diễn giải.

2.6 Kế hoạch thực hiện

Đề tài nghiên cứu của luận văn được thực hiện tại Khoa Công nghệ Thông tin, trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh.

Thời gian thực hiện đề tài nghiên cứu 06 tháng kể từ tháng 01/2026 đến 06/2026. Kế hoạch thực hiện chi tiết cho đề tài nghiên cứu được liệt kê như trong bảng 1.

Công việc	Thời gian thực hiện
Tìm hiểu các hướng tiếp cận và công trình liên quan	01/01/2026 - 15/02/2026
Khảo sát, đánh giá các công trình tiêu biểu và hoàn thiện đề cương	16/02/2026 - 16/03/2026
Nghiên cứu các phương pháp giải quyết bài toán diễn giải cho Meta-Learning	17/03/2026 - 20/04/2026
Đề xuất phương pháp cải tiến, thực nghiệm và báo cáo giữa kỳ	21/04/2026 - 06/05/2026
Thực hiện thực nghiệm bổ sung, đánh giá kết quả và viết bản thảo luận văn	07/05/2026 - 30/06/2026
Hoàn thiện quyển luận văn, chỉnh sửa theo góp ý của GVHD và chuẩn bị bảo vệ	01/07/2026 - 15/07/2026

Bảng 1: Bảng kế hoạch thực hiện đề tài khóa luận

Tài liệu

- [1] M. Haenlein and A. Kaplan, “A brief history of artificial intelligence: On the past, present, and future of artificial intelligence,” *California management review*, vol. 61, no. 4, pp. 5–14, 2019.
- [2] Y. Song and H. Jeong, “Towards cross domain generalization of hamiltonian representation via meta learning,” *arXiv preprint arXiv:2212.01168*, 2022.
- [3] C. Lu, Y. Wu, J. M. Hernández-Lobato, and B. Schölkopf, “Invariant causal representation learning for out-of-distribution generalization,” in *International conference on learning representations*, 2021.
- [4] D. Li, Y. Yang, Y.-Z. Song, and T. Hospedales, “Learning to generalize: Meta-learning for domain generalization,” in *Proceedings of the AAAI conference on artificial intelligence*, vol. 32, 2018.
- [5] C. Finn, P. Abbeel, and S. Levine, “Model-agnostic meta-learning for fast adaptation of deep networks,” in *International conference on machine learning*, pp. 1126–1135, PMLR, 2017.
- [6] H. Yao, Y. Wei, J. Huang, and Z. Li, “Hierarchically structured meta-learning,” in *International conference on machine learning*, pp. 7045–7054, PMLR, 2019.
- [7] H. Yao, X. Wu, Z. Tao, Y. Li, B. Ding, R. Li, and Z. Li, “Automated relational meta-learning,” in *International Conference on Learning Representations*, 2020.
- [8] W. D. Heaven, “Predictive policing algorithms are racist. they need to be dismantled,” *MIT Technology Review*, vol. 17, p. 2020, 2020.
- [9] Z. Yue, H. Zhang, Q. Sun, and X.-S. Hua, “Interventional few-shot learning,” *Advances in neural information processing systems*, vol. 33, pp. 2734–2746, 2020.

- [10] O. Vinyals, C. Blundell, T. Lillicrap, D. Wierstra, *et al.*, “Matching networks for one shot learning,” *Advances in neural information processing systems*, vol. 29, 2016.
- [11] M. Ren, E. Triantafillou, S. Ravi, J. Snell, K. Swersky, J. B. Tenenbaum, H. Larochelle, and R. S. Zemel, “Meta-learning for semi-supervised few-shot classification,” *arXiv preprint arXiv:1803.00676*, 2018.
- [12] L. Bertinetto, J. F. Henriques, P. H. Torr, and A. Vedaldi, “Meta-learning with differentiable closed-form solvers,” *arXiv preprint arXiv:1805.08136*, 2018.
- [13] C. Wah, S. Branson, P. Welinder, P. Perona, and S. Belongie, “The caltech-ucsd birds-200-2011 dataset,” 2011.
- [14] W.-Y. Chen, Y.-C. Liu, Z. Kira, Y.-C. F. Wang, and J.-B. Huang, “A closer look at few-shot classification,” *arXiv preprint arXiv:1904.04232*, 2019.
- [15] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, “Learning deep features for discriminative localization,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2921–2929, 2016.
- [16] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE international conference on computer vision*, pp. 618–626, 2017.
- [17] A. Chattopadhyay, A. Sarkar, P. Howlader, and V. N. Balasubramanian, “Grad-cam++: Generalized gradient-based visual explanations for deep convolutional networks,” in *2018 IEEE winter conference on applications of computer vision (WACV)*, pp. 839–847, IEEE, 2018.
- [18] H. Wang, Z. Wang, M. Du, F. Yang, Z. Zhang, S. Ding, P. Mardziel, and X. Hu, “Score-cam: Score-weighted visual explanations for convolutional neu-

ral networks,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*, pp. 24–25, 2020.

- [19] S.-Y. Byun and W. Lee, “Reciprocam: Lightweight gradient-free class activation map for post-hoc explanations,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8364–8370, 2024.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 16 tháng 03 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Danh mục các từ viết tắt

ARML Automated Relational Meta-Learning.

BiADT Bi-directional Attribution Deletion Test.

DL học sâu (Deep Learning).

FAMA Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning
(Feature-space Adjoint Meta-Learning Attribution).

FSL học ít mẫu (Few-shot Learning).

HeTRoM Heterogeneous Tasks Robust Meta-learning.

HSFM Hard-Set-Guided Feature-Space Meta-Learning.

HSML Hierarchically Structured Meta-Learning.

IFSL Interventional Few-shot Learning.

LIME Local Interpretable Model-Agnostic Explanations.

MAML Model-Agnostic Meta-Learning.

ML học máy (Machine Learning).

SHAP Shapley Additive Explanations.

XAI Explainable AI.

Mục lục

Nhận xét của GVHD và GVPB	ii
Lời cảm ơn	vi
Đề cương chi tiết	vii
Mục lục	xxv
Danh mục các từ viết tắt	xxv
Tóm tắt	xxx
1 Phần mở đầu	1
1.1 Tính cấp thiết của đề tài	1
1.2 Mục tiêu nghiên cứu	4
1.3 Phương pháp tiếp cận	5
1.4 Đóng góp của đề tài	6
1.5 Bố cục luận văn	7
2 Tổng quan nghiên cứu	9
2.1 Cơ sở lý thuyết	9
2.1.1 Bài toán học ít mẫu (Few-shot Learning) (FSL) và Meta-Learning	9
2.1.2 Model-Agnostic Meta-Learning (MAML)	10
2.1.3 Explainable AI (XAI)	13
2.1.4 Correctness và trustworthiness của một phương pháp XAI	16
2.2 Các nghiên cứu liên quan	17
2.2.1 Tác vụ không đồng nhất (heterogeneous task) và hiện tượng Negative Transfer	18

2.2.2	Các phương pháp hậu diễn giải dựa trên gradients và nhiễu loạn	19
2.2.3	Các phương pháp XAI cho Meta-Learning và Few-Shot Learning	20
2.2.4	Attribution dựa trên quỹ đạo huấn luyện	22
2.2.5	Tổng hợp và định vị nghiên cứu	24
3	Phương pháp đề xuất	25
3.1	Phát biểu bài toán	25
3.2	Độ lợi thích ứng	27
3.2.1	Định nghĩa	28
3.3	Phương pháp Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)	30
3.3.1	Ý tưởng tổng quan	30
3.3.2	Khai triển đạo hàm qua quỹ đạo	32
3.3.3	Phương pháp liên hợp	33
3.3.4	Đại lượng quy kết	36
3.3.5	Phép chiếu về không gian đầu vào và bản đồ quy kết	37
3.4	Cơ sở đánh giá	38
3.4.1	Bài kiểm chứng dựa trên xóa và đo hai chiều (Bi-directional Attribution Deletion Test (BiADT))	39
3.4.2	Bài kiểm chứng độ tinh tảo thông qua việc phá hủy tri thức tiên nghiệm θ_0	41
3.4.3	Bài kiểm chứng độ tinh tảo thông qua việc can thiệp vào tập hỗ trợ S_i	42
4	Kết quả thực nghiệm	45
4.1	Thiết lập thực nghiệm	45
4.2	Các tập dữ liệu	46
4.3	Cách thức thực nghiệm	47
4.3.1	Đánh giá định lượng	47
4.3.2	Đánh giá định tính	47
4.4	Kết quả định lượng	48

4.4.1	Kết quả BiADT	48
4.4.2	Kết quả kiểm tra tính tảo theo tri thức tiên nghiệm θ_0	49
4.4.3	Kết quả kiểm tra tính tảo theo can thiệp tập hỗ trợ S_i	51
4.5	Kết quả định tính	53
4.5.1	Nghiên cứu trường hợp	54
4.6	Tổng kết chương	57
5	Kết luận	59
5.1	Hạn chế và hướng phát triển	60
	Tài liệu tham khảo	61
A	Chứng minh Mệnh đề 1	67
A.1	Thiết lập và khai triển bậc hai	67
A.2	Bậc độ lớn của các số hạng dịch chuyển	68
A.3	Bậc độ lớn của C_b và R_h , và kết luận	69
B	Chứng minh phương pháp liên hợp và cận sai số	70
B.1	Tính tương đương của biến liên hợp (chứng minh Mệnh đề 2)	70
B.2	Suy ra công thức khai triển (3.8)	71
B.3	Ổn định của đệ quy liên hợp (chứng minh dựa trên Giả thuyết 2)	72

Danh sách hình

1.1	(A) Hình minh họa hiện tượng chuyển giao tiêu cực thông qua ví dụ về bài toán phân loại sử tử và chó sa mạc. (B) Sơ đồ mô hình cấu trúc nhân quả của meta-learning.	3
2.1	Hình minh họa một bài toán nhận diện hình học.	11
2.2	Quá trình MAML tìm kiếm vị trí khởi tạo thuận lợi cho tham số θ_0 trong giai đoạn meta-training.	12
2.3	Minh họa sự thay đổi của không gian biểu diễn F sau thích ứng nhanh.	14
3.1	Pipeline tổng quan của FAMA. Hai quỹ đạo (thích ứng toàn phần và can thiệp đóng băng) được sinh song song từ S_i ; một lượt lan truyền ngược liên hợp duy nhất tính chuỗi $\{\lambda_t\}$ cho mỗi quỹ đạo; tại mỗi bước t , tín hiệu λ_t được chiếu cục bộ lên bản đồ đặc trưng A_{t-1} ; các bản đồ cục bộ được tích lũy theo t rồi lấy hiệu giữa hai nhánh để ra bản đồ quy kết cuối cùng.	32
4.1	Phân phối độ lợi thích ứng ΔM trên hai bài toán min $\rightarrow$ cub và tiered $\rightarrow$ cub.	53
4.2	Bản đồ quy kết trên tác vụ chuyển giao tích cực nhất (ảnh trên) và tác vụ chuyển giao tiêu cực nhất (ảnh dưới) với thử nghiệm $MiniImagenet \rightarrow CUB-200-2011$	55
4.3	Bản đồ quy kết trên tác vụ chuyển giao tích cực nhất (ảnh trên) và tác vụ chuyển giao tiêu cực nhất (ảnh dưới) với thử nghiệm $TieredImagenet \rightarrow CUB-200-2011$	56

Danh sách bảng

4.1	Siêu tham số huấn luyện MAML trên backbone Conv4 (theo cấu hình chuẩn của Finn và cộng sự [10])	46
4.2	Kết quả BiADT: $ABC_{\downarrow}$ và $ABC_{\uparrow}$ trên bộ dữ liệu <i>TieredImageNet</i>	48
4.3	Hệ số tương quan giữa Φ_{FAMA} gốc và $\Phi_{\text{FAMA}}^{(\ell)}$ theo mức độ phá hủy các khối của θ_0^b (Mean $\pm$ MoE, $N = 600$)	49
4.4	Hệ số tương quan giữa Φ_{FAMA} gốc và $\Phi_{\text{FAMA}}^{(\ell)}$ theo mức độ phá hủy các tầng của θ_0^b và θ_0^h trong giả định $\Delta M := \Delta M'$	50
4.5	Hệ số tương quan Spearman và Pearson (Mean $\pm$ MoE) dưới các kịch bản can thiệp tập hỗ trợ	51

Tóm tắt

Học sâu hiện đại phụ thuộc nặng vào dữ liệu lớn, khiến các bài toán thiếu dữ liệu gán nhãn gặp nhiều trở ngại. Trong bối cảnh đó, meta-learning dựa trên gradient, tiêu biểu là MAML, nổi lên như hướng tiếp cận chủ đạo cho học ít mẫu. Tuy nhiên, cơ chế tri thức tiền nghiệm ở tham số khởi tạo θ_0 chi phối quá trình thích ứng nhanh vẫn là hộp đen, khiến chuyển giao tiêu cực (negative transfer) - khi tập hỗ trợ S_i định hướng sai làm giảm hiệu suất — chỉ được phát hiện qua các biểu hiện chứ chưa giải thích được ở cấp độ nguyên nhân. Đề tài đặt mục tiêu xây dựng phương pháp hậu diễn giải nhằm định lượng mức lợi/hại của bước thích nghi và định vị đặc trưng trong tập hỗ trợ gây ra ảnh hưởng đó. Trong đó, đề tài đề xuất độ lợi thích nghi ΔM , đo bằng chênh lệch hàm mất mát trên tập truy vấn giữa hai nhánh can thiệp và không can thiệp quá trình thích ứng, cùng phương pháp Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA) nhằm mở rộng Class Activation Mapping qua nhiều bước gradient để trực quan hóa đặc trưng có lợi/hại. Tính trung thực được kiểm định qua phép xóa-và-đo hai chiều và kiểm tra tính tảo, thực nghiệm trên kiến trúc Conv4 với *miniImageNet*, *tieredImageNet* và *CUB-200-2011*. Kết quả cho thấy hai chỉ số $ABC_{\downarrow}$, $ABC_{\uparrow}$ đạt ý nghĩa thống kê ($p < 0,001$), tương quan tính tảo sụt giảm gần như tức thời khi phá hủy tầng gần đầu ra, và phân tích trên 600 tác vụ chỉ ra "thiên lệch ngữ cảnh" là nguyên nhân cốt lõi gây chuyển giao tiêu cực. Kết quả khẳng định FAMA là công cụ diễn giải trung thực, đáng tin cậy cho thích nghi trong meta-learning, mở ra ứng dụng chẩn đoán, giảm thiểu chuyển giao tiêu cực, và làm nền tảng mở rộng sang kiến trúc sâu hơn.

Chương 1

Phần mở đầu

1.1 Tính cấp thiết của đề tài

Trong khoảng một thập kỷ trở lại đây, học máy (Machine Learning) (ML) nói chung và học sâu (Deep Learning) (DL) nói riêng đã đạt được những thành tựu vượt bậc trên nhiều bài toán thuộc các lĩnh vực khác nhau. Tuy nhiên, phần lớn thành công này dựa trên giả định rằng mô hình có thể được huấn luyện trên một tập dữ liệu quy mô lớn và đa dạng. Đồng thời, mạng có độ sâu càng sâu thì khả năng tổng quát hóa càng cao. Dù vậy, trong tình huống thực tế, giả định này vấp phải một rào cản lớn. Đối với các tác vụ nhạy cảm hoặc mang tính đặc thù cao, nơi việc thu thập dữ liệu bị ràng buộc bởi chi phí, rủi ro, hoặc các rào cản về đạo đức và pháp lý, việc xây dựng một tập dữ liệu đủ lớn là vô cùng thách thức, thậm chí bất khả thi [8], [46].


Xuất phát từ thực tiễn đó, bài toán học ít mẫu (Few-shot Learning) (FSL) vốn đã được đặt nền móng từ trước khi học sâu (Deep Learning) bùng nổ, đã trở nên đặc biệt cấp thiết trở lại trong kỷ nguyên học sâu (Deep Learning). Các phương pháp học ít mẫu (Few-shot Learning) hiện đại ra đời nhằm trực tiếp giải quyết rào cản về dữ liệu, cho phép mô hình học và tổng quát hóa hiệu quả chỉ với một lượng rất nhỏ mẫu được gán nhãn. Trong số các hướng tiếp cận, Meta-Learning (học cách học) [6], [34], là nền tảng đặc trưng và phổ biến nhất cho lớp bài toán này. Đặc biệt, với đột phá của C.Finn và các cộng sự [10], lớp phương pháp dựa trên gradient (gradient-based), tiêu biểu là Model-Agnostic Meta-Learning (MAML) đã trở thành hướng tiếp cận chủ đạo nhờ tính linh hoạt và khả năng tích hợp trên mọi kiến trúc mạng khả vi.

Dù vậy, cũng như phần lớn các mô hình học sâu khác, các mô hình Meta-Learning nói chung và MAML nói riêng vẫn là các mô hình hộp đen

(black-box models). Cơ chế mà tri thức tiền nghiệm (prior knowledge) ẩn chứa trong bộ tham số khởi tạo θ_0 chi phối quá trình thích ứng nhanh (fast-adaptation) trên tập hỗ trợ (support set) S vẫn chưa được biểu diễn một cách tường minh. Sự thiếu minh bạch này đã đặt ra các rào cản lớn trong việc triển khai các hệ thống đòi hỏi độ tin cậy cao, nơi người dùng cần có khả năng kiểm chứng các quyết định của mô hình thay vì chấp nhận các kết quả thuần túy dựa trên sự tương quan thống kê. [3], [17].

Đồng thời, tri thức tiền nghiệm (prior knowledge) không phải lúc nào cũng mang lại lợi ích cho tác vụ đích. Trong các kịch bản phức tạp như tác vụ không đồng nhất (heterogeneous tasks) được phân loại thành dữ liệu khó (hard tasks), dữ liệu nhiễu (noisy tasks), hoặc dữ liệu nằm ngoài phân phối (out-of-distribution) so với giai đoạn meta-training [37], quá trình thích ứng nhanh (fast-adaptation) có thể bị giảm hiệu suất nghiêm trọng. Mà nguyên nhân cốt lõi của sự suy giảm này là hiện tượng chuyển giao tiêu cực (negative transfer). Qua thực nghiệm, Yue và các cộng sự [51] đã chỉ ra rằng khi có sự sai khác về phân phối giữa tập hỗ trợ và tập truy vấn, các mô hình trích xuất đặc trưng (backbone) mạnh thậm chí còn hoạt động kém hơn các mô hình yếu. Điều này xảy ra do mô hình có xu hướng học các tương quan giả (spurious correlations) từ tri thức tiền nghiệm thay vì đặc trưng thực sự của đối tượng, chẳng hạn như dùng bối cảnh nền (cỏ, sa mạc) để phân loại thay vì nhận diện con vật. Dưới góc nhìn của mô hình cấu trúc nhân quả (Structural Causal Model - SCM), tri thức tiền nghiệm (D) đã vô tình mở ra các luồng nhân quả sai lệch (backdoor paths), như tri thức sinh ra đặc trưng sai lệch ($D \rightarrow X$) hoặc tri thức sinh ra ngữ cảnh sai lệch ($D \rightarrow X \rightarrow C$), khiến mô hình đưa ra quyết định dựa trên đặc trưng hoặc bối cảnh thiên lệch này thay vì bản chất cốt lõi của dữ liệu (Hình 2.1).

Dù tác động của việc chuyển giao tiêu cực đã được ghi nhận, các nghiên cứu hiện tại chủ yếu mới chỉ nhận diện hiện tượng này thông qua biểu hiện của sự sụt giảm độ chính xác trên tác vụ đích, thay vì giải thích tường minh ở cấp độ nguyên nhân của bản thân quá trình thích ứng nhanh vẫn còn tồn tại như một dạng hộp đen. Một kết quả khác do Raghu và các cộng sự [28] công bố, đã chỉ ra phần lớn hiệu quả của MAML thực chất đến từ việc tái sử dụng đặc trưng (feature reuse) thông qua việc thực hiện



Hình 1.1: (A) Hình minh họa hiện tượng chuyển giao tiêu cực thông qua ví dụ về bài toán phân loại sử tử và chó sa mạc. (B) Sơ đồ mô hình cấu trúc nhân quả của meta-learning.

đóng băng phần thân trích xuất đặc trưng (backbone) và chỉ cho phép phần đầu bộ phân lớp (head) được cập nhật thích ứng. Ngược lại, Oh và các cộng sự [21] chỉ ra đối với các tác vụ ngoài phân phối (cross-domain), việc đảo ngược quá trình, đóng băng phần đầu và chỉ cập nhật phần trích xuất đặc trưng (backbone) mới giúp mô hình thích ứng vượt trội thông qua việc thay đổi biểu diễn (representation change). Từ hai kết quả này, đã cho ta một giả thuyết cốt lõi về vai trò của tập hỗ trợ S . Trong đó, đóng vai trò như một tín hiệu điều hướng (steering signal) - hoặc tổ hợp lại tri thức cũ, hoặc tái cấu trúc biểu diễn mới - trên không gian đặc trưng đã được thiết lập từ quá trình meta-training. Hệ quả là, bản thân tập hỗ trợ S đã cụ thể hóa các biến nhiễu ẩn từ tri thức tiền nghiệm, làm bóp méo tín hiệu điều hướng và dẫn dắt mô hình hội tụ vào các tương quan giả trong bước thích ứng. Giả thuyết này được củng cố mạnh mẽ bởi Parast và các cộng sự [22] trong nghiên cứu gần đây cho thấy việc trực tiếp can thiệp lên các biểu diễn nhúng của tập S (support embeddings) trên một không gian đặc trưng đã được đóng băng có thể ngăn chặn hiệu quả việc mô hình đi chệch hướng.

Tuy nhiên tất cả các phương pháp trên, chỉ dừng ở việc **hiệu chỉnh** các biểu diễn hoặc cơ chế thích ứng nhằm cải thiện hiệu suất khái quát hóa của tác vụ đích, mà không nhằm **giải thích cho con người** về cơ chế mà tập hỗ trợ S đã định hướng như thế nào?

Ở một khía cạnh khác, lĩnh vực Explainable AI (XAI) trong những năm gần đây đã được giới học thuật đã chú ý trở lại và đạt được nhiều thành công đáng kể trong việc khai mở và giải thích các mô hình hộp đen.

Tiêu biểu là các phương pháp diễn giải cục bộ (local explanation) như Grad-CAM [36] hay SHAP [18] đã được đề xuất, áp dụng và nghiên cứu cải tiến một cách rộng rãi. Dù vậy, việc tích hợp các kỹ thuật giải thích này vào những kiến trúc tối ưu hai tầng như meta-learning hay MAML vẫn còn rất hạn chế.

Đối với dữ liệu phi cấu trúc như hình ảnh, các nỗ lực diễn giải chủ yếu chỉ tập trung vào giai đoạn sau thích ứng (post-adaptation) như Grad-CAM cục bộ [43], mà hoàn toàn bỏ qua quá trình thích ứng. Nổi bật gần đây có phương pháp TL-XML do Mitsuka và các cộng sự đề xuất [19] nhằm mở rộng hàm ảnh hưởng (influence functions) sang cấp độ tác vụ (task-level) để định lượng tác động của dữ liệu meta-training lên hành vi thích ứng. Nhưng nhược điểm của phương pháp này là sự phụ thuộc hoàn toàn vào dữ liệu huấn luyện gốc, gây ra rào cản khổng lồ về chi phí tính toán và tính khả thi trong các ứng dụng thực tế nơi dữ liệu meta-training bị đóng gói hoặc bảo mật.

Xuất phát từ khoảng trống trên, nghiên cứu này đặt ra câu hỏi trung tâm, *điều gì gây ra negative transfer trong quá trình thích ứng nhanh của meta-learning?*. Và câu hỏi này có thể được cụ thể hóa thành hai câu hỏi nghiên cứu theo thứ tự lần lượt như sau. Thứ nhất, quá trình thích ứng từ tri thức tiền nghiệm (prior knowledge) sang tri thức cụ thể (specific knowledge) với một tác vụ đích cho trước là có lợi hay có hại, và mức độ ảnh hưởng của nó là bao nhiêu? Thứ hai, những đặc trưng nào trong tập hỗ trợ S là nguyên nhân gây ra ảnh hưởng tích cực hay tiêu cực đó, và chúng nằm ở đâu trong không gian đặc trưng F ?

Để giải quyết và trả lời hai câu hỏi nghiên cứu trên, thứ đòi hỏi không chỉ là một cơ chế diễn giải đơn lẻ mà là một độ đo định lượng kết hợp cùng một cơ chế hậu diễn giải (post-hoc explanation) đáng tin cậy nhằm truy vết ngược nguyên nhân từ cho quá trình thích ứng nhanh là cần thiết và cấp bách.

1.2 Mục tiêu nghiên cứu

Xuất phát từ khoảng trống đã được phân tích ở phần 1.1 với hai câu hỏi nghiên cứu đã nêu, mục tiêu của đề tài hướng đến việc xây dựng một

cơ chế hậu diễn giải kép (post-hoc explanation framework) gồm hai thành phần chính, cùng với các bài kiểm tra thực nghiệm nhằm chứng minh tính trung thực và độ tin cậy của khung phương pháp này.

Với mục tiêu thứ nhất, là xây dựng một độ đo định lượng ứng với thành phần đầu tiên trong cơ chế diễn giải, nhằm xác định mức độ lợi/hại của các bước thích ứng nhanh trên một tác vụ đích cụ thể. Đồng thời, độ đo này phải nhạy cảm với sự thay đổi của S , thay vì chỉ đo hiệu suất tổng thể như độ chính xác truyền thống.

Với mục tiêu thứ hai, là xây dựng một phương pháp diễn giải thông qua trực quan hóa nhằm định vị các đặc trưng trong S , ứng với vị trí trong không gian đặc trưng chung F , đóng góp tích cực hay tiêu cực cho độ lợi thích ứng đo được ở thành phần thứ nhất.

Cuối cùng, đề tài đặt mục tiêu là thông qua các thực nghiệm định lượng lẫn định tính trên các bộ dữ liệu và kiến trúc mô hình chuẩn, nhằm minh chứng cho phương pháp được đề xuất là hiệu quả, trung thực (fairfulness) và đáng tin cậy (trustworthiness) trong việc phản ánh đúng cơ chế thích ứng.

1.3 Phương pháp tiếp cận

Tương ứng với các mục tiêu đã nêu, đề tài đề xuất một khung phương pháp gồm hai thành phần nối tiếp nhau, kết hợp cùng các phép kiểm định nhằm đảm bảo tính trung thực của cơ chế diễn giải. Đối với mục tiêu thứ nhất, để định lượng quá trình thích ứng, chúng tôi đề xuất xây dựng đại lượng **độ lợi thích ứng (adaptation gain)** ΔM dựa trên mức chênh lệch giá trị mất mát của tập truy vấn Q tại thời điểm sau khi thực hiện quá trình thích ứng nhanh với hai trường hợp thích ứng toàn phần và thích ứng phần đầu của bộ phân lớp (head). Giá trị này vừa trả lời cho câu hỏi định lượng đầu tiên, vừa cung cấp hàm mục tiêu cho bước giải thích. Đối với mục tiêu thứ hai, để truy vết nguyên nhân của ΔM thông qua các biểu diễn trên tập hỗ trợ, chúng tôi giới thiệu thuật toán **Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)** dựa nền tảng của phương pháp liên hợp (Adjoint method) cho phép mở rộng kỹ thuật

diễn giải của Grad-CAM vượt ra khỏi phạm vi một lớp mạng đơn lẻ để quét qua toàn bộ chuỗi gradient liên tiếp của quá trình thích ứng. Nhờ cơ chế này, FAMA có khả năng chiếu giá trị ΔM lên không gian đặc trưng chung F của tập S , qua đó cô lập chính xác các biểu diễn mang lại giá trị tích cực hoặc tiêu cực đối với tác vụ đích.

Cuối cùng, để kiểm chứng tính trung thực (fairfulness) của cơ chế diễn giải, chúng tôi thiết lập hai chuyên biệt dựa trên các bài kiểm tra nền tảng truyền thống. Đầu tiên, chúng tôi phát triển bài kiểm tra Bi-directional Attribution Deletion Test (BiADT), được điều chỉnh từ các phương pháp kiểm tra xóa-và-đo (deletion test) truyền thống để áp dụng vào bối cảnh động của quá trình thích ứng nhanh. Với mục đích là minh rằng các vùng phân bổ do FAMA chỉ ra có tác động trực tiếp đến hành vi thay đổi độ lợi thích ứng của mô hình. Thứ hai, chúng tôi áp dụng bài kiểm tra sự tỉnh táo (sanity check) theo đề xuất của Adebayo và các cộng sự [2], được hiệu chỉnh để chứng minh rằng các phân bổ đặc trưng của FAMA không phải là kết quả ngẫu nhiên, mà phụ thuộc mật thiết vào cả tham số khởi tạo θ_0 (tri thức tiền nghiệm được rút ra từ quá trình meta-training) lẫn cấu trúc biểu diễn thực tế của tập hỗ trợ S . Thông qua đó, chúng tôi bảo chứng rằng FAMA phản ánh chính xác cơ chế diễn giải mô hình thay vì chỉ thực hiện các phép biến đổi hình ảnh vô nghĩa.

1.4 Đóng góp của đề tài

Trong khuôn khổ luận văn, đề tài mang lại các đóng góp chính sau.

Thứ nhất, đề tài thiết lập một cách tiếp cận mới trong việc nghiên cứu hiện tượng chuyển giao tiêu cực (negative transfer) trong Meta-Learning. Thay vì dừng lại ở việc nhận diện thông qua biến thiên độ chính xác, chúng tôi phát biểu negative transfer trong meta-learning như một bài toán hậu diễn giải ở cấp độ đặc trưng cho *bản thân quá trình thích ứng nhanh (fast-adaptation)*, dựa trên khoảng trống đã được hệ thống hóa qua khảo sát các công trình liên quan (Mục 2.2.5) — theo đó, chưa ghi nhận phương pháp nào kết hợp đồng thời cả ba đặc điểm: diễn giải được cho con người, tổng hợp thông tin qua toàn bộ quỹ đạo thích ứng, và không đòi hỏi quyền truy cập dữ liệu meta-training. (Chương 3).

Thứ hai, đề tài đề xuất **độ lợi thích ứng** (ΔM), là một độ đo định lượng nhằm đánh giá tường minh mức độ lợi - hại mà quá trình thích ứng mang lại cho một tác vụ đích cụ thể. Nhằm tạo cơ sở để phát hiện và cô lập hiện tượng chuyển giao tiêu cực từ khía cạnh hiệu suất (Chương 3).

Thứ ba, đề tài giới thiệu Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA), là cơ chế diễn giải trực quan (visual explanation) có khả năng truy vết trên không gian đặc trưng chung F để chỉ ra các đặc trưng có lợi hay có hại cho quá trình thích ứng trong tập hỗ trợ. Từ đó hỗ trợ phát hiện và khắc phục được hiện tượng chuyển giao tiêu cực (negative transfer) bằng cách hiệu chỉnh các điểm dữ liệu trong tập hỗ trợ S để mô hình đạt được hiệu suất tốt nhất cho tác vụ đích. (Chương 3).

Thứ tư, đề tài hiệu chỉnh và đưa ra hai bài kiểm tra lần lượt là BiADT và sanity check tương ứng với bối cảnh thích ứng nhanh của các phương pháp dựa trên MAML nói riêng và các phương pháp Meta-Learning nói chung. Hai phương pháp này mang tính tổng quát và không phụ thuộc vào phương pháp FAMA và có thể áp dụng để kiểm định tính trung thực và khả năng tin cậy của bất kỳ phương pháp XAI nào khác được phát triển cho bài toán thích ứng nhanh trong Meta-Learning trong tương lai (Chương 4).

1.5 Bố cục luận văn

Phần còn lại của luận văn được tổ chức thành các chương như sau:

- **Chương 2 - Tổng quan nghiên cứu:** Trình bày các nền tảng lý thuyết về học ít mẫu (Few-shot Learning), Meta-Learning, tập trung vào cấu trúc tối ưu hóa hai tầng (bi-level) của MAML. Bên cạnh đó, các lý thuyết về hậu diễn giải (post-hoc explanation). Trên cơ sở đó, các công trình liên quan cũng sẽ được xem xét nhằm chỉ ra các hạn chế còn tồn đọng.
- **Chương 3 - Phương pháp đề xuất:** Phát biểu bài toán và trình bày chi tiết hai thành phần chính của cơ chế diễn giải. Bao gồm việc xây dựng **độ lợi thích ứng** ΔM và **phương pháp Phân bổ**

Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA), các cơ sở lý thuyết và ý nghĩa của chúng.

- **Chương 4 - Thực nghiệm và đánh giá:** Mô tả thiết lập thực nghiệm trên các bộ dữ liệu chuẩn và các phương pháp đối chứng. Đồng thời, cũng trình bày kết quả phân tích định lượng lẫn định tính qua các bài kiểm định tính trung thực và độ tin cậy của FAMA.
- **Chương 5 - Kết luận và hướng phát triển:** Tổng kết các kết quả đạt được của luận văn, và thảo luận về những hạn chế hiện tại của phương pháp, và đề xuất các hướng phát triển tiềm năng trong tương lai.

Chương 2

Tổng quan nghiên cứu

2.1 Cơ sở lý thuyết

2.1.1 Bài toán học ít mẫu (Few-shot Learning) (FSL) và Meta-Learning

Bài toán học ít mẫu (Few-shot Learning) (FSL) khởi nguồn từ các công trình về one-shot learning dựa trên suy luận Bayesian, khai thác tri thức đã học từ các lớp đối tượng trước đó để nhận diện một lớp mới chỉ từ một hoặc vài mẫu quan sát [9]. Khái niệm này ra đời từ trước khi học sâu (Deep Learning) bùng nổ, nhưng đã trở nên đặc biệt cấp thiết trở lại trong kỷ nguyên deep learning và từ đó phát triển thành một nhánh nghiên cứu riêng với hàng loạt phương pháp dựa trên mạng nơ-ron sâu, tập trung xây dựng các mô hình có khả năng khái quát hóa mạnh mẽ trên các lớp hoặc tác vụ mới mà không cần thu thập lượng dữ liệu quy mô lớn [46].

Về mặt hình thức, FSL phổ biến nhất với bài toán N -way K -shot, nơi mô hình cần xử lý các tác vụ, phân biệt N lớp, với điều kiện mỗi lớp chỉ có K mẫu được gán nhãn. Để mô hình đạt được năng lực khái quát hoá này, quá trình huấn luyện được tổ chức theo cơ chế *episodic training* trên một tập hợp các tác vụ nền (base tasks) phong phú, gọi là giai đoạn *meta-training*. Hiệu suất của mô hình sau đó sẽ được kiểm chứng trên các tác vụ hoàn toàn mới, không trùng lặp với giai đoạn trước, giai đoạn này gọi là *meta-testing*. Mỗi tác vụ $\mathcal{T}_i$ trong cả hai giai đoạn đều được phân tách thành hai tập con biệt lập, gồm tập hỗ trợ (support set) $S_i = \{(x_k^S, y_k^S)\}_{k=1}^{N \times K}$, đóng vai trò như một "cuốn sách giáo khoa" chỉ với vài mẫu để mô hình được phép quan sát và thích ứng nhanh chóng, và tập truy vấn (query set) $Q_i = \{(x_k^Q, y_k^Q)\}_{k=1}^M$, dùng để đánh giá năng lực của

mô hình sau thích ứng.

Dựa trên cách thức khai thác tri thức tiên nghiệm (prior knowledge), FSL thường được phân thành ba nhóm phương pháp chính [40], [46]: tăng cường dữ liệu (data augmentation/hallucination), học chuyển giao (transfer learning) và Meta-Learning. Trong đó, **Meta-Learning** hay còn gọi là "học cách học" tiếp cận bài toán bằng cách tối ưu hóa trên toàn bộ phân phối tác vụ $p(\mathcal{T})$ thay vì một tác vụ đơn lẻ. Mục tiêu của Meta-Learning là tìm kiếm một cơ chế thích ứng sao cho mô hình đạt được hiệu năng tối ưu trên tập truy vấn Q_i sau khi đã tiếp nhận tín hiệu từ tập hỗ trợ S_i của tác vụ $\mathcal{T}_i$ tương ứng.

Dựa trên thành phần được tối ưu ở cấp độ phân phối tác vụ, các phương pháp Meta-Learning được chia thành ba nhóm tiêu biểu [11].


Nhóm thứ nhất, là các phương pháp **Metric-based** học trên không gian nhúng (embedding space) sao cho khoảng cách giữa các mẫu trong cùng một lớp được tối thiểu, với tiêu biểu là Matching Networks [44] và Prototypical Networks [39]. **Nhóm thứ hai**, là các phương pháp **Model-based** sử dụng kiến trúc bộ nhớ ngoài hoặc siêu mạng (hyper-network) để trực tiếp sinh ra tham số cho tác vụ mới, mà tiêu biểu là Memory-Augmented Neural Networks [33]. **Cuối cùng**, là các phương pháp **Optimization-based** thực hiện việc thích ứng một cách tường minh qua các bước cập nhật gradient trên tập hỗ trợ S . Đây cũng là nhóm phương pháp có liên quan mật thiết nhất đến luận văn này, với đại diện tiêu biểu là MAML do C.Finn và các cộng sự đề xuất [10].

2.1.2 Model-Agnostic Meta-Learning (MAML)

Model-Agnostic Meta-Learning (MAML) [10] là đại diện tiêu biểu và có ảnh hưởng nhất trong nhóm các phương pháp dựa trên tối ưu hoá. Tiếp nối thành công của MAML nhiều biến thể đã được đề xuất nhằm tối ưu hóa quá trình học như Reptile [20] (một xấp xỉ bậc một của MAML), Meta-SGD [16] - tự động hóa việc học tốc độ học (learning rate) như một siêu tham số, ALFA [5] - học một cơ chế sinh siêu tham số thích ứng theo từng bước và từng tác vụ, Meta-Curvature [23] - học một ma trận tiền điều kiện (preconditioner) để định hình lại hình học của không

gian tham số trong inner loop, iMAML [29] - sử dụng định lý hàm ẩn để tránh phải lan truyền ngược qua toàn bộ quỹ đạo T bước của inner loop. Mà điểm chung của toàn bộ các phương pháp dựa trên tối ưu hoá này là chúng đều thừa nhận vai trò trung tâm của tập hỗ trợ S như một "lực định hướng" cho quá trình thích ứng thông qua quá trình tối ưu hai tầng (bi-level optimization) đối với bộ tham số khởi tạo chung (shared initialization parameters) θ_0 .

Cụ thể, để giải quyết bài toán học ít mẫu (Few-shot Learning), MAML dựa trên cảm hứng về cơ chế học tập của con người. Trong suốt cuộc đời, con người sử dụng tri thức tích lũy từ quá khứ để nắm bắt nhanh các cấu trúc đặc thù của một bài toán mới. Chẳng hạn, khi đối diện với các bài toán hình học lạ, con người tận dụng tri thức về số lượng cạnh, đỉnh hay tính chất bất biến của phép quay để truy xuất lời giải thay vì bắt đầu từ con số không (Hình 2.1).



Hình 2.1: Hình minh họa một bài toán nhận diện hình học.


Dựa trên cơ chế đó, MAML giải quyết bài toán học ít mẫu (Few-shot Learning) thông qua một quá trình tối ưu gồm hai tầng (Hình 2.2). Với tầng lặp trong (inner loop), mô hình học xuất phát từ tham số khởi tạo chung θ_0 thực hiện T bước cập nhật gradient trên hàm mất mát tính trên tập hỗ trợ S_i của tác vụ $\mathcal{T}_i$, theo phương trình 2.1.

$$\phi_j = \phi_{j-1} - \alpha \nabla_{\phi} \mathcal{L}_{S_i}(\phi_{j-1}), \quad j = 1, 2, \dots, T, \quad \phi_0 = \theta_0 \quad (2.1)$$

Trong đó α là tốc độ học của inner loop, và nghiệm sau T bước được ký hiệu là $\phi_i^* := \phi_T$. Sau đó, ở tầng lặp ngoài (outer loop), tham số khởi tạo chung θ_0 sẽ được cập nhật theo phương trình 2.2 sao cho tổng (hoặc trung bình) giá hàm mất mát trên các tập truy vấn Q_i , tính tại nghiệm đã thích ứng ϕ_i^* , được tối thiểu hoá trên toàn bộ phân phối tác vụ.

$$[h]\theta = \theta_0 - \beta \nabla_{\theta} \sum_k \mathcal{L}_{Q_i}(\phi_i^*) \quad (2.2)$$

Trong đó, β là tốc độ học của outer loop, $\mathcal{L}_{Q_i}$ là hàm mất mát trên tập truy vấn Q_i với mô hình sau khi cập nhật bởi inner loop và $\sum_k$ là tổng hàm mất mát của tất cả các tác vụ trong một meta-batch.



Hình 2.2: Quá trình MAML tìm kiếm vị trí khởi tạo thuận lợi cho tham số θ_0 trong giai đoạn meta-training.

Để lý giải cơ thích ứng nhanh của MAML, Raghu và các cộng sự [28] đã thực hiện thí nghiệm đóng băng phần thân trích xuất đặc trưng (backbone) θ_0^b và chỉ cho phép phần đầu phân loại (head) θ_0^h cập nhật trong inner loop - thuật toán ANIL (Almost No Inner Loop). Bằng cách so sánh biểu diễn của backbone trước và sau thích ứng thông qua CCA và CKA, nhóm tác giả cho thấy các lớp tích chập gần như không dịch chuyển, trong khi chỉ riêng head thay đổi đáng kể. Từ đó, đi tới kết luận rằng hiệu quả của MAML chủ yếu đến từ việc θ_0 đã sẵn mang những đặc trưng tổng quát, có thể tái sử dụng nguyên trạng các đặc trưng này cho hầu hết tác vụ mới (feature reuse). Trạng thái này được khái quát hóa tại Hình 2.3 A, trong đó không gian biểu diễn sau thích ứng (ϕ_i^*) duy trì sự đồng nhất gần như


tuyệt đối với không gian tiên nghiệm (θ_0). Cũng đồng nghĩa với việc vai trò thực sự của S_i , trong trường hợp này, chỉ là căn chỉnh lại ranh giới quyết định ở phần đầu phân loại (head) cho phù hợp với từng tác vụ cụ thể.

Mặc dù vậy, giả thuyết về tính phổ quát của việc *tái sử dụng đặc trưng* (*feature reuse*) bộc lộ sự hạn chế khi đối mặt với sự dịch chuyển phân phối (distribution shift) lớn giữa miền dữ liệu huấn luyện (meta-training) và miền kiểm tra (meta-testing). Oh và các cộng sự [21] đã phản bác hệ quả của ANIL thông qua một can thiệp kiến trúc đối xứng mang tên BOIL (Body Only Inner Loop) — chỉ cập nhật θ_0^b và đóng băng θ_0^h . Kết quả là trên các môi trường có miền dữ liệu khác nhau (cross-domain), tri thức tiên nghiệm θ_0 không chứa sẵn các biểu diễn có lợi và phù hợp cho tác vụ đích buộc phải dưới áp lực của S_i dần bị thu hẹp và bị triệt tiêu tối đa, nhường chỗ cho sự dịch chuyển và hình thành các vùng biểu diễn hoàn toàn mới (Hình 2.3 B).

Từ sự đối lập của hai cơ chế trên, có thể thấy MAML tiêu chuẩn khi không bị ràng buộc bởi việc đóng băng trên toàn bộ mạng, đã cho phép nó hoạt động dựa trên một trạng thái linh hoạt điều chỉnh tỷ trọng giữa việc "tái sử dụng" và "tái cấu trúc". Lập luận này được củng cố bởi các thí nghiệm do Gou và các cộng sự thực hiện kiểm chứng trên các tập dữ liệu có sự khác biệt lớn, với kết luận tỷ trọng biến đổi của phần thân (backbone) tỷ lệ thuận với khoảng cách phân phối dữ liệu (domain shift). Hệ quả là, không gian biểu diễn chung F của MAML sau khi thích ứng trở thành một môi trường giao thoa phức hợp bao gồm ba miền, (1) miền kế thừa nguyên trạng từ θ_0 , (2) miền đặc trưng cũ bị bẻ cong/điều biến dưới áp lực của S_i , và (3) miền tiếp thu các cấu trúc hoàn toàn mới (Hình 2.3 C).

2.1.3 Explainable AI (XAI)

Mặc dù MAML và các biến thể đã chứng minh được hiệu quả trong việc cải thiện *phương thức* thích ứng, cơ chế vận hành của "lực định hướng" này tại cấp độ đặc trưng vẫn là một dạng "hộp đen". Các phương pháp hiện nay chưa cung cấp một lý giải tường minh cho câu hỏi: *Tại sao một tập hỗ trợ cụ thể lại điều hướng mô hình tới một hướng thích ứng nhất định?* Sự



Hình 2.3: Minh họa sự thay đổi của không gian biểu diễn F sau thích ứng nhanh.

thiếu vắng này đặc biệt đáng chú ý tại không gian đặc trưng chung F . Dẫn đến việc chúng ta không thể truy vết được nguồn gốc của các tương quan giả khi mô hình rơi vào trạng thái chuyển giao tiêu cực (negative transfer).

Explainable AI (XAI) là lĩnh vực nghiên cứu các phương pháp giúp con người hiểu được cơ chế ra quyết định của một mô hình học máy, ra đời như một phản ứng tất yếu trước sự phát triển của các mô hình học sâu. Trong khi các mô hình như hồi quy tuyến tính hay cây quyết định vốn có tính minh bạch nội tại (intrinsic model), cho phép truy vết trực tiếp đường đi từ đặc trưng đầu vào đến dự đoán đầu ra, thì các kiến trúc phức tạp hơn như mạng nơ-ron sâu lại đánh đổi tính minh bạch đó để lấy độ chính xác, trở thành những mô hình "hộp đen" mà cơ chế nội tại không thể quan sát trực tiếp.

Dựa trên thời điểm can thiệp vào mô hình, các kỹ thuật XAI được chia thành hai nhóm. *Ante-hoc*, với tính khả diễn giải được tích hợp ngay từ khi thiết kế kiến trúc mô hình (cây quyết định, cơ chế attention, Self-Explaining Neural Networks) và *post-hoc*, với các kỹ thuật diễn giải được áp dụng ngay sau khi mô hình đã huấn luyện xong, nhằm phân tích và diễn giải một mô hình đã có mà không cần huấn luyện lại. Do các phương pháp post-hoc không yêu cầu thay đổi kiến trúc hay quy trình huấn luyện gốc của mô hình, nên chúng có tính linh hoạt cao và có thể áp dụng cho các mô hình hộp đen phức tạp đã được huấn luyện. Theo Arrieta và các

cộng sự [4], các kỹ thuật post-hoc thường dựa trên một trong ba cách tiếp cận chính. Gồm, đơn giản hoá mô hình (model simplification, xây dựng một mô hình thay thế — surrogate — dễ diễn giải hơn để xấp xỉ hành vi cục bộ của mô hình hộp đen, như LIME), độ liên quan đặc trưng (feature relevance explanation, xếp hạng mức độ quan trọng của từng đặc trưng đầu vào đối với một dự đoán cụ thể, như SHAP) và cuối cùng là trực quan hoá (visual explanation, cho phép con người quan sát trực tiếp bằng hình ảnh cơ chế mà mô hình đưa ra quyết định).

Trong ba hướng trên, trực quan hoá cho phép con người dễ dàng diễn giải lựa chọn của mô hình thông qua hình ảnh trực quan thay vì các con số trừu tượng. Tiêu biểu đối với các mạng nơ-ron tích chập (CNN) dùng cho các bài toán thị giác máy tính, các kỹ thuật trực quan hoá mức độ đóng góp (attribution visualization) đã được phát triển nhằm định vị và làm nổi bật những vùng đầu vào chi phối mạnh nhất đến kết quả dự đoán của mô hình. Khởi nguồn cho hướng tiếp cận này là bản đồ nổi bật (saliency map) của Simonyan và các cộng sự [38], sử dụng đạo hàm điểm ảnh (vanilla gradient) ứng với một lớp mục tiêu để sinh ra bản đồ có cùng kích thước không gian với ảnh đầu vào, qua đó định lượng trực tiếp mức độ đóng góp của từng vị trí vào quyết định của mô hình. Kế thừa nền tảng này, Guided Backpropagation [41] sau đó đã điều chỉnh lại quy tắc lan truyền ngược qua hàm kích hoạt ReLU nhằm triệt tiêu các gradient âm, từ đó tạo ra bản đồ phân bố sắc nét hơn, dù vẫn bị giới hạn ở các điểm ảnh riêng lẻ. Nhằm dịch chuyển trọng tâm phân tích sang các vùng không gian ngữ nghĩa, Zhou và các cộng sự [52] đề xuất Class Activation Mapping (CAM) bằng cách chèn thêm lớp global average pooling vào cuối kiến trúc mạng. Tuy nhiên, đổi lại CAM đòi hỏi phải thay đổi kiến trúc gốc và huấn luyện lại mô hình. Để khắc phục điểm nghẽn này, Gradient-weighted Class Activation Mapping (Grad-CAM) [35] đã tổng quát hoá CAM, cho phép áp dụng hậu diễn giải (post-hoc) trên mọi mạng CNN mà không cần can thiệp kiến trúc. Bằng cách tận dụng gradient của lớp mục tiêu lan truyền ngược đến lớp tích chập cuối cùng, Grad-CAM đã tổng hợp thành một bản đồ nhiệt không gian, một đặc tính vô cùng giá trị khi làm việc với các mô hình đã huấn luyện sẵn. Mặc dù vậy, một điểm mù cố hữu của toàn bộ các biến thể CAM là việc trích xuất tín hiệu diễn giải luôn bị bó hẹp tại một

trạng thái tham số tĩnh duy nhất, tức thời điểm suy luận sau khi mạng đã hội tụ. Đặc tính tĩnh này khiến chúng trở nên bất lực khi phải giải phẫu hệ động lực học của quá trình thích ứng nhanh (fast adaptation), nơi không gian biểu diễn không đứng yên mà liên tục biến thiên qua từng bước cập nhật gradient.

2.1.4 Correctness và trustworthiness của một phương pháp XAI

Theo Hướng dẫn Đạo đức cho AI Đáng tin cậy (Ethics Guidelines for Trustworthy AI) của Nhóm chuyên gia cấp cao về AI thuộc Ủy ban Châu Âu (EC) [13], tính minh bạch (transparency), bao hàm khả năng diễn giải (explainability), là một trong bảy yêu cầu tiên quyết để kiến tạo một hệ thống AI đáng tin cậy (*trustworthy*). Dẫu vậy, cần phân định rạch ròi giữa hai cấp độ khái niệm: "đáng tin cậy" là thuộc tính vĩ mô của *toàn bộ hệ thống*, trong khi một phương pháp XAI, để đóng góp vào thuộc tính này, trước hết phải tự chứng minh được **tính đúng đắn** (*correctness*) nội tại. Cụ thể, điều này đòi hỏi mức độ trung thành (*faithfulness*) tuyệt đối của lời giải thích đối với cơ chế ra quyết định thực tế của mô hình, hoàn toàn độc lập với việc lời giải thích đó "nhìn có vẻ hợp lý" dưới lăng kính trực giác cảm quan của con người.

Để định lượng tính trung thành này, **nguyên lý thứ nhất** được thiết lập dựa trên kỹ thuật nhiễu loạn đặc trưng, nổi bật là phép kiểm định *xóa-và-đo* (deletion test) do Samek và các cộng sự [32] đặt nền móng. Với ý tưởng cốt lõi là nếu bản đồ phân bố định vị chuẩn xác các vùng đầu vào mang tính quyết định, thì việc tuần tự che khuất các vùng này (bằng nhiễu hoặc giá trị nền) theo thứ tự độ quan trọng giảm dần sẽ khiến hiệu năng dự đoán của mô hình suy sụp nhanh hơn đáng kể so với việc xóa ngẫu nhiên. Kế thừa tư tưởng này, Petsiuk và các cộng sự [25] đã tiêu chuẩn hóa thành hai độ đo nghịch đảo — *Xóa* (*Deletion*) và *Thêm* (*Insertion*) — cho phép đánh giá khách quan tính trung thành thông qua diện tích dưới đường cong (AUC) của biểu đồ hiệu năng, qua đó triệt tiêu hoàn toàn sự phụ thuộc vào sự phán xét chủ quan của mắt người.

Nguyên lý thứ hai, được biết đến qua các phép kiểm tra tính hợp lý (sanity checks) do Adebayo và các cộng sự [2] đề xuất, lại tập trung vào

khả năng phản chiếu tri thức. Nguyên lý này lập luận, "một bản đồ phân bố đích thực phải thể hiện sự *nhạy cảm* trước những biến động phá vỡ cấu trúc tri thức tiềm ẩn của mạng". Thông qua kỹ thuật ngẫu nhiên hóa tham số lan truyền ngược từ lớp đầu ra (*cascading randomization*), nhóm tác giả chỉ ra việc nếu bản đồ phân bố gần như bất biến dù trọng số mô hình đã bị phá hủy ngẫu nhiên, phương pháp XAI đó thực chất không trích xuất bất kỳ tri thức nào, mà chỉ đang hoạt động như một bộ dò biên cạnh (edge detector) vô tri. Nghiên cứu này đã chỉ ra lỗ hổng nghiêm trọng của nhiều phương pháp XAI phổ biến khi chúng hoàn toàn trơ trước các lớp trọng số bậc cao, và bị che đậy đằng sau hình thức trực quan.

Tuy nhiên, như đã phân tích trước đó, dù cả hai nguyên lý trên đều cung cấp một khung đánh giá vững chắc, nhưng cũng đều tồn tại một điểm mù cố hữu. Chúng được thiết kế dành riêng cho các kiến trúc mô hình *tĩnh*, nơi tín hiệu diễn giải được trích xuất từ một trạng thái tham số bất động tại một thời điểm suy luận duy nhất. Khi áp đặt vào hệ động lực học của quá trình thích ứng nhanh (fast-adaptation), nơi các bản đồ phân bố được trích xuất liên tục chạy dọc theo một quỹ đạo cập nhật gradient, tính hiệu lực của các nguyên lý này lập tức bị thách thức. Bài toán làm thế nào để định lượng tính trung thành của một diễn giải XAI không chỉ tại một tọa độ tĩnh, mà xuyên suốt *một chuỗi các biến thiên tham số liên tiếp*, hiện vẫn là một "vùng tối" chưa có lời giải trong cộng đồng nghiên cứu, đòi hỏi một nỗ lực tái định chuẩn và mở rộng hệ thống đo lường toàn diện.

2.2 Các nghiên cứu liên quan

Dựa trên nền tảng lý thuyết ở Mục 2.1, chúng tôi tiến hành rà soát bốn nhóm nghiên cứu liên quan trực tiếp đến đề tài. Gồm, các phương pháp hiện có giải quyết bài toán tác vụ không đồng nhất (heterogenous task) và hiện tượng Negative Transfer (Mục 2.2.1), các công cụ hiện có cho hậu diễn giải (post-hoc) tổng quát dựa trên gradient và nhiễu loạn (perturbation) (Mục 2.2.2), khảo sát các phương pháp diễn giải hiện đang áp dụng riêng cho meta-learning (Mục 2.2.3) và attribution dựa trên quỹ đạo tham số (Mục 2.2.4). Mục 2.2.5 tổng hợp lại toàn bộ và chỉ ra các khoảng trống

còn tồn tại.

2.2.1 Tác vụ không đồng nhất (heterogeneous task) và hiện tượng Negative Transfer

Phần lớn các phương pháp meta-learning giả định ngầm rằng tập hợp tác vụ dùng để meta-training tương đối đồng nhất (*homogeneous*), sao cho một điểm khởi tạo chung θ_0 duy nhất là đủ tốt cho mọi tác vụ [10], [33], [39], [44]. Một nhánh nghiên cứu song song đã chỉ ra giả định này thường bị vi phạm trong thực tế, khi các tác vụ đích đến từ phân phối tác vụ không đồng nhất (task heterogeneous) với phân phối tác vụ trong giai đoạn meta-training. Dẫn đến sự ra đời của các cơ chế tùy chỉnh (customize) tri thức tiên nghiệm theo từng cụm hoặc nhóm tác vụ thay vì chia sẻ toàn cục.

Yao và các cộng sự đã đề xuất Hierarchically Structured Meta-Learning (HSML) [48], tổ chức các tác vụ thành một cấu trúc phân cụm phân cấp, qua đó đặc thù hóa tri thức chuyển giao cho từng nhóm tác vụ thay vì buộc mọi tác vụ chia sẻ một tri thức toàn cục, dựa trên cảm hứng từ cách con người tổ chức tri thức theo thứ bậc. Tiếp nối hướng đi này, nhóm tác giả tiếp tục phát triển Automated Relational Meta-Learning (ARML) [49], thay thế cho cấu trúc phân cụm thủ công bằng một siêu đồ thị tri thức (meta-knowledge graph) được xây dựng một cách tự động, cho phép mô hình hóa quan hệ giữa các tác vụ linh hoạt hơn. Theo đó, một hướng tiếp cận khác, HetMAML do Chen và các cộng sự [7] đã mở rộng bài toán tác vụ không đồng nhất sang không gian đặc trưng đầu vào (heterogeneous input/modality), làm rõ tính đa dạng của khái niệm "tác vụ không đồng nhất", từ sự không đồng nhất về phân phối ngữ nghĩa đến không đồng nhất về cấu trúc dữ liệu đầu vào.

Ở một góc nhìn khác, Yue và các cộng sự tập trung vào nguyên nhân nhân quả thay vì cấu trúc tác vụ, và đề xuất phương pháp Interventional Few-shot Learning (IFSL) [51] nhằm tạo ra sự can thiệp nhân quả để khác phục hiện tượng chuyển giao tiêu cực (negative transfer). Đồng thời, lý giải hiện tượng này thông qua một mô hình cấu trúc nhân quả (Structural Causal Model), trong đó tri thức tiên huấn luyện đóng vai trò như một

biến gây nhiễu (confounder) và tạo ra các tương quan giả cho việc dự đoán nhân, khiến mô hình vô tình gây ra sai lệch.

Gần đây, Si và các cộng sự đề xuất phương pháp Heterogeneous Tasks Robust Meta-learning (HeTRoM) [37], nhằm giải quyết bài toán từ góc độ *độ khó không đồng đều* giữa các tác vụ. Thay vì gán trọng số bằng nhau cho toàn bộ các tác vụ trong giai đoạn meta-training như giả định của MAML, HeTRoM sử dụng mục tiêu học tập dựa trên xếp hạng (rank-based task-level learning objective) để ngăn các tác vụ "dễ" lấn át quá trình tối ưu. Đồng thời, Parast và các cộng sự cũng đề xuất Hard-Set-Guided Feature-Space Meta-Learning (HSFM) [22] nhằm can thiệp trực tiếp lên các biểu diễn, bằng cách trực tiếp thao tác trên các embedding của tập hỗ trợ trong không gian đặc trưng đã đóng băng (frozen backbone), lan truyền ngược qua các bước thích ứng của bộ phân loại để tinh chỉnh support embeddings, giúp mô hình hoạt động tốt hơn trước các tương quan giả.

Nhìn chung, các nghiên cứu giải quyết bài toán tác vụ không đồng nhất cho thấy một xu hướng nhất quán. Cộng đồng ngày càng thừa nhận tính không đồng nhất là nguyên nhân cốt lõi gây suy giảm hiệu năng thích ứng, và các giải pháp đang đi sâu vào can thiệp ở cấp độ biểu diễn (embeddings). Tuy nhiên, không một phương pháp nào trong chuỗi này hướng đến việc *diễn giải tường minh* cơ chế mà S_i đã định hướng sai ở đâu trong không gian đặc trưng chung. Tất cả các nghiên cứu hiện hành đều dừng lại ở mức phát hiện qua biểu hiện của các chỉ số (thường là độ chính xác suy giảm) hoặc sửa chữa qua tối ưu hóa lại biểu diễn, mà chưa cung cấp một bản đồ phân bổ (attribution) trực quan nào có thể chẩn đoán được nguyên nhân của sự chệch hướng trong quá trình thích ứng.

2.2.2 Các phương pháp hậu diễn giải dựa trên gradients và nhiễu loạn

Ngoài các kiến trúc diễn giải nội tại như Class Activation Mapping đã trình bày ở Mục 2.1.3, cộng đồng nghiên cứu XAI đã phát triển các phương pháp **hậu diễn giải** (*post-hoc*) tổng quát. Các kỹ thuật này không bị giới hạn bởi cấu trúc kiến trúc mạng cụ thể, cho phép phân tích hành vi của

mô hình một cách linh hoạt hơn. Có thể chia các phương pháp này thành hai nhánh chính dựa trên cơ chế tác động.

Nhánh thứ nhất dựa trên phân tích gradient (đạo hàm) của đầu ra theo từng đặc trưng đầu vào. Integrated Gradients [42] tích phân gradient dọc theo đường thẳng nối giữa một điểm nền (*baseline*) và dữ liệu cần giải thích, thoả mãn các tiên đề về *Sensitivity* và *Implementation Invariance*. Trong khi đó, SmoothGrad **smilkov2017smoothgrad** khắc phục tình trạng nhiễu bằng cách lấy trung bình các bản đồ gradient được tính trên các biến thể của dữ liệu gốc đã bị thêm nhiễu ngẫu nhiên, dựa trên quan sát rằng gradient của các mô hình sâu thường dao động mạnh trong vùng lân cận nhỏ của đầu vào.

Nhánh thứ hai dựa trên kỹ thuật **nhiều loạn** (*perturbation*), nơi tầm quan trọng của đặc trưng được suy luận qua sự biến thiên của đầu ra khi dữ liệu đầu vào bị thay đổi thông qua làm nhiễu hoặc xáo trộn. Local Interpretable Model-Agnostic Explanations (LIME) **ribeiro2016lime** xấp xỉ hành vi cục bộ của mô hình "hộp đen" bằng một mô hình tuyến tính đơn giản, huấn luyện trên tập các mẫu bị nhiễu loạn xung quanh điểm dữ liệu mục tiêu. Shapley Additive Explanations (SHAP) [18] định lượng đóng góp của đặc trưng dựa trên giá trị Shapley, đảm bảo tính công bằng (*efficiency, symmetry*) mà các phương pháp như LIME không đạt được. RISE [25] tạo bản đồ phân bố được trích xuất từ sự tương quan giữa các mặt nạ ngẫu nhiên che đi dữ liệu đầu vào và điểm số dự đoán tương ứng.

Tuy nhiên, điểm chung của toàn bộ các phương pháp kể trên là bất kể dựa trên gradient hay nhiễu loạn, chúng đều giải thích hành vi của mô hình dựa trên giả định về một *trạng thái tham số tĩnh*. Các phương pháp này được thiết kế để giải thích hành vi mô hình tại một thời điểm suy luận duy nhất, do đó hoàn toàn thiếu khả năng tích lũy hoặc tổng hợp thông tin dọc theo một quỹ đạo biến thiên tham số. Đây chính là rào cản mang tính hệ thống khiến chúng không thể triển khai nhằm diễn giải cơ chế thích ứng nhanh của các phương pháp dựa trên gradient.

2.2.3 Các phương pháp XAI cho Meta-Learning và Few-Shot Learning

Mặc dù các nỗ lực giải quyết bài toán tác vụ không đồng nhất nói riêng và việc khai mở bản chất "hộp đen" của meta-learning nói chung đã đạt được những bước tiến nhất định, nhưng, nhìn chung việc xây dựng các khung diễn giải toàn diện và hệ thống vẫn còn nhiều hạn chế. Thực tế, các hướng nghiên cứu hiện nay vẫn tồn tại sự phân hóa rõ rệt, các nỗ lực diễn giải đang tập trung vào những hướng đi rất khác biệt thay vì hội tụ về một phương pháp chung. Cụ thể, có thể phân loại hai hướng tiếp cận tiêu biểu gần đây trong việc nỗ lực diễn giải cơ chế hoạt động của các mô hình meta-learning.

Hướng thứ nhất mở rộng *influence functions*, công cụ vốn được thiết kế để định lượng giá trị ảnh hưởng của một mẫu dữ liệu huấn luyện lên dự đoán của mô hình, sang cấu trúc phù hợp với bối cảnh meta-learning. Đại diện tiêu biểu là TLXML [19], phương pháp này định lượng mức độ ảnh hưởng của từng *tác vụ* trong giai đoạn meta-training lên hành vi thích ứng trên một tác vụ đích. Bằng cách sử dụng xấp xỉ Gauss-Newton cho Hessian, TLXML giải quyết được bài toán chi phí tính toán cao vốn là rào cản đặc thù của *influence functions* trong bối cảnh tối ưu hóa hai tầng. Tuy nhiên, phương pháp này vẫn coi thao tác thích ứng trên tập hỗ trợ (S_i) là một "hộp đen" ở cấp độ tác vụ, đồng thời đòi hỏi quyền truy cập vào toàn bộ dữ liệu đã huấn luyện trong quá trình meta-training, một điều kiện khó đáp ứng trong triển khai thực tế.

Hướng thứ hai tích hợp trực tiếp các kỹ thuật dựa trên CAM hoặc các cơ chế diễn giải nội tại vào quy trình huấn luyện/suy luận few-shot nhằm giám sát mô hình tập trung vào đặc trưng ngữ nghĩa thay vì tương quan giả. Một số framework như *expert-guided* cho ảnh y khoa [43] là đại diện sử dụng hướng đi này, bằng cách sử dụng Grad-CAM kết hợp với hàm mất mát căn chỉnh (alignment loss) giữa bản đồ nhiệt (heat map) và vùng chú thích đã được chuyên gia tạo sẵn (ground-truth). Tương tự, MTUNet [45] thiết kế một bộ so khớp (matcher) so sánh trực tiếp các patch đặc trưng giữa ảnh hỗ trợ và ảnh truy vấn, dùng điểm so khớp làm căn cứ trực quan cho quyết định phân loại. Do đó, điểm hạn chế chung của các

phương pháp này là bản đồ nhiệt (hoặc điểm so khớp) chỉ được trích xuất tại thời điểm mô hình *đã thích ứng hoàn tất* ($f_{\phi_i^*}$) tức là chỉ diễn giải kết quả suy luận cuối cùng, và một số còn cần các vùng chú thích được tạo sẵn hoặc phải thiết kế lại kiến trúc (intrinsic). Thành thử, các phương pháp này hoàn toàn bỏ qua việc giải thích bản chất của quá trình dịch chuyển tham số từ điểm khởi tạo θ_0 sang trạng thái thích ứng ϕ_i^* .

Tóm lại, cả hai hướng tiếp cận trên, dù có khác biệt về mặt kỹ thuật, nhưng đều bộc lộ giới hạn chung về mặt diễn giải. Với hướng thứ nhất bỏ qua cơ chế thích ứng nội tại ở cấp độ đặc trưng, trong khi hướng thứ hai xem nhẹ vai trò định hướng của tập hỗ trợ trong chính bước dịch chuyển không gian tham số.

2.2.4 Attribution dựa trên quỹ đạo huấn luyện

Khác với các tiến trình huấn luyện cố định, quá trình thích ứng nhanh (*fast adaptation*) trong meta-testing được đặc trưng bởi một chuỗi cập nhật tham số liên tiếp (như mô tả tại Phương trình 2.1). Đặc tính này đòi hỏi một cơ chế diễn giải mới cho các công cụ giải thích. Thay vì tìm kiếm nguyên nhân tại một trạng thái dừng (*static state*), ta cần một cơ chế có khả năng truy vết sự đóng góp của dữ liệu xuyên suốt toàn bộ **quỹ đạo biến thiên tham số** (*parameter trajectory*). Để xác lập cơ sở lý thuyết cho phương pháp đề xuất, chúng tôi sẽ hệ thống hóa các hướng nghiên cứu attribution hiện nay.

Influence Functions được Koh và các cộng sự [14] lần đầu đưa ra khái niệm xuất phát từ thống kê bền vững (robust statistics) áp dụng vào học máy, nhằm ước lượng ảnh hưởng của mẫu huấn luyện z_i lên loss tại mẫu kiểm thử z_{test} thông qua khai triển Taylor bậc nhất.

$$\mathcal{I}_{\text{up,loss}}(z_i, z_{\text{test}}) = -\nabla_{\theta} \mathcal{L}(z_{\text{test}}, \hat{\theta})^{\top} H_{\hat{\theta}}^{-1} \nabla_{\theta} \mathcal{L}(z_i, \hat{\theta}). \quad (2.3)$$

Phương pháp này chỉ quan sát *trạng thái hội tụ* $\hat{\theta}$, đòi hỏi mô hình khả vi bậc hai, lỗi chặt và chi phí tính toán nghịch đảo Hessian $O(np^2 + p^3)$ rất lớn.

Representer Point Selection được Yeh và cộng sự [50] giới thiệu dựa trên định lý representer cho tầng cuối của mạng nơ-ron. Với điều kiện

chính quy hoá L_2 trên trọng số Θ_1 của tầng cuối, giá trị tiền kích hoạt (pre-activation) tại một điểm kiểm thử x_t có thể được phân tích thành tổ hợp tuyến tính của các đặc trưng huấn luyện.

$$\Phi(x_t, \Theta^*) = \sum_{i=1}^n \alpha_i f_i^\top f_t, \quad \alpha_i = \frac{1}{-2\lambda n} \frac{\partial \mathcal{L}(x_i, y_i, \Theta)}{\partial \Phi(x_i, \Theta)}. \quad (2.4)$$

Phương pháp này tách biệt đóng góp *kích thích* ($\alpha_i > 0$) và *ức chế* ($\alpha_i < 0$), đồng thời hiệu quả hơn Influence Functions nhờ tránh được Hessian. Tuy nhiên, nó vẫn bị giới hạn tại *điểm dừng tĩnh* Θ^* và chỉ giải thích được logit dự đoán, không trực tiếp giải thích được loss.

TracIn (Attribution dựa trên quỹ đạo) được Pruthi và các cộng sự [27] đưa ra nhằm giải quyết các hạn chế của hai phương pháp trên. Đồng thời cũng là phương pháp duy nhất định lượng ảnh hưởng thông qua tích lũy gradient dọc theo quỹ đạo huấn luyện.

$$\mathcal{I}(z_i, z_{\text{test}}) = \sum_{e=1}^E \nabla_{\theta} \mathcal{L}(z_i, \theta_e) \cdot \nabla_{\theta} \mathcal{L}(z_{\text{test}}, \theta_e). \quad (2.5)$$

Trực giác cốt lõi của TracIn là xấp xỉ tổng mức giảm loss trên mẫu kiểm thử, tích lũy qua toàn bộ quá trình huấn luyện, mỗi khi mẫu huấn luyện z_i được sử dụng để cập nhật tham số. Về bản chất, đây là một phép tích lũy (aggregation) tín hiệu attribution qua *nhiều trạng thái tham số liên tiếp* $\{\theta_e\}_{e=1}^E$, thay vì chỉ tại một trạng thái duy nhất như hai phương pháp ở trên. Nhờ vậy, TracIn không đòi hỏi điều kiện hội tụ hay tối ưu bậc nhất, và có thể áp dụng cho bất kỳ mô hình nào huấn luyện bằng SGD hoặc biến thể của nó.

Mặt khác, khái niệm quỹ đạo tham số trong bối cảnh gradient-based meta-learning cũng đã được khai thác bởi Li và cộng sự thông qua A-MAML [15], phương pháp xem quá trình gradient descent của inner-loop như một phương trình vi phân thường (ODE) và dùng phương pháp liên hợp (adjoint method) để tính hiệu quả gradient của θ_0 mà không cần lưu trữ đồ thị tính toán trung gian. Tuy nhiên, mục tiêu của A-MAML hoàn toàn khác với hướng tiếp cận của đề tài này: đây là một kỹ thuật nhằm *tối ưu hóa hiệu quả tính toán lúc meta-training*, không phải một phương

pháp *hậu diễn giải* (post-hoc) cho một mô hình đã huấn luyện xong. Điểm tương đồng duy nhất giữa hai hướng là cùng sử dụng công cụ toán học liên hợp (adjoint/Pearlmutter HVP), trong khi bài toán được giải quyết là hoàn toàn khác biệt.

2.2.5 Tổng hợp và định vị nghiên cứu

Từ các cơ sở lý thuyết và phân tích ở trên, ta có thể nhận thấy ba khoảng trống nổi bật khi đối chiếu chúng với nhau. **Thứ nhất**, các phương pháp diễn giải cho meta-learning hiện có (TLXML, Grad-CAM-FSL) đều xử lý thao tác thích ứng ở một trong hai cách, hoặc là diễn giải hộp đen ở cấp tác vụ, hoặc là chỉ quan sát tại trạng thái cuối cùng và vẫn chưa tồn tại phương pháp nào tổng hợp các phân bổ (attribution) qua nhiều trạng thái tham số của chính quá trình thích ứng nhanh (fast-adaptation). **Thứ hai**, toàn bộ các phương pháp giải quyết không đồng nhất/negative transfer (HSML, ARML, IFSL, HeTRoM, HSFM) đều dừng ở mức biểu hiện (đo bằng hiệu năng, như HSML/ARML/HeTRoM) hoặc sửa chữa (chỉnh sửa biểu diễn, như IFSL hoặc HSFM), trong đó HSFM là phương pháp duy nhất thao tác đa trạng thái trong không gian đặc trưng, nhưng mục tiêu của nó vẫn là sửa chữa để tăng hiệu năng, không phải sinh ra một attribution có thể diễn giải được cho con người. **Thứ ba**, các phương pháp giải thích dựa trên việc truy vết quỹ đạo như TracIn chứng minh nguyên lý tích lũy attribution qua nhiều trạng thái tham số là một hướng đi vững chắc về mặt toán học, nhưng chỉ được xây dựng cho bối cảnh huấn luyện dài hạn nhằm quy kết trách nhiệm cho từng mẫu dữ liệu huấn luyện, không phải cho bối cảnh thích ứng nhanh của meta-learning. **Cuối cùng**, chưa có phương pháp nào kết hợp đồng thời cả ba đặc điểm, diễn giải được cho con người, tổng hợp thông tin qua toàn bộ T bước của quá trình thích ứng thay vì một trạng thái đơn lẻ, và không đòi hỏi quyền truy cập vào tập dữ liệu meta-training.

Chương 3

Phương pháp đề xuất

3.1 Phát biểu bài toán

Như đã đề cập tại Mục 1.1 và được hệ thống hóa qua các phân tích ở Chương 2, việc trả lời hai câu hỏi nghiên cứu đặt ra ở Chương 1 đòi hỏi phải giải quyết đồng thời hai bài toán. Thứ nhất, xây dựng một độ đo định lượng nhạy cảm với hiện tượng chuyển giao tiêu cực (negative transfer), và có khả năng phản ánh mức độ đóng góp (tích cực hay tiêu cực) của quá trình thích ứng của các tri thức tiền nghiệm ẩn trong tham số khởi tạo chung θ_0 trên tập hỗ trợ S_i . Thứ hai, dựa trên giá trị độ lợi chuyển giao, cần phải có một cơ chế hậu diễn giải có khả năng tổng hợp thông tin qua nhiều trạng thái tham số của quá trình thích ứng, điều mà chưa phương pháp nào hiện thời có thể đáp ứng cả ba tiêu chí đã nêu trong mục 2.2.5.

Trước khi xây dựng độ đo định lượng hay một cơ chế cụ thể, ta xét bài toán diễn giải trên một mô hình dựa trên MAML đã hoàn tất giai đoạn meta-training. Mô hình này sở hữu bộ tham số khởi tạo chung θ_0 thu được từ quá trình tối ưu hai cấp (bi-level optimization) theo phương trình (2.2) và (2.1). Với một tác vụ đích $\mathcal{T}_i$ bất kỳ tại thời điểm meta-testing, bao gồm một tập hỗ trợ $S_i = \{(x_k^S, y_k^S)\}_{k=1}^{N \times K}$ và tập truy vấn $Q_i = \{(x_k^Q, y_k^Q)\}_{k=1}^M$, quá trình thích ứng nhanh sinh ra một quỹ đạo tham số gồm $T + 1$ trạng thái liên tiếp sau theo đúng quy tắc cập nhật inner-loop (2.1).

$$\phi_0 = \theta_0 \longrightarrow \phi_1 \longrightarrow \cdots \longrightarrow \phi_T = \phi_i^*, \quad (3.1)$$

Với F là không gian đặc trưng chung mà ϕ_i^* và θ_0 cùng chia sẻ sau quá trình thích ứng nhanh, ta có thể phân rã mỗi trạng thái tham số ϕ_j trong quỹ đạo (3.1) thành hai thành phần chức năng $\phi_j = (\phi_j^b, \phi_j^h)$. Tương ứng với phần thân trích xuất đặc trưng (backbone) ϕ_j^b và phần đầu phân lớp (head) ϕ_j^h , kế thừa từ phương pháp tiếp cận của Raghu và các cộng sự [28]

cũng như Oh và các cộng sự [21]. Theo đó, hàm trích xuất đặc trưng $f_{\phi_j^b} : \mathcal{X} \rightarrow F$ ánh xạ một mẫu đầu vào x về không gian đặc trưng chung F , trong khi hàm phân lớp $g_{\phi_j^h} : F \rightarrow \mathcal{Y}$ đưa ra quyết định cuối cùng dựa trên biểu diễn đã được trích xuất, sao cho $h_{\phi_j}(x) = g_{\phi_j^h} \circ f_{\phi_j^b}(x)$.

Đặc biệt, tại trạng thái khởi đầu $\phi_0 = \theta_0$, F chính là không gian đặc trưng tiền nghiệm được hình thành từ giai đoạn meta-training. Trong khi đó, tại trạng thái cuối $\phi_T = \phi_i^*$, tuy cùng một không gian F nhưng ít nhiều đã bị điều biến bởi T bước cập nhật gradient chịu tác động trực tiếp từ tập hỗ trợ S_i . Nhờ việc ϕ_i^* và θ_0 cùng chia sẻ trên một không gian F duy nhất, mọi sự dịch chuyển giữa hai trạng thái này, dù là tái sử dụng đặc trưng (feature reuse) hay tái cấu trúc biểu diễn (representation change), đều có thể được quan sát và đối chiếu trực tiếp mà không cần một phép biến đổi trung gian nào khác.

Dựa trên sự phân rã này, bài toán diễn giải mà chúng tôi đặt ra không nhằm vào một trạng thái tham số đơn lẻ, như cách các phương pháp Grad-CAM cục bộ [35], [43] chỉ trích xuất tại ϕ_T , mà mục tiêu chính là **sự đóng góp thực sự của việc thích ứng phần thân trích xuất đặc trưng (backbone)** vào hiệu năng trên tác vụ đích.

Để cô lập đóng góp này, bên cạnh quỹ đạo thích ứng đầy đủ (full adaptation) $\{\phi_0, \phi_1, \dots, \phi_T\}$ (3.1), ta xét thêm một quỹ đạo can thiệp (intervention) $\{\phi_0^f, \phi_1^f, \dots, \phi_T^f\}$, được sinh ra bằng cách chủ động đóng băng phần thân tại θ_0^b trong suốt T bước, chỉ cho phép phần đầu phân lớp cập nhật theo quy tắc inner-loop (2.1), tức $\phi_j^f = (\theta_0^b, \phi_j^{f,h})$ với mọi $j = 0, \dots, T$. Việc can thiệp này chính là sự hiện thực hóa giả thuyết *tái sử dụng đặc trưng* (feature reuse) của Raghu và các cộng sự [28], đóng vai trò như một đường cơ sở (baseline) phản ánh phần hiệu năng mà mô hình đạt được *mà không cần* backbone rời khỏi θ_0^b . Trong khi đó, quỹ đạo đầy đủ $\{\phi_0, \dots, \phi_T\}$, nơi cả backbone lẫn head cùng thích ứng tự do, phản ánh khả năng *tái cấu trúc biểu diễn* (representation change) như quan sát của Oh và các cộng sự [21].

Cụ thể hơn, với $h(\phi, Q_i)$ là hành vi dự đoán của mô hình trên tập truy vấn Q_i khi được tham số hóa bởi ϕ , hai câu hỏi nghiên cứu đặt ra ở Mục 1.1 có thể được thu gọn về hai bài toán con có quan hệ nhân quả với nhau. Bài toán con thứ nhất đòi hỏi định lượng khoảng cách hiệu năng giữa

$h(\phi_T^f, Q_i)$ (nhánh can thiệp, backbone đóng băng) và $h(\phi_T, Q_i) = h(\phi_i^*, Q_i)$ (nhánh thích ứng toàn bộ, không can thiệp) theo một cách nhạy cảm với S_i , thay vì chỉ dừng ở độ chính xác thô trên từng nhánh riêng lẻ. Nói cách khác, đại lượng cần đo không phải là hiệu năng tuyệt đối sau thích ứng, mà là *phần chênh lệch do chính backbone rời khỏi θ_0^b mang lại*. Nếu $h(\phi_T, Q_i) \approx h(\phi_T^f, Q_i)$, việc thích ứng backbone gần như không tạo thêm giá trị so với khi bị can thiệp đóng băng. Nếu $h(\phi_T, Q_i)$ vượt trội hơn $h(\phi_T^f, Q_i)$, sự tái cấu trúc biểu diễn mang lại chuyển giao tích cực. Ngược lại, nếu $h(\phi_T, Q_i)$ kém hơn $h(\phi_T^f, Q_i)$, chính việc thích ứng backbone dưới áp lực của S_i là nguyên nhân gây ra chuyển giao tiêu cực. Bài toán con thứ hai, dựa trên giả thiết rằng độ lợi đo được ở bài toán con thứ nhất là một đại lượng có thể quy kết (attributable), đòi hỏi truy vết ngược đại lượng đó về từng mẫu $(x_k^S, y_k^S) \in S_i$ và định vị chúng trên không gian đặc trưng F tại từng trạng thái ϕ_j của quỹ đạo, thay vì chỉ xét tại điểm cuối ϕ_T .

Việc phát biểu bài toán theo hướng này cho phép chúng tôi tránh được hạn chế cố hữu của các phương pháp diễn giải tĩnh (Mục 2.2.2) vốn chỉ quan sát một lát cắt duy nhất của mô hình. Đồng thời, phương pháp đề xuất không đòi hỏi quyền truy cập vào dữ liệu meta-training như TLXML [19], do toàn bộ thông tin cần thiết, gồm cặp quỹ đạo $\{\phi_0, \dots, \phi_T\}$ và $\{\phi_0^f, \dots, \phi_T^f\}$, tập hỗ trợ S_i và tập truy vấn Q_i , đều đã sẵn có ngay tại thời điểm meta-testing. Trên cơ sở phát biểu bài toán này, Mục 3.2 tiếp theo sẽ trình bày chi tiết cách xây dựng độ lợi thích ứng ΔM nhằm giải quyết bài toán con thứ nhất, trước khi Mục 3.3 trình bày cơ chế FAMA nhằm giải quyết bài toán con thứ hai.

3.2 Độ lợi thích ứng

Như đã trình bày ở Mục 3.1, bài toán con thứ nhất đòi hỏi một đại lượng có khả năng định lượng phần chênh lệch hiệu năng sinh ra bởi chính việc backbone rời khỏi θ_0^b , thay vì đo hiệu năng tuyệt đối trên từng nhánh riêng lẻ. Để đại lượng này phục vụ được cả hai mục tiêu nghiên cứu đã nêu, chúng tôi đặt ra ba tiêu chí thiết kế bắt buộc.

Thứ nhất, tính khả vi (differentiability). Vì bài toán con thứ hai

đòi hỏi cần có cơ chế truy ngược sự đóng góp của đại lượng này về từng mẫu trong S_i thông qua lan truyền ngược qua quỹ đạo thích ứng. Do đó độ đo này không thể là một đại lượng rời rạc như độ chính xác (accuracy), mà phải liên tục và khả vi theo tham số ϕ .

Thứ hai, tính nhạy cảm với chuyển giao tiêu cực (sensitivity to negative transfer). Độ đo phải phản ánh được *chiều hướng* của đóng góp, tức là nó cần phân biệt rõ ràng giữa trường hợp việc thích ứng backbone mang lại lợi ích (positive transfer), gây hại (negative transfer), hay không tạo thêm giá trị (feature reuse) so với việc chỉ tái sử dụng đặc trưng sẵn có. Điều này loại trừ các độ đo chỉ đo độ lớn tuyệt đối của sự thay đổi (như khoảng cách biểu diễn CCA/CKA) mà không cho biết thay đổi đó tốt hay xấu cho tác vụ đích.

Thứ ba, tính tổng quát (generality). Độ đo không được ràng buộc vào một kiến trúc, hay một tập dữ liệu cụ thể, mà phải được biểu diễn dưới dạng kỳ vọng trên toàn bộ tác vụ $\mathcal{T}_i$ tại thời điểm meta-testing, nhất quán với cách MAML được đánh giá (Phương trình (2.2)).

3.2.1 Định nghĩa

Dựa trên cơ sở của ba tiêu chí được đặt ra, với

$$\mathcal{L}(Q_i, \phi) := \frac{1}{M} \sum_{k=1}^M \ell(h_\phi(x_k^Q), y_k^Q) \quad (3.2)$$

là hàm mất mát trung bình (chẳng hạn như cross-entropy) được tính từ hành vi dự đoán $h(\phi, Q_i)$ đã định nghĩa ở Mục 3.1 đối chiếu với nhãn thật trên tập truy vấn, chúng tôi định nghĩa **độ lợi thích ứng** (Adaptation Gain) như sau.

$$\Delta M := \mathbb{E}_{Q_i \sim \mathcal{T}_i} \left[\mathcal{L}(Q_i, \phi_T^f) - \mathcal{L}(Q_i, \phi_T) \right], \quad (3.3)$$

trong đó $\phi_T = \phi_i^*$ là trạng thái cuối của quỹ đạo thích ứng đầy đủ, còn $\phi_T^f = (\theta_0^b, \phi_T^{f,h})$ là trạng thái cuối của quỹ đạo can thiệp với backbone bị đóng băng tại θ_0^b , cả hai đều được sinh ra từ cùng một tập hỗ trợ S_i theo quy tắc inner-loop (2.1).

Định nghĩa (3.3) ngầm giả định rằng toàn bộ chênh lệch $\mathcal{L}(Q_i, \phi_T^f) - \mathcal{L}(Q_i, \phi_T)$ đến từ việc phân thân mạng (backbone) dịch chuyển khỏi θ_0^b . Tuy nhiên, vì phần đầu phân lớp (head) ở hai nhánh cũng được cập nhật trên các quỹ đạo khác nhau (ϕ_j^h so với $\phi_j^{f,h}$). Dẫn tới, một vấn đề cần được làm rõ trước khi phân tích ΔM : *Liệu phần chênh lệch do bản thân phần đầu phân lớp (head) thích ứng khác nhau giữa hai nhánh có làm nhiễu tín hiệu backbone hay không?*

Để giải quyết câu hỏi này, bằng khai triển Taylor bậc hai của $L(Q_i, \cdot)$ quanh θ_0 (chi tiết tại Phụ lục A), ta có thể phân rã ΔM thành

$$\begin{aligned} \Delta M = & - \underbrace{\left[g_b^\top \Delta b_T + \frac{1}{2} \Delta b_T^\top H_{bb} \Delta b_T + \Delta b_T^\top H_{bh} \Delta h_T \right]}_{C_b - \text{đóng góp thuần của backbone}} \\ & + \underbrace{\left[g_h^\top (\Delta h_T^f - \Delta h_T) + \frac{1}{2} (\Delta h_T^f{}^\top H_{hh} \Delta h_T^f - \Delta h_T^\top H_{hh} \Delta h_T) \right]}_{R_h - \text{dư sai lệch từ head}}, \end{aligned} \quad (3.4)$$

với g_b, g_h và H_{bb}, H_{bh}, H_{hh} lần lượt là gradient và các khối Hessian của $L(Q_i, \cdot)$ tại θ_0 , còn $\Delta b_T, \Delta h_T, \Delta h_T^f$ là độ dịch chuyển tích lũy sau T bước của mỗi nhánh.

Số hạng R_h chỉ triệt tiêu tuyệt đối khi $\Delta h_T = \Delta h_T^f$, tức khi hai nhánh cho ra cùng một quỹ đạo head. Điều này chỉ chính xác tuyệt đối khi $T = 1$, do hai nhánh khởi đầu từ cùng θ_0 nên bước gradient head đầu tiên trùng nhau. Với $T > 1$, hai nhánh dần tách khỏi nhau do backbone chỉ dịch chuyển ở nhánh đầy đủ, kéo theo $\Delta h_T \neq \Delta h_T^f$ và $R_h \neq 0$.

Giả định 1 (Cơ chế thích ứng nhanh). *Quá trình thích ứng nhanh của MAML vận hành với số bước T nhỏ và tốc độ học α nhỏ, sao cho $T\alpha \ll 1$. Điều này đảm bảo trạng thái ϕ_T nằm đủ gần θ_0 để khai triển Taylor bậc hai của $\mathcal{L}(Q_i, \cdot)$ quanh θ_0 là một xấp xỉ cục bộ (local approximation) hợp lệ, tương tự như cách Grant và các cộng sự [12] đã chứng minh. Điều kiện này cũng chính là tiền đề cấu thành khái niệm thích ứng nhanh (fast-adaptation) cốt lõi của MAML [10].*

Mệnh đề 1 (Tính chủ đạo của đóng góp backbone). *Dưới Giả định 1, ta*

có $C_b = O(T\alpha)$ trong khi $R_h = O((T\alpha)^2)$. Do đó,

$$\Delta M = -C_b + O((T\alpha)^2), \quad (3.5)$$

Tức trong chế độ thích ứng nhanh, ΔM xấp xỉ tuyến tính đóng góp thuần của backbone. Phần dư do sự sai lệch quỹ đạo của phần đầu phân lớp (head) là một vô cùng bé bậc cao và không làm thay đổi chiều hướng (dấu) của ΔM .

(Chứng minh chi tiết của Mệnh đề 1, bao gồm khai triển Taylor đầy đủ, trường hợp $T = 1$ (đẳng thức chính xác $R_h = 0$), và lập luận quy nạp cho $T > 1$ dẫn tới cận $R_h = O((T\alpha)^2)$, được trình bày chi tiết tại Phụ lục A.

Nhờ Mệnh đề 1, dấu và độ lớn của ΔM có thể được diễn giải trực tiếp qua C_b — đại lượng chỉ phụ thuộc vào độ dịch chuyển của backbone. Nếu $\Delta M > 0$ ($C_b < 0$), việc để backbone thích ứng tự do giúp giảm mất mát trên Q_i — quá trình tái cấu trúc biểu diễn (representation change) mang lại **chuyển giao tích cực**. Ngược lại, nếu $\Delta M < 0$ ($C_b > 0$), tương đương với việc thích ứng backbone dưới áp lực của S_i làm tăng mất mát trên Q_i so với khi bị đóng băng — nguyên nhân trực tiếp của **chuyển giao tiêu cực**, dù θ_0^b vẫn đủ tốt nếu được giữ nguyên. Nếu $\Delta M \approx 0$ ($C_b \approx 0$), giả thuyết **tái sử dụng đặc trưng** (feature reuse) của Raghu và các cộng sự [28] là đủ để giải thích hiệu năng đạt được.

Trong thực nghiệm, kỳ vọng $\mathbb{E}_{Q_i \sim \mathcal{T}_i}[\cdot]$ ở phương trình (3.3) được xấp xỉ Monte Carlo bằng trung bình ΔM trên một tập hợp lớn tác vụ lấy mẫu từ $\mathcal{T}_i$ tại thời điểm meta-testing, theo đúng cách thức đánh giá chuẩn của MAML.

3.3 Phương pháp Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)

3.3.1 Ý tưởng tổng quan


Độ lợi thích ứng ΔM (được xây dựng ở Mục 3.2) đã định lượng *mức độ lợi hay hại* khi cho phép phần thân mạng (backbone) tự do thích ứng

trên tập hỗ trợ. Tuy nhiên, bản thân ΔM chỉ là một đại lượng vô hướng (scalar) ở cấp độ tác vụ. Do đó, nó không thể hiện được *thành phần nào* trong tập hỗ trợ S_i , hay cụ thể hơn là *biểu diễn đặc trưng* nào trong không gian F , đã trực tiếp gây ra sự thay đổi đó. Việc định vị nguồn gốc của sự chuyển giao (tích cực hoặc tiêu cực) trên không gian ảnh chính là bài toán cốt lõi mà bài toán con thứ hai hướng tới giải quyết.

Về nguyên tắc, cách trực tiếp nhất để lan truyền ΔM (hay hiệu giữa $\mathcal{L}(Q_i, \phi_T)$ và $\mathcal{L}(Q_i, \phi_T^f)$) ngược về không gian điểm ảnh (pixel space) của S_i là thực hiện tính đạo hàm $\partial \Delta M / \partial S_i$. Nhưng quá trình này đòi hỏi vi phân trực tiếp qua toàn bộ T bước cập nhật của cả hai quỹ đạo (Backpropagation-Through-Time - BPTT). Việc này đã vấp phải hai rào cản chí mạng. **Thứ nhất**, về mặt tính toán, nó yêu cầu lưu trữ và vi phân qua đồ thị của $2T$ bước cập nhật, dẫn đến chi phí tăng tuyến tính theo thời gian T nhưng lại toàn phương theo số lượng tham số P . **Thứ hai**, về mặt ngữ nghĩa, giá trị vi phân được truyền đến tận ảnh đầu vào thường mang nhược điểm cố hữu của của bản đồ nổi bật (vanilla saliency map) [38] - nhiễu hạt, rời rạc theo từng điểm ảnh và đánh mất cấu trúc không gian. Đó cũng là lý do các phương pháp như Grad-CAM [35] chọn cách trích xuất tín hiệu giải thích tại tầng đặc trưng tích chập cuối cùng thay vì tại điểm ảnh.

Để vượt qua các rào cản này, chúng tôi đề xuất phương pháp **Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA)** như một cơ chế kết hợp nhằm kế thừa và mở rộng Grad-CAM. Phương pháp này thực hiện trích xuất tín hiệu (grab-cut) tại tầng đặc trưng, nhưng thay vì áp dụng trên một trạng thái tĩnh, FAMA thực hiện phép trích xuất này một cách *lặp đi lặp lại* tại trên từng tham số $\phi^{(t-1)}$ dọc theo quỹ đạo thích ứng. Sau đó, một kỹ thuật từ lý thuyết điều khiển tối ưu [26] gọi là **phương pháp liên hợp** (adjoint method) được sử dụng để tổng hợp các tín hiệu cục bộ này với độ phức tạp tính toán chỉ xấp xỉ tuyến tính $\mathcal{O}(TP)$. Hình 3.1 minh họa bức tranh tổng quan của toàn bộ quy trình.

Để đảm bảo tính mạch lạc, phần còn lại của Mục 3.3 sẽ trình bày chi tiết theo trình tự bốn bước. (1) Khai triển đạo hàm quỹ đạo (Mục 3.3.2). (2) Giải quyết chi phí tính toán bằng phương pháp liên hợp (Mục 3.3.3).



Hình 3.1: Pipeline tổng quan của FAMA. Hai quỹ đạo (thích ứng toàn phần và can thiệp đóng băng) được sinh song song từ S_i ; một lượt lan truyền ngược liên hợp duy nhất tính chuỗi $\{\lambda_t\}$ cho mỗi quỹ đạo; tại mỗi bước t , tín hiệu λ_t được chiếu cục bộ lên bản đồ đặc trưng A_{t-1} ; các bản đồ cục bộ được tích lũy theo t rồi lấy hiệu giữa hai nhánh để ra bản đồ quy kết cuối cùng.

- (3) Định nghĩa đại lượng quy kết trên không gian đặc trưng (Mục 3.3.4).
 và (4) Chiếu (projection) kết quả về không gian điểm ảnh (Mục 3.3.5).

3.3.2 Khai triển đạo hàm qua quỹ đạo

Xét một trong hai quỹ đạo (quá trình lập luận hoàn toàn tương tự đối với quỹ đạo còn lại). Gọi $g_{t-1} := \nabla_{\phi} \mathcal{L}(\phi_{(t-1)}, S_i)$ là gradient của hàm mất mát trên tập hỗ trợ. Theo quy tắc cập nhật vòng lặp trong (inner-loop) ở phương trình (2.1) cho $\phi_t = \phi_{t-1} - \alpha g_{t-1}$, ta thu được ma trận Jacobian cho một bước như sau.

$$\frac{\partial \phi_t}{\partial \phi_{t-1}} = I - \alpha H_{t-1}, \quad H_{t-1} := \nabla_{\phi}^2 \mathcal{L}(\phi_{t-1}, S_i). \quad (3.6)$$

Theo đó, ta suy ra được vi phân trực tiếp qua thời gian (Backpropagation-Through-Time) bằng cách nhân dồn Jacobian từng bước qua toàn bộ T

bước cập nhật như sau.

$$\frac{\partial \phi_T}{\partial \phi_0} = \prod_{t=1}^T (I - \alpha H_{t-1}), \quad (3.7)$$

Tích này tạo thành một ma trận có kích thước $P \times P$ (với P là số lượng tham số trong mạng). Do đó, việc tính toán và lưu trữ tường minh ma trận này kéo theo chi phí bộ nhớ và thời gian lên đến $\mathcal{O}(TP^2)$, là một mức độ phức tạp hoàn toàn bất khả thi đối với các mạng nơ-ron học sâu.

Mặt khác, vì tập hỗ trợ S_i đóng vai trò là đầu vào tường minh tại *mọi* bước cập nhật. Nên theo quy tắc mắt xích (chain rule), đạo hàm của hàm mất mát đích $\mathcal{L}(Q_i, \phi_T)$ theo S_i là tổng sự đóng góp của S_i tại từng bước t .

$$\frac{\partial \mathcal{L}(Q_i, \phi_T)}{\partial S_i} = - \sum_{t=1}^T \alpha \lambda_t \cdot \frac{\partial^2 \mathcal{L}(\phi_{t-1}, S_i)}{\partial \phi_{t-1} \partial S_i}, \quad (3.8)$$

trong đó $\lambda_t := \partial \mathcal{L}(Q_i, \phi_T) / \partial \phi_t$. (Được định nghĩa và chứng minh bằng quy nạp lùi tại Phụ lục B).

Mà từ cấu trúc phân rã ở phương trình (3.8) này, có thể thấy được đạo hàm toàn cục của $\mathcal{L}(Q_i, \phi_T)$ hoàn toàn có thể chia tách thành T số hạng cục bộ. Mà trong đó mỗi số hạng được đánh trọng số bởi λ_t . Dù vậy, bài toán tính λ_t vẫn phải đối mặt với mức chi phí khổng lồ $\mathcal{O}(TP^2)$ nếu thực hiện khai triển Jacobian trực tiếp.

3.3.3 Phương pháp liên hợp

Để vượt qua trở ngại về chi phí tính toán và bộ nhớ khi đánh giá ma trận Jacobian dọc theo quỹ đạo học, chúng tôi xây dựng cơ chế lan truyền dựa trên *phương pháp trạng thái liên hợp* (Adjoint State Method). Nền tảng của phương pháp này xuất phát từ Nguyên lý cực đại Pontryagin trong lý thuyết điều khiển tối ưu.

Trong lý thuyết điều khiển liên tục, xét một hệ động lực với biến trạng thái $\mathbf{x}(t) = (x^1(t), \dots, x^n(t))$ và biến điều khiển $u(t)$ thay đổi theo hệ phương trình vi phân $\frac{dx^i}{dt} = f^i(\mathbf{x}(t), u(t))$. Để tính toán độ nhạy của một hàm mục tiêu tại thời điểm cuối $\Phi(\mathbf{x}(t_1))$ đối với sự thay đổi trạng

thái ở một thời điểm t bất kỳ, Pontryagin định nghĩa một vectơ liên hợp $\psi(t) = (\psi_1(t), \dots, \psi_n(t))$ tuân theo hệ phương trình liên hợp (adjoint system) ngược chiều thời gian:

$$\frac{d\psi_i(t)}{dt} = - \sum_{\alpha=1}^n \frac{\partial f^\alpha(\mathbf{x}(t), u(t))}{\partial x^i} \psi_\alpha(t), \quad (3.9)$$

hay được biểu diễn gọn dưới dạng ma trận Jacobian chuyển vị:

$$\frac{d\psi(t)}{dt} = - \left(\frac{\partial f(\mathbf{x}(t), u(t))}{\partial \mathbf{x}} \right)^\top \psi(t), \quad (3.10)$$

với điều kiện biên được khởi tạo tại điểm đích: $\psi(t_1) = \nabla_{\mathbf{x}} \Phi(\mathbf{x}(t_1))$. Hệ thức này cho phép lan truyền thông tin gradient từ tương lai về quá khứ mà không cần tính toán trực tiếp sự thay đổi tiến của toàn bộ quỹ đạo.

Trong ngữ cảnh của chúng tôi, quỹ đạo thời gian liên tục được rời rạc hóa thành các bước cập nhật tham số (gradient descent) $\phi_t = \phi_{t-1} - \alpha \nabla_{\phi} \mathcal{L}(\phi_{t-1})$. Lúc này, ma trận Jacobian của quá trình dịch chuyển đóng vai trò tương đương với toán tử tiến hóa f của hệ thống, và vectơ liên hợp $\psi(t)$ của Pontryagin được chúng tôi ký hiệu và đối chiếu thành chuỗi biến rời rạc λ_t .

Quá trình tính toán chuỗi liên hợp $\{\lambda_t\}_{t=1}^T$ bắt đầu bằng việc khởi tạo điều kiện biên tại điểm cuối của quỹ đạo (tương đương $\psi(t_1)$):

$$\lambda_T := \mathbb{E}_{Q_i \sim \mathcal{T}_i} [\nabla_{\phi} \mathcal{L}(Q_i, \phi_T)]. \quad (3.11)$$

Đại lượng này được xấp xỉ bằng phương pháp Monte Carlo thông qua bootstrap phân tầng trên tập truy vấn Q_i . Từ mốc này, biến liên hợp λ_t được lan truyền *ngược* qua từng bước theo bản rời rạc hóa của phương trình (3.10):

$$\lambda_{t-1} = \lambda_t - \alpha H_{t-1} \lambda_t, \quad t = T, T-1, \dots, 1. \quad (3.12)$$

trong đó H_{t-1} là ma trận Hessian của hàm mất mát tại ϕ_{t-1} .

Mệnh đề 2 (Tính tương đương của phép liên hợp). *Với chuỗi $\lambda^{(t)}$ sinh*

ra bởi hệ phương trình (3.11)–(3.12), ta có đẳng thức thể hiện sự bảo toàn gradient: $\lambda^{(t)} = \partial \mathbb{E}_{Q_i}[\mathcal{L}(Q_i, \phi^{(T)})] / \partial \phi^{(t)}$ tại mọi bước $t = 0, 1, \dots, T$.

Từ mệnh đề 2 ta hoàn toàn có thể thực hiện phép toán liên hợp nhằm tìm ra λ_t tại mọi bước trong quỹ đạo mà không cần phải qua một chuỗi nhân Jacobian khổng lồ. Tuy nhiên, tính hợp lệ của phép tuyến tính hoá để đạt được hệ thức (3.12) qua nhiều bước liên tiếp đòi hỏi các ràng buộc chặt chẽ về mặt không gian trạng thái sau.

Giả định 2 (Tính trơn và ổn định của phép liên hợp).

- (i) $\mathcal{L}(\cdot, S_i)$ khả vi liên tục hai lần theo ϕ trong một lân cận mở chứa toàn bộ quỹ đạo $\{\phi_0, \dots, \phi_T\}$;
- (ii) Ma trận Hessian $H(\phi)$ thỏa mãn điều kiện liên tục Lipschitz, tức là tồn tại hằng số $L_H < \infty$ sao cho $\|H(\phi) - H(\phi')\| \leq L_H \|\phi - \phi'\|$, đảm bảo sai số tuyến tính hoá tại mỗi bước bị chặn bởi $\mathcal{O}(\alpha^2)$;
- (iii) Tốc độ học α phải thỏa mãn bất đẳng thức $\alpha \leq 2/\lambda_{\max}(H_{t-1})$ tại mọi bước t , nhằm đảm bảo toán tử $(I - \alpha H_{t-1})$ không giãn nở ($\|I - \alpha H_{t-1}\| \leq 1$), từ đó ngăn hiện tượng chuỗi $\{\lambda_t\}$ bùng nổ qua T bước lùi.

Và với cơ chế thích ứng nhanh ($T\alpha \ll 1$), ta gần như hoàn toàn có thể thỏa mãn các ràng buộc này đối với các cấu trúc phổ trị riêng thông thường (chứng minh chi tiết tại Phụ lục B).

Đồng thời khi chuyển sang hệ thức liên hợp (3.12), ta đã loại bỏ đi được rào cản về bộ nhớ bằng cách không cần phải lưu trữ và biểu diễn tường minh ma trận Hessian H_{t-1} (vốn có kích thước rất lớn $P \times P$). Thay vào đó, quá trình này chỉ yêu tính trực tiếp **tích vô hướng Hessian-vector (HVP)**, $H_{t-1}\lambda_t$.

Để thực thi điều này, chúng tôi áp dụng kỹ thuật lan truyền ngược kép mà Pearlmutter đã đề xuất [24]. Đó là, thay vì tính ma trận Hessian H , ta hoàn toàn có thể tính đạo hàm có hướng (directional derivative) của gradient theo hướng của vector λ_t như sau.

$$H_{t-1}\lambda_t = \nabla_{\phi_{t-1}} \langle \nabla_{\phi_{t-1}} \mathcal{L}, \lambda_t \rangle \quad (3.13)$$

Tương đương với việc thực hiện hai lần lan truyền ngược (forward-over-reverse hoặc reverse-over-reverse) trong các triển khai thực tế. Với lần lan truyền đầu tiên tạo ra đồ thị tính toán cho tích vô hướng $\langle \nabla \mathcal{L}, \lambda_t \rangle$, và lần tiếp theo chính là lấy gradient của chính tích vô hướng đó.

Thông qua kỹ thuật HVP này, việc cập nhật λ_{t-1} có thể được tính toán với chi phí không gian và thời gian tỷ lệ thuận với $\mathcal{O}(P)$. Kết quả là tổng chi phí qua T bước được làm phẳng, giảm mạnh từ $\mathcal{O}(TP^2)$ xuống mức tuyến tính $\mathcal{O}(TP)$. Và chuỗi trọng số $\{\lambda^{(t)}\}$ thu được với chi phí thấp này sau đó sẽ đóng vai trò dẫn hướng cho việc quy kết trên không gian đặc trưng.

3.3.4 Đại lượng quy kết

Gọi $A_j := f_{\phi_j^b}(S_i) \in F$ trong đó a_{jk} là biểu diễn đặc trưng của mẫu x_k^S tại bước thứ j của quỹ đạo (với kích thước $C \times H \times W$). Khác với các phương pháp giải thích tĩnh chỉ quan tâm đến một biểu diễn duy nhất ở cuối quỹ đạo A_T , FAMA xử lý một **chuỗi biểu diễn** $\{A_0, \dots, A_{T-1}\}$, mỗi phần tử gắn với một trạng thái backbone khác nhau ϕ_j^b dọc theo quỹ đạo.

Do A_j được tính toán lại từ đầu vào S_i tại mỗi mốc thời gian thông qua một backbone ϕ_j^b không ngừng biến đổi, do đó không tồn tại một đại lượng A toàn cục đóng vai trò trung gian cho toàn bộ quỹ đạo T bước. Nói cách khác, thay vì có một phép biến đổi $S \rightarrow A \rightarrow \Delta M$ để có thể áp dụng quy tắc mất xích một lần duy nhất, ta có T phép biến đổi cục bộ tách biệt độc lập như sau.

$$S_i \xrightarrow{f_{\phi_{t-1}^b}} A_{t-1} \rightarrow \mathcal{L}(\phi_{t-1}, S_i), \quad t = 1, \dots, T, \quad (3.14)$$

Nhận diện được cấu trúc này, FAMA thực hiện cơ chế can thiệp cục bộ. Tại mỗi bước, bản đồ A_{t-1} được ngắt khỏi mất xích đạo hàm (stop-gradient), biến nó thành một biến lá (leaf variable) độc lập với toàn bộ lịch sử tính toán trước đó. Khi đó, đại lượng cần quy kết không còn là đạo hàm toàn cục, mà là một **họ** gồm T giá trị phân bố cục bộ.

$$\text{Attr}_{(t-1)} := \frac{\partial}{\partial A_{(t-1)}} \left[\lambda_t \cdot \nabla_{\phi} \mathcal{L}(\phi_{t-1}, S_i) \right], \quad t = 1, \dots, T, \quad (3.15)$$

Tại đây, λ_t đóng vai trò trọng số tầm quan trọng, quy định mức độ ảnh hưởng của biến đổi tại bước t lên hàm mất mát mục tiêu ở cuối quỹ đạo.

3.3.5 Phép chiếu về không gian đầu vào và bản đồ quy kết

Khi A_{t-1} đã bị cô lập thành biến độc lập $\tilde{A}_{t-1}$ thông qua thao tác ngắt đạo hàm ra khỏi mắt xích, hàm mất mát $\mathcal{L}(\phi_{t-1}, S_i)$ chỉ còn phụ thuộc tường minh vào phần đầu phân lớp (head) ϕ_{t-1}^h và biểu diễn $\tilde{A}_{t-1}$. Do phần thân mạng (backbone) đã bị đóng băng về mặt hình thức, đạo hàm của vô hướng $h_t := \lambda_t \cdot \nabla_{\phi} \mathcal{L}$ theo các tham số backbone sẽ triệt tiêu. Điều này ép buộc Attr_{t-1} phản ánh chính xác khối Hessian chéo $\partial^2 \mathcal{L} / \partial \phi_h \partial A$ — mang ý nghĩa quy kết trực tiếp đặc trưng đối với bộ phân lớp.

Từ tensor Attr_{t-1} (kích thước $C \times H \times W$), thuật toán tích hợp thành bản đồ nhiệt (CAM) theo công thức tiêu chuẩn của Grad-CAM [35], áp dụng riêng cho từng bước t :

$$w_t^c = \frac{1}{HW} \sum_{i,j} \text{Attr}_{t-1}^{(c,i,j)}, \quad (3.16)$$

$$\text{CAM}_{t-1}^{(i,j)} = \sum_c w_t^c A_{t-1}^{(c,i,j)}, \quad (3.17)$$

$$\widehat{\text{CAM}}_{t-1} = \text{Upsample}(\text{CAM}_{t-1}, \quad (3.18)$$

Trong đó, phương trình (3.16) thực hiện gộp trung bình không gian theo kênh, phương trình (3.17) tính toán tổ hợp có trọng số, và (3.18) tiến hành nội suy song tuyến.

Lưu ý về dấu: Trái ngược với Grad-CAM vốn áp dụng hàm ReLU để loại bỏ tín hiệu âm, FAMA **bảo toàn dấu** của $\widehat{\text{CAM}}_{t-1}$. Bởi lẽ, cả vùng tạo ra chuyển giao tích cực (hướng ΔM theo chiều dương) và tiêu cực (chiều âm) đều là thông tin chẩn đoán quan trọng trong ngữ cảnh phân tích độ lợi thích ứng.

Sau đó, các bản đồ cục bộ sẽ được tích lũy dọc theo từng bước để tạo thành bản đồ nhiệt cho một nhánh quỹ đạo hoàn chỉnh.

$$\Phi(x_k^S) := \sum_{t=1}^T \alpha \widehat{\text{CAM}}_{t-1}. \quad (3.19)$$

Quy trình này được thực thi độc lập cho cả hai nhánh quỹ đạo thích ứng toàn phần (Φ_{full}) và quỹ đạo can thiệp đóng băng (Φ_{freeze}). Do đó, bản đồ quy kết cuối cùng chính là kết quả của hiệu số giữa hai nhánh.

$$\boxed{\Phi_{\text{FAMA}}(x_k^S) := \Phi_{\text{full}}(x_k^S) - \Phi_{\text{freeze}}(x_k^S).} \quad (3.20)$$

Về mặt ý nghĩa, vì nhánh Φ_{freeze} sử dụng biểu diễn tiền nghiệm tĩnh không đổi qua mọi bước, nó đóng vai trò là một **đường cơ sở tái sử dụng đặc trưng** (feature-reuse baseline). Do đó, phép trừ ở phương trình (3.20) sẽ cô lập hoàn toàn phần đóng góp *thuần túy* phát sinh do sự biến thiên của backbone dưới tác động của tập hỗ trợ. Việc này hoàn toàn đồng nhất với thành phần đóng góp cốt lõi C_b đã được chứng minh trong Mệnh đề 1.

Về mặt diễn giải, vùng $\Phi_{\text{FAMA}} > 0$ chỉ ra các đặc trưng mà khi được tinh chỉnh đã giúp giảm lỗi trên tập truy vấn (chuyển giao tích cực). Ngược lại, vùng $\Phi_{\text{FAMA}} < 0$ cảnh báo các đặc trưng gây hại (ví dụ: tương quan giả) khiến hiệu suất suy giảm khi thích ứng.

Tuy nhiên, vì phép nội suy ở phương trình (3.18) dựa trên giả định rằng không gian (spatial correspondence) giữa lưới đặc trưng và ảnh gốc có tính tương thích. Do đó, FAMA hoạt động hiệu quả trên các kiến trúc tích chập. Nhưng đối với các cấu trúc không bảo toàn không gian điểm ảnh (như các phương pháp dựa trên Transformer thuần túy), thuật toán sẽ cần có một số sự điều chỉnh tương ứng.

3.4 Cơ sở đánh giá

Để đánh giá tính hiệu quả của một phương pháp diễn giải, ta không thể chỉ phụ thuộc vào tính trực quan hay thẩm mỹ của bản đồ quy kết, mà cần dựa trên hai tiêu chí học thuật cốt lõi. Thứ nhất, về **tính trung thực** (faithfulness), bản đồ quy kết phải phản ánh chính xác cơ chế hoạt động nội bộ của mô hình đang được diễn giải. Trong ngữ cảnh meta-learning, điều này đồng nghĩa với việc lời giải thích phải nắm bắt đúng quá trình thích ứng nhanh (fast adaptation) trên tập hỗ trợ S_i , thay vì chỉ biểu diễn một mối tương quan bề mặt giữa đầu vào và đầu ra. Thứ hai, về **tính đáng tin cậy** (trustworthiness): phương pháp diễn giải phải thực sự nhạy cảm

với các yếu tố chi phối hệ thống. Cụ thể, trong bài toán này, kết quả quy kết bắt buộc phải phụ thuộc vào tri thức tiên nghiệm (prior knowledge) θ_0 và nội dung ngữ nghĩa của S_i , chứ không phải là một phép biến đổi hình học cố định độc lập với những tri thức mô hình đã học được. Tiêu chí thứ hai này đòi hỏi phải được đánh giá thông qua các phép thử tính hợp lệ (sanity check), vốn đã được chứng minh là điều kiện *cần* để một bản đồ quy kết có thể được tin cậy [2].

Nhằm điều chỉnh cho phù hợp với bối cảnh diễn giải trên quỹ đạo thích ứng đã trình bày ở Mục 3.3, nơi đối tượng phân tích không phải là một kết quả dự đoán tĩnh mà là một đại lượng động (ΔM) được tổng hợp qua nhiều trạng thái tham số trung gian. Chúng tôi đưa ra ba bài kiểm chứng lần lượt đánh giá tính trung thực và tính hợp lệ, được trình bày chi tiết như sau.

3.4.1 Bài kiểm chứng dựa trên xóa và đo hai chiều (Bi-directional Attribution Deletion Test (BiADT))

Nguyên tắc chung của một bài kiểm tra xóa và đo (deletion test) là nếu bản đồ quy kết thực sự định vị đúng vùng chi phối đầu ra của mô hình, thì việc tuần tự che đi các vùng được đánh giá là quan trọng nhất (theo thứ tự giảm dần) sẽ làm đầu ra thay đổi nhanh hơn đáng kể so với việc xóa theo thứ tự ngẫu nhiên. Tuy nhiên, khác với các bài kiểm tra xóa-và-đo truyền thống thường chỉ đánh giá sự suy giảm theo một chiều duy nhất của độ tin cậy của dự đoán, thì đại lượng Φ_{FAMA} chứa *dấu* nhằm đại diện cho chiều hướng ảnh hưởng. Cụ thể, các vùng có $\Phi_{\text{FAMA}} > 0$ được cho là nguồn gốc của chuyển giao tích cực, ngược lại, những vùng có $\Phi_{\text{FAMA}} < 0$ thì ứng với nguồn gốc của việc chuyển giao tiêu cực (Mục 3.3.5). Chính vì đặc thù này, quy trình kiểm định tính trung thực đối với Φ_{FAMA} cần được thiết kế theo **hai chiều** độc lập, với mỗi chiều kiểm chứng đúng một nửa giả thuyết về dấu.

Thiết lập. Với mỗi mẫu hỗ trợ $x_k^S \in S_i$, thông qua thuật toán phân đoạn chuẩn (ví dụ như SLIC [1]) không gian điểm ảnh của x_k^S được phân thành P vùng ảnh (superpixel) rời rạc $\{s_1, \dots, s_P\}$ và được gán bằng một

điểm số quy kết tổng hợp.

$$\bar{\Phi}(s_p) := \frac{1}{|s_p|} \sum_{(i,j) \in s_p} \Phi_{\text{FAMA}}(x_k^S)_{i,j},$$

và sắp xếp toàn bộ P vùng theo thứ tự *tăng dần* của $\bar{\Phi}$ (từ vùng có đóng góp tiêu cực nhất đến vùng có đóng góp tích cực nhất). Với một tỉ lệ xóa $\rho \in [0, 1]$, gọi $S_i^{(\rho, \pi)}$ là tập hỗ trợ nhận được sau khi làm mờ/thay bằng giá trị nền $\lfloor \rho P \rfloor$ vùng ảnh đầu tiên theo thứ tự xóa π , với π nhận một trong ba giá trị:

- $\pi = \text{tăng dần}$: xóa lần lượt từ đầu danh sách đã sắp xếp — tức xóa các vùng có Φ_{FAMA} *âm nhất* trước;
- $\pi = \text{giảm dần}$: xóa theo chiều ngược lại — tức xóa các vùng có Φ_{FAMA} *dương nhất* trước;
- $\pi = \text{ngẫu nhiên}$: xóa theo một hoán vị ngẫu nhiên của P vùng, lấy trung bình trên nhiều lần lặp độc lập để làm đường cơ sở kiểm soát (control baseline).

Với mỗi tổ hợp (ρ, π) , ta thay S_i bằng $S_i^{(\rho, \pi)}$, ta thực hiện việc tính độ lợi thích ứng (adaptation gain) theo phương trình (3.3), ký hiệu $\Delta M(\rho, \pi)$.

Giả thuyết kiểm định. Nếu Φ_{FAMA} là một bản đồ quy kết trung thực, ta kỳ vọng hai chiều xóa-và-đo mang lại hai xu hướng đối lập, và cùng tách biệt rõ rệt khỏi đường cơ sở ngẫu nhiên:

- Theo chiều **giảm dần** (xóa vùng dương nhất trước): vì các vùng bị loại bỏ sớm chính là nguồn gốc của chuyển giao tích cực, $\Delta M(\rho, \text{giảm dần})$ phải suy giảm nhanh hơn đáng kể so với $\Delta M(\rho, \text{ngẫu nhiên})$ khi ρ tăng.
- Theo chiều **tăng dần** (xóa vùng âm nhất trước): vì các vùng bị loại bỏ sớm chính là nguồn gốc của chuyển giao tiêu cực, việc loại bỏ chúng đồng nghĩa với "làm sạch" S_i , nên $\Delta M(\rho, \text{tăng dần})$ phải tăng nhanh hơn đáng kể so với $\Delta M(\rho, \text{ngẫu nhiên})$ khi ρ tăng.

Hai xu hướng này được lượng hóa bằng diện tích lệch khỏi đường ngẫu nhiên, tương tự chỉ số AOPC (Area Over Perturbation Curve) trong các bài kiểm tra xóa cổ điển:

$$\begin{aligned} \text{ABC}_\downarrow &:= \int_0^1 \left[\Delta M(\rho, \text{ngẫu nhiên}) - \Delta M(\rho, \text{giảm dần}) \right] d\rho, \\ \text{ABC}_\uparrow &:= \int_0^1 \left[\Delta M(\rho, \text{tăng dần}) - \Delta M(\rho, \text{ngẫu nhiên}) \right] d\rho. \end{aligned} \quad (3.21)$$

Và một bản đồ quy kết được xem là vượt qua BiADT nếu cả $\text{ABC}_\downarrow$ lẫn $\text{ABC}_\uparrow$ đều dương và có ý nghĩa thống kê trên nhiều tác vụ lấy mẫu. Việc đòi hỏi *cả hai* chiều đồng thời đạt ý nghĩa thống kê thay vì chỉ một chiều như các bài kiểm tra xóa-và-đo thông thường chính là điểm khác biệt cốt lõi giúp BiADT kiểm chứng trực tiếp giả thuyết giữ nguyên dấu của Φ_{FAMA} (Mục 3.3.5).

3.4.2 Bài kiểm chứng độ tinh tảo thông qua việc phá hủy tri thức tiên nghiệm θ_0

Bài kiểm tra ở Mục 3.4.1 xác nhận rằng Φ_{FAMA} có quan hệ nhân quả với ΔM thông qua can thiệp trực tiếp lên S_i . Tuy nhiên, nó không loại trừ khả năng bản đồ quy kết chỉ đơn thuần phản ánh cấu trúc hình học chung của kiến trúc mạng (ví dụ hoạt động tương tự một bộ dò biên cố định), mà hoàn toàn không phụ thuộc vào *nội dung* của tri thức tiên nghiệm θ_0 đã học được qua giai đoạn meta-training. Đây chính là hiện tượng đã được chỉ ra ở bài kiểm tra ngẫu nhiên hóa tham số mô hình (model parameter randomization test), *nhiều phương pháp giải thích phổ biến cho ra bản đồ gần như không đổi ngay cả khi toàn bộ trọng số mô hình bị thay bằng giá trị ngẫu nhiên* [2].

Thiết lập. Gọi $\theta_0^b = \{W_1, \dots, W_L\}$ là L lớp tham số phần thân trích xuất của mô hình. Với mỗi $\ell = 1, \dots, L$, ta có được một phiên bản tri thức tiên nghiệm bị phá hủy theo tầng (cascading randomization) là $\theta_0^{b,(\ell)}$, trong đó ℓ lớp cuối cùng $\{W_{L-\ell+1}, \dots, W_L\}$ — tính từ lớp gần đầu ra ngược về lớp gần đầu vào — được khởi tạo lại ngẫu nhiên theo đúng phân phối khởi tạo gốc của kiến trúc, còn $L - \ell$ lớp còn lại giữ nguyên giá trị có được ở

giai đoạn meta-training. Với $\ell = L$, toàn bộ backbone bị phá hủy hoàn toàn. Việc phá hủy theo tầng thay vì phá hủy toàn bộ một lượt cho phép xác định *lớp nào* là nơi bản đồ quy kết bắt đầu phân kỳ, và đặc biệt phù hợp với FAMA vì đối tượng quy kết của nó là một chuỗi biểu diễn $\{A_j\}$ (Mục 3.3.4) vốn được trích xuất trực tiếp từ chính các lớp này.

Với mỗi $\theta_0^{b,(\ell)}$, ta thực hiện áp dụng toàn bộ quy trình thích ứng nhanh và phép chiếu FAMA (Mục 3.3) từ đầu, thay θ_0^b gốc bằng $\theta_0^{b,(\ell)}$, thu được bản đồ quy kết bị nhiễu $\Phi_{\text{FAMA}}^{(\ell)}$. Sau đó ta so sánh $\Phi_{\text{FAMA}}^{(\ell)}$ với bản đồ gốc Φ_{FAMA} (ứng với $\ell = 0$, không can thiệp) bằng hệ số tương quan hạng Spearman hoặc Pearson $\rho_s(\Phi_{\text{FAMA}}^{(\ell)}, \Phi_{\text{FAMA}})$, tính trên toàn bộ điểm ảnh của x_k^S .

Giả thuyết kiểm định. Nếu Φ_{FAMA} thực sự phản ánh tri thức tiên nghiệm đã học ở θ_0^b , hệ số $\rho_s(\Phi_{\text{FAMA}}^{(\ell)}, \Phi_{\text{FAMA}})$ phải suy giảm đơn điệu và có ý nghĩa thống kê khi ℓ tăng, tiệm cận về mức tương quan giữa hai bản đồ độc lập ngẫu nhiên (ước lượng bằng cách hoán vị ngẫu nhiên Φ_{FAMA}) tại $\ell = L$. Ngược lại, nếu ρ_s vẫn giữ mức cao bất kể ℓ , điều đó đồng nghĩa FAMA thất bại phép kiểm tra tỉnh táo này. Bản đồ quy kết khi đó chỉ là một hàm số của kiến trúc mạng và nội dung ảnh đầu vào, hoàn toàn tách rời khỏi những gì mô hình đã thực sự học được từ meta-training, và do đó không thể được diễn giải như một lời giải thích có ý nghĩa cho hành vi thích ứng của mô hình.

3.4.3 Bài kiểm chứng độ tỉnh táo thông qua việc can thiệp vào tập hỗ trợ S_i

Song song với việc kiểm tra độ nhạy đối với θ_0 , ta cần kiểm tra độ nhạy của Φ_{FAMA} đối với chính nội dung ngữ nghĩa của tập hỗ trợ S_i , là nguyên nhân quyết định trực tiếp quỹ đạo thích ứng. Đây là phiên bản mở rộng của bài kiểm tra ngẫu nhiên hóa dữ liệu/nhãn (data/label randomization test) [2] sang bối cảnh few-shot, được thiết kế để bao quát ba dạng phổ biến của hiện tượng tác vụ không đồng nhất (heterogeneous task) [37] gồm nhãn nhiễu (label noise), tác vụ khó (task difficulty), và tác vụ nằm ngoài phân phối so với phân phối gốc (out-of-distribution). Với mỗi dạng, chúng tôi định nghĩa một phép can thiệp $S_i \rightarrow S'_i$ tương ứng.

(a) **Hoán vị nhãn (label permutation).** Áp dụng một hoán vị ngẫu nhiên σ lên tập N lớp của tác vụ $\mathcal{T}_i$, và gán lại $y_k^S \leftarrow \sigma(y_k^S)$ cho mọi mẫu hỗ trợ trong khi vẫn giữ nguyên x_k^S . Việc này phá vỡ hoàn toàn mối liên kết ngữ nghĩa giữa ảnh và nhãn mà quá trình thích ứng nhanh dựa vào.

(b) **Tăng độ khó tác vụ (hard-task perturbation).** Làm mờ (Gaussian blur) hoặc thêm nhiễu lên x_k^S , sao cho ranh giới phân biệt giữa các lớp trong $\mathcal{T}_i$ trở nên mờ nhạt hơn nhằm mục đích mô phỏng một tác vụ khó, nơi tín hiệu phân biệt hữu ích cho backbone khai thác bị suy giảm.

(c) **Trộn tác vụ ngoài phân phối (OOD task mixing).** Thay toàn bộ các mẫu trong tập hỗ trợ S_i bằng các mẫu lấy từ một tác vụ $\mathcal{T}_j$ khác tách biệt so với $\mathcal{T}_i$, nhưng vẫn giữ nguyên tập truy vấn Q_i (ví dụ một tập dữ liệu khác hoặc một tập hợp lớp không liên quan), tạo ra một tác vụ lai không đồng nhất mà quá trình meta-training chưa từng chuẩn bị.

Với mỗi phép can thiệp, ta thực hiện áp dụng quy trình thích ứng và FAMA trên S'_i để thu được Φ'_{FAMA} và $\Delta M'$, sau đó so sánh với Φ_{FAMA} và ΔM gốc.

Giả thuyết kiểm định. Cả ba phép can thiệp trên đều được thiết kế để phá hoại cấu trúc hữu ích của S_i theo những cách khác nhau, nên đều được kỳ vọng đẩy quá trình thích ứng nhanh về phía chuyển giao tiêu cực nhiều hơn. Tức là $\Delta M'$ có xu hướng thấp hơn ΔM một cách có ý nghĩa thống kê. Tương ứng, một bản đồ quy kết trung thực phải phản ánh đúng sự dịch chuyển này, phân bố không gian của Φ'_{FAMA} phải lệch về phía âm nhiều hơn so với Φ_{FAMA} . Ngược lại, nếu Φ'_{FAMA} không có sự khác biệt có ý nghĩa thống kê so với Φ_{FAMA} dù S_i đã bị can thiệp nghiêm trọng đến mức làm suy giảm rõ rệt $\Delta M'$, điều đó đồng nghĩa bản đồ quy kết đã tách rời khỏi nội dung ngữ nghĩa thực sự của S_i , và do đó không đáng tin cậy.

Ngoài ra, việc thực hiện cả ba bài kiểm chứng trên cần được lặp lại trên một tập hợp lớn các tác vụ $\mathcal{T}_i$ được lấy mẫu ngẫu nhiên tại thời điểm meta-testing, thay vì chỉ minh họa trên một vài tác vụ đơn lẻ. Do đó, các chỉ số tổng hợp ($\text{ABC}_\downarrow$, $\text{ABC}_\uparrow$, hệ số tương quan ρ_s , và độ lệch phân phối của Φ'_{FAMA}) vì vậy được báo cáo dưới dạng phân phối qua nhiều tác vụ, kèm khoảng tin cậy và kiểm định ý nghĩa thống kê so với đường cơ sở tương ứng, thay vì một con số đơn lẻ dễ gây hiểu lầm. Toàn bộ kết quả

thực nghiệm của ba bài kiểm chứng này, cùng các phân tích định tính bổ sung trên một số tác vụ minh họa, sẽ được trình bày chi tiết ở Chương 4.

Chương 4

Kết quả thực nghiệm

Chương này trình bày các thực nghiệm nhằm kiểm định phương pháp giải thích thông qua độ lợi thích ứng ΔM và FAMA đã được giới thiệu ở Chương 3. Đồng thời, toàn bộ thực nghiệm đều được tiến hành trên thuật toán MAML với kiến trúc backbone Conv4, một kiến trúc tích chập có độ sâu nông và nhẹ, cũng là tiêu chuẩn thực nghiệm trong các nghiên cứu về các phương pháp dựa trên MAML nói riêng và few-shot learning nói chung. Do đó, để bảo đảm kết quả kiểm định không bị nhiễu bởi các kiến trúc khác nhau và bảo đảm mang tính khách quan, các tham số/siêu tham số trong thực nghiệm này đều có chung cấu hình với các siêu tham số huấn luyện mà Finn và cộng sự [10] đã thiết lập.

4.1 Thiết lập thực nghiệm

Theo như thiết lập của MAML [10], chúng tôi huấn luyện mô hình với backbone Conv4, kiến trúc mạng gồm 4 khối tích chập giống hệt nhau, mỗi khối gồm một lớp tích chập 3×3 , chuẩn hóa theo lô (batch normalization), hàm kích hoạt ReLU, và một lớp gộp cực đại (max-pooling) 2×2 theo đúng cấu hình đã được đề xuất trong công trình gốc của Finn và cộng sự. Bảng 4.1 liệt kê các siêu tham số huấn luyện được sử dụng.

Toàn bộ thực nghiệm đánh giá ở chương này được thực hiện trên tập kiểm tra (test set) với mô hình MAML đã huấn luyện hội tụ, sử dụng số bước thích ứng $T = T_{\text{test}}$ tại thời điểm meta-testing. Ba bài kiểm chứng định lượng — BiADT, kiểm tra tĩnh táo theo θ_0 , và kiểm tra tĩnh táo theo S_i — được thực hiện đúng theo giao thức đã trình bày lần lượt tại các Mục 3.4.1, 3.4.2, và 3.4.3.

Bảng 4.1: Siêu tham số huấn luyện MAML trên backbone Conv4 (theo cấu hình chuẩn của Finn và cộng sự [10])

Siêu tham số	Giá trị
Kiến trúc backbone	Conv4 (4 khối: conv 3×3 + BN + ReLU + maxpool 2×2)
Tốc độ học vòng trong α	0.01
Tốc độ học vòng ngoài β (Adam)	0.001
Số bước thích ứng huấn luyện T_{train}	5
Số bước thích ứng kiểm tra T_{test}	10
Kích thước meta-batch	4
Số vòng lặp meta-training	60.000
Cấu hình N -way K -shot	5-way 1-shot

4.2 Các tập dữ liệu

Để kiểm định tính tổng quát của FAMA trên nhiều mức độ khó và đặc điểm phân phối tác vụ khác nhau, chúng tôi thực nghiệm trên ba bộ dữ liệu chuẩn của lĩnh vực few-shot learning: miniImageNet, tieredImageNet, và CUB-200-2011.

miniImageNet [30] là bộ dữ liệu phổ biến nhất trong các nghiên cứu few-shot learning nhờ kích thước vừa phải và độ khó trung bình, phù hợp làm bộ đối chứng chuẩn. Bộ dữ liệu gồm 100 lớp lấy từ tập dữ liệu lớn ImageNet, với mỗi lớp 600 ảnh có kích thước 84×84 , được chia theo tỉ lệ chuẩn 64/16/20 lớp cho train/val/test.

tieredImageNet [31] là phiên bản mở rộng quy mô lớn hơn của miniImageNet, gồm 608 lớp được nhóm theo 34 danh mục cấp cao (super-category) trong hệ thống phân cấp WordNet. Việc chia train/val/test được thực hiện ở *cấp danh mục* (20/6/8 danh mục, tương ứng khoảng 351/97/160 lớp) thay vì ở cấp lớp, nhằm đảm bảo các lớp tại tập test có khoảng cách ngữ nghĩa xa hơn với tập train. Qua đó kiểm tra khả năng tổng quát hoá nghiêm ngặt hơn so với miniImageNet, đồng thời tạo bối cảnh phù hợp để quan sát chuyển giao tiêu cực do dịch chuyển ngữ nghĩa giữa các tác vụ.

CUB-200-2011 [47] là bộ dữ liệu phân loại chim ở mức độ tinh (fine-grained), gồm 200 loài với tổng cộng khoảng 11.788 ảnh (trung bình xấp xỉ

60 ảnh/lớp), thường được chia theo tỉ lệ 100/50/50 lớp cho train/val/test trong các nghiên cứu few-shot. Vì ranh giới giữa các lớp chỉ khác biệt ở những chi tiết cục bộ tinh vi (hình dạng mỏ, màu lông, hoa văn cánh...), CUB-200-2011 được xem là bộ dữ liệu *khó* nhất trong ba bộ, một phép thử quan trọng cho giả thuyết rằng tác vụ càng khó thì nguy cơ chuyển giao tiêu cực càng cao (tương ứng phép can thiệp "tăng độ khó tác vụ" ở Mục 3.4.3).

4.3 Cách thức thực nghiệm

4.3.1 Đánh giá định lượng

Phần đánh giá định lượng tuân theo đúng ba bài kiểm chứng đã nêu ra ở Mục 3.4: (i) BiADT đo diện tích lệch $ABC_{\downarrow}$ (PDA - Positive Distance from Average), $ABC_{\uparrow}$ (NDA - Negative Distance from Average) giữa đường xóa-và-đo có định hướng và đường xóa-và-đo ngẫu nhiên (Phương trình (3.21)); (ii) kiểm tra tỉnh táo theo θ_{-1} đo hệ số tương quan giữa Φ_{FAMA} gốc và $\Phi_{\text{FAMA}}^{(\ell)}$ khi phá hủy backbone theo tầng; (iii) kiểm tra tỉnh táo theo S_i đo hệ số tương quan giữa Φ_{FAMA} gốc và Φ'_{FAMA} dưới ba kịch bản can thiệp tập hỗ trợ. Cả ba bài kiểm chứng đều được lặp lại trên nhiều tác vụ lấy mẫu ngẫu nhiên tại thời điểm meta-testing trên từng bộ dữ liệu, kết quả báo cáo dưới dạng trung bình $\pm$ độ lệch chuẩn.

Để tiến hành quy trình thực nghiệm một cách toàn diện, chúng tôi thực hiện việc đánh giá định lượng trên bộ dữ liệu *TieredImageNet* cho cả ba bài kiểm chứng. Riêng bộ dữ liệu *CUB-201-2011* sẽ được dùng để khai thác độc lập nhằm tạo ra các tác vụ lai nằm ngoài phân phối (OOD - Out-of-Distribution) phục vụ cho kịch bản can thiệp thứ ba của bài kiểm chứng (iii), qua đó đánh giá khả năng duy trì tính trung thực của phương pháp diễn giải khi đối mặt với sự dịch chuyển miền dữ liệu có cấu trúc ngữ nghĩa hoàn toàn khác biệt.

4.3.2 Đánh giá định tính

Bên cạnh các chỉ số định lượng, chúng tôi khai thác hai tình huống kiểm thử với ba nguồn dữ liệu đã thu thập trên 600 tác vụ lấy mẫu (trên mỗi bộ

dữ liệu) là *miniImagenet* $\rightarrow$ *CUB-200-2011* (mini2cub) và *tieredImageNet* $\rightarrow$ *CUB-200-2011* (tiered2cub) nhằm đưa ra cái nhìn cơ sở quan về những gì mà phương pháp diễn giải thể hiện.

4.4 Kết quả định lượng

4.4.1 Kết quả BiADT

Bảng 4.2: Kết quả BiADT: $ABC_{\downarrow}$ và $ABC_{\uparrow}$ trên bộ dữ liệu *TieredImageNet*

Bộ dữ liệu	$ABC_{\downarrow}$ (mean $\pm$ MoE)	p -value	$ABC_{\uparrow}$ (mean $\pm$ MoE)	p -value
tieredImageNet	0.1861 ± 0.109	1.99×10^{-4} (< 0.001)	0.289 ± 0.122	7.01×10^{-7} (< 0.001)

Nhận xét. Kết quả trên tieredImageNet cho thấy cả hai chỉ số $ABC_{\downarrow}$ và $ABC_{\uparrow}$ đều dương và đạt ý nghĩa thống kê rõ rệt ($p < 0.001$ ở cả hai chiều), chứng thực việc xóa các vùng ảnh theo thứ tự do Φ_{FAMA} chỉ định dù theo chiều dương hay âm đều làm ΔM dịch chuyển nhanh hơn đáng kể so với khi thực hiện xóa ngẫu nhiên. Với $ABC_{\uparrow}$ (0.289 ± 0.122) lớn hơn khá nhiều so với $ABC_{\downarrow}$ (0.186 ± 0.109), cho thấy tín hiệu định vị vùng gây *chuyển giao tiêu cực* tách biệt rõ khỏi đường cơ sở ngẫu nhiên hơn so với tín hiệu định vị vùng chuyển giao tích cực. Mặt khác, mức sai số biên (margin of error - MoE) tương đối lớn quan sát được (nhất là với $ABC_{\downarrow}$, xấp xỉ 59% mean) có khả năng bắt nguồn từ đặc thù của backbone Conv4. Cụ thể, do chiều sâu kiến trúc hạn chế, nên các bản đồ đặc trưng sau cùng có độ phân giải không gian rất thô trước khi được nội suy song tuyến (Phương trình (3.18)). Quá trình này vô tình làm mờ đi các ranh giới phân tách giữa các vùng ảnh, dẫn đến sự thiếu hụt độ sắc nét trong việc định vị không gian. Chính sự mờ nhòe này tạo ra sự dao động lớn trong các kết quả định lượng, song không làm mất đi tính đúng đắn tổng thể của giả thuyết về khả năng quy kết vùng của FAMA.

4.4.2 Kết quả kiểm tra tĩnh táo theo tri thức tiên nghiệm θ_0

Bảng 4.3: Hệ số tương quan giữa Φ_{FAMA} gốc và $\Phi_{\text{FAMA}}^{(\ell)}$ theo mức độ phá hủy các khối của θ_0^b (Mean $\pm$ MoE, $N = 600$)

Khối bị phá (ℓ)	Spearman	Pearson
$\ell = 0$ – Head (linear)	0.108 ± 0.016	0.111 ± 0.017
$\ell = 1$ – Block 1 (gần đầu ra nhất)	-0.007 ± 0.012	-0.008 ± 0.013
$\ell = 2$ – Block 2	0.003 ± 0.012	0.004 ± 0.012
$\ell = 3$ – Block 3	-0.006 ± 0.012	-0.008 ± 0.012
$\ell = 4$ – Block 4 (toàn bộ backbone)	-0.010 ± 0.012	-0.009 ± 0.012

Nhận xét. Kết quả thực nghiệm cho thấy, hệ số tương quan sụt giảm rất mạnh ngay từ mức phá hủy đầu tiên. Cụ thể, khi chỉ ngẫu nhiên hóa khối gần đầu ra nhất (Block 1, $\ell = 1$), mức tương quan đã giảm mạnh từ khoảng 0.108–0.111 xuống gần như bằng 0 (khoảng -0.008 đến -0.007). Và nếu tiếp tục phá hủy các khối sâu hơn, tương quan chỉ dao động quanh mức nền $[-0.010, 0.004]$.

Do đó, để xác định xem liệu hành vi này là một hạn chế của FAMA hay là một đặc tính tất yếu của chính thiết kế, chúng tôi tiến hành đối chiếu với một đại lượng đối chứng $\Delta M' := \mathbb{E}_{Q_i}[\mathcal{L}(Q_i, \theta_0) - \mathcal{L}(Q_i, \phi_T)]$. Đồng nghĩa với việc so sánh trực tiếp trạng thái *hoàn toàn chưa thích ứng* θ_0 với trạng thái thích ứng đầy đủ ϕ_T , thay cho định nghĩa gốc của **độ lợi thích nghi** được định nghĩa bởi phép toán (3.3). Thí nghiệm đối chứng này được thực hiện trên checkpoint Conv4/tieredImageNet gốc ở thang phá hủy chi tiết 9 mức (tách riêng lớp batch-norm và lớp tích chập trong từng khối); mục đích của bảng 4.4 thuần túy mang tính minh họa nguyên lý thiết kế (đối lập giữa suy giảm mượt và sụp đổ tức thời), không nhằm so sánh trực tiếp số liệu với bảng 4.3.

Với kết quả ở bảng 4.4 ta có thể thấy được qua các mức phá hủy $\ell = 0, \dots, 8$, hệ số tương quan dẫn xuất từ $\Delta M'$ suy giảm một cách *mượt mà và đơn điệu*, hoàn toàn trái ngược với sự sụt gãy của ΔM gốc.

Bảng 4.4: Hệ số tương quan giữa Φ_{FAMA} gốc và $\Phi_{\text{FAMA}}^{(\ell)}$ theo mức độ phá hủy các tầng của θ_0^b và θ_0^h trong giả định $\Delta M := \Delta M'$

Khối bị phá	Lớp	Spearman	Pearson
-	linear	0.6502 ± 0.013	0.6331 ± 0.0123
conv_block 4	bn4	0.2458 ± 0.014	0.2456 ± 0.014
	conv4	0.1045 ± 0.013	0.1067 ± 0.013
conv_block 3	bn3	0.0975 ± 0.013	0.0981 ± 0.013
	conv3	0.0857 ± 0.012	0.0846 ± 0.012
conv_block 2	bn2	0.0782 ± 0.014	0.0788 ± 0.015
	conv2	0.0825 ± 0.014	0.0807 ± 0.014
conv_block 1	bn1	0.0751 ± 0.014	0.074 ± 0.014
	conv1	0.0761 ± 0.014	0.0748 ± 0.013

Tuy nhiên, sự khác biệt này không phải là mâu thuẫn, mà đến từ việc hai đại lượng đo lường này phản ánh hai khía cạnh khác nhau của quá trình thích ứng nhanh. Với $\Delta M'$ đo lường lợi ích của *bất kỳ* sự thích ứng nào so với việc không làm gì cả. Và phần lớn giá trị này đến từ việc lớp phân loại (head) được hiệu chỉnh lại trên S_i , một đại lượng gần như luôn tồn tại và chỉ suy giảm từ từ theo mức phá hủy phần thân mạng, bởi lẽ ngay cả khi θ_0^b bị ngẫu nhiên hóa hoàn toàn, bản thân phép tích chập vẫn tạo ra các đặc trưng mang tính cấu trúc (bộ dò cạnh, kết cấu) mà phần đầu phân lớp tuyến tính vẫn có thể khai thác được để phân tách lớp ở một mức độ nhất định. Đây là hiện tượng vốn đã được ghi nhận trong các nghiên cứu về đặc trưng ngẫu nhiên/mạng chưa huấn luyện.

Ngược lại, ΔM theo định nghĩa gốc là một phép *trừ* giữa hai nhánh cùng xuất phát từ cùng một $\theta_0^{b,(\ell)}$ (dù đã bị phá hủy hay không) và cùng cho phép phần đầu mạng thích ứng tự do nên phần "sàn" chung do các đặc trưng cấu trúc cấp thấp mang lại gần như bị triệt tiêu hoàn toàn qua phép trừ, chỉ giữ lại phần chênh lệch thực sự do *phần thân mạng dịch chuyển thêm* so với $\theta_0^{b,(\ell)}$ dưới tác động của gradient trên S_i . Theo Mệnh đề 1, $\Delta M \approx -C_b$ với C_b phụ thuộc trực tiếp vào việc gradient có phản ánh đúng tri thức mà tác vụ đã học hay không. Do đó, khi khối gần đầu ra bị phá hủy, hướng gradient hữu ích đó gần như biến mất ngay lập tức chứ không suy giảm tuyến tính theo số khối bị phá, từ đó, giải thích trực tiếp cho bước sụt gần như tức thì quan sát được.

Theo đúng nguyên tắc kiểm tra tính tỉnh táo (sanity check) [2], một đường cong suy giảm *từ từ* (như $\Delta M'$) thực chất là dấu hiệu **đáng lo ngại**, vì nó cho thấy bản đồ quy kết phần lớn được chi phối bởi cấu trúc kiến trúc hơn là tri thức đã học ở θ_0^b . Do đó, việc ΔM và Φ_{FAMA} sụp đổ gần như ngay lập tức khi tri thức tiên nghiệm ở lớp gần đầu ra bị phá hủy chính là bằng chứng cho thấy thiết kế phép trừ hai nhánh của FAMA đã cô lập thành công phần tín hiệu thực sự phụ thuộc vào θ_0^b , loại bỏ được các nhiễu cấu trúc thuần túy. Nói cách khác, FAMA không chỉ **vượt qua** phép kiểm chứng sự tỉnh táo mà còn thể hiện tính đúng đắn đáng cao.

Tuy nhiên, kết quả thực nghiệm cũng có thể cho thấy hạn chế ở việc thang đo $\ell = 0, \dots, 4$ của Conv4 quá thô (chỉ có 5 mức) để quan sát chi tiết cấu trúc suy giảm ngay tại vùng sụt giảm mạnh. Và việc sử dụng các kiến trúc sâu hơn (ví dụ ResNet-12) hoặc kỹ thuật nội suy trọng số liên tục trong tương lai sẽ giúp quan sát hành vi sụt giảm này với độ phân giải cao hơn.

4.4.3 Kết quả kiểm tra tỉnh táo theo can thiệp tập hỗ trợ S_i

Bảng 4.5: Hệ số tương quan Spearman và Pearson (Mean $\pm$ MoE) dưới các kịch bản can thiệp tập hỗ trợ

Kịch bản can thiệp	Spearman	Pearson
(Trộn tác vụ) OOD task	0.351 ± 0.015	0.361 ± 0.015
(Hoán vị lớp) Noisy task	0.425 ± 0.019	0.439 ± 0.019
(Tăng độ khó tác vụ) Hard task	0.263 ± 0.013	0.272 ± 0.013

Nhận xét. Kết quả cho thấy cả ba kịch bản can thiệp đều cho hệ số tương quan ở mức thấp–trung bình (Spearman và Pearson nằm trong khoảng 0.26–0.44), thấp hơn đáng kể so với mức gần tuyệt đối mà một bản đồ "trơ" (không phụ thuộc nội dung S_i). Điều này nhất quán với việc kết luận ở Mục 4.4.2, khi FAMA có xu hướng loại bỏ tốt phần tín hiệu mang tính cấu trúc chung, và chỉ giữ lại phần thực sự phụ thuộc vào nội dung dẫn dắt quá trình thích ứng.


Trong ba kịch bản, mức độ nhạy cảm của bản đồ quy kết có thứ tự Hard task (0.263) < OOD task (0.351) < Noisy task (0.425) – tức can

thiếp làm mờ ảnh (Hard) gây xáo trộn bản đồ mạnh nhất, còn hoán vị nhãn (Noisy) gây xáo trộn ít nhất, dù trực giác ban đầu có thể kỳ vọng chiều ngược lại.

Sự khác biệt này bắt nguồn từ việc mỗi kịch bản can thiệp vào một thành phần khác nhau của S_i . Kịch bản Hard làm biến dạng trực tiếp *nội dung điểm ảnh* mà mọi bước trích xuất đặc trưng trong toàn bộ quỹ đạo thích ứng đều phụ thuộc vào, nên phá vỡ tín hiệu định vị không gian mà Φ_{FAMA} dựa vào một cách nghiêm trọng nhất. Ngược lại, kịch bản Noisy chỉ hoán vị *nhãn*, giữ nguyên toàn bộ nội dung hình ảnh gốc của S_i ; vì bản đồ Φ_{FAMA} được chiếu lên không gian đặc trưng trích xuất trực tiếp từ ảnh (Mục 3.3.4), cấu trúc không gian (vị trí, kết cấu, hình dạng đối tượng) mà backbone khai thác gần như không đổi, dù ranh giới phân lớp ở phần đầu (head) đã bị lệch hướng do nhãn sai – khiến hệ số tương quan không gian bị ảnh hưởng ít hơn hẳn hai kịch bản còn lại. Kịch bản OOD nằm ở giữa: toàn bộ đối tượng quan sát bị thay đổi hoàn toàn (ảnh từ một tác vụ khác), nhưng từng ảnh vẫn "nguyên vẹn" về mặt điểm ảnh (không bị méo/mờ như Hard), nên tác động kém trực tiếp hơn Hard.

Ngoài ra, mức độ nhạy cảm của kịch bản OOD (chưa phải mạnh nhất trong ba kịch bản) cũng có thể một phần xuất phát từ sự tương đồng về thống kê thị giác cấp thấp giữa hai bộ dữ liệu. Backbone Conv4 là một mạng nông, chủ yếu nhạy cảm với các đặc trưng cấu trúc cơ bản (bộ dò cạnh, kết cấu). Mặc dù *CUB-200-2011* (ảnh chim cận cảnh) và *tieredImageNet* rất khác nhau về *ngữ nghĩa* lớp, chúng lại khá tương đồng về *cấu trúc hình ảnh* (vật thể chính nằm giữa khung hình, tương phản rõ với nền). Sự tương đồng này vẫn đủ để kích hoạt các bộ lọc cấp thấp của Conv4 một cách tương tự nhau, khiến Φ_{FAMA} không dịch chuyển mạnh như có thể kỳ vọng ở một phép can thiệp thay đổi toàn bộ đối tượng quan sát. Điều này mở ra định hướng tinh chỉnh kịch bản OOD trong tương lai: đối với các mạng nông, việc sử dụng các tập dữ liệu OOD phi-vật-thể (như Places hoặc ảnh texture) sẽ tạo ra phép thử khắc nghiệt và chính xác hơn.

4.5 Kết quả định tính



Hình 4.1: Phân phối độ lợi thích ứng ΔM trên hai bài toán min $\rightarrow$ cub và tiered $\rightarrow$ cub.

Nhận xét chung. Dựa trên Hình 4.1, việc chuyển giao tri thức từ hai miền dữ liệu gốc khác nhau sang CUB-200-2011 cho thấy sự phân hóa rõ rệt về mặt hành vi thích ứng, được thể hiện cụ thể qua ba khía cạnh sau.


Thứ nhất, phân phối ΔM của tiered2cub trải rộng hơn đáng kể so với mini2cub. Các giá trị cực trị ở cả hai đầu đều bị đẩy ra xa nhau, đuôi âm chạm mức $\approx -25.88\%$ (so với $\approx -7.91\%$ của mini2cub) và đuôi dương vươn tới $\approx 41.24\%$ (so với $\approx 24.24\%$). Đồng thời, điểm cắt qua trục hoành có sự chênh lệch lớn, trong khi mini2cub chỉ có khoảng 11% số tác vụ rơi vào trạng thái chuyển giao tiêu cực ($\Delta M < 0$), tỷ lệ này ở tiered2cub lên tới xấp xỉ 50%.

Thứ hai, các điểm đầu mút của hai đường cong này hoàn toàn tương ứng với các trường hợp quy kết cụ thể đã được phân tích chi tiết tại Hình 4.2 và Hình 4.3. Điều này khẳng định sự dịch chuyển hiệu năng cực đoan là hiện tượng có tính hệ thống, có thể quan sát và diễn giải được ở cấp độ hình ảnh.


Thứ ba, sự phân cực mạnh của *tiered2cub* vừa chứa nhiều tác vụ chuyển giao tiêu cực nặng, vừa có những bước nhảy vọt tích cực cực đoan. Điều này hoàn toàn nhất quán với những gì đã thiết lập của bộ dữ liệu *tieredImageNet* ở Mục 4.2. Mặt khác, cách chia tách dữ liệu theo cấp độ siêu danh mục (category-level) của *tieredImageNet* cũng tạo ra một tri thức tiền nghiệm mang tính khái quát cao. Tuy nhiên, tri thức này lại thiếu đi sự chuyên biệt hóa cần thiết để xử lý các đặc trưng vi mô (fine-grained) trên CUB-200-2011. Hệ quả là quá trình cập nhật phần thân mạng trở nên kém ổn định, và dễ bị kéo lệch theo cả hai hướng tích cực/tiêu cực tùy thuộc vào đặc thù nội dung của từng tác vụ.

4.5.1 Nghiên cứu trường hợp

Dựa trên biểu đồ 4.1, mục này trình bày các tác vụ tiêu biểu được chọn lọc từ tập 600 tác vụ, gồm tác vụ có sự chuyển giao tích cực nhất và tiêu cực nhất.



Hình 4.2: Bản đồ quy kết trên tác vụ chuyển giao tích cực nhất (ảnh trên) và tác vụ chuyển giao tiêu cực nhất (ảnh dưới) với thử nghiệm *MiniImagenet* $\rightarrow$ *CUB-200-2011*



Hình 4.3: Bản đồ quy kết trên tác vụ chuyển giao tích cực nhất (ảnh trên) và tác vụ chuyển giao tiêu cực nhất (ảnh dưới) với thử nghiệm *TieredImageNet* $\rightarrow$ *CUB-200-2011*.

Nhận xét. Phân tích trực quan các bản đồ quy kết ở hai cực trị của phân phối ΔM bộc lộ những mẫu hình không gian phức tạp và đôi khi đi ngược lại trực giác. Phổ biến nhất là hiện tượng vùng màu xanh (gây hại) thường bám sát thân chim, trong khi vùng màu đỏ (hữu ích) lại tập trung vào bối cảnh (cành cây, lá), đặc biệt rõ ở các loài có bộ lông đơn điệu (như *Warbling Vireo*) hoặc bị che khuất. Tuy nhiên, trên các phong nền đơn giản, tín hiệu đỏ lại nắm bắt rất gọn vào thân hình con chim (*Bohemian Waxwing*) hoặc định vị chính xác vùng đặc trưng sinh học định danh (*Horned Lark*).

Hoặc bản đồ cũng thể hiện sự phản ứng rất mạnh với các chi tiết bất thường trong ảnh, chẳng hạn như gán nhãn xanh cho nhiều màu nhân tạo (*Red-eyed Vireo*), nhiễu động do màu nguy trang (*Crested Auklet*), hoặc bị phân tán bởi tay người (*Clay-colored Sparrow*). Ngoài ra, các bức ảnh có đối tượng quá nhỏ (*Scissor-tailed Flycatcher*) đều gặp hiện tượng vùng

màu từ nền "tràn" sang bao trùm lấy đường viền chim. Đặc biệt, có hai trường hợp lặp loài (*Yellow-breasted Chat* ở mini2cub và *California Gull* ở tiered2cub) xuất hiện ở cả hai nhóm tích cực và tiêu cực nhưng lại cho ra các bản đồ có cấu trúc phân bố hoàn toàn trái ngược nhau.

Từ các quan sát trên, có thể rút ra ba kết luận quan trọng về bản chất của quá trình thích ứng và phương pháp giải thích. Thứ nhất, mạng nơ-ron chịu ảnh hưởng nặng nề bởi "thiên lệch ngữ cảnh" (contextual bias); khi đối tượng chính thiếu đặc trưng phân tách mạnh, mô hình sẽ tự động học vệt các chi tiết môi trường xung quanh để bù đắp, dẫn đến chuyển giao tiêu cực. Thứ hai, sự thay đổi bản đồ trên cùng một nhãn loài, cũng như khả năng định vị chính xác các nhiễu ảnh/ngoại lai, là minh chứng thuyết phục cho thấy Φ_{FAMA} cực kỳ nhạy cảm với *nội dung của từng bức ảnh cụ thể* (độ che khuất, ánh sáng, bố cục) chứ không bị suy biến thành một bộ lọc cố định theo nhãn lớp. Cuối cùng, hiện tượng tràn màu ở các đối tượng nhỏ tiếp tục khẳng định giới hạn kiến trúc của mạng Conv4, lưới đặc trưng quá thô ở các khối chụp cuối đã làm suy giảm đáng kể độ phân giải không gian, khiến việc định vị ranh giới vật thể ở cấp độ điểm ảnh không thể đạt độ chính xác tuyệt đối.

4.6 Tổng kết chương

Thông qua quá trình đối chiếu và phân tích phương pháp diễn giải trên nền thuật toán MAML (với kiến trúc Conv4) xuyên suốt qua ba miền dữ liệu (miniImageNet, tieredImageNet và CUB-200-2011), sự kết hợp giữa các kết quả định lượng và định tính đã minh chứng rõ nét tính đúng đắn của phương pháp qua ba khía cạnh cốt lõi sau đây.

Thứ nhất, về tính trung thực và chính xác, kết quả của BiADT cùng hai bài kiểm tra tỉnh táo (sanity checks) đã xác nhận việc FAMA định vị chính xác các vùng ảnh chi phối độ lợi thích ứng là hoàn toàn trung thực và đáng tin cậy. Ngoài ra, bản đồ quy kết cũng đã phản ánh đúng tri thức thực sự mà mô hình đã học được từ dữ liệu S_i , triệt tiêu thành công các nhiễu do cấu trúc mạng hay việc ghi nhớ vệt nhãn lớp.

Thứ hai, việc phân tích định tính đã giúp trực quan hóa nguyên nhân cốt lõi gây ra chuyển giao tiêu cực. FAMA phơi bày rõ hiện tượng "thiên

lệch ngữ cảnh" (contextual bias), cho thấy mô hình thường xuyên học vệt phong nền để bù đắp khi đối tượng chính thiếu đặc trưng phân tách.

Cuối cùng, hiện tượng "tràn màu" (spatial bleeding) ở các đối tượng nhỏ chỉ ra hạn chế của kiến trúc Conv4 do lưới đặc trưng quá thô. Dù không làm mất đi tính đúng đắn của phương pháp, điều này mở ra định hướng ứng dụng FAMA trên các mạng sâu hơn (như ResNet) để tối ưu hóa độ phân giải không gian trong tương lai.

Chương 5

Kết luận

Nhằm giải quyết các câu hỏi nghiên cứu về hiện tượng chuyển giao tiêu cực (negative transfer) trong quá trình thích ứng nhanh của Model-Agnostic Meta-Learning (MAML) đã được phân tích tại Mục 1.1, luận văn đã đề xuất thành công phương pháp hậu diễn giải (post-hoc explanation) dựa trên độ lợi thích ứng ΔM và phương pháp Phân bổ Liên hợp trong Không gian Đặc trưng cho Meta-Learning (Feature-space Adjoint Meta-Learning Attribution) (FAMA).

Cụ thể, thông qua đại lượng ΔM , chiều hướng tác động (có lợi hoặc có hại) của việc thích ứng nhanh hoàn toàn có thể được xác định một cách tường minh. Mà dựa trên kết quả đó, FAMA thông qua việc phân bổ liên hợp trong không gian đặc trưng chung F mà định vị chính xác các vùng không gian trên tập hỗ trợ S_i là nguyên nhân gốc rễ gây ra tác động này xuyên suốt toàn bộ quỹ đạo thích ứng qua nhiều bước, nhờ đó mà có thể trực quan hóa được hiện tượng "thiên lệch ngữ cảnh" (contextual bias) dẫn đến hiện tượng chuyển giao tiêu cực.

Đồng thời, các thực nghiệm kiểm chứng cũng đã khẳng định phương pháp mà chúng tôi đề ra hoàn toàn trung thực và đáng tin cậy với việc chỉ ra cơ chế thích ứng nhanh. Các kết quả từ việc thực hiện Bi-directional Attribution Deletion Test (BiADT) đạt mức ý nghĩa thống kê cao ($p < 0.001$) ở cả hai chiều tích cực lẫn tiêu cực. Và, hai bài kiểm tra tính tỉnh táo (sanity checks) qua can thiệp tri thức tiên nghiệm θ_0 và dữ liệu S_i đã chứng minh bản đồ quy kết của FAMA thực sự bắt nguồn từ tri thức đã học và nội dung dữ liệu của tập hỗ trợ, điều này đồng nghĩa với việc triệt tiêu hoàn toàn sự chi phối của các yếu tố cấu trúc mạng trơ. Nhờ đó, luận văn mang đến một công cụ diễn giải hoàn toàn mới, khả vi và độc lập với dữ liệu meta-training cho lĩnh vực meta-learning.

5.1 Hạn chế và hướng phát triển

Tuy nhiên, nghiên cứu hiện tại vẫn còn một số hạn chế do việc sử dụng kiến trúc nông. Việc thực nghiệm trên kiến trúc Conv4 khiến lưới đặc trưng ở khối tích chập cuối có độ phân giải không gian thô, gây ra hiện tượng "tràn màu" (spatial bleeding) khi định vị các vật thể nhỏ và tạo ra mức sai số biên khá lớn trong đánh giá BiADT. Ngoài ra, kiến trúc nông cũng khiến kịch bản can thiệp OOD chưa phản ánh đúng độ nhạy kỳ vọng do sự tương đồng về thống kê thị giác cấp thấp giữa các tập dữ liệu, và thang đo phá hủy mạng ($\ell = 0, \dots, 4$) chưa đủ mịn để quan sát chi tiết sự sụt giảm hiệu năng.

Từ những hạn chế trên, luận văn đề xuất 4 hướng phát triển tiềm năng trong tương lai:

1. **Cải thiện độ phân giải không gian:** Mở rộng thực nghiệm sang các kiến trúc backbone sâu hơn (như ResNet-12) nhằm giải quyết triệt để hiện tượng tràn màu.
2. **Tinh chỉnh kịch bản can thiệp:** Sử dụng các tập dữ liệu phi-vật thể (như Places hoặc ảnh kết cấu) làm nhiễu OOD để tạo ra phép thử Sanity Check khắc nghiệt và chính xác hơn.
3. **Kiểm chứng tính phổ quát:** Khái quát hóa khung đánh giá ΔM và FAMA sang các biến thể tối ưu hóa khác (ANIL, BOIL, Meta-SGD) trong số các phương pháp thuộc họ MAML (MAML-based).
4. **Can thiệp chủ động:** Kết hợp FAMA với các cơ chế can thiệp biểu diễn (như HSFM) nhằm tiến xa hơn từ việc chẩn đoán sang việc tự động hiệu chỉnh tập hỗ trợ S_i , khép kín vòng lặp giữa diễn giải XAI và cải thiện trực tiếp hiệu năng mô hình.

Tài liệu tham khảo

Tiếng Anh

- [1] Achanta, R., Shaji, A., Smith, K., Lucchi, A., Fua, P., and Süsstrunk, S., “Slic superpixels compared to state-of-the-art superpixel methods,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 34, no. 11, pp. 2274–2282, 2012.
- [2] Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M., and Kim, B., “Sanity checks for saliency maps,” *Advances in neural information processing systems*, vol. 31, 2018.
- [3] Angwin, J., Larson, J., Mattu, S., and Kirchner, L., “Machine Bias,” *ProPublica*, 2016. [Online]. Available: <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>.
- [4] Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., *et al.*, “Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai,” *Information fusion*, vol. 58, pp. 82–115, 2020.
- [5] Baik, S., Choi, M., Choi, J., Kim, H., and Lee, K. M., “Meta-learning with adaptive hyperparameters,” *Advances in neural information processing systems*, vol. 33, pp. 20 755–20 765, 2020.
- [6] Bengio, S., Bengio, Y., Cloutier, J., and Gecsei, J., “On the optimization of a synaptic learning rule,” in *Optimality in biological and artificial networks?* Routledge, 2013, pp. 265–287.
- [7] Chen, J. and Zhang, A., “Hetmaml: Task-heterogeneous model-agnostic meta-learning for few-shot learning across modalities,” in *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*, 2021, pp. 191–200.

- [8] Fawakherji, M., Alaoui, S., and Turjya, S. M., “Learning to see with less: A survey on computer vision with limited and imperfect data,” *Archives of Computational Methods in Engineering*, pp. 1–37, 2026.
- [9] Fei-Fei, L., Fergus, R., and Perona, P., “One-shot learning of object categories,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 28, no. 4, pp. 594–611, 2006.
- [10] Finn, C., Abbeel, P., and Levine, S., “Model-agnostic meta-learning for fast adaptation of deep networks,” in *International conference on machine learning*, PMLR, 2017, pp. 1126–1135.
- [11] Gharoun, H., Momenifar, F., Chen, F., and Gandomi, A. H., “Meta-learning approaches for few-shot learning: A survey of recent advances,” *ACM Computing Surveys*, vol. 56, no. 12, pp. 1–41, 2024.
- [12] Grant, E., Finn, C., Levine, S., Darrell, T., and Griffiths, T., “Recasting gradient-based meta-learning as hierarchical bayes,” *arXiv preprint arXiv:1801.08930*, 2018.
- [13] High-Level Expert Group on AI, “Ethics guidelines for trustworthy AI,” European Commission, Brussels, Report, Apr. 2019. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>.
- [14] Koh, P. W. and Liang, P., “Understanding black-box predictions via influence functions,” in *International conference on machine learning*, PMLR, 2017, pp. 1885–1894.
- [15] Li, S., Wang, Z., Narayan, A., Kirby, R., and Zhe, S., “Meta-learning with adjoint methods,” in *Proceedings of The 26th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2023, pp. 7239–7251.
- [16] Li, Z., Zhou, F., Chen, F., and Li, H., “Meta-sgd: Learning to learn quickly for few-shot learning,” *arXiv preprint arXiv:1707.09835*, 2017.
- [17] Lum, K. and Isaac, W., “To predict and serve?” *Significance*, vol. 13, no. 5, pp. 14–19, 2016.

- [18] Lundberg, S. M. and Lee, S.-I., “A unified approach to interpreting model predictions,” *Advances in neural information processing systems*, vol. 30, 2017.
- [19] Mitsuka, Y., Golestan, S., Sufiyan, Z., Miwa, S., and Zaiane, O. R., “Tlxml: Task-level explanation of meta-learning via influence functions,” *arXiv preprint arXiv:2501.14271*, 2025.
- [20] Nichol, A., Achiam, J., and Schulman, J., “On first-order meta-learning algorithms,” *arXiv preprint arXiv:1803.02999*, 2018.
- [21] Oh, J., Yoo, H., Kim, C., and Yun, S.-Y., “Boil: Towards representation change for few-shot learning,” *arXiv preprint arXiv:2008.08882*, 2020.
- [22] Parast, A. Y., Islam, K., Won, S., Azam, B., and Akhtar, N., “Hsfm: Hard-set-guided feature-space meta-learning for robust classification under spurious correlations,” *arXiv preprint arXiv:2603.29313*, 2026.
- [23] Park, E. and Oliva, J. B., “Meta-curvature,” *Advances in neural information processing systems*, vol. 32, 2019.
- [24] Pearlmutter, B. A., “Fast exact multiplication by the hessian,” *Neural computation*, vol. 6, no. 1, pp. 147–160, 1994.
- [25] Petsiuk, V., Das, A., and Saenko, K., “Rise: Randomized input sampling for explanation of black-box models,” *arXiv preprint arXiv:1806.07421*, 2018.
- [26] Pontryagin, L. S., Boltyanskii, V. G., Gamkrelidze, R. V., and Mishchenko, E. F., *The Mathematical Theory of Optimal Processes*, Neustadt, L. W., Ed., trans. by Tirogoff, K. N. New York, London: Interscience Publishers, 1962, pp. 83–86, A division of John Wiley & Sons, Inc.
- [27] Pruthi, G., Liu, F., Kale, S., and Sundararajan, M., “Estimating training data influence by tracing gradient descent,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 19 920–19 930, 2020.

- [28] Raghu, A., Raghu, M., Bengio, S., and Vinyals, O., “Rapid learning or feature reuse? towards understanding the effectiveness of maml,” *arXiv preprint arXiv:1909.09157*, 2019.
- [29] Rajeswaran, A., Finn, C., Kakade, S. M., and Levine, S., “Meta-learning with implicit gradients,” *Advances in neural information processing systems*, vol. 32, 2019.
- [30] Ravi, S. and Larochelle, H., “Optimization as a model for few-shot learning,” in *International conference on learning representations*, 2017.
- [31] Ren, M., Triantafillou, E., Ravi, S., *et al.*, “Meta-learning for semi-supervised few-shot classification,” *arXiv preprint arXiv:1803.00676*, 2018.
- [32] Samek, W., Binder, A., Montavon, G., Lapuschkin, S., and Müller, K.-R., “Evaluating the visualization of what a deep neural network has learned,” *IEEE transactions on neural networks and learning systems*, vol. 28, no. 11, pp. 2660–2673, 2016.
- [33] Santoro, A., Bartunov, S., Botvinick, M., Wierstra, D., and Lillicrap, T., “Meta-learning with memory-augmented neural networks,” in *International conference on machine learning*, PMLR, 2016, pp. 1842–1850.
- [34] Schmidhuber, J., “Evolutionary principles in self-referential learning, or on learning how to learn: The meta-meta-... hook,” Ph.D. dissertation, Technische Universität München, 1987.
- [35] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D., “Grad-cam: Visual explanations from deep networks via gradient-based localization,” *International journal of computer vision*, vol. 128, no. 2, pp. 336–359, 2020.
- [36] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D., “Grad-cam: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 618–626.

- [37] Si, Z., Hu, S., Ji, K., and Lyu, S., “Meta-learning with heterogeneous tasks,” in *International Joint Conference on Artificial Intelligence*, Springer, 2025, pp. 74–94.
- [38] Simonyan, K., Vedaldi, A., and Zisserman, A., “Visualising image classification models and saliency maps,” *Deep Inside Convolutional Networks*, vol. 2, no. 2, 2014.
- [39] Snell, J., Swersky, K., and Zemel, R., “Prototypical networks for few-shot learning,” *Advances in neural information processing systems*, vol. 30, 2017.
- [40] Song, Y., Wang, T., Cai, P., Mondal, S. K., and Sahoo, J. P., “A comprehensive survey of few-shot learning: Evolution, applications, challenges, and opportunities,” *ACM Computing Surveys*, vol. 55, no. 13s, pp. 1–40, 2023.
- [41] Springenberg, J. T., Dosovitskiy, A., Brox, T., and Riedmiller, M., “Striving for simplicity: The all convolutional net,” *arXiv preprint arXiv:1412.6806*, 2014.
- [42] Sundararajan, M., Taly, A., and Yan, Q., “Axiomatic attribution for deep networks,” in *International conference on machine learning*, PMLR, 2017, pp. 3319–3328.
- [43] Uddin, I. I., Wang, L., and Santosh, K., “Expert-guided explainable few-shot learning for medical image diagnosis,” in *MICCAI Workshop on Data Engineering in Medical Imaging*, Springer, 2025, pp. 95–104.
- [44] Vinyals, O., Blundell, C., Lillicrap, T., Wierstra, D., *et al.*, “Matching networks for one shot learning,” *Advances in neural information processing systems*, vol. 29, 2016.
- [45] Wang, B., Li, L., Verma, M., Nakashima, Y., Kawasaki, R., and Nagahara, H., “Mtunet: Few-shot image classification with visual explanations,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2021.

- [46] Wang, Y., Yao, Q., Kwok, J. T., and Ni, L. M., “Generalizing from a few examples: A survey on few-shot learning,” *ACM computing surveys (csur)*, vol. 53, no. 3, pp. 1–34, 2020.
- [47] Welinder, P., Branson, S., Mita, T., *et al.*, “Caltech-ucsd birds 200,” 2010.
- [48] Yao, H., Wei, Y., Huang, J., and Li, Z., “Hierarchically structured meta-learning,” in *International conference on machine learning*, PMLR, 2019, pp. 7045–7054.
- [49] Yao, H., Wu, X., Tao, Z., *et al.*, “Automated relational meta-learning,” *arXiv preprint arXiv:2001.00745*, 2020.
- [50] Yeh, C.-K., Kim, J., Yen, I. E.-H., and Ravikumar, P. K., “Representer point selection for explaining deep neural networks,” *Advances in neural information processing systems*, vol. 31, 2018.
- [51] Yue, Z., Zhang, H., Sun, Q., and Hua, X.-S., “Interventional few-shot learning,” *Advances in neural information processing systems*, vol. 33, pp. 2734–2746, 2020.
- [52] Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., and Torralba, A., “Learning deep features for discriminative localization,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 2921–2929.

Chương A

Chứng minh Mệnh đề 1

Chương này chứng minh chi tiết Mệnh đề 1 (Mục 3.2.1): dưới chế độ thích ứng nhanh (Giả thuyết 1), $\Delta M = -C_b + O((T\alpha)^2)$.

A.1 Thiết lập và khai triển bậc hai

Ký hiệu $\theta_0 = (\theta_0^b, \theta_0^h)$. Xét hàm mất mát kỳ vọng trên tập truy vấn $L(\phi) := \mathbb{E}_{Q_i \sim \mathcal{T}_i}[\mathcal{L}(Q_i, \phi)]$, giả sử khả vi liên tục hai lần trong một lân cận mở chứa θ_0 và toàn bộ quỹ đạo. Đặt $b := \nabla_b L(\theta_0)$, $g_h := \nabla_h L(\theta_0)$, $H_{bb} := \nabla_{bb}^2 L(\theta_0)$, $H_{bh} := \nabla_{bh}^2 L(\theta_0)$, $H_{hh} := \nabla_{hh}^2 L(\theta_0)$.

Gọi $\Delta b_T := \phi_T^b - \theta_0^b$, $\Delta h_T := \phi_T^h - \theta_0^h$ (nhánh thích ứng toàn phần) và $\Delta h_T^f := \phi_T^{f,h} - \theta_0^h$ (nhánh can thiệp). Vì backbone bị đóng băng ở nhánh can thiệp, $\Delta b_T^f = 0$.

Khai triển Taylor bậc hai của L quanh θ_0 cho mỗi nhánh:

$$\begin{aligned} L(\phi_T) &= L(\theta_0) + g_b^\top \Delta b_T + g_h^\top \Delta h_T \\ &\quad + \frac{1}{2} \Delta b_T^\top H_{bb} \Delta b_T + \Delta b_T^\top H_{bh} \Delta h_T + \frac{1}{2} \Delta h_T^\top H_{hh} \Delta h_T + o(\|\Delta\|^2), \end{aligned} \tag{A.1}$$

$$L(\phi_T^f) = L(\theta_0) + g_h^\top \Delta h_T^f + \frac{1}{2} \Delta h_T^{f\top} H_{hh} \Delta h_T^f + o(\|\Delta h_T^f\|^2). \tag{A.2}$$

Trừ (A.2) cho (A.1) và dùng định nghĩa $\Delta M = L(\phi_T^f) - L(\phi_T)$ (Phương trình (3.3), đã lấy kỳ vọng theo Q_i), số hạng $L(\theta_0)$ triệt tiêu và ta thu được

chính xác Phương trình (A.3):

$$\begin{aligned} \Delta M = & - \underbrace{\left[g_b^\top \Delta b_T + \frac{1}{2} \Delta b_T^\top H_{bb} \Delta b_T + \Delta b_T^\top H_{bh} \Delta h_T \right]}_{C_b} \\ & + \underbrace{\left[g_h^\top (\Delta h_T^f - \Delta h_T) + \frac{1}{2} (\Delta h_T^f)^\top H_{hh} \Delta h_T^f - \Delta h_T^\top H_{hh} \Delta h_T \right]}_{R_h}, \end{aligned} \quad (\text{A.3})$$

A.2 Bậc độ lớn của các số hạng dịch chuyển

Bổ đề 1 (Dịch chuyển tích lũy $O(T\alpha)$). *Giả sử $\|\nabla_\phi \mathcal{L}(\phi, S_i)\| \leq G$ trong lân cận quỹ đạo. Khi đó $\|\Delta b_T\|, \|\Delta h_T\|, \|\Delta h_T^f\| = O(T\alpha)$.*

Proof. Mỗi bước cập nhật inner-loop (2.1) dịch chuyển tham số một lượng $\alpha \|\nabla_\phi \mathcal{L}\| \leq \alpha G$. Sau T bước, theo bất đẳng thức tam giác, tổng dịch chuyển tích lũy bị chặn bởi $T\alpha G = O(T\alpha)$, áp dụng như nhau cho cả ba đại lượng vì cả hai nhánh đều thực hiện đúng T bước cập nhật dạng này (nhánh can thiệp chỉ khác ở việc phần backbone bị ghi đè về θ_0^b sau mỗi bước, không ảnh hưởng đến bậc của phần head). $\square$

Bổ đề 2 (Độ lệch giữa hai quỹ đạo head là $O((T\alpha)^2)$). *Đặt $\delta_j := \Delta h_j - \Delta h_j^f$. Dưới điều kiện $\nabla_h \mathcal{L}(\cdot, S_i)$ Lipschitz với hằng số L theo ϕ (hệ quả của Giả thuyết 2(ii)), ta có $\delta_T = O((T\alpha)^2)$. Đặc biệt, tại $T = 1$, $\delta_1 = 0$ **tuyệt đối**.*

Proof. Tại $j = 1$: cả hai nhánh cùng xuất phát từ $\phi_0 = \phi_0^f = \theta_0$, nên bước gradient đầu tiên của head trùng nhau tuyệt đối, $\delta_1 = 0$.

Với $j \geq 2$, từ quy tắc cập nhật:

$$\delta_j = \delta_{j-1} - \alpha \left[\nabla_h \mathcal{L}(\phi_{j-1}, S_i) - \nabla_h \mathcal{L}(\phi_{j-1}^f, S_i) \right].$$

Hai đối số $\phi_{j-1} = (\phi_{j-1}^b, \phi_{j-1}^h)$ và $\phi_{j-1}^f = (\theta_0^b, \phi_{j-1}^{f,h})$ khác nhau ở backbone một lượng $\Delta b_{j-1} = O((j-1)\alpha)$ (Bổ đề 1) và ở head một lượng δ_{j-1} . Do tính Lipschitz,

$$\begin{aligned} \|\nabla_h \mathcal{L}(\phi_{j-1}, S_i) - \nabla_h \mathcal{L}(\phi_{j-1}^f, S_i)\| & \leq L(\|\Delta b_{j-1}\| + \|\delta_{j-1}\|) \\ & = O((j-1)\alpha + \|\delta_{j-1}\|). \end{aligned}$$

Suy ra

$$\|\delta_j\| \leq (1 + \alpha L)\|\delta_{j-1}\| + O((j-1)\alpha^2).$$

Với $\delta_1 = 0$ và khai triển đệ quy, do $T\alpha \ll 1$ (Giả thuyết 1) nên $(1 + \alpha L)^T = 1 + O(T\alpha)$ vẫn bị chặn:

$$\begin{aligned} \|\delta_T\| &\leq \sum_{k=1}^{T-1} O(k\alpha^2) \cdot (1 + O(\alpha))^{T-1-k} \\ &= O(\alpha^2) \sum_{k=1}^{T-1} k \cdot (1 + O(T\alpha)) \\ &= O(\alpha^2 T^2) = O((T\alpha)^2). \end{aligned}$$

□

A.3 Bậc độ lớn của C_b và R_h , và kết luận

Từ Bổ đề 1: số hạng tuyến tính $g_b^\top \Delta b_T = O(T\alpha)$ là bậc chủ đạo trong C_b ; hai số hạng bậc hai còn lại của C_b đều là $O((T\alpha)^2)$. Vậy $C_b = O(T\alpha)$.

Từ Bổ đề 2: số hạng tuyến tính của R_h là $g_h^\top (\Delta h_T^f - \Delta h_T) = -g_h^\top \delta_T = O((T\alpha)^2)$; các số hạng bậc hai còn lại của R_h (hiệu hai dạng toàn phương) cũng có bậc $O((T\alpha)^2)$ vì δ_T là bậc chủ đạo của hiệu Δh_T^f và Δh_T . Vậy $R_h = O((T\alpha)^2)$, và

$$\Delta M = -C_b + R_h = -C_b + O((T\alpha)^2),$$

đúng như Phương trình (3.5), hoàn tất chứng minh Mệnh đề 1. ■

Đặc biệt, với $T = 1$, Bổ đề 2 cho $\delta_1 = 0$ tuyệt đối, kéo theo $R_h = 0$ *chính xác* (không chỉ là vô cùng bé), khớp với nhận xét tại Mục 3.2.1.

Chương B

Chứng minh phương pháp liên hợp và cận sai số

Chương này chứng minh Mệnh đề 2 (tính tương đương của $\lambda^{(t)}$), suy ra công thức khai triển (3.8), và thiết lập cận ổn định/sai số dưới Giả thuyết 2.

B.1 Tính tương đương của biến liên hợp (chứng minh Mệnh đề 2)

Xét một nhánh quỹ đạo bất kỳ (lập luận đối xứng cho nhánh còn lại), viết gọn $\bar{L}(\phi) := \mathbb{E}_{Q_i}[\mathcal{L}(Q_i, \phi)]$. Ta chứng minh bằng quy nạp lùi rằng

$$\lambda^{(t)} = \frac{\partial \bar{L}(\phi^{(T)})}{\partial \phi^{(t)}}, \quad t = T, T-1, \dots, 0.$$

Cơ sở quy nạp ($t = T$). Vì $\phi^{(T)}$ là đối số trực tiếp của $\bar{L}$, ta có:

$$\partial \bar{L}(\phi^{(T)}) / \partial \phi^{(T)} = \nabla_{\phi} \bar{L}(\phi^{(T)}) = \lambda^{(T)}$$

theo đúng định nghĩa (3.11).

Bước quy nạp. Giả sử mệnh đề đúng tại t , ta chứng minh đúng tại $t-1$. Vì $\phi^{(T)}$ phụ thuộc vào $\phi^{(t-1)}$ duy nhất thông qua trung gian $\phi^{(t)}$ (quy tắc cập nhật (2.1) là một chuỗi Markov tham số), quy tắc dây chuyền cho

$$\frac{\partial \bar{L}(\phi^{(T)})}{\partial \phi^{(t-1)}} = \left(\frac{\partial \phi^{(t)}}{\partial \phi^{(t-1)}} \right)^{\top} \frac{\partial \bar{L}(\phi^{(T)})}{\partial \phi^{(t)}} \stackrel{\text{gt quy nạp}}{=} (I - \alpha H_{t-1})^{\top} \lambda^{(t)},$$

sử dụng Jacobian một bước đã tính ở Phương trình (3.6). Vì $H_{t-1} =$

$\nabla_\phi^2 \mathcal{L}(\phi^{(t-1)}, S_i)$ là ma trận Hessian, nó đối xứng ($H_{t-1}^\top = H_{t-1}$), nên

$$(I - \alpha H_{t-1})^\top \lambda^{(t)} = \lambda^{(t)} - \alpha H_{t-1} \lambda^{(t)} = \lambda^{(t-1)}$$

đúng theo định nghĩa đệ quy (3.12). Vậy $\partial \bar{L}(\phi^{(T)}) / \partial \phi^{(t-1)} = \lambda^{(t-1)}$, hoàn tất bước quy nạp. ■

Nhận xét quan trọng. Chứng minh trên không dùng bất kỳ phép xấp xỉ nào — Jacobian (3.6) là *chính xác* (đạo hàm của một bước gradient descent), nên với H_{t-1} được tính đúng (không xấp xỉ), đệ quy liên hợp (3.12) tính $\lambda^{(t)}$ một cách *chính xác tuyệt đối*, không phải xấp xỉ bậc nhất. Đây là điểm khác biệt căn bản so với các phương pháp liên hợp cho hệ động lực liên tục (neural ODE) vốn phải rời rạc hóa một phương trình vi phân — ở đây hệ đã rời rạc sẵn (inner-loop là SGD hữu hạn bước), nên không phát sinh sai số rời rạc hóa.

B.2 Suy ra công thức khai triển (3.8)

Xem $\phi^{(t)} = \Psi_t(\phi^{(t-1)}, S_i) := \phi^{(t-1)} - \alpha \nabla_\phi \mathcal{L}(\phi^{(t-1)}, S_i)$ là một hệ động lực rời rạc trong đó S_i xuất hiện lặp lại như một *tham số dùng chung* tại mọi bước $t = 1, \dots, T$. Theo quy tắc đạo hàm tổng (total derivative) cho tham số dùng chung qua nhiều bước của một chuỗi hàm hợp,

$$\begin{aligned} \frac{d\bar{L}(\phi^{(T)})}{dS_i} &= \sum_{t=1}^T \left(\frac{\partial \Psi_t}{\partial S_i} \Big|_{\phi^{(t-1)}} \right)^\top \left(\frac{\partial \phi^{(T)}}{\partial \phi^{(t)}} \right)^\top \nabla_\phi \bar{L}(\phi^{(T)}) \\ &= \sum_{t=1}^T \left(\frac{\partial \Psi_t}{\partial S_i} \Big|_{\phi^{(t-1)}} \right)^\top \lambda^{(t)}, \end{aligned}$$

Trong đó bước cuối dùng đúng kết quả vừa chứng minh ở trên vì

$$(\partial \phi^{(T)} / \partial \phi^{(t)})^\top \nabla_\phi \bar{L}(\phi^{(T)}) = \partial \bar{L}(\phi^{(T)}) / \partial \phi^{(t)} = \lambda^{(t)}$$

$$\text{Mà } \Psi_t(\phi^{(t-1)}, S_i) = \phi^{(t-1)} - \alpha \nabla_\phi \mathcal{L}(\phi^{(t-1)}, S_i),$$

$$\frac{\partial \Psi_t}{\partial S_i} \Big|_{\phi^{(t-1)}} = -\alpha \frac{\partial^2 \mathcal{L}(\phi^{(t-1)}, S_i)}{\partial \phi^{(t-1)} \partial S_i}.$$

Thay vào, ta thu được chính xác Phương trình (3.8):

$$\frac{\partial \bar{L}(\phi^{(T)})}{\partial S_i} = - \sum_{t=1}^T \alpha \lambda^{(t)} \cdot \frac{\partial^2 \mathcal{L}(\phi^{(t-1)}, S_i)}{\partial \phi^{(t-1)} \partial S_i}.$$

Áp dụng công thức này riêng biệt cho nhánh thích ứng toàn phần ($\phi^{(T)} = \phi_T$) và nhánh can thiệp ($\phi^{(T)} = \phi_T^f$), rồi lấy hiệu theo đúng định nghĩa ΔM ở Phương trình (3.3), ta thu được công thức $\partial \Delta M / \partial S_i$ dùng làm điểm xuất phát của Mục 3.3. ■

B.3 Ổn định của đệ quy liên hợp (chứng minh dựa trên Giả thuyết 2)

Mệnh đề 3 (Không giãn nở). *Dưới Giả thuyết 2(iii), $\|\lambda^{(t-1)}\| \leq \|\lambda^{(t)}\|$ với mọi t , do đó $\|\lambda^{(0)}\| \leq \|\lambda^{(T)}\|$: chuỗi $\{\lambda^{(t)}\}$ không bùng nổ qua T bước lùi.*

Proof. Vì H_{t-1} đối xứng, nó chéo hóa trực giao được với các trị riêng thực $\{\mu_i\}$. Theo (iii), $\alpha \leq 2/\lambda_{\max}(H_{t-1})$, nên với mọi trị riêng $\mu_i \in [\lambda_{\min}, \lambda_{\max}]$ của H_{t-1} , giá trị riêng tương ứng $1 - \alpha\mu_i$ của toán tử $I - \alpha H_{t-1}$ thỏa $|1 - \alpha\mu_i| \leq 1$ (vì $0 \leq \alpha\mu_i \leq \alpha\lambda_{\max} \leq 2$, nên $1 - \alpha\mu_i \in [-1, 1]$). Do đó $\|I - \alpha H_{t-1}\|_{\text{op}} \leq 1$, và từ (3.12): $\|\lambda^{(t-1)}\| = \|(I - \alpha H_{t-1})\lambda^{(t)}\| \leq \|\lambda^{(t)}\|$. □

Mệnh đề 4 (Cận sai số khi H_{t-1} được ước lượng xấp xỉ). *Trong triển khai thực tế, $\lambda^{(T)}$ ở Phương trình (3.11) và các tích Hessian-vector $H_{t-1}\lambda^{(t)}$ đều được ước lượng bằng bootstrap phân tầng hữu hạn trên Q_i (Mục 3.3.3), do đó chịu sai số thống kê. Giả sử tại mỗi bước t , sai số ước lượng của tích Hessian-vector bị chặn bởi $\|\widehat{H_{t-1}\lambda^{(t)}} - H_{t-1}\lambda^{(t)}\| \leq \varepsilon$. Khi đó, dưới Giả thuyết 2(ii)–(iii), sai số tích lũy sau T bước lùi bị chặn bởi*

$$\|\hat{\lambda}^{(0)} - \lambda^{(0)}\| \leq T\alpha\varepsilon.$$

Proof. Đặt $e_t := \hat{\lambda}^{(t)} - \lambda^{(t)}$ là sai số tích lũy tại bước t (với $e_T = 0$ nếu bỏ qua sai số ước lượng $\lambda^{(T)}$ ban đầu, hoặc cộng thêm nếu có). Từ đệ quy xấp xỉ $\hat{\lambda}^{(t-1)} = \widehat{\hat{\lambda}^{(t)} - \alpha H_{t-1}\lambda^{(t)}}$ và đệ quy đúng (3.12),

$$e_{t-1} = (I - \alpha H_{t-1})e_t - \alpha(\widehat{H_{t-1}\lambda^{(t)}} - H_{t-1}\lambda^{(t)}).$$

Lấy chuẩn hai vế, dùng $\|I - \alpha H_{t-1}\|_{\text{op}} \leq 1$ (Mệnh đề 3) và giả thiết sai số từng bước $\leq \varepsilon$:

$$\|e_{t-1}\| \leq \|e_t\| + \alpha\varepsilon.$$

Khai triển đệ quy từ $t = T$ (với $e_T = 0$) xuống $t = 0$ qua T bước, mỗi bước cộng thêm tối đa $\alpha\varepsilon$:

$$\|e_0\| \leq T\alpha\varepsilon.$$

□

Ý nghĩa thực nghiệm. Mệnh đề 4 cho thấy sai số của toàn bộ bản đồ quy kết Φ_{FAMA} do việc xấp xỉ Monte Carlo trên Q_i (thay vì lấy kỳ vọng chính xác) tăng *tuyến tính* theo $T\alpha$ — đúng bậc mà chế độ thích ứng nhanh (Giả thuyết 1, $T\alpha \ll 1$) giữ ở mức nhỏ. Đây là căn cứ lý thuyết cho việc chọn số lượng bootstrap `num_bootstraps` đủ lớn (nhằm giảm ε) trong cài đặt tại Mục 3.3.3, thay vì phải tăng theo cấp số nhân với T .